

P&D UTE Norte Fluminense\PUC-Rio

**Relatório Técnico: Aumento da competitividade
na comercialização de contratos de energia
proveniente de fontes renováveis no ACL**

Prof. Alexandre Street, *Coordenador*; Prof. Delberis A. Lima, *Gerente*; Prof. Álvaro Veiga;
Alexandre Moreira da Silva; Bruno Fânzeres; Lucas Freire; e Ana Luiza Lopes

SUMÁRIO

I. Resumo	3
II. Introdução	4
A. Motivação	4
B. Relevância e originalidade	5
C. Aplicabilidade	5
D. Descrição do produto principal	7
E. Razoabilidade dos custos	9
F. Pesquisas correlatas	9
III. Modelo estatístico da Ferramenta de Vento & Vazão	10
A. Formulação do modelo VARX para a Ferramenta V&V	11
B. Estimação dos parâmetros por máxima verossimilhança condicional	12
C. Estimação heurística rápida por máxima verossimilhança condicional	13
D. Simulação de cenários de vento e vazão coerentes com o PLD	14
E. Estudos de caso	16
IV. Modelo matemático da Ferramenta de Contratação	22
A. Tipos de contrato de comercialização de energia	22
B. Critérios de risco	28
C. O modelo de otimização	31
V. Estudos de caso de contratação ótima	32
VI. Conclusão	39
Referências Bibliográficas	41
ANEXO 1: Transformações das variáveis dependentes V_z e FC	43
ANEXO 2: Produto de Kronecker	44
ANEXO 3: Resultados do modelo V&V para o estudo de caso 1	45
ANEXO 4: Resultados do modelo V&V para os estudos de caso 2 e 3	74

I. RESUMO

Um dos maiores e mais importantes desafios enfrentados pelo órgão regulador brasileiro hoje é ensinar a expansão da geração de maneira “limpa”, segura e eficiente, respeitando a modicidade tarifária. Para que isso seja possível, diversos desafios devem ser superados.

No que diz respeito aos desafios comerciais, vejamos o caso das fontes renováveis no Ambiente de Comercialização Livre (ACL). A forte intermitência e sazonalidade inerente a essas fontes torna a sua comercialização no ACL – onde se negociam majoritariamente contratos por quantidade – um negócio extremamente arriscado, por conta da alta exposição ao risco de preço e quantidade a que se submete o comercializador. Isso porque, nos contratos por quantidade, o excedente ou o déficit de energia produzida pela fonte em relação ao montante de energia deve ser liquidado ao Preço de Liquidação das Diferenças (PLD), que é uma variável sistêmica e altamente volátil. O gráfico abaixo (Fig. 1) mostra o histórico do PLD.




Fig. 1 – Histórico mensal do Preço de Liquidação das Diferenças (PLD) para os 4 subsistemas brasileiros.

Nesse gráfico, podemos notar um padrão de longos períodos de PLD baixo interrompidos por picos elevados. Essa característica pode ser explicada pelo processo de formação desse preço. O PLD reflete o custo marginal de operação do sistema elétrico brasileiro (truncado em um piso e teto), que é basicamente hidrelétrico. Para garantir uma operação segura, o sistema é projetado com uma sobreoferta estrutural para suportar a ocorrência de condições adversas de aflúências. Assim, na maior parte do tempo, o sistema é operado com folga e, portanto, o custo marginal de produção da energia vale zero (valor da água sem perspectiva de déficits futuros). Entretanto, em condições de desequilíbrio, as térmicas são acionadas para prevenir déficits e o custo marginal passa a ser dependente do valor dos combustíveis utilizados, que podem chegar a 1000 R\$/MWh.

Uma característica bastante conhecida e estudada pelo setor elétrico brasileiro é a complementaridade entre o perfil de geração eólica da região Nordeste (onde estão concentradas a maioria das eólicas existentes e os projetos futuros) e o perfil de geração hídrica da região Sudeste. Com base nisso, é possível formar um portfólio de venda conjunto dessas fontes que resultaria em um fluxo de caixa menos arriscado e com menor exposição ao PLD, se comparado ao fluxo de caixa das fontes negociadas no mercado isoladamente. Contudo, para que o risco inerente à comercialização no ACL seja considerado de forma adequada, é preciso que os fatores de risco associados à aleatoriedade do preço de curto prazo e à incerteza na geração de energia em relação ao contrato sejam devidamente modelados.

O PLD futuro pode ser simulado através do modelo de despacho do Operador Nacional do Sistema (ONS). Já a produção futura de usinas renováveis não despacháveis – eólicas e Pequenas Centrais

Hidrelétricas (PCHs), por exemplo – pode ser simulada individualmente através de modelos estatísticos externos ao modelo de despacho. Nesse contexto, a precificação de riscos de qualquer estratégia de comercialização dessas fontes requer o casamento (correlação) dos cenários simulados da geração das usinas renováveis em questão com os cenários simulados de PLD. Além disso, no caso da formação de portfólio, é preciso correlacionar também as diferentes fontes de geração entre si, através de um modelo multivariado.

Em vista disso, o presente projeto desenvolveu uma ferramenta capaz de simular cenários de recursos renováveis devidamente ajustados aos cenários de PLD, a que denominamos Ferramenta V&V (Vento & Vazão). Para comprovar a eficácia da ferramenta produzida, realizamos um estudo de caso piloto em que foram simulados cenários de fator de capacidade de usinas eólicas e vazão de PCHs, ambos correlacionados com cenários de PLD produzidos pelo modelo de despacho. Essa ferramenta é a principal inovação do projeto, visto que a correlação entre as variáveis (geração/recursos renováveis e PLD), do ponto de vista estatístico, nunca foi abordada na literatura ou em trabalhos técnicos anteriores.

Além da Ferramenta V&V, como subproduto do projeto, desenvolvemos uma segunda ferramenta que permite gerenciar e otimizar um portfólio de oportunidades (contratos) de diversos formatos e especificações levando em conta uma série de características reais de mercado, tais como diferentes submercados e patamares de geração, além de considerar diferentes padrões de aversão a risco. Essa ferramenta foi chamada de Ferramenta de Contratação.

Devido à complexidade dos modelos envolvidos no projeto, uma plataforma de comercialização, que abrange as duas ferramentas, foi desenvolvida com uma interface amigável para diferentes tipos de análise. Dentre as principais análises que podem ser executadas, é possível destacar:

- (i) simulação de cenários de recursos renováveis ajustados aos cenários de preço de liquidação das diferenças (PLD);
- (ii) simulação e/ou otimização da contratação de energia com fontes de energia renováveis e/ou convencionais; e
- (iii) simulação e/ou otimização da comercialização de energia considerando diferentes modalidades de contrato, diferentes perfis de risco e diferentes tipos de fonte.

Neste documento, detalhamos as ferramentas desenvolvidas no projeto, discorrendo sobre os modelos estatísticos de estimação de parâmetros e simulação de recursos renováveis da Ferramenta V&V e os diversos modelos usados na Ferramenta de Contratação. Alguns resultados e discussões que ilustram a importância das ferramentas desenvolvidas também estão presentes.

Palavras-chave — Simulação de cenários de recursos renováveis correlacionados com o PLD; comercialização de energia elétrica; otimização de contratos de energia; análise de risco.

II. INTRODUÇÃO

A. Motivação

Após a crise de abastecimento de energia do início dos anos 2000, o governo brasileiro estabeleceu importantes modificações no modelo institucional do setor elétrico a fim de aumentar a segurança no suprimento de energia no país, fomentar a modicidade tarifária e promover a universalização do atendimento aos consumidores [17]. As bases do novo modelo consistem no planejamento de longo prazo, na coexistência dos ambientes de contratação regulada (ACR) e livre (ACL) e na premissa de que os consumidores devem ter 100% da energia demandada lastreada por capacidade assegurada de suprimento [1][18][19]. Para implementar essas novas medidas, buscou-se estimular investimentos em geração com a antecedência necessária para que o crescimento de carga fosse lastreado com nova capacidade de geração. Esse processo foi implementado através de leilões que licitam contratos de longo prazo (15 anos para termelétricas, 20 para eólicas e 30 para hidros) com 3 e 5 anos de antecedência – A-3 e A-5, respectivamente [26]. Tais leilões proporcionam uma remuneração mínima de longo prazo a preços definidos através de um processo licitatório. Nesse contexto, cria-se a segurança necessária para que órgãos financiadores aportem recursos a taxas de juros mais baixas, atraindo investidores privados para participar na expansão do parque gerador [2].

No que diz respeito ao ACR, os leilões de energia, promovidos a partir de 2004, resultaram em um grande impulso no setor elétrico como um todo. Ao mesmo tempo, para incentivar o uso de fontes alternativas de energia, foi instituído, em 2004, o Programa de Incentivo a Fontes Alternativas (PROINFA) [3], em que as principais fontes alternativas de energia no Brasil (eólica, pequenas centrais hidrelétricas e biomassa) competiram em leilões exclusivos. Inicialmente, o preço médio da energia foi de 298.00 R\$/MWh. Nos leilões seguintes, observou-se uma queda significativa nos preços, chegando a patamares inferiores a 90.00 R\$/MWh no A-5 de 2012.

As vantagens da comercialização de fontes alternativas no ACR estão relacionadas principalmente aos contratos de longo prazo, que permitem viabilizar novos investimentos em geração com a segurança de fluxos de caixa previsíveis no médio e longo prazo. Entretanto, as sucessivas quedas no preço da energia nos últimos leilões têm obrigado investidores a buscar novas alternativas de contratação.

Comparado ao ACR, o ACL sempre foi visto pelas renováveis como um ambiente de contratação de alto risco em função da baixa previsibilidade da produção dessas fontes, dos prazos de vigência dos contratos¹ e da incerteza no PLD. No ACL, são majoritariamente negociados contratos de quantidade, em que fica sob a responsabilidade do produtor liquidar a diferença entre produção e o montante contratado na CCEE. Nessa modalidade contratual, a incerteza do PLD somada à incerteza na geração produz o conhecido risco de preço e quantidade [23][24][25]. Assim, o presente projeto proporciona o ferramental necessário para que empresas geradoras e comercializadoras possam criar estratégias inovadoras a fim de comercializar energia renovável no ACL de maneira mais segura.

B. Relevância e originalidade

Na prática de comercialização do setor elétrico, o nível de contratação (montante a contratar da oportunidade) do comercializador/gerador elétrico que sofre o risco de preço e quantidade é, via de regra, obtido através da resolução de um problema de programação estocástica. Nele, as incertezas do PLD e da produção das usinas são tratadas como cenários simulados, e o modelo decide quanto é aconselhável vender de energia a fim de maximizar o valor do fluxo de caixa estocástico futuro. Entretanto, o valor de um fluxo de caixa estocástico deve levar em conta um desconto pelo risco (prêmio de risco). O risco de preço e quantidade na comercialização de fontes renováveis depende intrinsecamente da relação ou dinâmica entre o PLD e a produção das renováveis. Assim, o modelo V&V torna-se a peça chave na criação de novas estratégias de comercialização no ACL lastreada em energia renovável.

Contudo, essa prática não tem sido adotada pelo setor elétrico; portanto, a atual caracterização do risco de comercialização pode ser considerada inadequada, deixando o comercializador/gerador exposto a um risco desconsiderado.

O modelo proposto para este projeto também pode ser aplicado para avaliar o benefício da energia eólica no mecanismo de realocação de energia (MRE) hídrico ou mesmo no estudo da criação de um MRE Renovável (artigo e dissertação de mestrado em andamento de um dos membros da equipe). Além disso, com ele é possível casar os cenários de vento e geração despachável, hidrelétrica total ou termelétrica de maneira individual. Nesse contexto, o modelo pode ser aplicado ainda para estudos operativos de congestionamento de rede, atendimento à ponta, e risco de racionamento, uma vez que pode gerar cenários de produção eólica de todos os subsistemas casados com a simulação operativa.

Tanto quanto se sabe, essa correlação não foi até agora considerada. Assim, propomos um modelo inovador para lidar com um problema que se originou na área de comercialização, mas que ao final do projeto se mostrou relevante para uma gama de outras áreas.

C. Aplicabilidade

A aplicabilidade da Ferramenta V&V, principal inovação deste projeto, pode se dar em diversas áreas: na comercialização conjunta de fontes renováveis no ACL, foco do projeto, e no planejamento da operação e expansão do sistema elétrico, objetivo secundário descoberto ao longo do projeto. Para ilustrar a aplicabilidade do foco principal, realizamos um breve estudo que evidencia a capacidade do modelo de capturar um risco não previsto por outras metodologias. Nesse estudo, utilizamos um parque eólico no Nordeste (fictício, mas com dinâmica histórica baseada em um caso real) com 1 MW médio de lastro e 100% contratado por quantidade a 100 R\$/MWh no mesmo submercado. Com base nos mesmos cenários

1. Os contratos de energia no ACL em geral são de poucos anos (5 no máximo), enquanto no ACR esses contratos podem chegar a 30 anos.

de PLD simulados pelo NEWAVE, analisamos o sinal de risco que diferentes formas de projetar os cenários de geração desse parque eólico podem produzir. Assim, avaliamos a distribuição de renda anual do gerador sob três métodos de simulação da geração do parque:

- I. **Cenários independentes do PLD via Bootstrap:** aplicar a técnica de *bootstrap* (geração de cenários a partir da seleção aleatória dos anos do histórico) no histórico de geração da usina, que proporciona resultados estatisticamente independentes do PLD.
- II. **Cenários independentes do PLD via modelo estatístico:** utilizar o modelo estatístico apresentado neste relatório sem levar em consideração as variáveis operativas do sistema e, consequentemente, obter cenários simulados também independentes do PLD.
- III. **Cenários casados com o PLD via modelo estatístico:** recorrer ao modelo estatístico desenvolvido no projeto, utilizando sua capacidade de gerar séries de *FC* correlacionadas com os cenários de PLD provenientes de um caso de simulação operativa.

Em II e III, a mesma estrutura temporal de modelo é utilizada. No caso II, porém, a sazonalidade é tratada através de variáveis *dummies* para cada mês. Já no caso III, a sazonalidade é tratada através das Energias Naturais Afluentes (ENAs), que, como detalharemos mais adiante neste documento, realiza o link entre o modelo estatístico V&V e os cenários de PLD. Nos três casos, a análise é feita sob a mesma ótica: calcula-se a renda mensal durante um ano de contrato para cada um dos cenários de geração produzidos pelas três metodologias. A partir da renda mensal, obtêm-se a renda anual de cada cenário apenas somando, para cada série, os valores mensais. Com as séries de renda anual, analisamos o risco da comercialização a partir da sua curva de pertinência, que mede a probabilidade de ocorrência de determinado valor de renda. Essa curva pode ser entendida como a curva de probabilidade acumulada transposta, em que a probabilidade acumulada encontra-se no eixo horizontal e os quantis de renda (ou cenários de renda anual ordenados) se encontram no eixo vertical. Apresentamos o gráfico comparativo com as curvas de pertinência de cada modalidade a seguir.

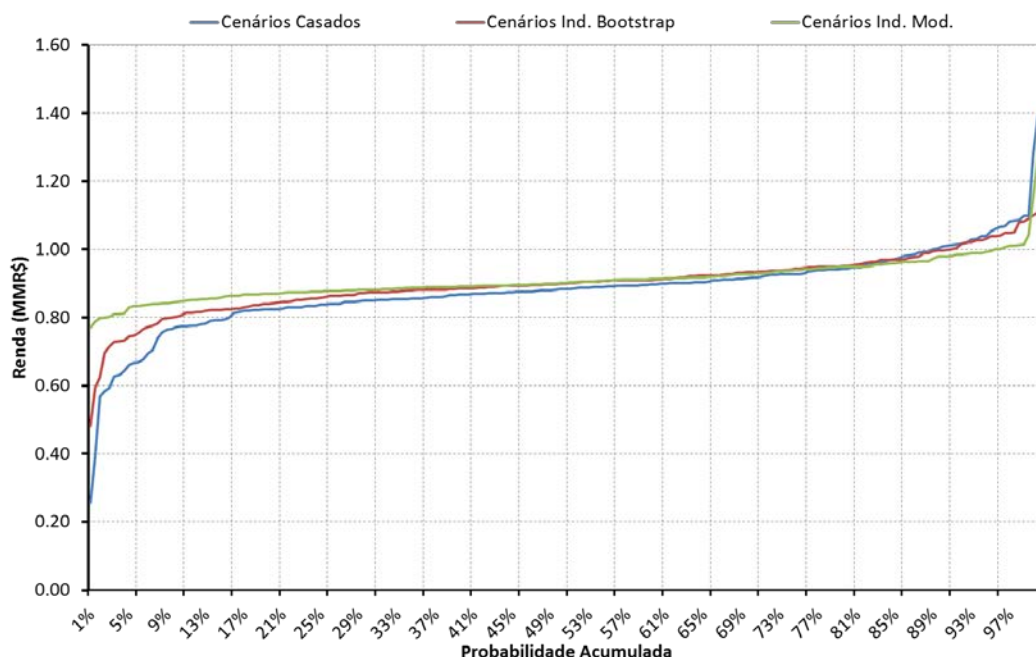


Fig. 2 – Comparação do risco na comercialização utilizando-se três maneiras diferentes de obter os cenários de geração.

Vemos que, em média (parte central das curvas), o comportamento da renda da comercialização é bastante semelhante e coerente com o risco da comercialização. Contudo, a informação mais importante a se extrair da Fig. 2 está na cauda esquerda das curvas. É possível perceber que os piores cenários de renda ocorreram quando as séries utilizadas foram extraídas do modelo V&V (caso III). Isso significa que esse método de geração de cenários captura um risco não apreendido pelos demais modelos, que pressupõem independência do PLD. Já o método por bootstrap (I), bastante utilizado por agentes do setor elétrico, captura levemente o risco da contratação, mas não de maneira eficaz. Assim, vemos que os três modelos praticamente “concordam” nos cenários medianos. O ponto de discordância está justamente nos cenários

mais arriscados, onde os dois modelos que não capturam a correlação da geração eólica com o PLD subestimam o risco na contratação. Esses resultados proporcionam evidências empíricas de que o nosso modelo de simulação de cenários de geração de recursos casados com o PLD proporciona uma informação mais precisa acerca dos riscos envolvidos na comercialização de energia renovável no ACL do que os modelos que desconsideram a correlação com o PLD.

D. Descrição do produto principal

O objetivo central deste projeto é desenvolver um modelo de simulação de recursos renováveis capaz de produzir cenários casados (correlacionados) com os cenários de PLD do modelo de despacho hidrotérmico brasileiro, o NEWAVE. Como mencionamos anteriormente, apesar do foco na comercialização, o nosso modelo também pode ser empregado a fim de correlacionar cenários de geração ou recursos naturais com cenários simulados de outras variáveis operativas. Nesse sentido, ele pode visto, desde uma perspectiva mais ampla, como um modelo de simulação de recursos naturais (ou de seus subprodutos) que gera cenários casados com os cenários simulados pelo modelo operativo NEWAVE.

O modelo foi implementado em uma ferramenta computacional, denominada Ferramenta de Vento & Vazão (V&V). A interface dessa ferramenta foi programada em MS Excel®² com o intuito de torná-la amigável e facilmente adequável a qualquer sistema já conhecido do usuário. Já as operações de estimação e simulação são realizadas no MatLab®. O MS Excel®, porém, é o único programa com que o usuário precisa interagir. A fim de gerar cenários da produção de fontes renováveis, criamos uma metodologia baseada em um modelo do tipo VARX (*Vector AutoRegression with eXternal variables*, isto é, autorregressivo vetorial com variáveis externas). Nesse caso, o comportamento futuro dos recursos associados às fontes renováveis é explicado por seu comportamento passado, sendo que o número de defasagens (*lags*) que influenciam diretamente na formação um passo a frente da variável é especificado pelo usuário. Além disso, como forma de estabelecer uma relação entre o comportamento dos recursos renováveis e o preço de curto prazo, consideramos a Energia Natural Afluente (ENAs) de cada submercado como variável explicativa do modelo. Assim, uma vez que o PLD é estabelecido por uma relação determinística com a ENA, o casamento do modelo de geração renovável com os cenários de ENA implica um casamento com todas as variáveis operativas já intrinsecamente casadas a esta, por exemplo, o próprio PLD.

O desenvolvimento da metodologia de geração de cenários se dá em duas etapas: (i) estimação dos coeficientes do modelo e (ii) simulação de cenários de geração renovável. Na primeira etapa, o modelo é ajustado utilizando as ENAs históricas produzidas pelo NEWAVE. Na segunda, a metodologia lança mão dos cenários de ENA simulados pelo NEWAVE a fim de gerar cenários futuros de produção renovável. Dessa maneira, os cenários de geração renovável podem ser utilizados em conjunto com qualquer saída do NEWAVE, desde que sigam a ordenação das séries produzidas por ele. Por fim, ao estudarmos séries de produção eólica no Nordeste e de vazão de um rio típico do Sudeste, o Rio Paraíba, foi possível constatar uma lei de variância ao longo dos meses, que foi então considerada no nosso modelo. É importante ressaltar que o modelo desenvolvido neste projeto possui uma característica bastante geral, sendo possível utilizar como recurso simulado qualquer tecnologia que possua geração sazonal e intermitente (eólica, pch, solar, entre outras), além de ser possível incluir múltiplas usinas. Como variável explicativa, também é permitido ao usuário adicionar a série que desejar, isto é, ele não está restrito apenas a ENAs. O número de *lags* das variáveis explicativas também é livre e, como dissemos, deve ser especificado pelo usuário. A Fig. 3 exibe uma representação esquemática da estrutura da metodologia de geração de cenários.

Com essa ferramenta, podemos criar diversas aplicações para aumentar a competitividade das fontes de energia renováveis no ACL. Neste documento, apresentamos algumas ideias de como tirar proveito dessa inovação através de estudos de caso. Para evidenciar o potencial e valor da inovação, recorremos a uma plataforma de comercialização de energia, também desenvolvida ao longo do projeto, que reúne a Ferramenta V&V a outra, que denominamos Ferramenta de Contratação. Esta última permite extrair valor dos cenários de geração das centrais de energia renovável casados com o PLD através de inúmeras aplicações de comercialização que podem ser modeladas. Para isso, foi desenvolvido um modelo de otimização estocástica a fim de encontrar o *mix* de contratos que melhor se beneficia do efeito portfólio, permitindo maximizar o retorno e mitigar o risco associado à comercialização das fontes. A Ferramenta de Contratação também foi implementada com uma interface amigável em MS Excel®, sendo a otimização realizada por um software específico de otimização, o Xpress®.

2. Quanto à linguagem de programação, optamos por VBA, já incluída no MS Excel®.




Fig. 3 – Geração de cenários com o modelo V&V.

Os modelos desenvolvidos podem ser utilizados em sequência, como uma plataforma de apoio à decisão: Ferramenta V&V e Ferramenta de Contratação. Na Fig. 4, apresentamos os principais elementos que compõe a plataforma de comercialização.

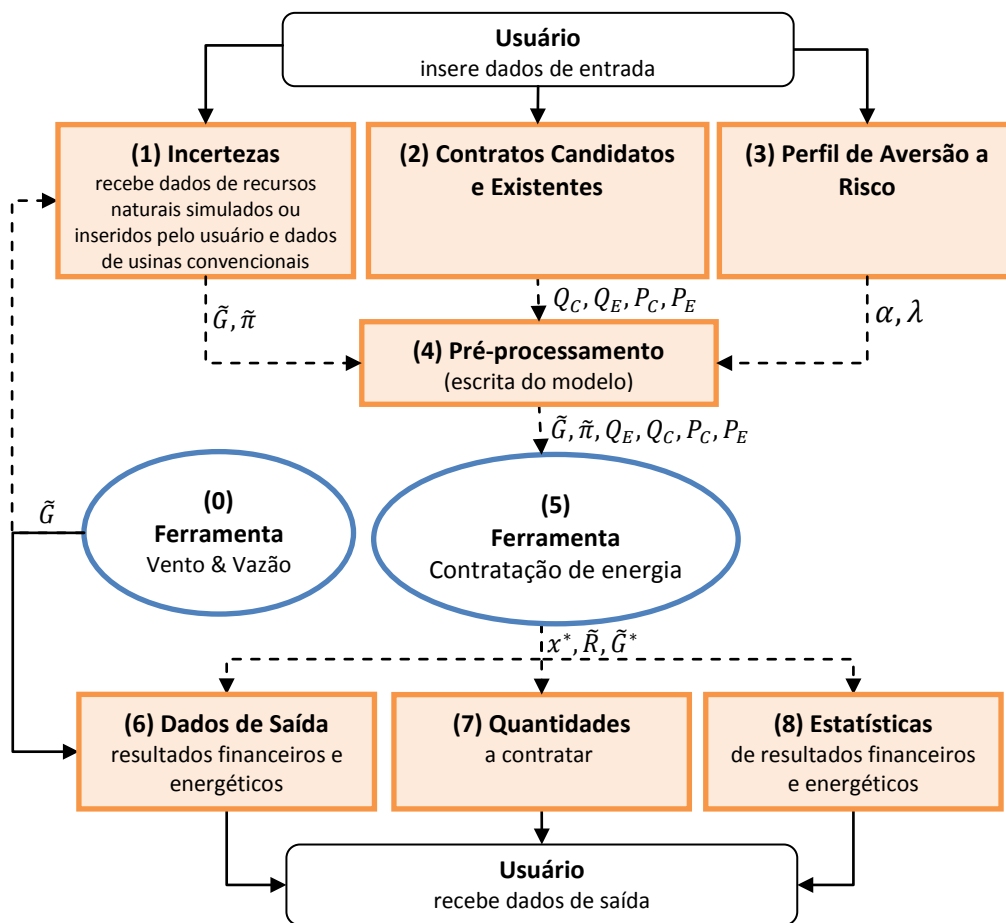


Fig. 4 – Fluxograma da plataforma de comercialização de energia

O bloco 0 (zero) representa a Ferramenta V&V, usada para geração de cenários de recursos renováveis correlacionados com o PLD. Nesse ponto, o usuário pode cadastrar séries de dados referentes ao histórico dos recursos de diferentes usinas, bem como o histórico das variáveis operativas (ENAs e PLDs). A ferramenta, então, gera cenários futuros (\tilde{G}) de disponibilidade de recursos renováveis correlacionados com as ENAs e, consequentemente, com os PLDs ($\tilde{\pi}$).

Considerando um fluxo de informações completo da plataforma de comercialização, o bloco 1 organiza os cenários simulados de recursos renováveis correlacionados com o PLD para alimentar a Ferramenta de Contratação. Os parâmetros que definem a contratação de energia são provenientes dos blocos 2 e 3. O bloco 2 fornece os contratos candidatos (Q_C) e existentes (Q_E) e seus respectivos preços (P_C e P_E). Já o bloco 3 provê as informações para definir o perfil de aversão a risco (α, λ) do comercializador.

As setas pontilhadas representam o fluxo de informação que ocorre automaticamente dentro da plataforma e não se destinam ao usuário nem se originam dele. As demais setas representam saídas ou entradas de dados cuja interferência do usuário é necessária.

No bloco 4, as informações são organizadas para entrada na Ferramenta de Contratação e, no bloco 5, as informações são otimizadas com o objetivo de gerar o maior valor possível para a contratação de energia. Os resultados da otimização são transmitidos aos blocos 6, 7 e 8, definindo o percentual de energia a contratar de cada fonte (x^*) e o valor financeiro estocástico associado à contratação (\tilde{R}).

E. Razoabilidade dos custos

A área de comercialização de energia é a atividade fim de geradores e comercializadores. Um gerador típico renovável (eólica, PCH ou biomassa) tem potência de 30 MW médios e poderia negociar desde pequenos montantes até a totalidade de sua garantia física no ACL (cerca de 50% da potência instalada). Assim, para cada MW médio comercializado durante um período de contrato de 1 ano, horizonte típico de comercialização no ACL (que varia entre poucos meses e 5 anos), estamos lidando com quantias em torno de $1(MW\text{médio}) \cdot 8760(\text{horas no ano}) \cdot 120\left(\frac{R\$}{MWh}\right) = 1.051.200,00(R\$)$. O presente projeto apresentou um orçamento inferior a esse valor, que pode ser entendido como um valor unitário (em termos de energia e de quantidade de operações) movimentado nas transações compreendidas como foco das ferramentas em análise. No primeiro estudo de caso abordado neste relatório, um exemplo de comercialização de 10 MW médios é considerado. Nesse caso, os valores giram em torno de 10 MMR\$/transação.

Outro ponto que vale a pena ser ressaltado é a economia direta em termos de risco, não otimizada³, que o modelo V&V pode produzir somente pelo fato de capturar o risco de preço e quantidade não capturado por outras modelagens. A Fig. 2 mostra a curva de pertinência dos três modelos. Nessa figura, é possível medir o valor da Ferramenta V&V para 1 MW médio de contrato de uma eólica no Nordeste através da diferença entre os quantis de 5% gerada pelos diferentes modelos. Se compararmos a diferença entre os quantis da curva azul (modelo proposto neste projeto) e a verde, obtemos um valor de aproximadamente 200 mil R\$. Assim, para um eólica com 10 MW médio de contrato, esse montante chega a 2 MMR\$.

A partir dos dois exemplos acima, entendemos que o custo deste projeto, inferior a 1 MMR\$, é mais do que compensado pelos seus benefícios em apenas uma utilização.

F. Pesquisas correlatas

O grupo envolvido no projeto vem contribuindo com o objeto desta pesquisa há alguns anos, publicando artigos de alto impacto e orientando pesquisa na área. Entre os artigos publicados, destacamos:

- i. A. Street, A. Moreira, A. Veiga, B. Fanzeres, D. Lima, e L. Freire, “Simulação da Geração de Usinas Renováveis Coerentes com os Cenários de Operação do Sistema Elétrico Brasileiro,” (Resumo aceito) *XXII SNPTEE 2013*, Brasília, Brasil, 2013;
- ii. A. Street, B. Fanzeres, D. Lima, J. Garcia, L. Freire, e R. Rajagopal, “Mecanismo de Realocação de Energia Renovável: Uma Nova Proposta para Fontes Alternativas,” (Resumo aceito) *XXII SNPTEE 2013*, Brasília, Brasil, 2013.

3. Caso esse novo fator de risco fosse então considerado no segundo módulo, de otimização da comercialização, os ganhos que serão mencionados a seguir seriam algumas vezes amplificados.

- iii. A. Street, D. Lima, L. Freire, J. Contreras, "Renewable Energy Pool: A new model to trade energy in a free market", *IEEE PES T&D LA 2012*, Montevideo, Uruguay, Setembro de 2012
- iv. A. Street, D. Lima, A. Veiga, B. Fanzeres, L. Freire, e B. Amaral, "Fostering Wind Power Penetration into the Brazilian Forward-Contract Market", *IEEE PES General Meeting 2012*, San Diego, California, Julho de 2012;
- v. B. Fanzeres, A. Street, D. Lima, A. Veiga, L. Freire, e B. Amaral, "Comercialização de Energia Eólica no Ambiente Livre: Desafios e Soluções Inovadoras," *XII SEPOPE 2012*, Rio de Janeiro, Rio de Janeiro, Brasil, Maio de 2012;
- vi. B. Fanzeres, e A. Street, "Cálculo da Curva de Disposição a Contratar de Geradores Hidrelétricos: Uma Abordagem Robusta ao Preço de Curto-Prazo", *XXI SNPTTE 2011*, Santa Catarina, Brasil, Outubro de 2011;
- vii. A. Street, D. Lima, e L. Freire, "Sharing Quotas of a Renewable Energy Hedge Pool: A Cooperative Game Theory Approach." *IEEE PowerTech 2011*, Trondheim, Norway, Junho de 2011;
- viii. A. Street, L. Barroso, B. Flach, M. Pereira, e S. Granville, "Risk Constrained Portfolio Selection of Renewable Sources in Hydrothermal Electricity Markets", *IEEE Transactions on Power Systems*, v. 24, p. 1136-1144, 2009;

Nas próximas seções deste documento, apresentamos o modelo estatístico usado para a Ferramenta V&V e o modelo matemático da Ferramenta de Contratação (seções III e IV respectivamente). Já na seção V, desenvolvemos estudos de caso com dados realistas do setor elétrico brasileiro para exemplificar e motivar o uso e os benefícios das ferramentas produzidas nesse projeto. Por fim, na seção VI, relatamos as conclusões que os estudos de caso proporcionam. Em seguida, estão as referências bibliográficas e os anexos, que trazem informações mais detalhadas dos modelos utilizados.

III. MODELO ESTATÍSTICO DA FERRAMENTA DE VENTO & VAZÃO

A Ferramenta V&V foi construída em torno de um modelo de séries temporais multivariado do tipo VARX (*Vector Autoregression with eXternal variables*, isto é, autoregressivo vetorial com variáveis externas) descrevendo a dinâmica de evolução das energias produzidas por um conjunto de usinas renováveis com perfil de geração aleatória e sazonal. Neste projeto analisamos o comportamento da geração de usinas em base mensal⁴.

Para uma análise representativa do período, o conjunto de produção energética de um mês é escrito como uma função dos valores defasados e de valores de variáveis externas (explicativas). A modelagem vetorial, ou multivariada, permite capturar não apenas a dinâmica de cada série em separado, mas principalmente o comportamento conjunto.

Especificamente, o modelo descreve a produção mensal de usinas renováveis eólicas e de PCHs como uma função dos mesmos valores dos últimos 12 meses⁵ e das ENAs, variáveis exógenas, obtidas pelo modelo de despacho hidrotérmico brasileiro, o NEWAVE. A Ferramenta V&V é, portanto, concebida para ser utilizada em conjunto com o NEWAVE, servindo-se de diversos elementos gerados por ele.

Na fase de ajuste dos parâmetros, são utilizados os dados históricos da produção das usinas eólicas e das PCHs, bem como as ENAs históricas calculadas pelo NEWAVE. É importante notar que as ENAs constituem um processo estocástico não estacionário, pois à medida que novos empreendimentos hidrelétricos entram em operação, a ENA se eleva. Assim, o histórico de ENAs e, portanto, o modelo V&V dependem da configuração do parque hidrelétrico. Nesse contexto, o modelo deve ser estimado para cada histórico de ENA associado a uma diferente configuração do sistema. Isso permite realizar o que denominamos simulação encadeada. Nela, a Ferramenta V&V utiliza um modelo estatístico para cada configuração de maneira encadeada no tempo. Assim, na etapa de simulação, a dependência entre a geração renovável e as ENAs é considerada de forma consistente com o parque gerador de todas as etapas

4. A base mensal foi escolhida, pois a simulação da contratação de energia é feita em base mensal. Ressaltamos, porém, que o modelo é genérico e pode ser utilizado em qualquer base, desde que as variáveis dependentes e explicativas sejam dadas na mesma base.

5. Os 12 meses foram escolhidos para se adequar à base mensal dos dados. Contudo, ressaltamos mais uma vez que o modelo é geral e o usuário pode utilizar a quantidade de períodos que desejar.

do horizonte de simulação. Além disso, para cada trajetória de ENA pelo NEWAVE, a Ferramenta V&V pode gerar uma ou mais trajetórias para a produção de recursos renováveis.

A. Formulação do modelo VARX para a Ferramenta V&V

Considere \mathbf{Y}_t um vetor de dimensão K^6 , onde os primeiros m componentes do vetor representam, por exemplo, as vazões (Vz) de PCHs e os $(K - m)$ elementos finais representam o fator de capacidade (FC) de parques eólicos no período t^7 , com $t = 1, 2, \dots, T$.

Considere ainda \mathbf{x}_t um vetor de variáveis explicativas geral, mas que para efeitos dos estudos de caso desse relatório será de dimensão 4 – contendo as ENAs dos quatro submercados observadas no período t . No modelo, utilizamos valores transformados dessas variáveis, segundo descrito no ANEXO 1. Essa transformação é necessária para que os cenários gerados posteriormente estejam no intervalo correto.

Uma vez definidos \mathbf{Y}_t e \mathbf{x}_t , podemos modelar \mathbf{Y}_t como um processo vetorial autorregressivo com variáveis externas, VARX. O modelo considera p (tipicamente 12) defasagens de \mathbf{Y}_t , além de q (tipicamente 2) defasagens da variável \mathbf{x}_t , incluindo a própria \mathbf{x}_t . O modelo pode ser expresso por:

$$\mathbf{Y}_t = \mathbf{c} + \sum_{i=1}^p \boldsymbol{\phi}_i \mathbf{Y}_{t-i} + \sum_{j=1}^q \boldsymbol{\theta}_j \mathbf{x}_{t+1-j} + \mathbf{A}_{m(t)} \boldsymbol{\varepsilon}_t, \quad (1)$$

$$\boldsymbol{\varepsilon}_t \sim N(\mathbf{0}, \mathbf{I}_K). \quad (2)$$

A componente sazonal pode ser modelada através das ENAs ou de variáveis indicadoras, que podem ser representadas pela variável \mathbf{x}_t . Além disso, note que o modelo admite uma matriz de covariâncias da componente aleatória $\mathbf{A}_{m(t)} \boldsymbol{\varepsilon}_t$, dada por $\mathbf{A}_{m(t)} \mathbf{A}_{m(t)}^T$, diferente para cada mês do ano. Essa característica foi observada nos dados históricos dessas variáveis.

Os parâmetros a serem estimados na equação (1) estão descritos a seguir:

- \mathbf{c} é o intercepto do modelo representado por um vetor de dimensão K ;
- $\boldsymbol{\phi}_i$, $i = 1, \dots, p$, são as matrizes/coeficientes de dimensão $K \times K$;
- $\boldsymbol{\theta}_j$, $j = 1, \dots, q$, são as matrizes/coeficientes de dimensão $K \times 4$; e
- $\mathbf{A}_{m(t)}$ são matrizes $K \times K$ associadas às respectivas decomposições de Cholesky das matrizes de covariância dos meses do ano, onde $m(t)$ é o índice do mês referente ao período t de estudo.

Nas próximas subseções, apresentaremos um método exato de estimação baseado no critério da máxima verossimilhança condicional. Observamos, porém, que esse método sofre de instabilidade numérica quando $K > 8$. A Tabela 1 mostra o número de coeficientes a estimar em função de K , calculado por $K + 12K^2 + 8K$, assumindo $p = 12$ e $q = 2$. A parte da variância, descrita pelas matrizes \mathbf{A}_k , $k = 1, \dots, 12$, contém $6K(K + 1)$ elementos a serem estimados.

K	NÚMERO DE COEFICIENTES
1	21
2	66
3	135
4	228
5	345
6	486
7	651
8	840
9	1053
10	1290

Tabela 1 – Relação entre o número de usinas e o de coeficientes.

6. A dimensão do vetor e, portanto, o número de usinas incluídas no modelo seria, a princípio, ilimitado. Contudo, como verificaremos mais adiante, o número de parâmetros do modelo cresce com o quadrado de K , enquanto a quantidade de dados cresce linearmente com K . Assim sendo, o número de parâmetros cresce mais rápido do que o número de dados. A diferença entre os dois determina os chamados graus de liberdade do modelo, que, por sua vez, afetam a precisão da estimativa. Quanto mais graus de liberdade, melhor. Em geral, espera-se que o número de dados seja pelo menos 5 vezes maior do que o número de parâmetros.

7. Lembrando que o modelo é de base mensal e que $t=1$ corresponde ao primeiro mês do período de análise e, não necessariamente, ao primeiro mês do ano.

Para tornar a estimação estável, proporemos um método heurístico que pode ser utilizado, em princípio, para um número arbitrariamente grande de usinas no que se refere à estimação dos coeficientes. Todavia, para que seja possível obter estimativas das matrizes de covariâncias que sejam positivas definidas, o número de anos e dados deve crescer junto com o número de usinas.

B. Estimação dos parâmetros por máxima verossimilhança condicional

Inicialmente, propusemos uma estimação dos parâmetros baseada no critério dos mínimos quadrados ponderados (MQP). O MQP tem a vantagem de não exigir a adoção de uma distribuição específica para a componente aleatória ε_t . Por outro lado, a estimação da variância é feita sem uma justificativa teórica. Para suprir essa deficiência, cogitamos a estimação clássica por máxima verossimilhança (MV). Para isso, todavia, é necessário atribuir uma distribuição Normal à componente aleatória ε_t . Na prática, quando a distribuição escolhida é a Normal, os valores estimados pelos métodos de MQP e MV resultarão os mesmos. O mesmo não acontece quando a distribuição não é a Normal. Nesses casos, o método de estimação é frequentemente chamado de máxima quasi-verossimilhança (MQV). É possível provar a consistência dos estimadores MQV para casos bastante gerais, incluindo o modelo proposto neste projeto (1).

Neste ponto, convém reescrever o modelo a fim de lidarmos com um único vetor contendo todos os coeficientes. Primeiramente, definimos uma matriz \mathbf{B} , cujo número elementos é $K(1 + Kp + 4q)$, onde 4 representa a quantidade de subsistemas considerados, contendo todos os coeficientes:

$$\mathbf{B} = [\mathbf{c} \ \phi_1 \dots \phi_p \ \theta_1 \dots \theta_q]. \quad (3)$$

Definimos também um vetor com todas as variáveis do lado direito da equação (1).

$$\mathbf{w}_{t-1} = \begin{bmatrix} 1 \\ \mathbf{Y}_{t-1} \\ \vdots \\ \mathbf{Y}_{t-p} \\ \mathbf{x}_t \\ \mathbf{x}_{t+1-q} \end{bmatrix}. \quad (4)$$

Com isso, o modelo pode ser escrito de forma mais concisa:

$$\mathbf{Y}_t = \mathbf{B}\mathbf{w}_{t-1} + \mathbf{A}_{m(t)}\varepsilon_t. \quad (5)$$

Avançando um pouco mais, chegamos à forma desejada em que os coeficientes estão todos colocados em um vetor. Assim, definimos $\boldsymbol{\beta} = \text{vec}(\mathbf{B})$ e $\mathbf{W}_{t-1} = (\mathbf{w}_{t-1}^T \otimes \mathbf{I})$, onde o operador vec representa uma transformação linear que converte uma matriz em vetor coluna e \otimes , um produto de Kronecker. Ambos os operadores citados estão descritos em [4], e detalhes sobre a técnica podem ser vistos no ANEXO 2. Com isso, o modelo pode ser expresso por:

$$\mathbf{Y}_t = \mathbf{W}_{t-1}\boldsymbol{\beta} + \mathbf{A}_{m(t)}\varepsilon_t, \quad (6)$$

O desenvolvimento proposto é necessário para que seja possível calcular a derivada da função de verossimilhança, apresentada a seguir, com relação ao vetor de coeficientes. Considere observações históricas de $t = 1, \dots, T$. Assim, a função de log-verossimilhança condicional às p (assumindo $p \geq q$) primeiras observações pode ser expressa por:

$$l(\boldsymbol{\beta}, \mathbf{A}_1, \dots, \mathbf{A}_{12}) = \mathbf{c} + \frac{1}{2} \sum_{t=p+1}^T \ln |\boldsymbol{\Sigma}_{m(t)}|^{-1} - \frac{K}{2} \sum_{t=p+1}^T (\mathbf{Y}_t - \mathbf{W}_{t-1}\boldsymbol{\beta})^T (\boldsymbol{\Sigma}_{m(t)})^{-1} (\mathbf{Y}_t - \mathbf{W}_{t-1}\boldsymbol{\beta}), \quad (7)$$

onde $\boldsymbol{\Sigma}_{m(t)} = \mathbf{A}_{m(t)}\mathbf{A}_{m(t)}^T$. É importante notar que, para estimar $\mathbf{A}_{m(t)}$, o método da máxima verossimilhança vai estimar primeiramente $\boldsymbol{\Sigma}_{m(t)}$. A matriz $\mathbf{A}_{m(t)}$ é posteriormente encontrada a partir da decomposição de Cholesky [6] da matriz $\boldsymbol{\Sigma}_{m(t)}$. Outro detalhe operacional se refere ao número de anos de dados necessários para que a matriz $\boldsymbol{\Sigma}_{m(t)}$ seja invertível, um pressuposto para a existência da função de

verossimilhança. A fim de que tal matriz seja invertível, nenhum de seus autovalores pode ser nulo, isto é, ela deve ser de posto cheio. Para tanto, é necessário que o número de dados, neste caso o número de anos de dados, seja maior do que K , como demonstrado em [7]. Assim, T tem que ser maior do que $12K$.

A maximização da função da log-verossimilhança expressa no formato acima é um cálculo clássico, presente em livros-texto, como em [4]. Para estimar, devemos resolver o sistema:

$$\hat{\beta} \in \operatorname{argmax}(l(\beta, A_1, \dots, A_{12})) = \left[\sum_{t=p+1}^T (\mathbf{w}_{t-1}^T \hat{\Sigma}_{m(t)}^{-1} \mathbf{w}_{t-1}) \right]^{-1} \left[\sum_{t=p+1}^T (\mathbf{w}_{t-1}^T \hat{\Sigma}_{m(t)}^{-1} \mathbf{y}_{t-1}) \right]; \quad (8)$$

$$\hat{\Sigma}_k \in \operatorname{argmax}(l(\beta, A_1, \dots, A_{12})) = \frac{\sum_{t=p+1, m(t)=k}^T (\mathbf{y}_t - \mathbf{w}_{t-1} \hat{\beta})(\mathbf{y}_t - \mathbf{w}_{t-1} \hat{\beta})^T}{\text{numero de meses } k \text{ na amostra}}, \quad (9)$$

$k = 1, \dots, 12.$

Para resolver o sistema acima, podemos empregar o método do ponto fixo que consiste em aplicar o seguinte procedimento:

1. Iniciar contador $iter = 0$.
2. Atribuir um valor inicial para $\hat{\beta}$, por exemplo $\hat{\beta}^{iter} = 0$.
3. Fazer $iter = iter + 1$.
4. Calcular $\hat{\Sigma}_k^{iter}$ utilizando (9).
5. Recalcular $\hat{\beta}^{iter}$ utilizando (8).
6. Avaliar se $|\hat{\beta}^{iter} - \hat{\beta}^{C-1}| < tol$.
7. Caso a condição em 6 se verifique verdadeira, o processo convergiu ($\hat{\beta} = \hat{\beta}^{iter}$ e $\hat{\Sigma}_k = \hat{\Sigma}_k^{iter}$); caso contrário, retornar ao passo 3.

Após a convergência, é possível obter o estimador das matrizes A_k , para $k = 1, \dots, 12$, pela decomposição de Cholesky da matriz $\hat{\Sigma}_k$, também para $k = 1, \dots, 12$. A decomposição de Cholesky é aquela que expressa uma matriz simétrica como o produto $\hat{\Sigma}_k = A_k A_k^T$, onde A_k é uma matriz triangular inferior. Essa decomposição só será possível se $\hat{\Sigma}_k$ for invertível, reforçando a exigência colocada anteriormente sobre o valor mínimo de T .

C. Estimação heurística rápida por máxima verossimilhança condicional

Na subseção B, apresentamos o método convencional para calcular a função de máxima verossimilhança. No entanto, o procedimento exige a inversão de uma matriz com dimensão igual ao número total de coeficientes do modelo, o que pode levar a problemas numéricos. Uma forma de reduzir esse problema é estimar o modelo separadamente para cada usina. Com isso, podemos estimar os coeficientes e a variância da componente aleatória de cada série. Todavia, sob esse enfoque, as covariâncias entre as séries não podem ser estimadas. Propomos, então, que essas covariâncias sejam estimadas diretamente dos resíduos após a convergência da estimação dos modelos individuais. Segundo nossos experimentos, esse procedimento leva a uma aproximação da metodologia convencional apresentada anteriormente. Há ainda a vantagem de ser numericamente estável, pois trocamos um problema com número de coeficientes da ordem de K^2 por K problema de ordem K .

O modelo individual para uma usina k pode ser escrito como:

$$Y_{k,t} = \mathbf{w}_{t-1}^T \beta_k + \mathbf{h}_{k,m(t)} \varepsilon_{k,t}, \quad k = 1, \dots, K, \quad (10)$$

com β_k sendo a k -ésima linha da matriz B .

Com isso, o algoritmo de estimação pode ser dividido em duas etapas, conforme descrito a seguir.

ETAPA 1

Use o método de estimação descrito na seção anterior para resolver o sistema para K usinas. Assim,

$$\hat{\beta}_k = \left[\sum_{t=p+1}^T (\mathbf{w}_{t-1} \hat{\mathbf{h}}_{k,m(t)}^{-1} \mathbf{w}_{t-1}^T) \right]^{-1} \left[\sum_{t=p+1}^T (\mathbf{w}_{t-1} \hat{\mathbf{h}}_{k,m(t)}^{-1} \mathbf{Y}_{k,t-1}) \right], \quad (11)$$

$$\hat{\mathbf{h}}_{k,i} = \frac{\sum_{t \geq p+1, m(t)=i} (\mathbf{Y}_{k,t} - \mathbf{w}_{t-1}^T \hat{\beta}_k)^2}{\text{número de meses } i \text{ na amostra}} \quad i = 1, \dots, 12. \quad (12)$$

ETAPA 2

Após a convergência da primeira etapa, a covariância entre as séries k e r são estimadas por:

$$\hat{\sigma}_{k,r,i} = \frac{\sum_{t \geq p+1, m(t)=i} (\mathbf{Y}_{k,t} - \mathbf{w}_{t-1}^T \hat{\beta}_k)(\mathbf{Y}_{r,t} - \mathbf{w}_{t-1}^T \hat{\beta}_r)}{\text{número de meses } i \text{ na amostra}} \quad i = 1, \dots, 12. \quad (13)$$

Uma vez montada a matriz de covariância, as matrizes $A_{m(t)}$ podem ser obtidas pela decomposição de Cholesky.

D. Simulação de cenários de vento e vazão coerentes com o PLD

Nesta seção, descrevemos o método de geração de cenários para os recursos renováveis, representados pelo vetor \mathbf{Y}_t . Nosso objetivo é criar cenários condicionais aos cenários de ENAs gerados pelo modelo de despacho brasileiro, o NEWAVE. Sendo que, para cada cenário de ENA, há um cenário de PLD produzido internamente pelo NEWAVE. Com esse conjunto de cenários, correspondentes à produção de energia e ao PLD, o usuário pode determinar, por exemplo, cenários de receita para cada tipo de contrato, tratando o risco inerente à comercialização de forma adequada. O modelo de otimização estocástica, então, determinará a carteira ótima levando em conta esses cenários de receita.

Nossa estratégia será percorrer cada trajetória de ENA produzida pelo NEWAVE e, lançando mão do modelo (1), gerar uma ou mais trajetórias para o vetor \mathbf{Y}_t de produção de energia através da geração aleatória de valores para o ruído ε_t . A geração aleatória pode ser feita por método Monte Carlo usando a distribuição Normal padrão ou através do sorteio dos resíduos padronizados obtidos na etapa de estimação dos parâmetros do modelo (1).

Outro fato que deve ser levado em conta para que seja possível gerar cenários coerentes é que a configuração do sistema evolui ao longo do período de estudo. Com isso, as ENAs históricas reconstruídas tendem a aumentar como consequência do aumento da capacidade do sistema. O NEWAVE leva isso em conta, recalcula as ENAs históricas a cada nova configuração e reajusta o modelo de geração de cenários de ENAs. O nosso método de geração de cenários usa o mesmo princípio e, cada vez que o NEWAVE reconstrói o histórico de ENAs, o modelo (1) é reestimado.

Vale ressaltar que o modelo de geração de cenários deve ser utilizado em sincronia com um conjunto de dados (*deck*) de simulação do NEWAVE⁸, onde constam as datas de mudança de configuração, os históricos de ENAs para cada configuração e os cenários de ENAs e PLDs.

Outra característica do modelo de geração de cenários proposto neste projeto é que, contrariamente aos modelos utilizados para gerar cenários de ENAs no NEWAVE, não há cenários com valores fora do intervalo permitido, como vazões negativas ou fatores de capacidade maiores do que 100%. Isso se deve ao tipo de transformação aplicada às variáveis do modelo, que garante essa propriedade, segundo descrito no ANEXO 1.

a) Algoritmo de simulação

Considere um *deck* do NEWAVE contendo uma análise para períodos mensais $t = 1, \dots, T$. Considere que o NEWAVE produziu S séries sintéticas hidrológicas para as ENAs (comumente temos $S = 2000$). É

8. O *deck* do NEWAVE é um conjunto com todas as entradas e saídas referentes a uma execução do programa. Ele contém informações como custos, configurações do sistema, cenários, modelos, dados históricos etc.

importante ressaltar que a correlação com o PLD não é explícita na simulação dos recursos renováveis, ela aparece como consequência da relação ENA e PLD interna no NEWAVE. Denote por x_t^s a ENA do instante t da s -ésima série hidrológica simulada pelo NEWAVE (arquivo EAFBXX.dat, onde XX representa o número do subsistema), sendo $s = 1, \dots, S$. Denote por $d(t)$ a configuração vigente no período t do horizonte de estudo (definida no arquivo PMO.dat, no caso se PMO, ou RELAT.dXX, para decenal, onde XX representa o último ano da simulação do decenal em análise).

Finalmente, considere que se deseja produzir R cenários de recursos renováveis para cada série hidrológica s de ENA, totalizando $R \times S$ cenários de geração renovável.

O algoritmo é composto de 3 etapas, conforme descrevemos a seguir.

1. Condições iniciais.

Para iniciar o processo, são necessários, como condição inicial, os últimos valores do vetor \mathbf{Y} de recursos renováveis correspondentes ao número de *lags* da parte autorregressiva, além dos valores atuais simulados, representando o mesmo instante de tempo dos recursos renováveis que estão sendo simulados, e defasados das ENAs históricas⁹ (ver o modelo (1)). Tudo está reunido no vetor \mathbf{w}_0 , conforme demonstramos abaixo:

$$\mathbf{w}_0 = \begin{bmatrix} \mathbf{1} \\ \mathbf{Y}_{-1} \\ \vdots \\ \mathbf{Y}_{-p} \\ \mathbf{x}_0 \\ \vdots \\ \mathbf{x}_{1-q} \end{bmatrix}.$$

As condições iniciais de ENAs podem ser encontradas no arquivo EAFPAST.dat.

2. Geração das sequências de ruídos: $\left\{ \boldsymbol{\varepsilon}_t^{(r,s)} \right\}_{t=1, \dots, H}^{r=1, \dots, R, s=1, \dots, S}$, com $\boldsymbol{\varepsilon}_t^{(r,s)} \sim N_K(\mathbf{0}, \mathbf{I})$.

A seguir, é preciso produzir $R \times S$ amostras Monte Carlo de H vetores $N_K(\mathbf{0}, \mathbf{I})$ de dimensão K . Formalmente, $\boldsymbol{\varepsilon}_t^{(r,s)}$ denota o vetor de ruídos que vai formar o cenário do instante t referente ao r -ésimo cenário de \mathbf{Y} calculado com as ENAs da s -ésima série hidrológica produzida pelo NEWAVE.

Outra opção é usar os resíduos da estimação do modelo para construir amostras *bootstrap*, isto é, através de sorteio com reposição. Isso foi experimentado durante o desenvolvimento do projeto e está disponível na ferramenta.

3. Construir as trajetórias para o vetor de vento e vazão: $\left\{ \mathbf{Y}_t^{(r,s)} \right\}_{t=1, \dots, H}^{r=1, \dots, R, s=1, \dots, S}$.

Por fim, aplicar recursivamente a equação (1) usando os ruídos da segunda etapa e as condições iniciais da primeira.

É importante lembrar que a configuração do sistema se altera à medida que t avança. Por isso, o valor dos parâmetros do modelo, \mathbf{c} , $\boldsymbol{\phi}_i$, $\boldsymbol{\theta}_j$ e $\mathbf{A}_{m(t)}$ deve se alterar da mesma forma. Considerando que podemos estimar os valores dos parâmetros do modelo sob toda configuração $d \in D$, $\hat{\mathbf{c}}^{(d)}$, $\hat{\boldsymbol{\phi}}_i^{(d)}$, $\hat{\boldsymbol{\theta}}_j^{(d)}$ e $\hat{\mathbf{A}}_{m(t)}^{(d)}$, o procedimento de simulação se resume no seguinte *loop*:

Para todo $t = 1, \dots, T$, $s = 1, \dots, S$ e $r = 1, \dots, R$, calcule:

$$\mathbf{Y}_t^{(r,s)} = \hat{\mathbf{c}}^{(d(t))} + \sum_{i=1}^p \hat{\boldsymbol{\phi}}_i^{(d(t))} \mathbf{Y}_{t-1}^{(r,s)} + \sum_{j=1}^q \hat{\boldsymbol{\theta}}_j^{(d(t))} \mathbf{x}_{t+1-j}^s + \hat{\mathbf{A}}_{m(t)}^{(d(t))} \boldsymbol{\varepsilon}_t^{(r,s)}. \quad (14)$$

9. Neste projeto, por conta dos dados com granularidade mensal, utilizamos 12 como o número de *lags* da parte autorregressiva. Com relação às ENAs, adotamos 1 *lag* de defasagem.

E. Estudos de caso

A título de ilustração, apresentamos neste trecho uma aplicação do modelo V&V para duas usinas, uma eólica e outra PCH, com o objetivo de comparar o desempenho das duas metodologias de estimação apresentadas, utilizando como critério de avaliação as propriedades estatísticas dos modelos estimados, bem como a qualidade das simulações produzidas por eles. Em seguida, apresentamos outros estudos de caso em que utilizamos apenas o método de máxima verossimilhança heurístico para produzir os resultados.

a) Estudo de caso 1: Avaliação das metodologias de estimação

Neste exemplo em particular, a complementariedade mensal entre a produção eólica (fator de capacidade – FC) e a afluência hídrica (Vazão – Vz) é bastante nítida. É preciso ressaltar, porém, que isso não necessariamente se reproduz com outros conjuntos de usinas. Assim, o modelo bivariado será apresentado em três versões.

- (i) Na primeira, utilizamos o método de máxima verossimilhança (subseção III.B) considerando a correlação entre as produções eólica e hídrica constantes ao longo do ano.
- (ii) Em seguida, recorreremos mais uma vez ao método de máxima verossimilhança, mas deixamos a correlação entre as produções eólica e hídrica variar ao longo do ano.
- (iii) Finalmente, utilizamos o método de máxima verossimilhança heurístico (subseção III.C) deixando, como no item (ii), que as correlações variem ao longo do ano.




Fig. 5 – Histórico de vento e vazão utilizados neste estudo.

Os resultados completos referentes à estimação dos modelos (medidas de ajuste, análise de resíduos, previsão fora da amostra) e sua utilização para a geração de cenários, são apresentados no ANEXO 3. Nesta seção, vamos nos ater a comparar os principais resultados.

Essencialmente, concluiremos que, especificamente para os dados utilizados, o modelo com correlações variantes no tempo revela uma correlação significativa entre FC e Vz em alguns meses e não-significante em outros. Essa é uma característica importante, dado que poderá ser utilizada para construir estratégias de contratação mais eficientes. Observamos também que o modelo estimado pelo método da máxima verossimilhança heurística revela uma estrutura de correlações mês a mês bastante próxima às obtidas pelo método clássico ou não heurístico.

Comparação do ajuste dos modelos dentro da amostra

As três formulações apresentaram desempenho bastante semelhante em termos da qualidade de ajuste. A Fig. 29 à Fig. 36, a Fig. 65 à Fig. 72 e a Fig. 101 à Fig. 108¹⁰ mostram a análise de resíduos e resíduos ao

10. Essas e outras figuras mencionadas no Estudo de caso 1, com exceção da Fig. 5 à Fig. 7, encontram-se no ANEXO 3.

quadrado, ambas de vento e vazão para cada caso. É possível verificar que em nenhum dos casos os resíduos apresentam correlação serial. Há uma ligeira vantagem nos métodos que deixam a correlação variar ao longo do ano. No que diz respeito à plataforma de comercialização, o conhecimento dessa variação aperfeiçoa a otimização dos contratos.

O mesmo pode ser dito em relação às medidas de ajuste (R^2 e R^2 ajustado) apresentadas na Tabela 7, na Tabela 14 e na Tabela 21. O teste de Jarque-Bera [5][6][7] indica que os resíduos referentes à variável Vz possuem distribuição Normal sob um nível de significância de 5%, mas não para um nível de 1%. Consideramos o resultado aceitável e atribuímos o desvio moderado da normalidade a uma observação aberrante à esquerda da amostra, conforme é possível observar, por exemplo, no histograma dos resíduos padronizados na Fig. 33 e na Fig. 34. Já para a variável FC , o alto valor do P-Valor para este teste indica que os resíduos são provenientes de uma distribuição Normal com alto grau de credibilidade.

Comparação da estrutura de correlações entre FC e Vz

A Fig. 6 apresenta as correlações estimadas pelo modelo de correlações constantes ao longo dos meses (linha pontilhada) e pelo modelo de correlações variantes mês a mês, ajustadas pelos métodos heurístico e não-heurístico.




Fig. 6 – Resultado da correlação entre FC e Vz mês a mês, com os modelos heurístico e não-heurístico.

Conforme adiantamos, as correlações estimadas mês a mês variam bastante. O valor médio anual é próximo ao valor obtido pelo modelo com correlação constante para os dois métodos. É interessante notar que os meses de outubro e novembro têm correlações positivas entre FC e Vz . Há alguma discrepância entre os métodos para o mês de outubro, mas a estrutura geral foi mantida.

Os valores das variâncias mês a mês, estimados pelos dois métodos, foram muito semelhantes para a variável FC , conforme podemos verificar na Fig. 7. Já no caso das variâncias mês a mês da variável Vz , ambos os métodos encontraram o mesmo resultado. Assim, concluímos que, para efeitos da estimação da variância mensal, o método heurístico apresentou um resultado satisfatório para os dados utilizados.




Fig. 7 – Resultado da variância de *FC* mês a mês, com os modelos heurístico e não-heurístico (clássico).

Comparação da capacidade de previsão fora da amostra

As três versões do modelo tiveram desempenho praticamente idêntico fora da amostra. Isso era esperado na medida em que a estimação dos coeficientes do modelo VARX é pouco influenciada pela estrutura de covariâncias do modelo. Isso fica demonstrado na Tabela 8, na Tabela 15 e na Tabela 22¹¹.

Geração de cenários

Na Fig. 47, na Fig. 48, na Fig. 83, na Fig. 84, na Fig. 119, na Fig. 120, na Fig. 139 e na Fig. 140, os históricos estão representados por pontos; os intervalos de confiança para 2000 cenários produzidos para *FC* e *Vz*, por linhas azuis; as médias dos cenários, por linhas pretas; e os mínimos e máximos também dos cenários, por linhas vermelhas. Tais cenários foram gerados segundo a metodologia descrita na subseção III.D com base nas três formulações e podem ser vistos na Fig. 45, na Fig. 46, na Fig. 81, na Fig. 82, na Fig. 117, na Fig. 118, na Fig. 137 e na Fig. 138.

A semelhança entre as distribuições históricas e simuladas também pode ser evidenciada pelos gráficos de probabilidade mês a mês apresentados na Fig. 49 à Fig. 64, na Fig. 85 à Fig. 100, na Fig. 121 à Fig. 136 e na Fig. 141 à Fig. 156, onde é possível observar um excelente ajuste, caracterizado pela relação quase perfeitamente linear entre os quantis observados e os simulados.

b) Estudo de caso 2: Uma usina eólica com sazonalidade via variáveis *dummies*

Neste estudo, pretendemos estimar um modelo para *FC* lançando mão do próprio *FC* defasado no tempo, além de *dummies* (variáveis indicadoras binárias) para os meses do ano como variáveis explicativas de maneira a caracterizar a sazonalidade. Em seguida, simularemos 2000 cenários de *FC* utilizando o modelo estimado. Vale ressaltar que, neste modelo, as variáveis exógenas que explicam a variação do *FC* são *dummies* (indicadoras) mensais e não tem relação alguma com as ENAs ou o PLD. Assim, os cenários gerados por este modelo não serão casados com o PLD. Contudo, nosso modelo está preparado para receber qualquer variável explicativa que o usuário queira, inclusive combinando as ENAs com outra variável qualquer, por exemplo, essas *dummies*. As séries históricas de vento utilizadas nesse estudo podem ser vistas a seguir, na Fig. 8.

11. As tabelas referentes ao Estudo de caso 1 também se encontram no ANEXO 3.




Fig. 8 – FC : Séries históricas de janeiro a dezembro empilhadas.

Estimamos então o modelo, cujos coeficientes podem ser vistos na Tabela 33, no ANEXO 4. Abaixo, podemos verificar a análise básica dos resíduos na Fig. 9 à Fig. 14.




Fig. 9 – Fac dos resíduos FC' .




Fig. 10 – Facp dos resíduos FC' .




Fig. 11 – Fac dos resíduos quadrados FC' .




Fig. 12 – Facp dos resíduos quadrados FC' .




Fig. 13 – FC': Histograma dos resíduos.




Fig. 14 – FC': Comparativo anual dos resíduos.

As figuras acima confirmam uma boa qualidade na estimação, o que é corroborado pelos resultados das medidas de aderência presentes na Tabela 2.

	<i>FC</i>
R^2	0.8170
R^2 ajustado	0.8064
P-valor JB dos Resíduos	0.0053

Tabela 2 – Medidas de Aderência – Dentro da Amostra.

No gráfico da Fig. 15, a seguir, os pontos representam as realizações dos anos do histórico em análise empilhadas mês a mês sobre o eixo horizontal; as linhas azuis representam o intervalo de confiança dos cenários simulados para o primeiro ano de estudo; e a linha preta, a média dos cenários. Por fim, as linhas vermelhas apresentam o mínimo e o máximo dos cenários simulados, que sob uma simulação de S cenários, representam a estimativa dos quantis de $\left(\frac{100}{s}\right)\%$ e 100%.




Fig. 15 – FC': Histórico com Intervalo de Confiança de 95%.

A Fig. 15 evidencia que as simulações providas pelo modelo estão bem ajustadas às realizações históricas do FC eólico uma vez que os cenários representados capturaram a dinâmica histórica dessa variável, estando coerente com a sazonalidade característica da fonte.

c) Estudo de caso 3: Uma usina eólica com sazonalidade via ENAs

Neste estudo de caso, repetiremos a análise anterior, mas buscaremos caracterizar a sazonalidade não mais através de variáveis *dummies*. Isso agora será feito através das ENAs dos 4 submercados considerados no estudo operativo. O histórico utilizado é o mesmo da Fig. 8.

Novamente, estimamos o modelo utilizando o método de máxima verossimilhança heurístico, e os coeficientes obtidos constam da Tabela 34, no ANEXO 4. A seguir, apresentamos os gráficos referentes à análise básica dos resíduos (Fig. 16 a Fig. 21).




Fig. 16 – Fac dos resíduos FC' .




Fig. 17 – Facp dos resíduos FC' .




Fig. 18 – Fac dos resíduos quadrados FC' .




Fig. 19 – Facp dos resíduos quadrados FC' .




Fig. 20 – FC' : Histograma dos resíduos.




Fig. 21 – FC' : Comparativo anual dos resíduos.

Os gráficos acima nos mostram que o modelo foi bem estimado e confirmam os resultados da Tabela 3.

	<i>FC</i>
R^2	0.7596
R^2 ajustado	0.7457
P-valor JB dos Resíduos	0.3418

Tabela 3 – Medidas de Aderência – Dentro da Amostra.

A seguir, a Fig. 22 apresenta o histórico com o intervalo de confiança dos cenários gerados em linhas azuis, a média dos cenários em uma linha preta e o mínimo e máximo dos cenários em linhas vermelhas. Esse gráfico indica que a simulação está coerente com os dados observados.




Fig. 22 – FC: Histórico com intervalo de confiança de 95% das simulações.

IV. MODELO MATEMÁTICO DA FERRAMENTA DE CONTRATAÇÃO

Após a reforma do setor elétrico, os contratos de energia se tornaram um importante mecanismo de incentivo à expansão da geração elétrica e um instrumento decisivo para mitigar a exposição dos geradores/comercializadores ao preço de liquidação das diferenças (PLD). Contudo, o nível de contratação do comercializador é algo preocupante e deve ser tratado adequadamente por conta do risco de preço e quantidade [10][18][19][20][21][22][23][24][25][26]. No Ambiente de Contratação Livre (ACL), os contratos são negociados livremente entre a entidade vendedora de energia e a compradora. Assim, sob o ponto de vista do comercializador, é um grande desafio montar uma carteira de contratos diversificados entre diferentes vendedores e, além disso, maximizar uma medida de valor para si. Tornase necessário, então, modelar adequadamente cada tipo de contrato e o perfil de risco do agente, além de utilizar técnicas de otimização para obter a quantidade contratada ótima das oportunidades contratuais.

Nesta seção, descreveremos a modelagem matemática dos contratos mais comuns na comercialização no ACL, bem como as diferentes maneiras de tratar o risco de comercialização consideradas na plataforma de comercialização de energia desenvolvida neste projeto. Por fim, apresentaremos um esquema do modelo de otimização implementado.

A. Tipos de contrato de comercialização de energia

A plataforma de comercialização contempla quatro formas distintas de contrato: Contratos de Quantidade Padrão, Contratos de Quantidade *Flex*, Contratos de Quantidade Baseados no PLD com Piso e Teto e Contratos de Disponibilidade. Além desses, acrescentamos uma quinta modalidade, denominada Contratos Generalizados.

a) Contratos de Quantidade Padrão

O Contrato de Quantidade Padrão é a forma mais simples de negociar um contrato. O vendedor se compromete a entregar ao comprador, para cada período de vigência do contrato, uma determinada quantidade de energia. A expressão da receita devido à venda desse contrato é definida como:

$$R_{i,t,p}^Q = P_{i,t,p} \cdot h_{t,p} \cdot Q_{i,t,p}. \quad (15)$$

Sendo:

$Q_{i,t,p}$ a quantidade de energia do contrato i sazonalizada no período t no patamar de carga p (em MW \cdot med);

$P_{i,t,p}$ o preço da energia contratada através do contrato i no período t no patamar de carga p (em R\$/MWh); e

h_t o número de horas do período t no patamar de carga p .

De maneira análoga, o custo devido à compra de um contrato i de quantidade no período t é definido como:

$$C_{i,t,p}^Q = P_{i,t,p} \cdot h_{t,p} \cdot Q_{i,t,p}. \quad (16)$$

b) Contratos de Quantidade Flex

Os Contratos de Quantidade *Flex* permitem flexibilizar a quantidade de energia contratada para uma quantidade mínima (Q_i^{min}) ou uma quantidade máxima (Q_i^{max}) em função do preço do contrato e do PLD do submercado a que esse contrato está associado. Na prática de negociação do setor, os parâmetros mais comuns definidos em contratos desse tipo são: $Q_{i,t,p}^{nom}$, que representa uma quantidade nominal que pode ser sazonalizada para cada período t e patamar de carga p do contrato (MW \cdot med), e $\gamma(\%)$, que representa a flexibilidade de variação da quantidade do contrato em relação à quantidade nominal de cada período.

Assim, a expressão de receita de venda associada aos Contratos de Quantidade *Flex* assume uma forma similar a de (15). Contudo, a quantidade de energia contratada passa a ser função do preço da energia do contrato i com relação ao preço *spot* ($\pi_{t,s,p}^{sub_i}$) no submercado do contrato i , no período t , no cenário s e patamar de carga p . Dessa forma:

$$Q_{i,t,p}(\pi_{t,s,p}^{sub_i}) = \begin{cases} Q_{i,t,p}^{nom}(1 + \gamma), & \pi_{t,s,p}^{sub_i} \geq P_{i,t,p}^{flex}; \\ Q_{i,t,p}^{nom}(1 - \gamma), & \pi_{t,s,p}^{sub_i} < P_{i,t,p}^{flex}. \end{cases} \quad (17)$$

Sendo:

$\pi_{t,s,p}^{sub_i}$ o preço *spot* (em R\$/MWh) do submercado onde está localizado o contrato i no período t e patamar de carga p e

$P_{i,t,p}^{flex}$ o preço da energia contratada (R\$/MWh) por meio do contrato i , no contrato de venda de quantidade *Flex* no período t e patamar de carga p .

Nesse tipo de contrato, a prerrogativa de escolha é do comprador. A decisão de consumo passa a ser função do PLD, uma vez que o comprador pode comprar e vender energia no curto prazo. Assim, toda vez que o PLD ($\pi_{t,s,p}^{sub_i}$) estiver acima do preço de contrato ($P_{i,t,p}^{flex}$), ele tem direito de consumir o máximo da sua capacidade e, eventualmente, revender o excesso de energia no curto prazo a um preço superior ao de compra. Caso contrário, ele consome o mínimo, comprando a energia que falta no curto prazo a um preço inferior ao do contrato.

c) Contratos de Quantidade Baseados no PLD com Piso e Teto

Assim como na modalidade *Flex*, os contratos baseados no PLD com piso e teto também permitem flexibilizar parâmetros do contrato. Nesse caso, o ajuste é realizado no preço do contrato em função dos cenários de PLD. As expressões de renda e custo dessa modalidade permanecem as mesmas dos Contratos de Quantidade Padrão ((15) e (16) respectivamente), contudo o preço a ser pago pela energia a entregar é função também do PLD.

$$P_{i,t,p}(\pi_{t,s,p}^{sub_i}) = \begin{cases} \pi_i^{max}, & \pi_{t,s,p}^{sub_i}(1 + a_i) \geq \pi_i^{max}; \\ \pi_i^{min}, & \pi_{t,s,p}^{sub_i}(1 + a_i) \leq \pi_i^{min}; \\ \pi_{t,s,p}^{sub_i}(1 + a_i), & \pi_i^{min} \leq \pi_{t,s,p}^{sub_i}(1 + a_i) \leq \pi_i^{max}. \end{cases} \quad (18)$$

Sendo:

a_i o valor do ágio aplicado sobre o preço *spot* (em %) do submercado onde foi firmado o contrato i ;

π_i^{max} o preço *spot* teto (R\$/MWh) do contrato i ; e

π_i^{min} o preço *spot* piso (R\$/MWh) do contrato i .

Exemplo da Dinâmica de Cada Modalidade dos Contratos de Quantidade

Neste exemplo, vamos analisar o fluxo de cada modalidade de contrato apresentado até agora, mostrando como se comporta cada um deles frente a diferentes cenários de preço *spot*. Para fins didáticos, vamos considerar dois cenários extremos de PLD, 10 R\$/MWh (1º Período) e 500 R\$/MWh (2º Período) para um patamar de carga apenas. Consideraremos, também, uma comercializadora sem geração própria, apenas vendendo contratos a consumidores.

i) Quantidade Padrão

Os parâmetros do primeiro tipo de contrato apresentado são:

P (R\$/MWh)	Q (MWh)
100	1

O fluxo dessa modalidade de contrato, para os dois cenários de preço *spot*, é:

Período	PLD (R\$/MWh)	Custo <i>Spot</i>	Renda Contrato	Total (Contrato - <i>Spot</i>)
1	10	$Q \cdot \pi = R\$ 10$	$Q \cdot P = R\$ 100$	$100 - 10 = R\$ 90$
2	500	$Q \cdot \pi = R\$ 500$	$Q \cdot P = R\$ 100$	$100 - 500 = - R\$ 400$
Período 1 + 2		R\$ 510	R\$ 200	- R\$ 310

ii) Quantidade Flex

Nos contratos de quantidade *flex*, a quantidade de energia a ser contratada é função da relação entre o preço de referência do contrato e o preço *spot*, segundo (17). Vemos, porém, que há um favorecimento ao comprador (*game* do comprador) uma vez que, para um PLD acima do preço do contrato, a quantidade é máxima e para um PLD abaixo do preço do contrato, a quantidade é mínima. Isso maximiza a renda do comprador uma vez que ele adquire uma quantidade máxima, podendo liquidar mais energia em um preço *spot* alto. Já para um *spot* baixo, a quantidade é mínima, valendo o mesmo raciocínio.

Como estamos analisando um contrato de venda, ou seja, estamos assumindo a contraparte vendedora do contrato, esperamos que esta modalidade de contrato tenha o pior resultado, do ponto de vista da comercializadora, dentre as analisadas até agora. Vamos supor um contrato *Flex* com os seguintes parâmetros:

P (R\$/MWh)	Q^{nom} (MWh)	γ (%)
100	1.0	0.5

De acordo com (17), tempo que:

- Para o primeiro período, $\pi = 10 \text{ R\$/MWh} < P = 100 \text{ R\$/MWh}$; assim, a quantidade de energia contratada passa a ser $Q = 0.5 \text{ MWh}$.
- Já para o segundo período, $\pi = 500 \frac{\text{R\$}}{\text{MWh}} > P = 100 \frac{\text{R\$}}{\text{MWh}}$; dessa forma, a quantidade de energia contratada passa a ser $Q = 1.5 \text{ MWh}$.

Assim, o fluxo dessa modalidade de contrato, para os dois cenários de preço spot, é:

Período	PLD (R\$/MWh)	Custo Spot	Renda Contrato	Total (Contrato - Spot)
1	10	$Q \cdot \pi = \text{R\$ } 5$	$Q \cdot P = \text{R\$ } 50$	$50 - 5 = \text{R\$ } 45$
2	500	$Q \cdot \pi = \text{R\$ } 750$	$Q \cdot P = \text{R\$ } 150$	$150 - 750 = - \text{R\$ } 600$
Período 1 + 2		R\$ 755	R\$ 200	- R\$ 555

iii) Quantidade baseados no PLD com piso e teto

Nos contratos de quantidade baseados no PLD com piso e teto, o preço de referência dos contratos pode assumir diferentes valores em função do preço spot, como visto em (18). Assim, vamos supor um contrato PLD com os seguintes parâmetros:

$Q \text{ (MWh)}$	$\pi^{\max} \text{ (R\$/MWh)}$	$\pi^{\min} \text{ (R\$/MWh)}$	Ágio
100	150	50	0

De acordo com (18), temos que:

- Para o primeiro período, $\pi = 10 \text{ R\$/MWh} < \pi^{\min} = 50 \text{ R\$/MWh}$; assim, o preço de referência do contrato passa a ser $P = \pi^{\min} = 50 \text{ R\$/MWh}$.
- Já para o segundo período, $\pi = 500 \text{ R\$/MWh} > \pi^{\max} = 100 \text{ R\$/MWh}$; dessa forma, o preço de referência do contrato passa a ser $P = \pi^{\max} = 150 \text{ R\$/MWh}$.

O fluxo dessa modalidade de contrato, para os dois cenários de preço spot, é:

Período	PLD (R\$/MWh)	Custo Spot	Renda Contrato	Total (Contrato - Spot)
1	10	$Q \cdot \pi = \text{R\$ } 10$	$Q \cdot \pi^{\min} = \text{R\$ } 50$	$50 - 10 = \text{R\$ } 40$
2	500	$Q \cdot \pi = \text{R\$ } 500$	$Q \cdot \pi^{\max} = \text{R\$ } 150$	$150 - 500 = - \text{R\$ } 350$
Período 1 + 2		R\$ 510	R\$ 200	- R\$ 310

iv) Comparação entre os fluxos dos contratos

Nas tabelas abaixo, podemos comparar os fluxos de cada modalidade contratual para o mesmo cenário de preço spot.

	Período	PLD (R\$/MWh)	Custo Spot	Renda Contrato	Total (Contrato - Spot)
Qt.	1	10	$Q \cdot \pi = \text{R\$ } 10$	$Q \cdot P = \text{R\$ } 100$	$100 - 10 = \text{R\$ } 90$
	2	500	$Q \cdot \pi = \text{R\$ } 500$	$Q \cdot P = \text{R\$ } 100$	$100 - 500 = - \text{R\$ } 400$
	Período 1 + 2		R\$ 510	R\$ 200	- R\$ 310
Flex	1	10	$Q \cdot \pi = \text{R\$ } 5$	$Q \cdot P = \text{R\$ } 50$	$50 - 5 = \text{R\$ } 45$
	2	500	$Q \cdot \pi = \text{R\$ } 750$	$Q \cdot P = \text{R\$ } 150$	$150 - 750 = - \text{R\$ } 600$
	Período 1 + 2		R\$ 755	R\$ 200	- R\$ 555

PLD	1	10	$Q \cdot \pi = R\$ 10$	$Q \cdot \pi^{min} = R\$ 50$	$50 - 10 = R\$ 40$
	2	500	$Q \cdot \pi = R\$ 500$	$Q \cdot \pi^{max} = R\$ 150$	$150 - 500 = - R\$ 350$
	Período 1 + 2		R\$ 510	R\$ 200	- R\$ 310

Em primeiro lugar, comprova-se a expectativa de que o contrato *Flex* seria a modalidade que traria o pior rendimento à comercializadora, o que faz sentido na medida em que estamos analisando um contrato de venda. Já o contrato de PLD com piso e teto, apesar de seu resultado coincidir com o resultado final do contrato de quantidade padrão, ele possui uma volatilidade menor devido ao preço que se ajusta a um intervalo pré-definido em contrato (π^{max}, π^{min}).

d) Contratos de Disponibilidade

Podemos definir os Contratos de Disponibilidade como contratos de “aluguel” ou “arrendamento” de usinas em que o comprador paga um valor mensal a um gerador pelo direito de comercializar todo ou parte do seu lastro e produção. No caso de usinas térmicas, nas ocasiões em que o PLD supera o valor do custo variável unitário (CVU) estabelecido em contrato, o comprador deve reembolsar o gerador pelo custo variável associado à geração acima de um valor mínimo G^{min} . Já para contratos com renováveis, o CVU pode ser considerado zero e o custo do contrato para o comprador passa a ser apenas o custo fixo mensal. Além disso, no caso das renováveis, como a produção não está associada a um despacho centralizado e sim à natureza do recurso renovável em questão, existe a possibilidade de limitar a entrega de energia por meio de um piso e um teto. Assim, o gerador assume o risco de ter que recorrer ao mercado de curto prazo se a sua geração for inferior ao piso. Em contrapartida, caso a geração seja superior ao teto, o gerador tem direito à renda referente à liquidação no *spot* da geração excedente.

Na plataforma de comercialização, duas modalidades de Contrato de Disponibilidade foram consideradas: uma para térmicas e outra para renováveis. No primeiro caso, os parâmetros da usina i considerados no contrato são: garantia física (GF_i), em MW_{med} ; potência, em MW ; geração mínima, em MW_{med} ; e CVU, em $R\$/MWh$. A partir desses parâmetros e do PLD, a plataforma monta os cenários de geração associados a essa usina para que sejam considerados na comercialização. Já nos Contratos de Disponibilidade para renováveis, os parâmetros considerados para a usina i são: piso e teto de geração, em MW_{med} , e o CVU da usina, em $R\$/MWh$, ainda que este último seja considerado zero na maioria dos casos.¹²

Na plataforma de comercialização, consideramos que os Contratos de Disponibilidade estão disponíveis apenas para compra. Nesse caso, a compra de um contrato i de disponibilidade proporciona um custo no período t , cenário s e patamar de carga p de:

$$C_{i,t,s,p}^D = Q_{i,t,p}^D \cdot h_{t,p} \cdot P_{i,t,p}^D + (G_{i,t,s,p} - G_i^{min}) \cdot Q_{i,t,p}^D \cdot CVU_i \cdot h_{t,p}. \quad (19)$$

Sendo:

$Q_{i,t,p}^D$ a quantidade de energia do contrato i no período t e patamar de carga p na modalidade disponibilidade (em MW_{med});

$P_{i,t,p}^D$ o preço do contrato i no período t e patamar de carga p na modalidade disponibilidade (em $R\$/MWh$);

$G_{i,t,s,p}$ a geração da usina no período t , cenário s e patamar de carga p , associada ao contrato i ;

G_i^{min} a geração mínima da usina associada ao contrato i ;

CVU_i o custo variável unitário de geração associado ao contrato i (em $R\$/MWh$); e

$h_{t,p}$ o número de horas do período t e patamar de carga p .

e) Contratos Generalizados

Visando tornar a plataforma de comercialização mais completa, incluímos ainda um tipo genérico de contrato, denominado Generalizado, a fim de atender os contratos não especificados na plataforma. Essa modalidade permite ao usuário incluir qualquer outro tipo de contrato.

Nesses casos, o agente simplesmente cadastra o perfil de preço e quantidade do contrato. As expressões de receita e custo permanecem as mesmas dos Contratos Padrão (15) e (16).

12. Contudo, em algumas situações, o CVU diferente de zero para usinas renováveis pode ser interessante, como no caso de usinas a biomassa, que podem produzir comprando cavaco de cana, palha ou outros insumos.

f) Expressão de Renda Líquida na CCEE

De acordo com o modelo vigente do setor elétrico brasileiro, todas as compras e vendas no ACL devem ser registradas na *Câmara de Comercialização de Energia Elétrica* (CCEE). Na prática, toda energia comprada e vendida por uma comercializadora é contabilizada na CCEE ao PLD. Os direitos e deveres dessa liquidação na CCEE para a comercializadora têm as seguintes expressões de receita e despesa respectivamente:

$$R_{t,s}^{CCEE} = \sum_{p \in Pat} \left(\sum_{i \in CC_Q \cup CC_{Gen} \cup CC_{PLD}} x_i \cdot Q_{i,t,p} \cdot \pi_{t,s,p}^{sub_i} + \sum_{i \in DC} x_i \cdot G_{i,t,s,p} \cdot \pi_{t,s,p}^{sub_i} \right. \\ \left. + \sum_{i \in CC_{Flx}} x_i \cdot Q_{i,t,p}(\pi_{t,s,p}^{sub_i}) \cdot \pi_{t,s,p}^{sub_i} + \sum_{i \in CE_Q \cup CE_{Gen} \cup CE_{PLD}} Q_{i,t,p} \cdot \pi_{t,s,p}^{sub_i} \right. \\ \left. + \sum_{i \in DE} x_i \cdot G_{i,t,s,p} \cdot \pi_{t,s,p}^{sub_i} + \sum_{i \in CE_{Flx}} Q_{i,t,p}(\pi_{t,s,p}^{sub_i}) \cdot \pi_{t,s,p}^{sub_i} \right); \quad (20)$$

$$C_{t,s}^{CCEE} = \sum_{p \in Pat} \left(\sum_{i \in VC_Q \cup VC_{Gen} \cup VC_{PLD}} x_i \cdot Q_{i,t,p} \cdot \pi_{t,s,p}^{sub_i} + \sum_{i \in VE_Q \cup VC_{Gen} \cup VE_{PLD}} Q_{i,t,p} \cdot \pi_{t,s,p}^{sub_i} \right. \\ \left. + \sum_{i \in VC_{Flx}} x_i \cdot Q_{i,t,p}(\pi_{t,s,p}^{sub_i}) \cdot \pi_{t,s,p}^{sub_i} + \sum_{i \in VE_{Flx}} Q_{i,t,p}(\pi_{t,s,p}^{sub_i}) \cdot \pi_{t,s,p}^{sub_i} \right). \quad (21)$$

Sendo:

x o vetor de variáveis de decisão (o elemento i do vetor x representa o percentual da quantidade $Q_{i,t}$ a ser contratada, sendo $x_i \in [0,1]$);

Pat o conjunto de patamares;

CC_j o conjunto de contratos candidatos de compra pertencentes à modalidade j ;

CE_j o conjunto de contratos existentes de compra pertencentes à modalidade j ;

VC_j o conjunto de contratos candidatos de venda pertencentes à modalidade j ;

VE_j o conjunto de contratos existentes de venda pertencentes à modalidade j ;

DC o conjunto de contratos candidatos pertencentes à modalidade *Disponibilidade*; e

DE o conjunto de contratos existentes pertencentes à modalidade *Disponibilidade*;

onde a modalidade j tal que $j \in \{Q, Flx, PLD, Gen\}$;

Q os contratos de *quantidade*;

Flx os contratos de quantidade com cláusula de *flexibilidade*;

PLD os contratos de quantidade com preços *baseados no PLD com piso e teto*;

Gen os contratos generalizados.

$R_{t,s}^{CCEE}$ a receita proveniente da contabilização dos direitos da comercializadora na CCEE (R\$); e

$C_{t,s}^{CCEE}$ o custo proveniente da contabilização dos deveres da comercializadora na CCEE (R\$).

É importante ressaltar que toda quantidade de contrato comprada passa a ser um direito da comercializadora, assim como toda quantidade vendida passa a ser uma obrigação. A CCEE é o ambiente em que todos esses direitos e obrigações são liquidados ao PLD. Dessa forma, os contratos de compra geram uma liquidação positiva e os de venda uma liquidação negativa, ambos na proporção da quantidade contratada – com exceção dos Contratos de Disponibilidade, cujo direito se dá sobre o despacho de uma

usina. Portanto, o saldo final da contabilização dos direitos e deveres da comercializadora na CCEE possui a expressão a seguir.

$$S_{t,s}^{CCEE} = R_{t,s}^{CCEE} - C_{t,s}^{CCEE}. \quad (22)$$

g) Expressão Final de Renda da Comercializadora

Por fim, a expressão de renda final da comercializadora para um período t e um cenário s , considerando os contratos existentes e candidatos, pode ser obtida por:

$$R_{t,s} = S_{t,s}^{CCEE} - \sum_{p \in Pat} \left(\sum_{i \in DC} x_i \cdot C_{i,t,p}^D - \sum_{i \in DE} C_{i,t,p}^D + \sum_{\substack{i \in VC_Q \\ \cup VC_{Flx} \\ \cup VC_{PLD} \\ \cup VC_{Gen}}} x_i \cdot R_{i,t,s,p}^Q + \sum_{\substack{i \in VE_Q \\ \cup VE_{Flx} \\ \cup VE_{PLD} \\ \cup VE_{Gen}}} R_{i,t,s,p}^Q - \sum_{\substack{i \in CC_Q \\ \cup CC_{Flx} \\ \cup CC_{PLD} \\ \cup CC_{Gen}}} x_i \cdot C_{i,t,s,p}^Q - \sum_{\substack{i \in CE_Q \\ \cup CE_{Flx} \\ \cup CE_{PLD} \\ \cup CE_{Gen}}} C_{i,t,s,p}^Q \right). \quad (23)$$

A relação entre contratos de compra e venda no período t deve satisfazer a restrição de balanço de energia, garantindo que a comercializadora não sofrerá penalidade¹³. Assim:

$$\begin{aligned} \sum_{p \in Pat} \left(\sum_{\substack{i \in VC_Q \\ \cup VC_{PLD}}} x_i \cdot Q_{i,t,p} + \sum_{\substack{i \in VE_Q \\ \cup VE_{PLD}}} Q_{i,t,p} \right) + \sum_{VC_{Flx}} x_i \cdot Q_{i,t}^{nom} + \sum_{VE_{Flx}} Q_{i,t}^{nom} \\ \leq \sum_{p \in Pat} \left(\sum_{\substack{i \in CC_Q \\ \cup CC_{PLD}}} x_i \cdot Q_{i,t,p} + \sum_{\substack{i \in CE_Q \\ \cup CE_{PLD}}} Q_{i,t,p} + \sum_{i \in DC} x_i \cdot Q_{i,t,p}^{CD} + \sum_{i \in DE} Q_{i,t,p}^{CD} \right) \\ + \sum_{CC_{Flx}} x_i \cdot Q_{i,t}^{nom} + \sum_{CE_{Flx}} Q_{i,t}^{nom} \end{aligned} \quad (24)$$

B. Critérios de risco

O problema de seleção da carteira ótima de contratos de energia consiste na escolha de ativos que desencadearão receitas futuras estocásticas. Essa natureza aleatória acarreta um problema nada trivial, pois cada possibilidade de carteira proporciona um conjunto de cenários de fluxos de caixa para cada período do horizonte de estudo. Tais cenários caracterizam sequências de distribuições de probabilidade no tempo, que, em geral, são dependentes entre si. Dessa forma, a utilização da otimização a fim de encontrar a melhor carteira de ativos exige que seja possível expressar a preferência entre diferentes fluxos de caixa estocásticos de forma analítica.

Tradicionalmente, os economistas abordam esse problema através da axiomatização de propriedades que as preferências devem ter para serem consideradas racionais. Em função desses axiomas, é possível estabelecer formas funcionais que as preferências podem exibir. O caso mais clássico é a Teoria da

13. De fato, a restrição de lastro contratual é verificada através de uma média móvel. Entretanto, adotamos aqui uma restrição mais conservadora.

Utilidade Esperada [8]. Na prática, porém, essa teoria pouco contribuiu para a tomada de decisão de agentes financeiros, pois é difícil para empresas especificarem uma função utilidade. Destacamos [9] para uma discussão relevante em torno da aplicabilidade da Teoria de Utilidade Esperada e medidas de risco em decisões financeiras. Algumas maneiras práticas de resolver esse problema são apresentadas em [10].

Em busca de uma solução pragmática e consistente, a análise de risco ganhou espaço entre os agentes financeiros, que passaram a defini-lo em termos de perdas financeiras ou da distância em relação a uma determinada meta. Nesse sentido, o uso de medidas de risco passou a caracterizar a abordagem preferencial desses agentes e voltou os holofotes da academia ao estudo das suas propriedades e às escolhas decorrentes do seu uso. Muitas medidas de risco foram utilizadas desde o trabalho inicial de seleção de portfólio de Markowitz [13]. Originalmente, esse trabalho recorria ao desvio padrão da distribuição dos retornos de uma carteira de ativos financeiros para expressar o risco inerente à comercialização. Posteriormente, muitas outras medidas de risco foram propostas com diversos intuitos. A semivariância [14], por exemplo, foi a primeira tentativa de considerar a assimetria das distribuições e caracterizar como risco apenas os desvios negativos. Logo após, surgiu o VaR (*Value-at-Risk*) [12], que visa quantificar o valor da perda financeira que não é excedida por um determinado nível de significância. Mais recentemente, foi criado o CVaR (*Conditional Value-at-Risk*) [15] [16], que expressa o valor esperado das perdas condicional aos eventos de perdas que superam o VaR.

Em especial, o CVaR tem recebido bastante atenção na última década, tanto pelos acadêmicos quanto pela indústria. Os principais motivos para o súbito interesse são: (i) a sua interpretação econômica intuitiva, o que permite, com uma ligeira redefinição, que ele possa ser entendido como medida de valor [16]; (ii) o seu enquadramento como medida coerente de risco, caracterizada por quatro propriedades desejáveis [11]; e, por fim, (iii) a sua forma funcional escrita como um problema de programação matemática convexo, o que proporciona uma grande vantagem algorítmica, pois não interfere na convexidade de problemas convexas ao considerarmos tal medida como métrica de otimização [15].

O CVaR, por ser uma medida de risco, é tradicionalmente definido como a média dos $(1 - \alpha) \cdot 100\%$ ¹⁴ piores (maiores) cenários de perdas financeiras [15]. Entretanto, assim como em [16], vamos considerá-lo um funcional de valor para distribuições de renda ou lucro, já que o lucro da comercialização de energia é o foco do nosso estudo neste projeto. Nesse sentido, podemos definir o CVaR como a média dos $(1 - \alpha) \cdot 100\%$ piores (menores) cenários de renda ou lucro. Na figura a seguir, ilustramos o CVaR para uma distribuição contínua de renda líquida.




Fig. 23 – CVaR e VaR redefinidos para uma densidade de probabilidade de receita.

Assim, para uma distribuição de renda líquida genérica \tilde{R} , caracterizada pelos respectivos pares de cenários e probabilidades $\{R_s, p_s\}_{s=1}^S$, o CVaR de $\alpha \cdot 100\%$ pode ser obtido através do seguinte problema de programação linear:

$$CVaR_{\alpha}(\tilde{R}) = \max_{z, \delta} z - \frac{1}{(1 - \alpha)} \sum_{s=1}^S p_s \delta_s \quad (25)$$

sujeito a:

$$\delta_s \geq z - R_s, \quad \forall s = 1, \dots, S \quad (26)$$

$$\delta_s \geq 0, \quad \forall s = 1, \dots, S. \quad (27)$$

14. Tendo como valor típico algo entre 1% e 5%.

Como leitura complementar, destacamos a referência [16]. Nesse artigo, o Remark 3 apresenta uma interpretação bastante pragmática e objetiva para a preferência de um agente que busca otimizar o CVaR. O principal conceito a ser extraído desse trecho, que justifica o uso do CVaR como medida de risco pode ser descrito da seguinte forma: quando uma das variáveis aleatórias a analisar representa o valor do projeto, o CVaR é a medida do pior valor que esse projeto pode ter. Assim, um investidor avesso a risco que aposte em tal projeto cria um valor pessimista de referência para o seu resultado – VaR ou quantil de 5%, por exemplo – e só se arrepende do investimento caso o futuro que se realize proporcione um valor pior do que a referência com a qual contava. Nesse caso, para cada unidade abaixo da referência, tal investidor exibe um decréscimo marginal de satisfação de $(1 - \alpha)^{-1}$. Entretanto, para os casos em que o futuro se realize de maneira satisfatória, ou seja, acima do resultado de referência, o investidor utiliza o mesmo valor de referência para fins de tomada de decisão.

Em vista das mencionadas virtudes do CVaR, julgamos que esse funcional, definido conforme (25)-(27), é a melhor opção disponível hoje na literatura para medir o valor pessimista de segurança de um determinado projeto. Assim, ao limitarmos o CVaR da receita a um recebimento mínimo, é possível garantir uma alta probabilidade (definida pelo usuário através do parâmetro α , tipicamente entre 0.95 e 0.99) de que esse limite não seja ultrapassado.

No caso multiperíodo, o controle do risco deve ser realizado não somente em relação ao total acumulado do resultado financeiro, mas também sobre cada período. Isso decorre da possibilidade de endividamento para cobrir resultados negativos das empresas. Nesse sentido, diversas abordagens podem ser utilizadas a fim de controlar o risco financeiro quando as decisões apresentam consequências em mais de um período. Essas abordagens serão listadas a seguir supondo um horizonte de tempo de T períodos em que uma função de renda líquida estocástica genérica, dada por $\{\tilde{R}_t(\mathbf{x})\}_{t=1}^T$, é decorrente das decisões de comercialização representadas pelo vetor de decisões \mathbf{x} . Em todos os exemplos a seguir, assumiremos que o processo estocástico (sequência temporal de variáveis aleatórias) realiza um conjunto de cenários discreto e finito com probabilidades conhecidas: $\{R_{ts}(\mathbf{x}), p_s\}_{t,s=1}^{T,S}$.

a) Restrição de CVaR mínimo por período

Esse caso se justifica toda vez que a política de risco da empresa não deseja contar com os lucros acumulados de períodos anteriores para garantir o resultado mínimo por período exigido. Assim, aplicamos uma restrição de CVaR para cada período da seguinte forma:

$$CVaR_\alpha(\tilde{R}_t(\mathbf{x})) \geq R_t^{min}, \quad \forall t = 1, \dots, T. \quad (28)$$

b) Restrição de CVaR acumulado mínimo por período

Esse caso se aplica toda vez que a política de risco da empresa deseja contar com os lucros acumulados para garantir o resultado mínimo exigido por período. Essa política deve ser empregada ao caixa da empresa ou da área de comercialização. Assim, utilizamos uma restrição de CVaR sobre o caixa (\tilde{C}_t) para cada período da seguinte forma:

$$\tilde{C}_t = \tilde{C}_{t-1} + \tilde{R}_t(\mathbf{x}), \quad \forall t = 1, \dots, T; \tilde{C}_0 = 0 \quad (29)$$

$$CVaR_\alpha(\tilde{C}_t) \geq R_t^{min}, \quad \forall t = 1, \dots, T. \quad (30)$$

c) Risco máximo por período

Esse critério impõe que o Valor Esperado da renda líquida menos o CVaR seja superior a um valor mínimo por período.

$$\mathbb{E}[\tilde{R}_t(\mathbf{x})] - CVaR_\alpha(\tilde{R}_t(\mathbf{x})) \geq R_t^{min}, \quad \forall t = 1, \dots, T. \quad (31)$$

Outro meio de considerar a aversão a risco na tomada de decisão é incluir o CVaR na função objetivo. Nesse caso, a relevância do CVaR na função objetivo pode ser conjugada com a do valor esperado incondicional por meio de uma combinação convexa entre ambos. De acordo com [16], se um agente toma suas decisões de modo a maximizar o CVaR da decisão resultante, este pode ser entendido como o

Equivalente Certo (EC) do agente. O EC de uma distribuição de renda pode ser definido como o menor valor financeiro (determinístico) que um agente estaria disposto a trocar por essa distribuição, ou seja, o valor determinístico de indiferença com o fluxo incerto. Como o CVaR de um montante determinístico assume o valor do próprio montante, então, o Equivalente Certo ($EC(\tilde{R})$ em R\$) de uma distribuição de renda genérica \tilde{R} pode ser encontrado através da seguinte relação: $CVaR_\alpha(EC(\tilde{R})) = CVaR_\alpha(\tilde{R})$, que resulta em $EC(\tilde{R}) = CVaR_\alpha(\tilde{R})$ (ver [16]). Como a combinação convexa entre o CVaR e o valor esperado da renda líquida possui unidade monetária, a métrica descrita no próximo tópico pode ser utilizada como função objetivo.

d) Métrica de otimização baseada no valor presente das combinações entre CVaR e valor esperado de cada período

$$EC(\{\tilde{R}_t(\mathbf{x})\}_{t=1}^T) = \sum_{t=1}^T \left[\frac{\lambda \cdot CVaR_\alpha(\tilde{R}_t(\mathbf{x})) + (1 - \lambda) \cdot \mathbb{E}(\tilde{R}_t(\mathbf{x}))}{(1 + K)^t} \right]. \quad (32)$$

Essa medida, valor presente do fluxo de equivalentes certos ao longo do horizonte, envolve o custo de capital livre de risco K (em % equivalente por período) e o parâmetro de aversão a risco $\lambda \in [0,1]$. Esse parâmetro define a proporção da função objetivo que será destinada ao CVaR e ao valor esperado de cada período, onde $\lambda = 1$ significa 100% aversão a risco e $\lambda = 0$, totalmente neutro a risco. Essa métrica pode ser entendida como o Equivalente Certo do fluxo financeiro e, assim, a expressão (32) pode ser otimizada e conjugada com os critérios de restrição de risco descritos anteriormente.

e) Métrica de otimização baseada na combinação entre o VPL e o CVaR do VPL de cada período

$$EC(\{\tilde{R}_t(\mathbf{x})\}_{t=1}^T) = \lambda \cdot CVaR_\alpha(VPL(\tilde{R}_t(\mathbf{x}))) + (1 - \lambda) \cdot \mathbb{E}[VPL(\tilde{R}_t(\mathbf{x}))], \quad (33)$$

$$\text{onde, } VPL(\tilde{R}_t(\mathbf{x})) = \sum_{t \in T} \frac{\tilde{R}_t(\mathbf{x})}{(1 + K)^t}.$$

Essa métrica envolve os mesmos parâmetros da anterior, contudo, primeiro a renda líquida da comercialização é trazida a valor presente ao custo de capital livre de risco K (em % equivalente por período) e só depois as funções de valor – CVaR e valor esperado – são calculadas. No que diz respeito à ponderação λ , vale a mesma interpretação da métrica anterior.

C. O modelo de otimização

Uma vez apresentada a modelagem matemática dos contratos e as medidas de risco adotadas na comercialização, o modelo de otimização utilizado na plataforma está formado e pode ser descrito como:

$$EC^* = \max_{\mathbf{x}} \{(32) \text{ ou } (33)\}$$

sujeito a:

(23) → Expressão da Renda da Comercialização

(24) → Balanço de Energia

(28)-(30)-(31) → Restrições de Risco, caso o agente queira adotá-las.

Sendo que \mathbf{x} é o vetor de quantidades dos contratos candidatos.

V. ESTUDOS DE CASO DE CONTRATAÇÃO ÓTIMA

a) Estudo de Caso 1: Eólica e PCH

Neste estudo de caso, analisaremos, sob a ótica de um comercializador, a formação de um portfólio de compra de energia proveniente de duas usinas renováveis, uma eólica e uma PCH. Esse portfólio será constituído via contratos por disponibilidade, com entrega nos respectivos submercados dos geradores renováveis – PCH no Sudeste e eólica no Nordeste. O objetivo é lastrear a venda de um contrato de quantidade com um consumidor livre inicialmente no submercado Sudeste e posteriormente no Nordeste. O estudo terá duração de um ano, com todos os contratos iniciando em janeiro de 2014, em etapas mensais. Um dos nossos objetivos é determinar a partir de qual preço de venda esse negócio é vantajoso para o comercializador. Além disso, apresentaremos uma maneira alternativa de caracterizar o perfil de aversão a risco do agente comercializador através de “restrições de risco”.

Como decisão do modelo, teremos as quantidades de compra e venda dos contratos candidatos do comercializador: contratos de disponibilidade com as renováveis e de venda por quantidade com um consumidor. Esse portfólio será otimizado de forma a maximizar o valor da comercialização para o agente. A fim de atender toda a oportunidade de venda, o comercializador pode se contratar apenas com uma das duas fontes ou com uma combinação das duas, desde que o montante “comprado” (MW_{médio}) garanta uma quantidade de lastro suficiente para cobrir o contrato de venda. Antes de apresentar os resultados do estudo, explicaremos as etapas para a sua realização com o auxílio da plataforma de comercialização desenvolvida pelo projeto.

Na Ferramenta de Contratação, adicionaremos dois contratos candidatos de compra do tipo disponibilidade para renováveis: um deles firmado com uma PCH situada no Sudeste e outro, com uma eólica no Nordeste, ambas com potência instalada de 30 MW. Para cada um deles é necessário associar os arquivos de cenários simulados de geração por unidade de garantia física para todo o período de vigência do contrato. No nosso caso, acessamos os cenários simulados pela Ferramenta V&V.

As garantias físicas da usina eólica e da PCH são, respectivamente, 11.5 MW_{méd} e 18.4 MW_{méd}. Para o contrato de venda, cadastramos um contrato candidato de quantidade com 10 MW_{méd}. A ideia é emular uma situação em que o agente tenha a opção de atender toda a oportunidade de venda com apenas uma das fontes, caso isso corresponda à solução ótima. Como ponto de partida, adotaremos o preço de 100 R\$/MWh para todos os contratos (compra e venda).

Quanto aos critérios de risco, utilizaremos um perfil de neutralidade ao risco, o que equivale a um agente que maximiza o valor esperado da renda. Na ferramenta, isso se traduz como $\lambda = 0$. Por fim, devemos cadastrar também os dados de PLD dos dois subsistemas presentes na análise – SE e NE. Cadastrados os preços, podemos otimizar a carteira do comercializador.

Veja a seguir o resultado deste primeiro estudo:

Preço Venda (R\$/MWh)	Contratação PCH	Contratação Eólica	Contratação Venda
100	0%	0%	0%

Tabela 4 – Estratégia otimizada de comercialização.

O procedimento descrito até aqui nos permitiu analisar um caso base, em que a preferência do agente não considera o *tradeoff* entre risco e retorno. Além disso, comprar por disponibilidade a 100R\$/MWh para vender por quantidade ao mesmo preço não apresenta uma estratégia eficiente de comercialização e, portanto, o modelo responde com quantidades iguais a zero, anulando a operação e resultando então em um lucro igual a zero.

Esse caso não corresponde a um estudo aprofundado de comercialização e ainda é pobre no que diz respeito à disposição a contratar do agente comercializador. Serve apenas como um primeiro contato com a ferramenta. Como podemos realizar uma análise de sensibilidade mais profunda? Como variam as contratações em relação à medida de risco adotada e, principalmente, em relação ao preço do contrato de venda? Para responder a essas perguntas é necessário simular o caso diversas vezes para diferentes preços e diferentes medidas de risco. Assim, foram realizados três conjuntos de estudos variando o preço do contrato de venda entre 100 e 200 R\$/MWh através do parametrizador da Ferramenta de

Contratação¹⁵. A diferença entre cada um desses conjuntos está apenas nos critérios de risco adotados, todos na função objetivo.

1. Função objetivo igual ao valor esperado ($\lambda = 0$).
2. Função objetivo igual à combinação linear entre $CVaR_{95\%}$ e valor esperado ($\lambda = 0.5$ e $\alpha = 95\%$).
3. Função objetivo igual ao $CVaR_{95\%}$ ($\lambda = 1$ e $\alpha = 95\%$).

Para todos os casos, o otimizador sugere não contratar nada das oportunidades de compra e venda até que o preço do contrato de venda seja significativamente maior do que a média do PLD do Sudeste (109.30 R\$/MWh), submercado do contrato de venda, criando uma curva de disposição a contratar na forma de degrau. Em contrapartida, a partir desse preço, a indicação é contratar totalmente a oportunidade de venda. Veja o resultado dos três estudos na tabela abaixo.

	$CVaR_{95\%}$	$0.5 \cdot CVaR_{95\%} + 0.5 \cdot E[]$	$E[]$
Preço de Gatilho (R\$/MWh)	185	155	115
Contratação PCH (MWmédio)	7.65	5.13	0.00
Contratação Eólica (MWmédio)	9.52	11.40	10.00
Contratação Venda (MWmédio)	10.00	10.00	10.00

Tabela 5 – Resultados da comercialização otimizada para diferentes funções objetivo.

Por fim, apresentaremos outra maneira de considerar o perfil de aversão a risco do agente comercializador, inserindo uma “restrição de risco” ao estudo. Vamos considerar como medida de valor da comercialização (função objetivo) o valor esperado dos cenários de renda ($\lambda = 0$) e acrescentar uma restrição determinando que o $CVaR_{95\%}$ da renda em cada mês do estudo seja superior a -1 MMR\$ e outra restrição parecida determinando que o $CVaR_{95\%}$ da renda anual também seja superior a -1 MMR\$. Essa restrição é equivalente a limitar o $CVaR_{95\%}$ da perda a 1 MMR\$ mensal e anualmente.

A fim de entender a motivação dessa escolha, suponha que as fontes consideradas no estudo desejam vender o contrato por quantidade descrito acima lastreado apenas em sua respectiva garantia física, simulando assim a entrada de uma fonte renovável sozinha no ACL. É comum no mercado de energia que os agentes considerem apenas restrições anuais (como adotado na segunda restrição mencionada) no que diz respeito a perdas em sua receita. Contudo, como apresentaremos a seguir, a realização mensal das incertezas pode proporcionar perdas substanciais ao longo dos meses, impactando a operação anual. Além disso, a receita anual pode ser “maquiada” por grandes receitas em alguns meses, compensando possíveis perdas mensais fora do regime de risco adotado pela companhia.

Antes de apresentarmos os resultados, ressaltamos que, **apenas neste estudo com as fontes individuais**, o preço da oportunidade de venda por quantidade foi alterado para 120 R\$/MWh, 9% superior à média do PLD no Sudeste (109.30 R\$/MWh) e 24% acima do PLD do Nordeste (96.70 R\$/MWh), a função objetivo utilizada foi o valor esperado ($\lambda = 0$) e o submercado do contrato de venda está associado ao subsistema da fonte geradora (Nordeste – Eólica e Sudeste – PCH).

15. O parametrizador é uma subferramenta da Ferramenta de Contratação. Com ela, o usuário pode realizar, automaticamente, análises de sensibilidade no caso considerado, coletando os resultados de interesse para cada passo. Em outras palavras, é possível avaliar como se comportam as decisões e resultados da carteira de oportunidades cadastradas variando parâmetros do projeto. Além disso, todos os resultados das análises são automaticamente salvos na pasta do projeto e o usuário pode, se assim desejar, aprofundar-se nos resultados de um determinado passo abrindo a planilha de resultados e carregando uma otimização específica. Na Ferramenta de Contratação é possível variar desde os preços e quantidades de um determinado contrato até os parâmetros de aversão ao risco como λ e α . Como exemplo, neste caso considerado, podemos avaliar a contratação da carteira PCH/Eólica para diferentes valores de preços de venda do contrato por quantidade.

Mês	CVaR EOL (MMR\$)	CVaR PCH (MMR\$)	Mês	CVaR EOL (MMR\$)	CVaR PCH (MMR\$)
Janeiro	0.120	0.817	Julho	0.809	-1.884
Fevereiro	-0.465	0.366	Agosto	1.023	-2.257
Março	-1.325	0.875	Setembro	1.012	-2.313
Abril	-0.971	0.032	Outubro	1.045	-1.816
Maio	-0.341	-0.251	Novembro	1.003	-0.759
Junho	0.499	-1.486	Dezembro	0.917	-0.274

Tabela 6 – CVaR_{95%} mensal da comercialização sozinha de uma PCH e uma Eólica no ACL para um contrato de venda por quantidade a 120 R\$/MWh.

Primeiramente, como podemos ver na Tabela 6, o resultado do CVaR_{95%} mensal apresenta padrão extremamente sazonal e coerente com o padrão sazonal da respectiva fonte. Vemos que em períodos de pouco vento na região Nordeste, a eólica possui perdas superiores a 1 MMR\$. Em períodos de baixa vazão/pouca chuva na região Sudeste, as perdas da PCH podem superar 2 MMR\$ em termos de CVaR. Contudo, especialmente para a fonte eólica, há períodos de receitas positivas também superiores a 1 MMR\$. Isso pode, em termos anuais, “mascarar” os resultados de baixa produção dos recursos renováveis, deixando o agente exposto a um risco não considerado no momento de decidir o montante a contratar da oportunidade de venda disponível.

Vemos ainda que, em relação ao CVaR mensal da receita, vento e vazão também são complementares. Esse resultado vai ao encontro de uma importante pesquisa que vem sendo realizada no Brasil cujos resultados evidenciam a complementariedade entre fontes renováveis (PCH, Eólica, Solar e Biomassa, entre outras) (ver [21][22][23] e suas referências). Tal pesquisa motiva a busca por meios adequados de comercializar essas fontes conjuntamente, dando extrema importância ao modelo de simulação de cenários de recursos renováveis desenvolvido neste projeto.

A seguir, apresentaremos os resultados obtidos com a comercialização conjunta dessas duas fontes alternativas no ACL, considerando a oportunidade de venda no Sudeste como descrito anteriormente.

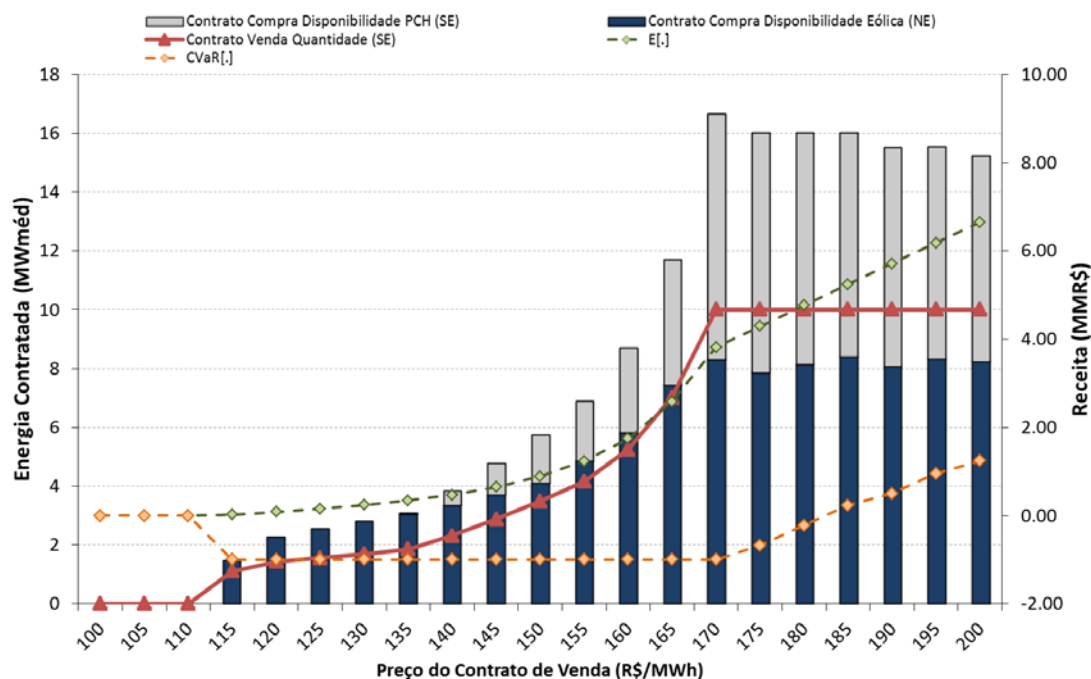


Fig. 24 – Análise de contratação de portfólio renovável por disponibilidade lastreando um contrato de venda no Sudeste por quantidade.

No gráfico acima são exibidos os montantes ótimos de compra e venda dos contratos candidatos para cada possível preço do contrato de venda, considerando as restrições de perdas mensais e anuais de, no

máximo, 1 MMR\$ em termos de $\text{CVaR}_{95\%}$. Ao observá-lo, é possível perceber que, a partir de 170 R\$/MWh, passa a ser ótimo contratar 100% da oportunidade de venda (10 MW_{méd}). Outro fato interessante de notar é a maneira como se dá a formação do portfólio de renováveis. Conforme era de se esperar, é vantajoso para o agente diversificar o portfólio de compra, tirando proveito dos benefícios do efeito portfólio. Com isso, é possível reduzir o impacto da sazonalidade e intermitência inerentes à geração das renováveis, principal fator de risco da comercialização desse tipo de fonte. Além disso, a solução ótima indica a contratação de um montante além da quantidade do contrato de venda. Essa é uma forma de se proteger do risco de preço e quantidade, resultante da absorção de todo o risco da geração das renováveis decorrente das compras por disponibilidade, ao vender um contrato por quantidade. O risco de preço e quantidade se materializa em cenários de baixa geração e alto valor de PLD. Nesses cenários, o comercializador deve comprar energia no mercado *spot* para cobrir a quantidade contratada a um PLD que pode valer até seis vezes o preço do contrato, podendo onerar substancialmente o fluxo de caixa do empreendedor. Nesse contexto, o excesso de compra mitiga a probabilidade dos cenários de geração apresentarem valores inferiores ao montante de venda, minimizando assim, a exposição ao PLD.

Ainda na Fig. 24, as linhas pontilhadas em verde e laranja representam, respectivamente, o valor esperado e $\text{CVaR}_{95\%}$ da receita total da comercialização. Como estamos buscando maximizar o valor esperado, é natural que ele apresente um comportamento crescente à medida que aumentamos o preço de venda. Com relação ao $\text{CVaR}_{95\%}$, percebemos que, até o preço de venda de 170 R\$/MWh, essa medida é limitada à restrição mínima imposta na decisão de $-1 \text{ MMR\$}$, sendo positiva, apenas, acima de 185 R\$/MWh. Esse resultado é bastante relevante, pois implica que, para um agente avesso ao risco e que procura valores positivos nos piores cenários de renda, esse negócio não é passível de ser implementado uma vez que não será possível encontrar um consumidor disposto a pagar esse preço pelo contrato. Esse resultado se deve ao fato do PLD no Nordeste ser em média superior ao PLD do Sudeste. Com isso, a energia eólica comprada pelo comercializador será liquidada no Nordeste a valores menores, em geral, que o PLD do contrato de venda, não permitindo ao agente tirar vantagem da diferença de subsistemas.

Podemos, então, realizar esse mesmo estudo para uma situação ligeiramente diferente, em que o contrato de venda é firmado com um consumidor no Nordeste. Neste caso, podemos proceder com a mesma análise do caso anterior.

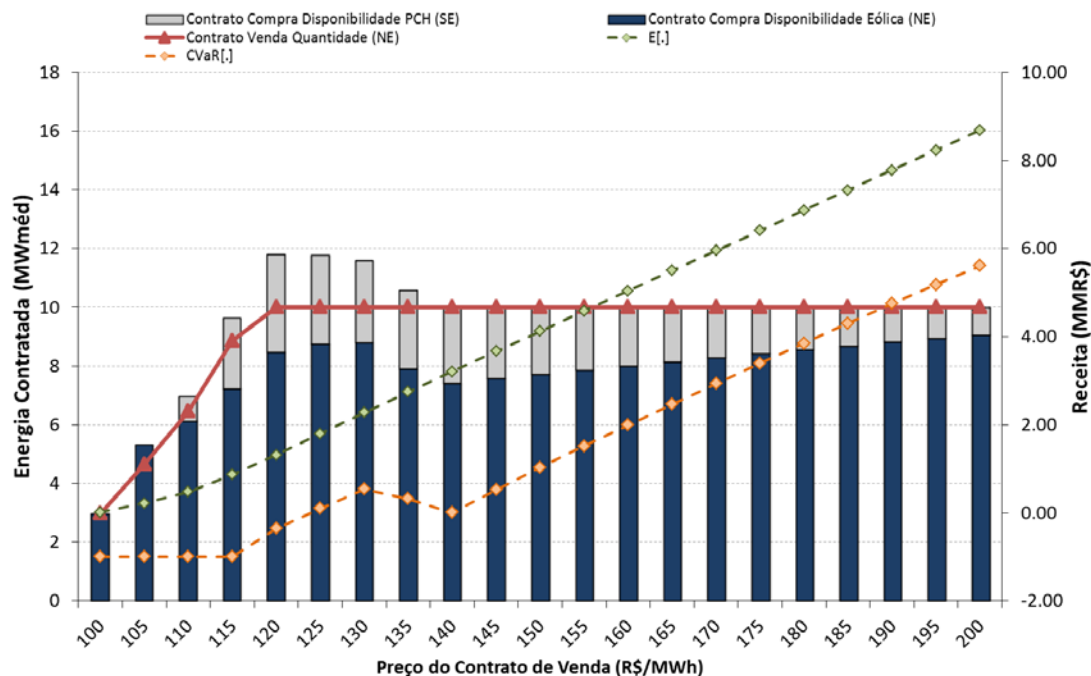


Fig. 25 – Análise de contratação de portfólio renovável por disponibilidade lastreando um contrato de venda no Nordeste por quantidade.

É possível constatar que o preço de venda a partir do qual o comercializador decide entrar 100% no negócio é bastante inferior ao caso em que a venda é realizada no submercado Sudeste, passando de 170.00 para 120.00 R\$/MWh. Isso indica que o sobrepreço necessário para compensar o risco de comprar por disponibilidade das renováveis nos seus submercados e revender por quantidade no Nordeste gera

um negócio menos arriscado do que vender no Sudeste. Essa conclusão está embasada, mais uma vez, no fato de que os PLDs do Nordeste costumam ser levemente mais baixos que os do Sudeste. Com isso, a liquidação na CCEE da parcela da PCH, que está no Sudeste, implica uma receita superior ao custo referente à liquidação na CCEE relativa à parcela do contrato de venda, quando este está no Nordeste. Assim, quando o agente pode tirar vantagem do subsistema, o $CVaR_{95\%}$ (linha pontilhada laranja) está no limite da restrição somente para preços de venda inferiores a 120 R\$/MWh, estando sempre positivo a partir deste preço. Este resultado é bastante relevante, pois reforça que, ao contrário do contrato de venda no Sudeste, a venda no Nordeste é um negócio mais adequado para o comercializador uma vez que os preços dos contratos estão mais competitivos (120 R\$/MWh com relação à 170 R\$/MWh no Sudeste) e o risco associado às perdas potenciais em termos de $CVaR_{95\%}$ estão em patamares adequados, sendo inclusive positivos (sem perdas financeiras nos piores cenários).

b) Estudo de Caso 2: Eólica e Térmica a gás

O objetivo deste estudo é determinar o valor que 1 MW_{méd} de contrato de disponibilidade com uma unidade termelétrica tem para um gerador eólico localizado no Nordeste que comercializa, no ACL, sua energia. Vamos assumir que a eólica vende um contrato de quantidade padrão *flat* para um consumidor livre no seu submercado. Para criar um *hedge* contra o risco de preço e quantidade, ela decide adquirir 1 MW_{méd} de contrato de disponibilidade com uma termelétrica no Sudeste, o que equivale à aquisição de uma opção de compra de energia com preço de exercício igual ao CVU (custo variável unitário, em R\$/MWh) da térmica. Em todos os cenários em que o PLD assume um valor superior ao do CVU, o contrato pagará ao seu comprador (gerador eólico), a diferença entre o PLD e o CVU. Assim, esse contrato protege o gerador eólico em momentos de baixa produção e alto PLD. **Para efeitos práticos, ao longo deste estudo de caso, denominaremos o contrato de compra de disponibilidade térmico como contrato de *hedge* ou opção de compra.**

O valor (ou prêmio) da opção de compra para o gerador eólico depende implicitamente do risco a que este está exposto, logo, do contrato de venda que esse gerador comercializa com o consumidor livre. Para um gerador 100% contratado, o risco de preço e quantidade é maior do que para um gerador que otimiza o montante de venda de maneira a considerar esse risco. Assim sendo, vamos calcular o valor da opção de compra para ambos os casos e, então, encontrar limites para o valor do *hedge* que essa opção pode proporcionar. Por fim, entendendo que a decisão de compra do contrato de *hedge* e a decisão de venda do contrato de quantidade são dependentes, vamos abordar um terceiro caso em que o gerador eólico traça sua estratégia ótima de venda levando em conta o efeito de *hedge* da opção de compra. Assim, vamos traçar a oferta ótima de contrato de venda de energia de maneira conjunta à demanda ótima pela opção de compra para cada possível preço (ou prêmio) dessa opção.

Para os três casos, vamos assumir um gerador eólico no Nordeste do Brasil com 30 MW de potência disponível e garantia física igual a 11.5 MW_{méd}, bem como um contrato de venda de quantidade padrão de um ano a 100 R\$/MWh com montante igual à garantia física da usina, 11.5 MW_{méd}. Se otimizássemos a comercialização desse contrato a esse preço, sem a opção de compra, a contratação ótima equivaleria a 9.54 MW_{méd} (aproximadamente 83% da garantia física); e o $CVaR$, a MMR\$ 7.59.

A opção de compra terá um valor de exercício (CVU) de 90 R\$/MWh. Assim sendo, toda vez que o PLD assumir um valor acima desse patamar, o contrato de *hedge* dará o direito ao gerador eólico de comprar 1 MW_{méd} de energia a 90 R\$/MWh. Conforme mencionado anteriormente, vamos abordar os seguintes casos:

- (i) gerador eólico com 100% da garantia física contratada no ACL,
- (ii) gerador eólico com quantidade de contrato de venda otimizado e
- (iii) gerador eólico com contrato de venda e opção de compra otimizados em conjunto.

Os casos (i) e (ii) seguirão uma metodologia de busca pela indiferença, onde o valor do portfólio do gerador eólico considerando a opção de compra, além do contrato de venda, será contrastado com o valor do portfólio somente com o contrato de venda. Para isso, o preço do contrato de *hedge* (preço fixo pago pelo contrato de disponibilidade com a termelétrica) será variado até que o $CVaR$ da renda anual do portfólio considerando o contrato de *hedge* se iguale ao $CVaR$ do portfólio da eólica somente com o contrato de venda. Esperamos identificar um valor muito mais alto para o preço de indiferença no caso (i) do que para o caso (ii). Isso se deve ao fato de que o valor do *hedge* para um contrato não-otimizado deve ser maior do que para um contrato que foi otimizado justamente para minimizar o risco para o qual o contrato de *hedge* oferece proteção. Já no caso (iii), como analisamos a possibilidade do gerador eólico

realizar a venda da energia de maneira conjunta com a compra do contrato de *hedge*, o que desejamos identificar é o *surplus* na quantidade ótima de contrato de venda de energia, acima da quantidade ótima que o gerador venderia sem o *hedge*, que o contrato de *hedge* permite o gerador eólico realizar.

Como estamos realizando o estudo sob o ponto de vista do gerador eólico e a ferramenta de comercialização contempla o caso geral de um agente comercializador, podemos supor que a comercializadora “compra” por disponibilidade a produção da eólica a preço nulo, simulando uma situação em que o comercializador é o dono do parque gerador. Uma vez que o preço do contrato é 0, ao inserirmos um contrato candidato de compra por disponibilidade com 100% da garantia física do gerador eólico, a estratégia ótima será sempre comprar todo o montante desse contrato, resultando no aluguel de 100%, a custo zero, desse gerador.

Caso (j): Gerador eólico com 100% da garantia física contratada no ACL

Para realizar este estudo, devemos adicionar três contratos na Ferramenta de Contratação. A oportunidade de venda segue o mesmo padrão apresentado no estudo de caso anterior (venda de um contrato por quantidade). Contudo, como o montante contratado é fixo, ele deve ser tratado como um contrato existente. O mesmo procedimento deve ser seguido para a opção de compra de um contrato de disponibilidade com a termelétrica. O cadastro do contrato deve ser feito em Contratos Existentes, adicionando um contrato por disponibilidade “Térmica”. Além do CVU de 90 R\$/MWh, os parâmetros da opção são potência e garantia física de 1 MW e geração mínima de 0 MW. Os cenários de geração desse contrato são formados automaticamente pela plataforma em função dos cenários de PLD associados à opção. Como mencionamos anteriormente, um contrato de compra de disponibilidade com o gerador eólico, a preço zero e quantidade igual a 100% da garantia física, deve ser inserido como contrato existente.

Uma vez cadastrados os contratos, a figura abaixo apresenta o CVaR da renda anual do portfólio com e sem o contrato de *hedge*, para distintos valores do preço do contrato de *hedge*.

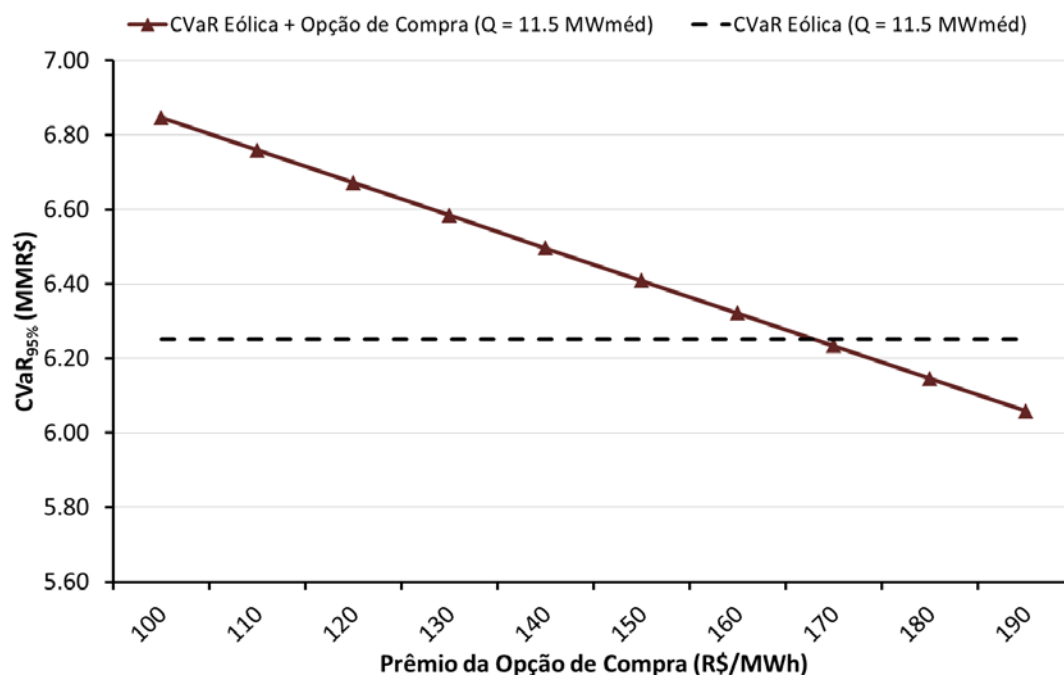


Fig. 26 – Evolução do CVaR_{95%} da eólica com e sem a opção de compra ao longo do valor do prêmio da opção para o caso de 100% contratado (11.5 MWméd).

Neste estudo percebemos que o valor de indiferença entre ter e não ter a opção de compra, em termos de CVaR, é de 170 R\$/MWh. Daí se conclui que esse gerador eólico estaria disposto a pagar um prêmio de até 170 R\$/MWh pela opção de compra de 1 MWméd a 90 R\$/MWh para se proteger do risco de preço e quantidade produzido pela venda, por quantidade, de 100% de sua GF a 100 R\$/MWh no ACL (Nordeste).

Gerador eólico com quantidade de contrato de venda otimizado

Este segundo estudo tem características muito semelhantes ao estudo anterior. A única diferença está no montante contratado da oportunidade de venda pela eólica, que assumiremos ser de 9.54 MW_{méd} (como mencionamos anteriormente, 83% da GF do gerador eólico). Na plataforma, basta substituímos o valor de 11.5, atribuído ao contrato de quantidade padrão de venda existente, por 9.54 e proceder como no estudo anterior. Para chegar a esse valor, deve-se considerar o contrato de venda de quantidade como candidato, sem o contrato de *hedge*, e otimizar o CVaR do VPL da renda levando em conta uma taxa de desconto de 0% a.a. O gráfico a seguir mostra o novo ponto de indiferença.

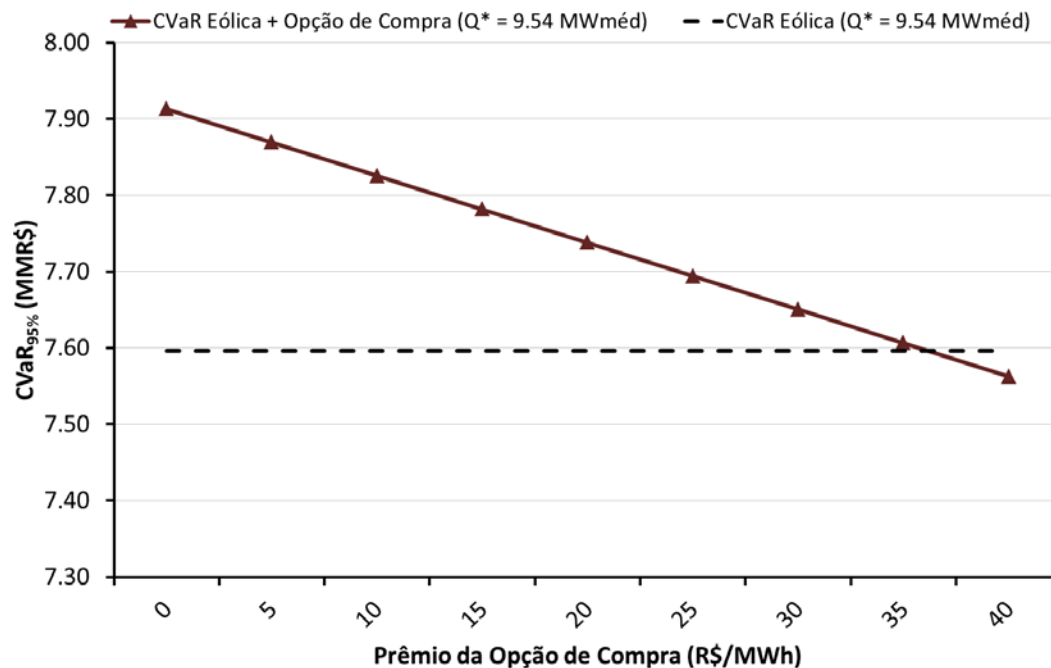


Fig. 27 – Evolução do CVaR_{95%} da eólica com e sem a opção de compra ao longo do valor do prêmio da opção para o caso de otimismo contratado (9.54 MW_{méd})

O principal efeito da mudança é a drástica queda no valor de indiferença, que passa a ser de 35 R\$/MWh. Esse resultado é coerente e já era esperado, pois, na medida em que a contratação da eólica é otimizada para maximizar o CVaR da renda anual, o valor base de comparação – CVaR da renda somente com o contrato de venda – sobe bastante: de 6.25 para 7.59 MMR\$. Além disso, o diminui a necessidade de proteção que o contrato de *hedge* pode proporcionar em cenários de PLD alto, pois a quantidade ótima de venda é inferior a 100% da GF da eólica justamente para mitigar casos de geração inferior ao montante de contrato em períodos de PLD alto. Consequentemente, diminui também o prêmio pago pelo *hedge*.

Gerador eólico com contrato de venda e opção de compra otimizados em conjunto

Por fim, vamos analisar o comportamento da comercialização em um caso em que ambas as quantidades – montante de venda e opção de compra – são otimizadas conjuntamente. Na plataforma, são poucas as alterações a serem feitas. Basta que os dois contratos cadastrados como existentes nos estudos anteriores (disponibilidade com a termelétrica e quantidade padrão de venda) sejam cadastrados como candidatos. Assim, para distintos valores de prêmio para a opção de compra, encontramos os montantes ótimos de contrato de venda no ACL e de compra dessa opção. O gráfico a seguir ilustra os valores de quantidade ótima de ambos os contratos otimizados em conjunto. Nesse mesmo gráfico, o CVaR da renda anual do portfólio otimizado (venda + contrato de *hedge*) e do portfólio somente com o contrato de venda otimizado são contrastados.




Fig. 28 – Evolução do CVaR_{95%} da eólica com e sem a opção de compra e do % contratado da oportunidade candidata com relação ao prêmio da opção de compra

Pela figura acima, podemos perceber que, até 40 R\$/MWh, a decisão ótima seleciona 100% da opção de compra (1 MWmédio) e o montante de venda por quantidade ótimo sobe de 83% para 90% da GF da eólica (9.54 para 10.35 MWmédio).

VI. CONCLUSÃO

Este projeto teve duração de dois anos e envolveu um total de sete pesquisadores, sendo quatro alunos de mestrado e três professores, todos do departamento de engenharia elétrica da PUC-Rio. Os principais frutos diretos gerados pelo projeto são:

1. Duas ferramentas de apoio à decisão: Ferramenta V&V e Ferramenta de Contratação.
2. Sete artigos completos em conferências internacionais e nacionais.
3. Quatro apresentações nos principais fóruns de energia eólica do Brasil (Wind Power Brazil e Brazil Wind Forum, ambos em 2011 e 2012) como palestrantes convidados.
4. Duas dissertações de mestrado iniciadas durante o projeto e outras duas que se iniciarão após o término do projeto;
5. Temas para duas Iniciações Científicas com alunos de graduação,
6. Seis apresentações em congresso,
7. Dois artigos em periódicos internacionais sendo confeccionados para a submissão.

Indiretamente, o projeto proporcionou a inauguração de uma nova linha de pesquisa no departamento – Recursos Naturais para a Geração de Energia Elétrica –, na qual estão envolvidos outros professores e alunos que não participaram diretamente do projeto.

A principal inovação deste projeto reside em um modelo capaz de simular cenários de geração de energia elétrica de centrais renováveis – eólicas e PCHs – de maneira casada com os cenários simulados de variáveis operativas do sistema elétrico. Como principal objetivo e motivação, encontra-se a comercialização de contratos no ACL lastreados na geração das mencionadas centrais renováveis. Argumentamos que somente através de cenários casados de geração renovável e PLD, este último fruto da simulação operativa, podemos capturar corretamente o risco de preço e quantidade presente na negociação de contratos de quantidade.

A versão final da Ferramenta V&V foi desenvolvida a partir de um modelo VARX (*Vector Autoregression with eXternal variables*) que utiliza como variáveis explicativas o histórico de vento e vazão dessas fontes e as ENAs de cada submercado brasileiro. Estudos desenvolvidos com a Ferramenta V&V neste relatório indicam um R^2 de 76.86% para o *FC* de uma eólica no Nordeste e de 75.49% para a *Vz* de uma PCH no Sudeste. Contudo, o modelo apresentado é genérico e pode ser utilizado para qualquer usina com padrão de produção sazonal e intermitente.

Com o objetivo de impulsionar a competitividade das fontes renováveis no ACL, uma segunda ferramenta, de comercialização, foi produzida. Nela, diferentes estratégias de portfólio de fontes renováveis complementares, por exemplo, PCHs no Sudeste e eólicas no Nordeste, podem ser criadas e otimizadas. Apresentamos três estudos de caso com diferentes estratégias de comercialização envolvendo portfólios das fontes renováveis. Todas as estratégias abordadas nos estudos de caso são inovadoras e têm possibilidade de aplicação direta no desenho atual do ACL.

No primeiro estudo de caso, apresentamos uma estratégia otimizada para uma comercializadora que compra lastro de uma PCH e de uma eólica por disponibilidade a fim de lastrear a venda de um contrato de quantidade no ACL. Recorrendo aos cenários produzidos pela Ferramenta V&V para as duas fontes, a Ferramenta de Contratação encontra um portfólio de compra que restringe o risco de perdas financeiras, oriundas do risco de preço e quantidade, ao mesmo tempo em que busca maximizar o valor esperado da receita líquida do portfólio. Mostramos que, sob as restrições de risco impostas (perdas máximas aceitáveis de 1 MMR\$ ao ano e ao mês), a venda de 10 MW médios de um contrato de quantidade de 1 ano a 120 R\$/MWh (no Nordeste) pode ser lastreada pela compra de 3 MW médios de lastro de PCH (no Sudeste) e 8.7 MW médios de eólica (no Nordeste), ambos a 100 R\$/MWh por disponibilidade.

No segundo estudo, mostramos o valor (prêmio) que uma opção de compra pode ter para uma eólica com 100% de sua garantia física vendida no ACL por quantidade. Nesse estudo, uma eólica de 30 MW médio e 40% de *FC* anuais estaria disposta a pagar como prêmio até 170 R\$/MWh por um MW médio de uma opção de compra a 90 R\$/MWh. Contudo, o valor do prêmio se reduz para 35 R\$/MWh quando a mesma eólica vende um valor otimizado da sua garantia física (no caso estudado, 83%).

Com base nos resultados ilustrados nos estudos de caso, as ferramentas desenvolvidas neste projeto proporcionam um diferencial competitivo para os geradores ou comercializadores que negociam energia renovável no ACL. Assim, entendemos que as inovações, materializadas nas ferramentas produzidas, permitem aos empreendedores criarem estratégias de comercialização mais seguras e rentáveis nesse ambiente.

REFERÊNCIAS BIBLIOGRÁFICAS

- [1] ANEEL – Agência Nacional de Energia Elétrica. **Resolução Normativa ANEEL Nº 5163**, de 30 de julho de 2004.
- [2] MME – Ministério das Minas e Energia. **Modelo institucional do setor elétrico**, Brasília, dezembro de 2003.
- [3] PROINFA – Programa de Incentivo às Fontes Alternativas de Energia Elétrica. [Online]. Disponível em: <http://www.mme.gov.br/programas/proinfa/>.
- [4] H. Lütkepohl, “Introduction to Multiple Time Series Analysis,” Berlin: Springer-Verlag, 1993.
- [5] P. Kennedy, “A guide to econometrics,” 3. ed. Massachusetts: The MIT Press, 1992.
- [6] J.D. Hamilton, “Time Series Analysis,” New Jersey: Princeton University Press, 1994.
- [7] R. Johnson, and D. Wichern, “Applied Multivariate Statistical Analysis,” Prentice Hall, 1992.
- [8] D. Luenberger, “Investment Science,” New York: Oxford University Press, 1997.
- [9] A. Street, “Equivalente Certo e Medidas de Risco em decisões de Comercialização de Energia Elétrica,” Rio de Janeiro. 2008. 174p. Tese de Doutorado – Departamento de Engenharia Elétrica, Pontifícia Universidade Católica do Rio de Janeiro (PUC-Rio).
- [10] A. Street, “Estratégia de Oferta de Geradoras em Leilões de Contratação de Energia Elétrica,” Rio de Janeiro, 2004. 103p. Dissertação de Mestrado – Departamento de Engenharia Elétrica, Pontifícia Universidade Católica do Rio de Janeiro (PUC-Rio).
- [11] P. Artzner, F. Delbaen, J.M. Eber, and D. Heath, “Coherent Measures of Risk,” *Mathematical Finance*, vol. 9, n. 3, p. 203-228, 1999.
- [12] P. Jorion, “Value-at-Risk: The New Benchmark for Managing Financial Risk,” 3 ed. McGraw-Hill, 2006.
- [13] H. Markowitz, “Portfolio Selection,” *The Journal of Finance*, vol. 7, n. 1, p. 77-91, 1952.
- [14] H. Markowitz, P. Todd, G. Xu, and Y. Yamane, “Computation of mean-semivariance efficient sets by the Critical Line Algorithm,” *Annals of Operations Research*, vol. 45, n. 1, p 307-317, 1993.
- [15] R.T. Rockafellar, and S.P. Uryasev, “Optimization of conditional Value-at-Risk,” *Journal of Risk*, vol. 2, p. 21-41, 2000.
- [16] A. Street, “On the Conditional Value-at-Risk Probability Dependent Utility Function,” *Theory and Decision*, vol. 68, p. 49-68, 2010.
- [17] M.V. Pereira, L.A. Barroso, and J. Rosenblatt, “Supply Adequacy in the Brazilian Power Market,” *IEEE Power Engineering Society General Meeting 2004*, vol. 1, pp. 1016-1021, June 2004.
- [18] A. Street, L.A. Barroso, S. Granville, and M.V. Pereira, “Offering Strategies and Simulation of Multi Item Dynamic Auctions of Energy Contracts,” *IEEE Trans. Power Syst.*, vol.26, no.4, pp. 1917-1928, Nov. 2011.
- [19] L.A. Barroso, A. Street, S. Granville, and B. Bezerra, “Bidding Strategies in Auctions for Long-Term Electricity Supply Contracts for New Capacity,” *IEEE Power Engineering Society General Meeting 2008*, Pittsburgh, Pennsylvania, USA.
- [20] B. Fanzeres, A. Street, D. Lima, A. Veiga, L. Freire, e B. Amaral, “Comercialização de Energia Eólica no Ambiente Livre: Desafios e Soluções Inovadoras,” *XII SEPOPE 2012*, Rio de Janeiro, Rio de Janeiro, Brasil.
- [21] B. Fanzeres, A. Street, D. Lima, A. Veiga, L. Freire, and B. Amaral, “Fostering Wind Power Penetration into the Brazilian Forward-Contract Market,” *IEEE Power Engineering Society General Meeting 2012*, San Diego, California, USA.
- [22] B. Fanzeres, e A. Street, “Cálculo da Curva de Disposição a Contratar de Geradores Hidrelétricos: Uma Abordagem Robusta ao Preço de Curto-Prazo,” *XXI SNPTEE 2011*, Florianópolis, Santa Catarina, Brasil.

- [23] L. Freire, A. Street, and D. Lima, "Sharing Quotas of a Renewable Energy Hedge Pool: A Cooperative Game Theory Approach," IEEE PowerTech 2011, Trondheim, Norway.
- [24] A. Street, L.A. Barroso, S. Granville, and M.V. Pereira, "Bidding Strategy Under Uncertainty for Risk-Averse Generator Companies in a Long-Term forward Contract Auction," *IEEE Power Engineering Society General Meeting 2009*, Calgary, Alberta, Canada.
- [25] A. Street, L.A. Barroso, B. Flach, M.V. Pereira, and S. Granville, "Risk Constrained Portfolio Selection of Renewable Sources in Hydrothermal Electricity Markets," *IEEE Trans. Power Syst.*, vol.24, no.3, pp. 1136-1144, 2009.
- [26] B. Bezerra, L.A. Barroso, S. Granville, A. Guimarães, A. Street, and M.V. Pereira, "Energy Call options Auctions for Generation Adequacy in Brazil," IEEE Power Engineering Society General Meeting 2006, Montreal, Quebec, Canada.
- [27] F. Bouffard, and F.D. Galiana, "Stochastic Security for Operations Planning with Significant Wind Power Generation," *IEEE Trans. Power Syst.*, vol. 23, no. 2, pp. 306-316, May 2008.

ANEXO 1: TRANSFORMAÇÕES DAS VARIÁVEIS DEPENDENTES *Vz* E *FC*

Uma das possíveis variáveis de interesse para a simulação, o fator de capacidade (*FC*), é representada em valores percentuais e, portanto, é restrita ao intervalo [0,1]. Assim, a transformação deve respeitar essa restrição e gerar um modelo capaz de simular valores consistentes.

A transformação selecionada, para o nosso caso, é conhecida como Logaritmo da Razão de Chance [5]. No seu uso original, a Razão de Chance é a probabilidade de um evento ocorrer dividida pela probabilidade de não ocorrer. Observa-se que a Razão de Chance é um número no intervalo $[0, \infty)$. Usa-se então um logaritmo para obter uma medida no intervalo $(-\infty, +\infty)$.

Neste trabalho, adaptamos essa ideia para o caso de variáveis com valor no intervalo (Min, Max), já que os mínimos e máximos dos recursos renováveis estão dentro de limites bem definidos. Assim, seja X_t uma variável e seja X'_t a sua transformada, então,

$$FC'_t = X'_t = \ln \left(\frac{X_t - \text{Min}}{\text{Max} - X_t} \right). \quad (1A)$$

Como o fator de capacidade é um percentual da potência nominal, *FC* deverá ficar entre Min=0 e Max=100. Logo, a variável FC'_t (*FC* transformada para cada período de tempo), será expressa da seguinte forma:

$$FC'_t = \ln \left(\frac{FC_t}{100 - FC_t} \right) ; \quad \forall t \in T. \quad (1B)$$

A transformação da Vazão (*Vz*) – outra variável que possivelmente será bastante utilizada neste modelo – seguirá o mesmo conceito, porém com um limite diferente. A vazão é uma variável que mede a quantidade de água escoada em m³/s. Teoricamente não há limite máximo para essa variável; contudo, há algumas considerações físicas que devemos respeitar. Observando os dados históricos, percebemos que a vazão máxima registrada para o rio considerado no estudo foi igual a 270 [m³/s]. Dessa forma, atribuímos uma vazão máxima de 300 [m³/s]. Assim, a variável Vz'_t (*Vz* transformada para cada período de tempo) será expressa da seguinte forma:

$$Vz'_t = \ln \left(\frac{Vz_t}{300 - Vz_t} \right) ; \quad \forall t \in T. \quad (1C)$$

Como o uso da Razão de Chance nas variáveis dependentes foi motivado pela constatação de valores não realistas na simulação de cenários de vento e vazão, e como as ENAs são variáveis exógenas ao modelo, sendo a simulação apenas condicional a elas, essas variáveis sofrerão apenas uma simples transformação logarítmica. Assim:

$$SE'_t = \ln(SE_t) ; \quad S'_t = \ln(S_t) ; \quad NE'_t = \ln(NE_t) ; \quad N'_t = \ln(N_t) ; \quad \forall t \in T. \quad (1D)$$

Ressaltamos que a transformação das variáveis é opcional e a ferramenta contempla a opção de não realizar tais transformações, tanto nas variáveis dependentes (recursos renováveis) quanto nas variáveis explicativas.

ANEXO 2: PRODUTO DE KRONECKER

Considere as matrizes \mathbf{A} de dimensão $(m \times n)$ e a matriz \mathbf{B} de dimensão $(u \times v)$, conforme descrito abaixo:

$$\mathbf{A} = \begin{bmatrix} a_{11} & \cdots & a_{1n} \\ \vdots & \ddots & \vdots \\ a_{m1} & \cdots & a_{mn} \end{bmatrix}, \quad (2A)$$

$$\mathbf{B} = \begin{bmatrix} b_{11} & \cdots & b_{1u} \\ \vdots & \ddots & \vdots \\ b_{v1} & \cdots & b_{uv} \end{bmatrix}. \quad (2B)$$

O operador vec representa uma transformação linear que converte uma matriz em vetor coluna. Assim:

$$vec(\mathbf{A}) = \begin{bmatrix} a_{11} \\ a_{21} \\ \vdots \\ a_{mn} \end{bmatrix}. \quad (2C)$$

O produto de Kronecker, representado pelo operador \otimes , é uma operação em duas matrizes de tamanho arbitrário, resultando em uma matriz de bloco. Logo:

$$\mathbf{A} \otimes \mathbf{B} = \begin{bmatrix} a_{11} \cdot \mathbf{B} & \cdots & a_{1n} \cdot \mathbf{B} \\ \vdots & \ddots & \vdots \\ a_{m1} \cdot \mathbf{B} & \cdots & a_{mn} \cdot \mathbf{B} \end{bmatrix}. \quad (2D)$$

ANEXO 3: RESULTADOS DO MODELO V&V PARA O ESTUDO DE CASO 1

A. Método não-heurístico

a) Correlações constantes

a.1) Especificação – Fator de Capacidade Eólico (FC')




Fig. 29 – FC' : Histograma dos resíduos.




Fig. 30 – FC' : Comparativo anual dos resíduos.




Fig. 31 – FC' : Correlograma para os resíduos.




Fig. 32 – FC' : Correlograma para os quadrados dos resíduos.

a.2) Especificação – Vazão (V_z')




Fig. 33 – V_z' : Histograma dos resíduos.




Fig. 34 – V_z' : Comparativo anual dos resíduos.




Fig. 35 – V_z' : Correlograma para os resíduos.




Fig. 36 – V_z' : Correlograma para os quadrados dos resíduos.

a.3) Análise do modelo

ANÁLISE DENTRO DA AMOSTRA




Fig. 37 – FC: Previsão dentro da amostra.




Fig. 38 – V_z' : Previsão dentro da amostra.

	<i>FC</i>	<i>Vz</i>
R^2	0.7594	0.7578
R^2 ajustado	0.7371	0.7354
P-valor JB dos Resíduos	0.4330	0.0488

Tabela 7 – Medidas de aderência – Dentro da amostra.




Fig. 39 – Resíduos X valor predito para *FC*.




Fig. 40 – Resíduos X valor predito para *Vz*.




Fig. 41 – Resíduos padronizados X valor predito para *FC*.






Fig. 42 – Resíduos padronizados X valor predito para *Vz*.

ANÁLISE FORA DA AMOSTRA

Fig. 43 – Desempenho do modelo fora da amostra para FC .Fig. 44 – Desempenho do modelo fora da amostra para Vz .

	FC	Vz
MAPE	41.17	14.30
MAE	4.63	9.37
RMS	6.71	12.30
MPE	0.36	-0.04
SDPE	0.98	0.17
U	0.08	0.09

Tabela 8 – Medidas de Aderência – Fora da Amostra.



a.4) Correlações

CORRELAÇÃO ENTRE AS SÉRIES DE VAZÃO (Vz) E FATOR DE CAPACIDADE (FC)

	Resíduos FC'	Resíduos Vz'
Resíduos FC'	$r_{1,1}^2 = 1,0000$	$r_{1,2}^2 = -0,1393$
Resíduos Vz'	$r_{2,1}^2 = -0,1393$	$r_{2,2}^2 = 1,0000$

Tabela 9 – Matriz de correlação residual ε_t .

a.5) Simulação

Fig. 45 – FC : 2000 simulações.Fig. 46 – Vz : 2000 simulações.




Fig. 47 – FC: Histórico com Intervalo de Confiança de 95% das simulações.




Fig. 48 – Vz: Histórico com Intervalo de Confiança de 95% das simulações.

Estatísticas Descritivas FC	Período Observado							Simulações						
	Média	Desvio	Mínimo	Máximo	Q.5%	Mediana	Q.95%	Média	Desvio	Mínimo	Máximo	Q.5%	Mediana	Q.95%
Janeiro	35.73	7.65	18.00	49.00	19.15	38.00	48.00	36.54	10.22	10.97	71.93	17.77	36.88	53.98
Fevereiro	26.30	8.93	8.00	42.00	8.75	28.00	38.85	26.23	9.85	5.68	60.97	11.59	25.37	43.31
Março	19.06	8.49	5.00	35.00	5.45	21.00	31.85	16.44	8.00	2.06	58.39	6.13	15.01	31.66
Abril	21.64	9.85	5.00	43.00	6.15	22.00	35.00	16.41	7.49	2.01	50.30	6.21	15.21	30.34
Maio	30.30	8.35	10.00	44.00	14.45	31.00	43.85	25.05	6.58	9.09	51.03	15.43	24.46	36.70
Junho	40.85	5.18	28.00	49.00	31.15	42.00	48.70	36.43	6.05	19.68	62.83	27.58	36.01	47.08
Julho	45.97	5.08	34.00	54.00	35.60	46.00	53.00	42.75	5.50	27.54	65.09	33.86	42.79	52.02
Agosto	52.21	3.50	46.00	60.00	47.15	52.00	57.00	51.52	4.35	36.75	64.79	44.09	51.77	58.32
Setembro	54.52	3.02	48.00	62.00	49.30	55.00	60.55	54.29	3.35	42.32	66.16	48.67	54.28	59.84
Outubro	54.15	2.28	49.00	59.00	49.30	54.00	57.85	54.46	3.42	42.78	69.77	48.93	54.38	60.23
Novembro	52.58	2.77	47.00	58.00	48.00	53.00	56.85	52.76	4.03	40.45	68.83	46.30	52.68	59.43
Dezembro	46.73	4.93	32.00	54.00	36.30	47.00	53.85	46.86	5.89	28.13	69.06	37.59	46.55	56.72

Tabela 10 – Análise de cenários simulados – FC – Escala original.

Estatísticas Descritivas FC	Período Observado							Simulações						
	Média	Desvio	Mínimo	Máximo	Q.5%	Mediana	Q.95%	Média	Desvio	Mínimo	Máximo	Q.5%	Mediana	Q.95%
Janeiro	105.64	30.58	61.00	179.00	64.15	105.00	167.85	100.68	34.42	19.20	223.32	49.87	97.61	161.70
Fevereiro	112.09	45.45	50.00	270.00	55.90	108.00	200.15	110.16	50.61	17.62	295.70	44.07	103.85	200.75
Março	95.70	32.66	49.00	209.00	65.00	93.00	169.75	104.15	35.70	21.27	260.65	53.08	100.09	168.01
Abril	79.12	26.11	42.00	143.00	42.75	77.00	129.35	79.08	30.62	13.16	227.72	37.47	75.00	137.21
Maio	60.70	18.27	31.00	111.00	41.60	56.00	104.05	55.71	18.08	15.06	156.92	30.19	53.73	88.39
Junho	53.79	22.46	27.00	149.00	32.15	51.00	92.45	45.82	17.88	6.59	122.82	20.07	43.53	78.44
Julho	46.73	12.36	26.00	83.00	31.45	43.00	75.90	39.64	14.14	9.09	119.75	20.14	37.75	65.90
Agosto	40.30	11.55	23.00	75.00	28.00	38.00	64.95	31.59	8.73	8.59	82.99	19.12	30.74	47.28
Setembro	48.45	20.16	21.00	130.00	25.60	46.00	86.05	35.72	12.99	7.12	100.31	16.73	34.17	59.57
Outubro	52.30	15.32	24.00	89.00	30.90	49.00	86.20	44.81	16.02	7.85	138.40	21.45	43.07	73.61
Novembro	59.85	13.98	30.00	87.00	40.15	60.00	83.40	54.04	18.37	12.95	147.13	28.21	51.64	89.25
Dezembro	77.70	24.64	40.00	149.00	46.15	76.00	121.55	68.83	22.86	15.35	161.38	35.73	66.22	110.43

Tabela 11 – Análise de cenários simulados – Vz – Escala original.

Estatísticas Descritivas FC	Período Observado							Simulações						
	Média	Desvio	Mínimo	Máximo	Q.5%	Mediana	Q.95%	Média	Desvio	Mínimo	Máximo	Q.5%	Mediana	Q.95%
Janeiro	-0.61	0.36	-1.52	-0.04	-1.44	-0.49	0.10	-0.58	0.47	-2.09	0.94	-1.53	-0.54	0.16
Fevereiro	-1.10	0.53	-2.44	-0.32	-2.36	-0.94	0.52	-1.10	0.54	-2.81	0.45	-2.03	-1.08	-0.27
Março	-1.56	0.64	-2.94	-0.62	-2.87	-1.32	0.12	-1.74	0.60	-3.86	0.34	-2.73	-1.73	-0.77
Abril	-1.41	0.67	-2.94	-0.28	-2.73	-1.27	-0.39	-1.73	0.57	-3.89	0.01	-2.72	-1.72	-0.83
Maio	-0.87	0.45	-2.20	-0.24	-1.78	-0.80	-0.73	-1.13	0.36	-2.30	0.04	-1.70	-1.13	-0.55
Junho	-0.38	0.22	-0.94	-0.04	-0.79	-0.32	-0.90	-0.57	0.26	-1.41	0.52	-0.97	-0.57	-0.12
Julho	-0.16	0.21	-0.66	0.16	-0.59	-0.16	-1.17	-0.30	0.23	-0.97	0.62	-0.67	-0.29	0.08
Agosto	0.09	0.14	-0.16	0.41	-0.11	0.08	-1.37	0.06	0.18	-0.54	0.61	-0.24	0.07	0.34
Setembro	0.18	0.12	-0.08	0.49	-0.03	0.20	-1.00	0.17	0.14	-0.31	0.67	-0.05	0.17	0.40
Outubro	0.17	0.09	-0.04	0.36	-0.03	0.16	-1.00	0.18	0.14	-0.29	0.84	-0.04	0.18	0.41
Novembro	0.10	0.11	-0.12	0.32	-0.08	0.12	-1.04	0.11	0.16	-0.39	0.79	-0.15	0.11	0.38
Dezembro	-0.13	0.20	-0.75	0.16	-0.56	-0.12	-0.49	-0.13	0.24	-0.94	0.80	-0.51	-0.14	0.27

Tabela 12 – Análise de cenários simulados – FC – Escala transformada.

Estatísticas Descritivas FC	Período Observado							Simulações						
	Média	Desvio	Mínimo	Máximo	Q.5%	Mediana	Q.95%	Média	Desvio	Mínimo	Máximo	Q.5%	Mediana	Q.95%
Janeiro	-0.74	0.44	-1.45	0.24	-1.38	-0.72	0.10	-0.83	0.53	-2.75	0.84	-1.69	-0.82	0.02
Fevereiro	-0.65	0.66	-1.69	1.69	-1.55	-0.67	0.52	-0.71	0.77	-2.84	2.50	-1.83	-0.73	0.52
Março	-0.89	0.47	-1.71	0.63	-1.37	-0.89	0.12	-0.77	0.53	-2.64	1.48	-1.62	-0.79	0.10
Abril	-1.16	0.44	-1.89	-0.21	-1.87	-1.15	-0.39	-1.18	0.53	-3.15	0.90	-2.02	-1.18	-0.29
Maio	-1.49	0.35	-2.23	-0.63	-1.90	-1.55	-0.73	-1.61	0.40	-3.01	-0.04	-2.26	-1.60	-0.96
Junho	-1.66	0.43	-2.38	-0.14	-2.19	-1.66	-0.90	-1.87	0.47	-3.86	-0.47	-2.70	-1.85	-1.12
Julho	-1.80	0.29	-2.43	-1.05	-2.22	-1.86	-1.17	-2.02	0.41	-3.53	-0.51	-2.70	-2.01	-1.35
Agosto	-1.97	0.31	-2.56	-1.18	-2.34	-2.00	-1.37	-2.25	0.31	-3.59	-1.05	-2.76	-2.24	-1.75
Setembro	-1.79	0.44	-2.66	-0.38	-2.44	-1.78	-1.00	-2.14	0.42	-3.78	-0.78	-2.90	-2.12	-1.48
Outubro	-1.67	0.35	-2.51	-0.95	-2.24	-1.71	-1.00	-1.88	0.43	-3.68	-0.27	-2.63	-1.86	-1.21
Novembro	-1.50	0.30	-2.27	-0.99	-1.94	-1.47	-1.04	-1.65	0.41	-3.17	-0.16	-2.34	-1.65	-0.95
Dezembro	-1.18	0.41	-1.95	-0.14	-1.78	-1.17	-0.49	-1.35	0.44	-2.99	0.02	-2.07	-1.34	-0.64

Tabela 13 – Análise de cenários simulados – Vz – Escala transformada.

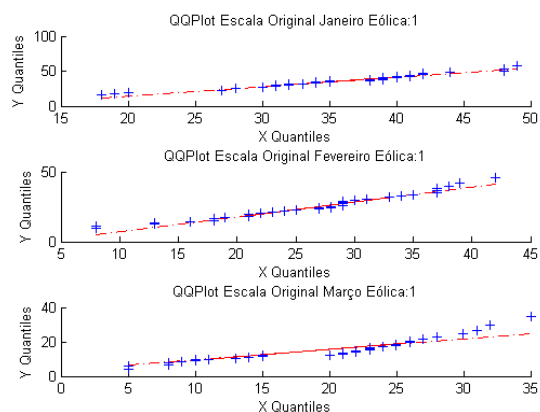


Fig. 49 – FC: QQplot (janeiro, fevereiro e março) – Variáveis originais.

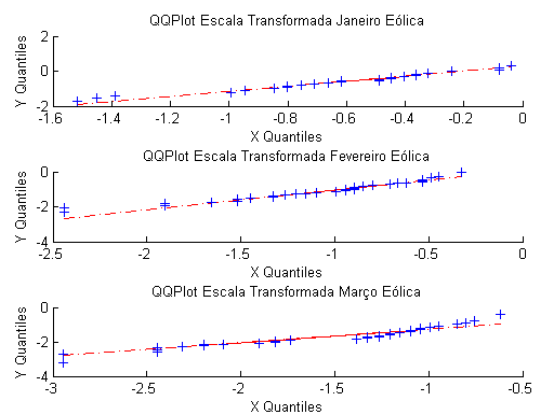


Fig. 50 – FC: QQplot (janeiro, fevereiro e março) – Variáveis transformadas.

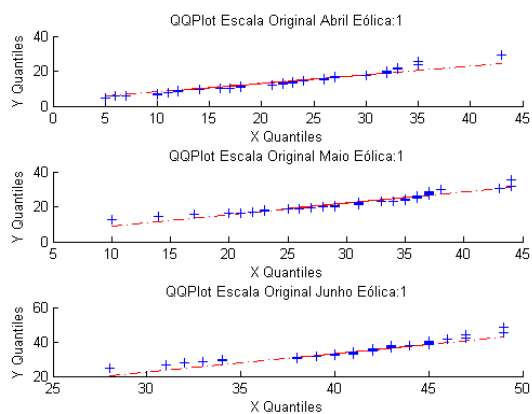


Fig. 51 – FC: QQplot (abril, maio e junho) – Variáveis originais.




Fig. 52 – FC: QQplot (abril, maio e junho) – Variáveis transformadas.




Fig. 53 – FC: QQplot (julho, agosto e setembro) – Variáveis originais.




Fig. 54 – FC: QQplot (julho, agosto e setembro) – Variáveis transformadas.

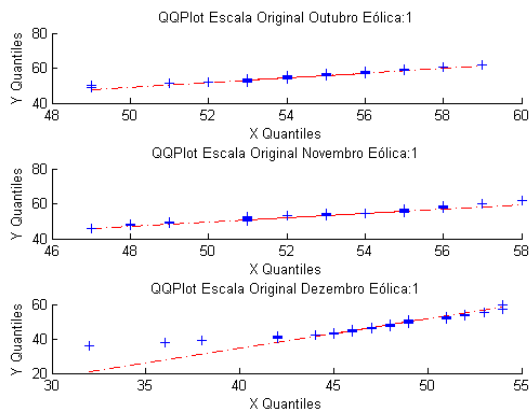


Fig. 55 – FC: QQplot (outubro, novembro e dezembro) – Variáveis originais.

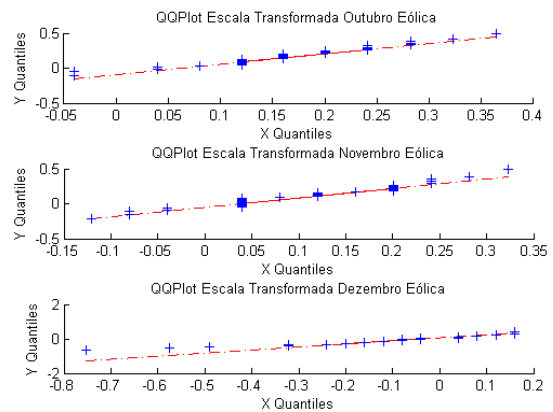


Fig. 56 – FC: QQplot (outubro, novembro e dezembro) – Variáveis transformadas.




Fig. 57 – Vz: QQplot (janeiro, fevereiro e março) – Variáveis originais.

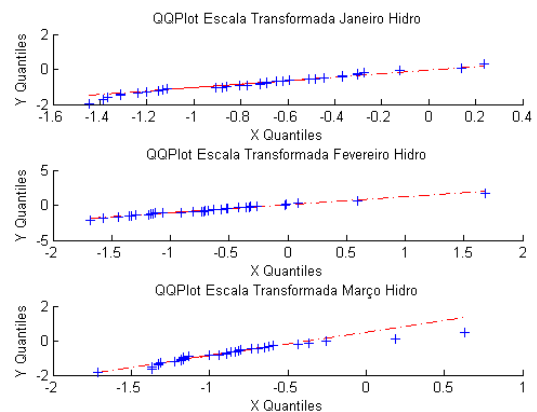


Fig. 58 – Vz: QQplot (janeiro, fevereiro e março) – Variáveis transformadas.




Fig. 59 – Vz: QQplot (abril, maio e junho) – Variáveis originais.




Fig. 60 – Vz: QQplot (abril, maio e junho) – Variáveis transformadas.

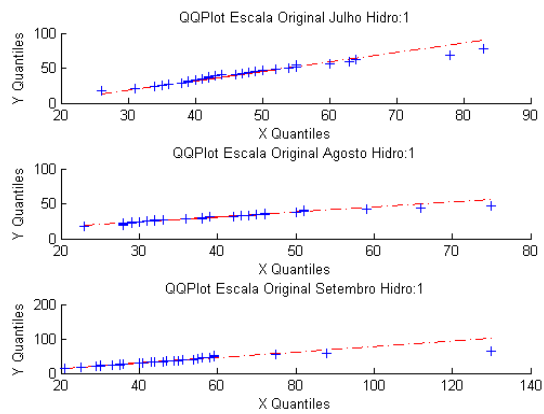


Fig. 61 – Vz: QQplot (julho, agosto e setembro) – Variáveis originais.




Fig. 62 – Vz: QQplot (julho, agosto e setembro) – Variáveis transformadas.




Fig. 63 – Vz: QQplot (outubro, novembro e dezembro) – Variáveis originais.

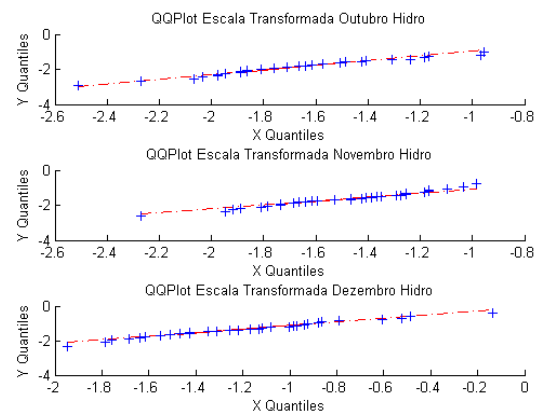


Fig. 64 – Vz: QQplot (outubro, novembro e dezembro) – Variáveis transformadas.

b) Correlações mês a mês

b.1) Especificação – Fator de Capacidade Eólico (FC')




Fig. 65 – FC' : Histograma dos resíduos.




Fig. 66 – FC' : Comparativo anual dos resíduos.




Fig. 67 – FC' : Correlograma para os resíduos.




Fig. 68 – FC' : Correlograma para os quadrados dos resíduos.

b.2) Especificação – Vazão (Vz')




Fig. 69 – Vz' : Histograma dos resíduos.




Fig. 70 – Vz' : Comparativo anual dos resíduos.




Fig. 71 – Vz': Correlograma para os resíduos.




Fig. 72 – Vz': Correlograma para os quadrados dos resíduos.

b.3) Análise do modelo

ANÁLISE DENTRO DA AMOSTRA




Fig. 73 – FC: Previsão dentro da amostra.




Fig. 74 – Vz: Previsão dentro da amostra.

	<i>FC</i>	<i>Vz</i>
R^2	0.7634	0.7502
R^2 ajustado	0.7408	0.7262
P-valor JB dos Resíduos	0.3756	0.0452

Tabela 14 – Medidas de Aderência – Dentro da Amostra.




Fig. 75 – Resíduos X valor predito para FC.




Fig. 76 – Resíduos X valor predito para Vz.




Fig. 77 – Resíduos padronizados X valor predito para FC.




Fig. 78 – Resíduos padronizados X valor predito para Vz.

ANÁLISE FORA DA AMOSTRA




Fig. 79 – Desempenho do modelo fora da amostra para FC.




Fig. 80 – Desempenho do modelo fora da amostra para Vz.

	<i>FC</i>	<i>Vz</i>
MAPE	41.17	14.30
MAE	4.63	9.37
RMS	6.71	12.30
MPE	0.35	-0.04
SDPE	0.98	0.17
U	0.08	0.09

Tabela 15 – Medidas de Aderência – Fora da Amostra.

b.4) Correlações

CORRELAÇÃO ENTRE AS SÉRIES DE VAZÃO (*Vz*) E FATOR DE CAPACIDADE (*FC*)

MÊS	σ_1	σ_2	CORRELAÇÃO
1	0.44	0.40	-54.97%
2	0.50	0.63	-38.32%
3	0.67	0.26	-43.11%
4	0.50	0.33	-0.82%
5	0.19	0.09	-10.78%
6	0.17	0.17	-12.25%
7	0.19	0.20	-25.96%
8	0.11	0.13	-7.58%
9	0.07	0.17	-11.04%
10	0.06	0.20	25.97%
11	0.09	0.26	9.91%
12	0.17	0.26	2.77%

Tabela 16 – Desvio padrão e correlação mensal das séries.

b.5) Simulação




Fig. 81 – FC: 2000 simulações.




Fig. 82 – Vz: 2000 simulações.




Fig. 83 – FC: Histórico com Intervalo de Confiança de 95% das simulações.




Fig. 84 – Vz: Histórico com Intervalo de Confiança de 95% das simulações.

Estatísticas Descritivas FC	Período Observado							Simulações						
	Média	Desvio	Mínimo	Máximo	Q.5%	Mediana	Q.95%	Média	Desvio	Mínimo	Máximo	Q.5%	Mediana	Q.95%
Janeiro	35.73	7.65	18.00	49.00	19.15	38.00	48.00	36.45	10.10	10.97	70.73	17.91	36.64	53.17
Fevereiro	26.30	8.93	8.00	42.00	8.75	28.00	38.85	26.38	9.46	6.11	61.98	11.96	25.80	42.82
Março	19.06	8.49	5.00	35.00	5.45	21.00	31.85	17.25	8.38	2.12	58.24	6.52	15.64	33.92
Abril	21.64	9.85	5.00	43.00	6.15	22.00	35.00	17.09	7.95	2.29	51.45	6.57	15.78	31.67
Maio	30.30	8.35	10.00	44.00	14.45	31.00	43.85	25.54	6.66	8.81	51.70	15.53	25.08	37.39
Junho	40.85	5.18	28.00	49.00	31.15	42.00	48.70	36.71	6.05	19.64	60.18	27.27	36.29	47.22
Julho	45.97	5.08	34.00	54.00	35.60	46.00	53.00	43.16	5.52	27.49	62.57	34.16	43.12	52.02
Agosto	52.21	3.50	46.00	60.00	47.15	52.00	57.00	51.57	4.21	36.66	65.55	44.40	51.71	58.19
Setembro	54.52	3.02	48.00	62.00	49.30	55.00	60.55	53.96	3.38	41.66	67.20	48.40	53.94	59.52
Outubro	54.15	2.28	49.00	59.00	49.30	54.00	57.85	53.95	3.40	42.26	67.46	48.44	53.87	59.71
Novembro	52.58	2.77	47.00	58.00	48.00	53.00	56.85	52.51	4.01	39.76	68.30	46.19	52.39	59.13
Dezembro	46.73	4.93	32.00	54.00	36.30	47.00	53.85	46.68	6.02	29.68	68.72	37.15	46.55	57.18

Tabela 17 – Análise de cenários simulados – FC – Escala original.

Estatísticas Descritivas FC	Período Observado							Simulações						
	Média	Desvio	Mínimo	Máximo	Q.5%	Mediana	Q.95%	Média	Desvio	Mínimo	Máximo	Q.5%	Mediana	Q.95%
Janeiro	105.64	30.58	61.00	179.00	64.15	105.00	167.85	103.00	34.96	20.09	226.36	50.59	99.77	165.12
Fevereiro	112.09	45.45	50.00	270.00	55.90	108.00	200.15	111.23	49.61	19.74	298.28	45.69	104.35	199.76
Março	95.70	32.66	49.00	209.00	65.00	93.00	169.75	103.65	34.71	22.21	247.25	53.57	99.33	166.30
Abril	79.12	26.11	42.00	143.00	42.75	77.00	129.35	79.36	30.12	15.86	210.51	37.73	74.86	136.09
Maio	60.70	18.27	31.00	111.00	41.60	56.00	104.05	55.47	17.55	15.18	157.74	30.14	53.54	87.16
Junho	53.79	22.46	27.00	149.00	32.15	51.00	92.45	45.48	17.41	9.16	168.03	20.86	43.57	77.19
Julho	46.73	12.36	26.00	83.00	31.45	43.00	75.90	39.58	13.99	8.22	103.36	20.21	37.59	65.99
Agosto	40.30	11.55	23.00	75.00	28.00	38.00	64.95	32.10	8.79	9.82	94.88	19.35	31.37	47.55
Setembro	48.45	20.16	21.00	130.00	25.60	46.00	86.05	36.51	12.98	6.31	94.39	16.98	35.47	59.72
Outubro	52.30	15.32	24.00	89.00	30.90	49.00	86.20	45.57	16.27	7.09	119.61	22.01	43.98	74.85
Novembro	59.85	13.98	30.00	87.00	40.15	60.00	83.40	55.47	18.46	12.84	163.69	29.26	53.04	88.85
Dezembro	77.70	24.64	40.00	149.00	46.15	76.00	121.55	70.74	23.50	12.32	183.37	35.88	68.61	112.82


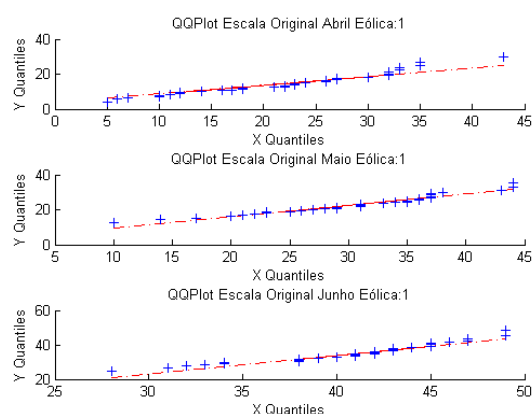
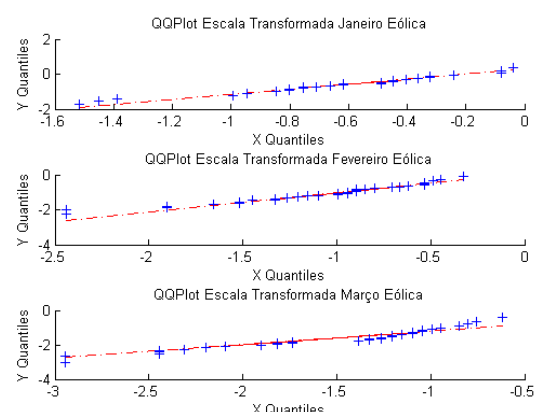
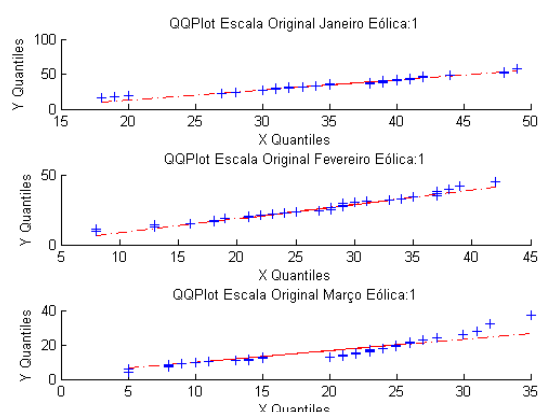
Tabela 18 – Análise de cenários simulados – Vz – Escala original.

Estatísticas Descritivas FC	Período Observado							Simulações						
	Média	Desvio	Mínimo	Máximo	Q.5%	Mediana	Q.95%	Média	Desvio	Mínimo	Máximo	Q.5%	Mediana	Q.95%
Janeiro	-0.61	0.36	-1.52	-0.04	-1.44	-0.49	-0.08	-0.46	0.15	-0.84	0.20	-0.68	-0.48	-0.18
Fevereiro	-1.10	0.53	-2.44	-0.32	-2.36	-0.94	-0.45	-0.77	0.16	-1.19	-0.13	-1.02	-0.78	-0.49
Março	-1.56	0.64	-2.94	-0.62	-2.87	-1.32	-0.76	-1.07	0.21	-1.53	-0.41	-1.37	-1.07	-0.74
Abril	-1.41	0.67	-2.94	-0.28	-2.73	-1.27	-0.62	-1.17	0.27	-1.65	-0.40	-1.53	-1.12	-0.78
Maio	-0.87	0.45	-2.20	-0.24	-1.78	-0.80	-0.25	-0.89	0.20	-1.30	-0.23	-1.17	-0.88	-0.58
Junho	-0.38	0.22	-0.94	-0.04	-0.79	-0.32	-0.05	-0.45	0.14	-0.78	0.16	-0.66	-0.46	-0.21
Julho	-0.16	0.21	-0.66	0.16	-0.59	-0.16	0.12	-0.13	0.10	-0.40	0.24	-0.28	-0.14	0.04
Agosto	0.09	0.14	-0.16	0.41	-0.11	0.08	0.28	0.09	0.09	-0.16	0.44	-0.05	0.08	0.24
Setembro	0.18	0.12	-0.08	0.49	-0.03	0.20	0.43	0.17	0.09	-0.07	0.61	0.04	0.16	0.34
Outubro	0.17	0.09	-0.04	0.36	-0.03	0.16	0.32	0.18	0.11	-0.11	0.69	0.02	0.16	0.38
Novembro	0.10	0.11	-0.12	0.32	-0.08	0.12	0.28	0.08	0.12	-0.26	0.66	-0.10	0.07	0.30
Dezembro	-0.13	0.20	-0.75	0.16	-0.56	-0.12	0.15	-0.16	0.14	-0.57	0.48	-0.37	-0.18	0.10

Tabela 19 – Análise de cenários simulados – FC – Escala transformada.

Estatísticas Descritivas FC	Período Observado							Simulações						
	Média	Desvio	Mínimo	Máximo	Q.5%	Mediana	Q.95%	Média	Desvio	Mínimo	Máximo	Q.5%	Mediana	Q.95%
Janeiro	-0.74	0.44	-1.45	0.24	-1.38	-0.72	0.10	-0.98	0.35	-2.44	0.16	-1.59	-0.96	-0.44
Fevereiro	-0.65	0.66	-1.69	1.69	-1.55	-0.67	0.52	-0.97	0.37	-2.41	0.04	-1.61	-0.95	-0.40
Março	-0.89	0.47	-1.71	0.63	-1.37	-0.89	0.12	-1.04	0.35	-2.48	-0.09	-1.62	-1.03	-0.50
Abril	-1.16	0.44	-1.89	-0.21	-1.87	-1.15	-0.39	-1.43	0.35	-2.78	-0.54	-2.04	-1.41	-0.90
Maio	-1.49	0.35	-2.23	-0.63	-1.90	-1.55	-0.73	-1.80	0.30	-2.97	-0.97	-2.32	-1.78	-1.35
Junho	-1.66	0.43	-2.38	-0.14	-2.19	-1.66	-0.90	-1.99	0.39	-3.38	-0.91	-2.70	-1.95	-1.41
Julho	-1.80	0.29	-2.43	-1.05	-2.22	-1.86	-1.17	-2.17	0.31	-3.42	-1.30	-2.72	-2.15	-1.70
Agosto	-1.97	0.31	-2.56	-1.18	-2.34	-2.00	-1.37	-2.25	0.24	-3.39	-1.51	-2.69	-2.23	-1.88
Setembro	-1.79	0.44	-2.66	-0.38	-2.44	-1.78	-1.00	-2.20	0.37	-3.72	-1.26	-2.89	-2.15	-1.67
Outubro	-1.67	0.35	-2.51	-0.95	-2.24	-1.71	-1.00	-1.91	0.37	-3.37	-0.93	-2.57	-1.86	-1.37
Novembro	-1.50	0.30	-2.27	-0.99	-1.94	-1.47	-1.04	-1.67	0.30	-2.86	-0.83	-2.20	-1.64	-1.21
Dezembro	-1.18	0.41	-1.95	-0.14	-1.78	-1.17	-0.49	-1.32	0.33	-2.72	-0.44	-1.93	-1.29	-0.84

Tabela 20 – Análise de cenários simulados – Vz – Escala transformada.






Fig. 89 – FC: QQplot (julho, agosto e setembro) – Variáveis originais.




Fig. 90 – FC: QQplot (julho, agosto e setembro) – Variáveis transformadas.

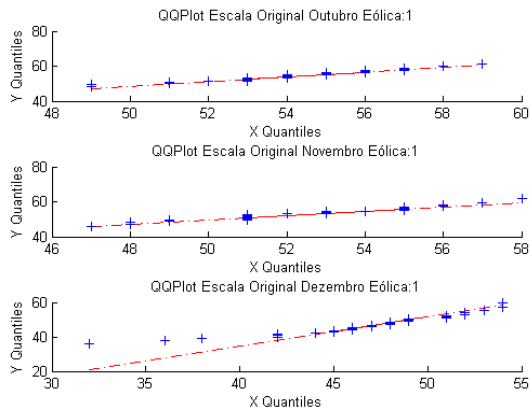


Fig. 91 – FC: QQplot (outubro, novembro e dezembro) – Variáveis originais.

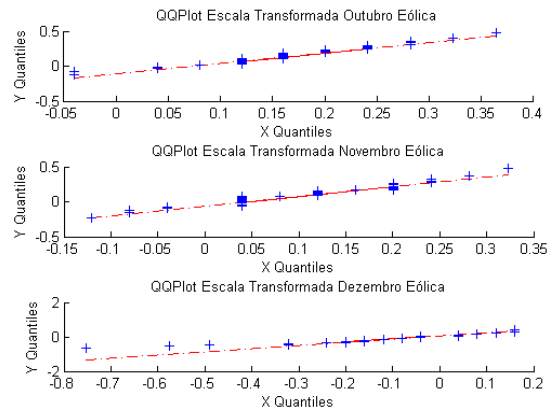


Fig. 92 – FC: QQplot (outubro, novembro e dezembro) – Variáveis transformadas.

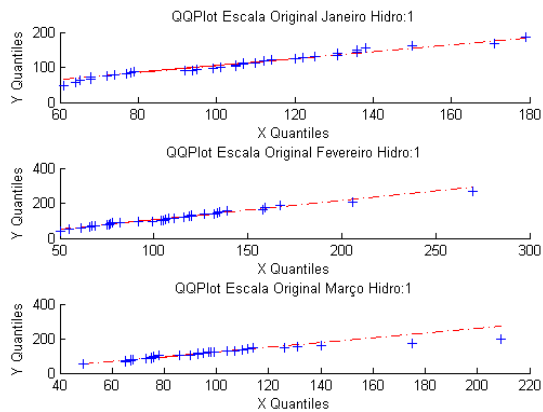


Fig. 93 – Vz: QQplot (janeiro, fevereiro e março) – Variáveis originais.




Fig. 94 – Vz: QQplot (janeiro, fevereiro e março) – Variáveis transformadas.




Fig. 95 – Vz: QQplot (abril, maio e junho) – Variáveis originais.




Fig. 96 – Vz: QQplot (abril, maio e junho) – Variáveis transformadas.

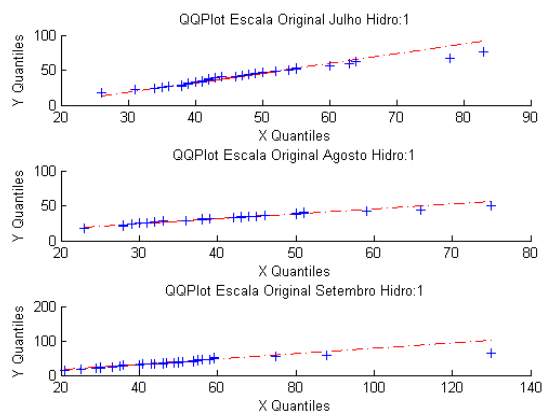


Fig. 97 – Vz: QQplot (julho, agosto e setembro) – Variáveis originais.




Fig. 98 – Vz: QQplot (julho, agosto e setembro) – Variáveis transformadas.




Fig. 99 – Vz: QQplot (outubro, novembro e dezembro) – Variáveis originais.

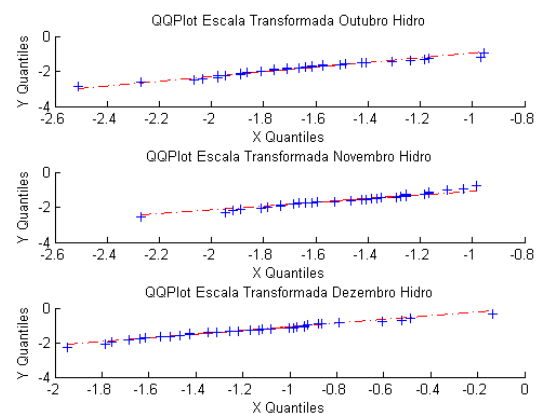


Fig. 100 – Vz: QQplot (outubro, novembro e dezembro) – Variáveis transformadas.

B. Método heurístico

a) Correlações constantes

a.1) Especificação – Fator de Capacidade Eólico (FC')




Fig. 101 – FC' : Histograma dos resíduos.




Fig. 102 – FC' : Comparativo anual dos resíduos.




Fig. 103 – FC' : Correlograma para os resíduos.




Fig. 104 – FC' : Correlograma para os quadrados dos resíduos.

a.2) Especificação – Vazão (Vz')




Fig. 105 – Vz' : Histograma dos resíduos.




Fig. 106 – Vz' : Comparativo anual dos resíduos.




Fig. 107 – Vz' : Correlograma para os resíduos.




Fig. 108 – Vz' : Correlograma para os quadrados dos resíduos.

a.3) Análise do modelo

ANÁLISE DENTRO DA AMOSTRA




Fig. 109 – FC: Previsão dentro da amostra.




Fig. 110 – Vz: Previsão dentro da amostra.

	<i>FC</i>	<i>Vz</i>
R^2	0.7686	0.7549
R^2 ajustado	0.7464	0.7314
P-valor JB dos Resíduos	0.3263	0.0344

Tabela 21 – Medidas de Aderência – Dentro da Amostra.




Fig. 111 – Resíduos X valor predito para *FC*.




Fig. 112 – Resíduos X valor predito para *Vz*.




Fig. 113 – Resíduos padronizados X valor predito para *FC*.




Fig. 114 – Resíduos padronizados X valor predito para *Vz*.

ANÁLISE FORA DA AMOSTRA




Fig. 115 – Desempenho do modelo fora da amostra para FC .




Fig. 116 – Desempenho do modelo fora da amostra para Vz .

	FC	Vz
MAPE	41.21	14.36
MAE	4.63	9.27
RMS	6.71	12.05
MPE	0.36	-0.04
SDPE	0.98	0.17
U	0.08	0.09

Tabela 22 – Medidas de Aderência – Fora da Amostra.

a.4) Correlações constantes

CORRELAÇÃO ENTRE AS SÉRIES DE VAZÃO (Vz) E FATOR DE CAPACIDADE (FC)

	Resíduos FC'	Resíduos Vz'
Resíduos FC'	$r_{1,1}^2 = 1,0000$	$r_{1,2}^2 = -0,1306$
Resíduos Vz'	$r_{2,1}^2 = -0,1306$	$r_{2,2}^2 = 1,0000$

Tabela 23 – Matriz de correlação residual ϵ_t .

SIMULAÇÃO




Fig. 117 – FC : 2000 simulações.




Fig. 118 – Vz : 2000 simulações.




Fig. 119 – FC: Histórico com Intervalo de Confiança de 95% das simulações.




Fig. 120 – Vz: Histórico com Intervalo de Confiança de 95% das simulações.

Estatísticas Descritivas FC	Período Observado							Simulações						
	Média	Desvio	Mínimo	Máximo	Q.5%	Mediana	Q.95%	Média	Desvio	Mínimo	Máximo	Q.5%	Mediana	Q.95%
Janeiro	35.73	7.65	18.00	49.00	19.15	38.00	48.00	38.95	10.55	9.25	75.56	22.53	38.41	57.54
Fevereiro	26.30	8.93	8.00	42.00	8.75	28.00	38.85	31.97	11.62	6.70	76.42	14.98	30.61	53.17
Março	19.06	8.49	5.00	35.00	5.45	21.00	31.85	26.68	13.60	2.53	85.71	8.86	24.17	52.87
Abril	21.64	9.85	5.00	43.00	6.15	22.00	35.00	24.24	11.61	3.68	77.51	9.26	22.03	47.17
Maio	30.30	8.35	10.00	44.00	14.45	31.00	43.85	28.84	7.95	10.90	61.10	17.44	27.91	43.33
Junho	40.85	5.18	28.00	49.00	31.15	42.00	48.70	38.61	6.44	21.08	70.48	28.65	38.25	49.68
Julho	45.97	5.08	34.00	54.00	35.60	46.00	53.00	46.01	5.90	26.62	67.27	36.50	45.90	56.01
Agosto	52.21	3.50	46.00	60.00	47.15	52.00	57.00	51.93	4.10	37.83	65.70	45.01	51.98	58.65
Setembro	54.52	3.02	48.00	62.00	49.30	55.00	60.55	54.39	3.31	43.42	68.60	49.04	54.26	60.06
Outubro	54.15	2.28	49.00	59.00	49.30	54.00	57.85	54.72	3.44	40.60	69.81	49.27	54.57	60.55
Novembro	52.58	2.77	47.00	58.00	48.00	53.00	56.85	52.18	4.10	38.37	68.76	45.47	52.12	58.96
Dezembro	46.73	4.93	32.00	54.00	36.30	47.00	53.85	46.01	5.99	24.57	69.20	36.33	45.90	55.71

Tabela 24 – Análise de cenários simulados – FC – Escala original.

Estatísticas Descritivas FC	Período Observado							Simulações						
	Média	Desvio	Mínimo	Máximo	Q.5%	Mediana	Q.95%	Média	Desvio	Mínimo	Máximo	Q.5%	Mediana	Q.95%
Janeiro	105.64	30.58	61.00	179.00	64.15	105.00	167.85	91.97	33.31	8.65	226.99	43.66	89.23	151.52
Fevereiro	112.09	45.45	50.00	270.00	55.90	108.00	200.15	98.75	46.83	5.94	263.47	31.65	92.64	186.50
Março	95.70	32.66	49.00	209.00	65.00	93.00	169.75	92.28	33.98	13.19	228.63	42.30	89.14	153.62
Abril	79.12	26.11	42.00	143.00	42.75	77.00	129.35	69.06	27.93	11.57	215.51	30.35	65.34	120.89
Maio	60.70	18.27	31.00	111.00	41.60	56.00	104.05	49.76	16.63	10.13	119.52	25.32	48.00	80.24
Junho	53.79	22.46	27.00	149.00	32.15	51.00	92.45	42.61	16.80	6.98	121.97	18.78	40.74	72.86
Julho	46.73	12.36	26.00	83.00	31.45	43.00	75.90	35.93	12.86	7.27	100.69	18.07	34.25	59.50
Agosto	40.30	11.55	23.00	75.00	28.00	38.00	64.95	31.59	8.60	9.10	70.21	18.67	30.95	46.90
Setembro	48.45	20.16	21.00	130.00	25.60	46.00	86.05	33.32	12.03	4.44	87.59	15.30	32.20	54.87
Outubro	52.30	15.32	24.00	89.00	30.90	49.00	86.20	42.85	15.40	8.06	106.42	20.30	41.28	71.09
Novembro	59.85	13.98	30.00	87.00	40.15	60.00	83.40	52.13	17.76	11.50	128.85	26.51	50.35	84.82
Dezembro	77.70	24.64	40.00	149.00	46.15	76.00	121.55	70.67	24.02	11.76	168.29	35.52	68.21	113.72


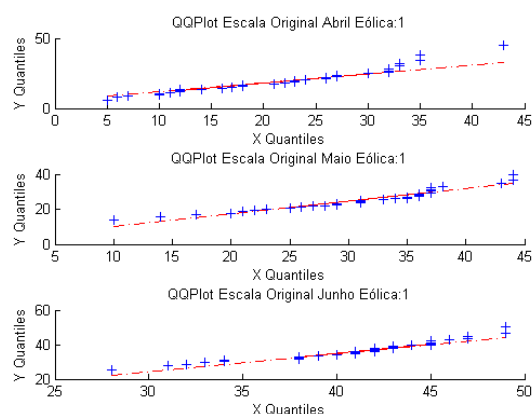
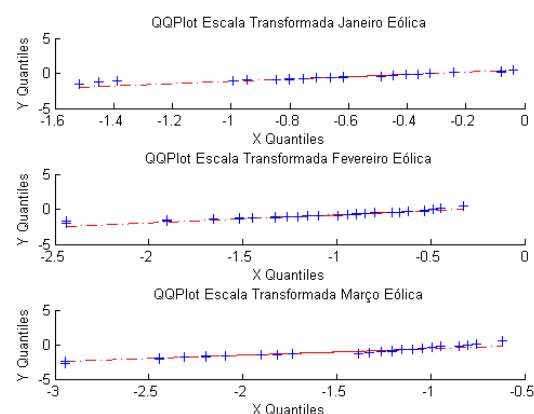

Tabela 25 – Análise de cenários simulados – Vz – Escala original.

Estatísticas Descritivas FC	Período Observado							Simulações						
	Média	Desvio	Mínimo	Máximo	Q.5%	Mediana	Q.95%	Média	Desvio	Mínimo	Máximo	Q.5%	Mediana	Q.95%
Janeiro	-0.61	0.36	-1.52	-0.04	-1.44	-0.49	-0.08	-0.47	0.46	-2.28	1.13	-1.24	-0.47	0.30
Fevereiro	-1.10	0.53	-2.44	-0.32	-2.36	-0.94	-0.45	-0.81	0.56	-2.63	1.18	-1.74	-0.82	0.13
Março	-1.56	0.64	-2.94	-0.62	-2.87	-1.32	-0.76	-1.13	0.75	-3.65	1.79	-2.33	-1.14	0.11
Abril	-1.41	0.67	-2.94	-0.28	-2.73	-1.27	-0.62	-1.24	0.65	-3.26	1.24	-2.28	-1.26	-0.11
Maio	-0.87	0.45	-2.20	-0.24	-1.78	-0.80	-0.25	-0.93	0.39	-2.10	0.45	-1.55	-0.95	-0.27
Junho	-0.38	0.22	-0.94	-0.04	-0.79	-0.32	-0.05	-0.47	0.27	-1.32	0.87	-0.91	-0.48	-0.01
Julho	-0.16	0.21	-0.66	0.16	-0.59	-0.16	0.12	-0.16	0.24	-1.01	0.72	-0.55	-0.16	0.24
Agosto	0.09	0.14	-0.16	0.41	-0.11	0.08	0.28	0.08	0.17	-0.50	0.65	-0.20	0.08	0.35
Setembro	0.18	0.12	-0.08	0.49	-0.03	0.20	0.43	0.18	0.13	-0.26	0.78	-0.04	0.17	0.41
Outubro	0.17	0.09	-0.04	0.36	-0.03	0.16	0.32	0.19	0.14	-0.38	0.84	-0.03	0.18	0.43
Novembro	0.10	0.11	-0.12	0.32	-0.08	0.12	0.28	0.09	0.17	-0.47	0.79	-0.18	0.08	0.36
Dezembro	-0.13	0.20	-0.75	0.16	-0.56	-0.12	0.15	-0.16	0.24	-1.12	0.81	-0.56	-0.16	0.23

Tabela 26 – Análise de cenários simulados – FC – Escala transformada.

Estatísticas Descritivas FC	Período Observado							Simulações						
	Média	Desvio	Mínimo	Máximo	Q.5%	Mediana	Q.95%	Média	Desvio	Mínimo	Máximo	Q.5%	Mediana	Q.95%
Janeiro	-0.74	0.44	-1.45	0.24	-1.38	-0.72	0.10	-0.97	0.54	-3.58	0.89	-1.85	-0.95	-0.11
Fevereiro	-0.65	0.66	-1.69	1.69	-1.55	-0.67	0.52	-0.91	0.76	-3.97	1.54	-2.21	-0.90	0.33
Março	-0.89	0.47	-1.71	0.63	-1.37	-0.89	0.12	-0.96	0.55	-3.15	0.92	-1.88	-0.95	-0.08
Abril	-1.16	0.44	-1.89	-0.21	-1.87	-1.15	-0.39	-1.37	0.54	-3.28	0.72	-2.26	-1.36	-0.50
Maio	-1.49	0.35	-2.23	-0.63	-1.90	-1.55	-0.73	-1.75	0.41	-3.42	-0.52	-2.45	-1.73	-1.09
Junho	-1.66	0.43	-2.38	-0.14	-2.19	-1.66	-0.90	-1.95	0.48	-3.80	-0.48	-2.77	-1.92	-1.22
Julho	-1.80	0.29	-2.43	-1.05	-2.22	-1.86	-1.17	-2.13	0.41	-3.76	-0.78	-2.82	-2.12	-1.48
Agosto	-1.97	0.31	-2.56	-1.18	-2.34	-2.00	-1.37	-2.25	0.31	-3.53	-1.27	-2.78	-2.23	-1.76
Setembro	-1.79	0.44	-2.66	-0.38	-2.44	-1.78	-1.00	-2.22	0.43	-4.26	-0.98	-2.99	-2.19	-1.58
Outubro	-1.67	0.35	-2.51	-0.95	-2.24	-1.71	-1.00	-1.93	0.44	-3.66	-0.70	-2.69	-1.91	-1.25
Novembro	-1.50	0.30	-2.27	-0.99	-1.94	-1.47	-1.04	-1.69	0.42	-3.29	-0.39	-2.40	-1.68	-1.02
Dezembro	-1.18	0.41	-1.95	-0.14	-1.78	-1.17	-0.49	-1.32	0.46	-3.27	0.10	-2.08	-1.31	-0.60

Tabela 27 – Análise de cenários simulados – Vz – Escala transformada.






Fig. 125 – FC: QQplot (julho, agosto e setembro) – Variáveis originais.




Fig. 126 – FC: QQplot (julho, agosto e setembro) – Variáveis transformadas.

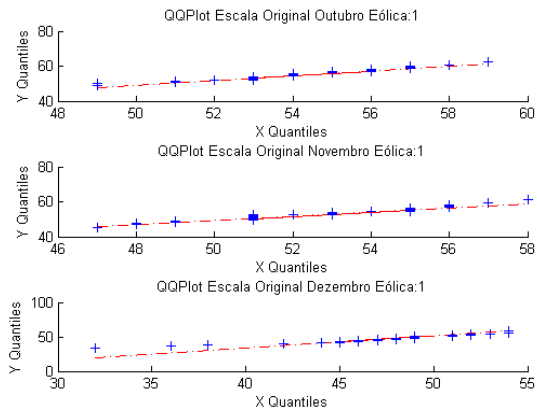


Fig. 127 – FC: QQplot (outubro, novembro e dezembro) – Variáveis originais.

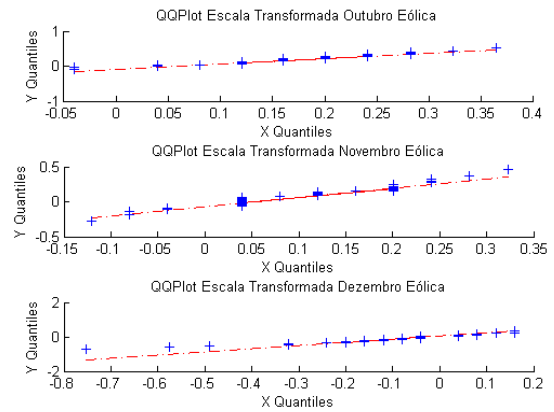


Fig. 128 – FC: QQplot (outubro, novembro e dezembro) – Variáveis transformadas.

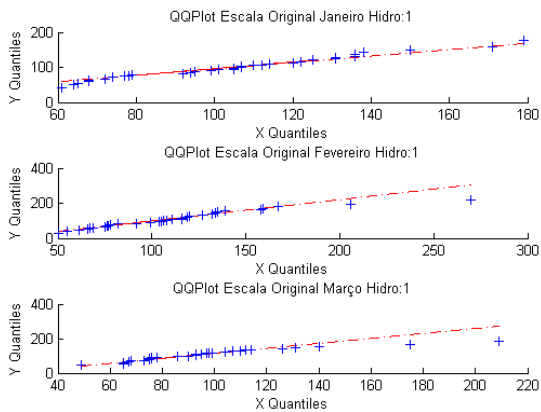


Fig. 129 – Vz: QQplot (janeiro, fevereiro e março) – Variáveis originais.




Fig. 130 – Vz: QQplot (janeiro, fevereiro e março) – Variáveis transformadas.




Fig. 131 – Vz: QQplot (abril, maio e junho) – Variáveis originais.

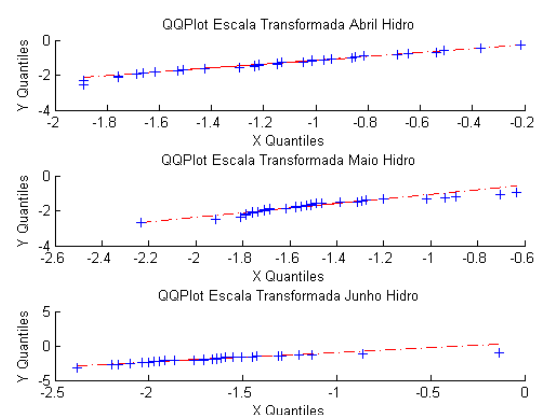


Fig. 132 – Vz: QQplot (abril, maio e junho) – Variáveis transformadas.




Fig. 133 – Vz: QQplot (julho, agosto e setembro) – Variáveis originais.




Fig. 134 – Vz: QQplot (julho, agosto e setembro) – Variáveis transformadas.

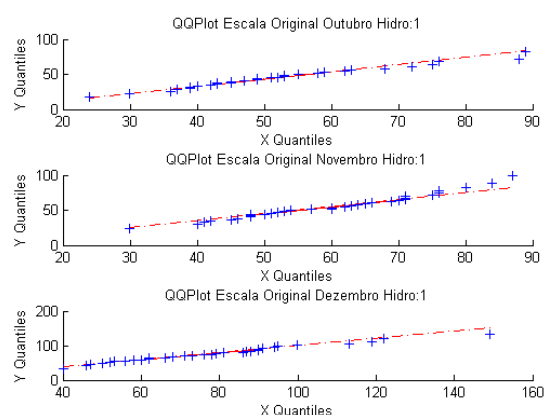


Fig. 135 – Vz: QQplot (outubro, novembro e dezembro) – Variáveis originais.




Fig. 136 – Vz: QQplot (outubro, novembro e dezembro) – Variáveis transformadas.

b) Correlações mês a mês

CORRELAÇÃO ENTRE AS SÉRIES DE VAZÃO (V_z) E FATOR DE CAPACIDADE (FC)

MÊS	σ_1	σ_2	CORRELAÇÃO
1	0.43	0.38	-50.00%
2	0.49	0.64	-35.46%
3	0.66	0.26	-33.94%
4	0.50	0.33	1.42%
5	0.19	0.09	-6.85%
6	0.17	0.17	-9.82%
7	0.18	0.20	-22.45%
8	0.11	0.13	-5.08%
9	0.07	0.18	-5.50%
10	0.07	0.21	13.34%
11	0.09	0.26	3.14%
12	0.18	0.26	-3.30%

Tabela 28 – Desvio padrão e correlação mensal das séries.

SIMULAÇÃO




Fig. 137 – FC : 2000 simulações.




Fig. 138 – V_z : 2000 simulações.




Fig. 139 – FC: Histórico com Intervalo de Confiança de 95% das simulações.




Fig. 140 – Vz: Histórico com Intervalo de Confiança de 95% das simulações.

Estatísticas Descritivas FC	Período Observado							Simulações						
	Média	Desvio	Mínimo	Máximo	Q.5%	Mediana	Q.95%	Média	Desvio	Mínimo	Máximo	Q.5%	Mediana	Q.95%
Janeiro	35.73	7.65	18.00	49.00	19.15	38.00	48.00	38.66	10.91	12.00	78.37	22.03	37.81	58.12
Fevereiro	26.30	8.93	8.00	42.00	8.75	28.00	38.85	31.94	11.88	5.48	78.67	14.89	30.66	53.49
Março	19.06	8.49	5.00	35.00	5.45	21.00	31.85	26.77	13.73	2.23	83.26	8.47	24.65	52.28
Abril	21.64	9.85	5.00	43.00	6.15	22.00	35.00	24.61	12.07	2.37	73.16	8.90	22.37	47.84
Maio	30.30	8.35	10.00	44.00	14.45	31.00	43.85	29.04	8.34	10.41	69.71	16.96	28.21	44.20
Junho	40.85	5.18	28.00	49.00	31.15	42.00	48.70	38.61	6.62	18.47	69.81	28.31	38.34	49.97
Julho	45.97	5.08	34.00	54.00	35.60	46.00	53.00	46.21	6.05	26.93	67.33	36.38	46.15	56.39
Agosto	52.21	3.50	46.00	60.00	47.15	52.00	57.00	51.89	4.10	37.79	65.07	44.78	52.00	58.42
Setembro	54.52	3.02	48.00	62.00	49.30	55.00	60.55	54.38	3.34	41.12	67.48	48.97	54.32	60.05
Outubro	54.15	2.28	49.00	59.00	49.30	54.00	57.85	54.71	3.40	44.62	66.62	49.24	54.60	60.45
Novembro	52.58	2.77	47.00	58.00	48.00	53.00	56.85	52.22	3.97	35.32	67.31	45.78	52.13	59.01
Dezembro	46.73	4.93	32.00	54.00	36.30	47.00	53.85	46.10	5.97	26.10	68.74	36.71	45.98	56.47

Tabela 29 – Análise de cenários simulados – FC – Escala original.

Estatísticas Descritivas FC	Período Observado							Simulações						
	Média	Desvio	Mínimo	Máximo	Q.5%	Mediana	Q.95%	Média	Desvio	Mínimo	Máximo	Q.5%	Mediana	Q.95%
Janeiro	105.64	30.58	61.00	179.00	64.15	105.00	167.85	93.13	33.91	16.31	243.48	43.81	89.70	154.20
Fevereiro	112.09	45.45	50.00	270.00	55.90	108.00	200.15	98.86	47.23	4.57	270.40	32.91	93.22	188.36
Março	95.70	32.66	49.00	209.00	65.00	93.00	169.75	92.79	34.09	11.21	228.68	42.09	89.00	155.40
Abril	79.12	26.11	42.00	143.00	42.75	77.00	129.35	70.10	28.33	8.06	211.82	30.20	67.09	122.69
Maio	60.70	18.27	31.00	111.00	41.60	56.00	104.05	50.15	16.56	11.92	117.73	26.15	48.47	79.38
Junho	53.79	22.46	27.00	149.00	32.15	51.00	92.45	42.60	16.39	7.76	109.42	18.85	40.68	72.26
Julho	46.73	12.36	26.00	83.00	31.45	43.00	75.90	36.14	12.77	7.16	97.74	18.14	34.66	59.37
Agosto	40.30	11.55	23.00	75.00	28.00	38.00	64.95	31.45	8.52	10.50	79.45	18.97	30.53	46.51
Setembro	48.45	20.16	21.00	130.00	25.60	46.00	86.05	33.51	12.19	4.58	98.88	15.45	32.27	55.45
Outubro	52.30	15.32	24.00	89.00	30.90	49.00	86.20	42.72	15.26	7.78	120.24	20.81	41.35	69.78
Novembro	59.85	13.98	30.00	87.00	40.15	60.00	83.40	52.00	17.68	9.72	149.03	26.89	50.03	84.30
Dezembro	77.70	24.64	40.00	149.00	46.15	76.00	121.55	70.64	23.90	14.55	191.54	35.01	68.12	113.48

Tabela 30 – Análise de cenários simulados – Vz – Escala original.

Estatísticas Descritivas FC	Período Observado							Simulações						
	Média	Desvio	Mínimo	Máximo	Q.5%	Mediana	Q.95%	Média	Desvio	Mínimo	Máximo	Q.5%	Mediana	Q.95%
Janeiro	-0.61	0.36	-1.52	-0.04	-1.44	-0.49	-0.08	-0.49	0.48	-1.99	1.29	-1.26	-0.50	0.33
Fevereiro	-1.10	0.53	-2.44	-0.32	-2.36	-0.94	-0.45	-0.81	0.58	-2.85	1.31	-1.74	-0.82	0.14
Março	-1.56	0.64	-2.94	-0.62	-2.87	-1.32	-0.76	-1.13	0.76	-3.78	1.60	-2.38	-1.12	0.09
Abril	-1.41	0.67	-2.94	-0.28	-2.73	-1.27	-0.62	-1.23	0.68	-3.72	1.00	-2.33	-1.24	-0.09
Maio	-0.87	0.45	-2.20	-0.24	-1.78	-0.80	-0.25	-0.93	0.41	-2.15	0.83	-1.59	-0.93	-0.23
Junho	-0.38	0.22	-0.94	-0.04	-0.79	-0.32	-0.05	-0.47	0.28	-1.49	0.84	-0.93	-0.48	0.00
Julho	-0.16	0.21	-0.66	0.16	-0.59	-0.16	0.12	-0.15	0.25	-1.00	0.72	-0.56	-0.15	0.26
Agosto	0.09	0.14	-0.16	0.41	-0.11	0.08	0.28	0.08	0.17	-0.50	0.62	-0.21	0.08	0.34
Setembro	0.18	0.12	-0.08	0.49	-0.03	0.20	0.43	0.18	0.14	-0.36	0.73	-0.04	0.17	0.41
Outubro	0.17	0.09	-0.04	0.36	-0.03	0.16	0.32	0.19	0.14	-0.22	0.69	-0.03	0.18	0.42
Novembro	0.10	0.11	-0.12	0.32	-0.08	0.12	0.28	0.09	0.16	-0.60	0.72	-0.17	0.09	0.36
Dezembro	-0.13	0.20	-0.75	0.16	-0.56	-0.12	0.15	-0.16	0.24	-1.04	0.79	-0.54	-0.16	0.26

Tabela 31 – Análise de cenários simulados – FC – Escala transformada.

Estatísticas Descritivas FC	Período Observado							Simulações						
	Média	Desvio	Mínimo	Máximo	Q.5%	Mediana	Q.95%	Média	Desvio	Mínimo	Máximo	Q.5%	Mediana	Q.95%
Janeiro	-0.74	0.44	-1.45	0.24	-1.38	-0.72	0.10	-0.95	0.54	-2.92	1.16	-1.84	-0.94	-0.07
Fevereiro	-0.65	0.66	-1.69	1.69	-1.55	-0.67	0.52	-0.91	0.77	-4.24	1.70	-2.17	-0.89	0.36
Março	-0.89	0.47	-1.71	0.63	-1.37	-0.89	0.12	-0.96	0.55	-3.32	0.92	-1.89	-0.95	-0.06
Abril	-1.16	0.44	-1.89	-0.21	-1.87	-1.15	-0.39	-1.35	0.54	-3.66	0.67	-2.26	-1.33	-0.48
Maio	-1.49	0.35	-2.23	-0.63	-1.90	-1.55	-0.73	-1.74	0.40	-3.25	-0.54	-2.42	-1.72	-1.11
Junho	-1.66	0.43	-2.38	-0.14	-2.19	-1.66	-0.90	-1.95	0.47	-3.69	-0.65	-2.77	-1.93	-1.23
Julho	-1.80	0.29	-2.43	-1.05	-2.22	-1.86	-1.17	-2.12	0.41	-3.78	-0.82	-2.81	-2.11	-1.48
Agosto	-1.97	0.31	-2.56	-1.18	-2.34	-2.00	-1.37	-2.25	0.30	-3.38	-1.11	-2.76	-2.25	-1.77
Setembro	-1.79	0.44	-2.66	-0.38	-2.44	-1.78	-1.00	-2.22	0.43	-4.23	-0.80	-2.98	-2.19	-1.56
Outubro	-1.67	0.35	-2.51	-0.95	-2.24	-1.71	-1.00	-1.94	0.43	-3.69	-0.51	-2.67	-1.91	-1.28
Novembro	-1.50	0.30	-2.27	-0.99	-1.94	-1.47	-1.04	-1.70	0.42	-3.46	-0.14	-2.39	-1.69	-1.03
Dezembro	-1.18	0.41	-1.95	-0.14	-1.78	-1.17	-0.49	-1.32	0.45	-3.04	0.40	-2.10	-1.31	-0.60

Tabela 32 – Análise de cenários simulados – Vz – Escala transformada.

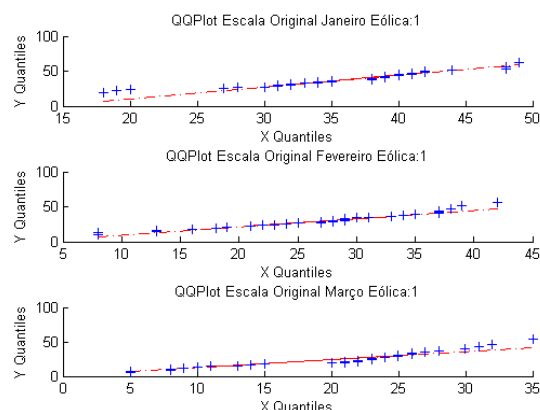


Fig. 141 – FC: QQplot (janeiro, fevereiro e março) – Variáveis originais.




Fig. 142 – FC: QQplot (janeiro, fevereiro e março) – Variáveis transformadas.

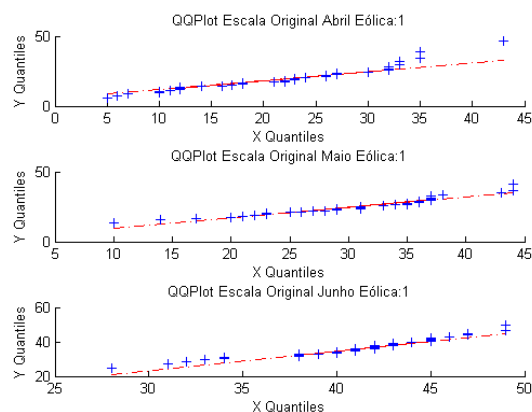


Fig. 143 – FC: QQplot (abril, maio e junho) – Variáveis originais.




Fig. 144 – FC: QQplot (abril, maio e junho) – Variáveis transformadas.




Fig. 145 – FC: QQplot (julho, agosto e setembro) – Variáveis originais.




Fig. 146 – FC: QQplot (julho, agosto e setembro) – Variáveis transformadas.

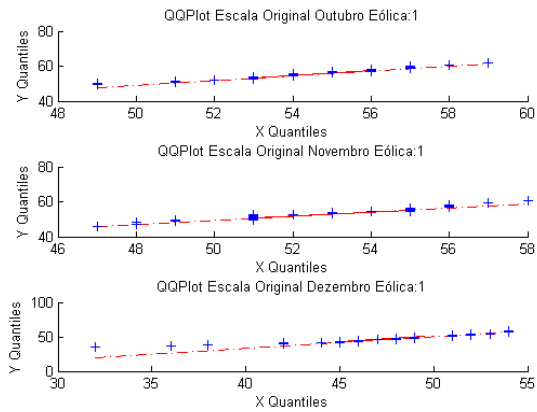


Fig. 147 – FC: QQplot (outubro, novembro e dezembro) – Variáveis originais.

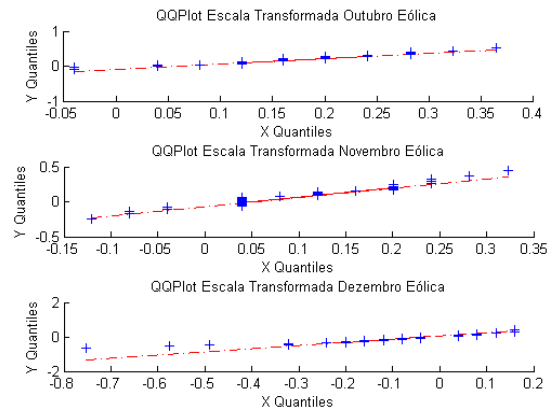


Fig. 148 – FC: QQplot (outubro, novembro e dezembro) – Variáveis transformadas.

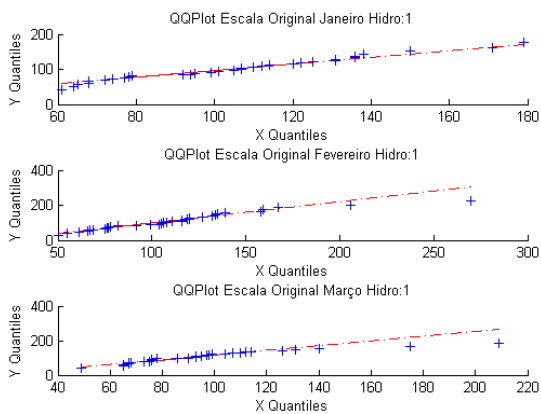


Fig. 149 – Vz: QQplot (janeiro, fevereiro e março) – Variáveis originais.




Fig. 150 – Vz: QQplot (janeiro, fevereiro e março) – Variáveis transformadas.




Fig. 151 – Vz: QQplot (abril, maio e junho) – Variáveis originais.




Fig. 152 – Vz: QQplot (abril, maio e junho) – Variáveis transformadas.




Fig. 153 – Vz: QQplot (julho, agosto e setembro) – Variáveis originais.




Fig. 154 – Vz: QQplot (julho, agosto e setembro) – Variáveis transformadas.




Fig. 155 – Vz: QQplot (outubro, novembro e dezembro) – Variáveis originais

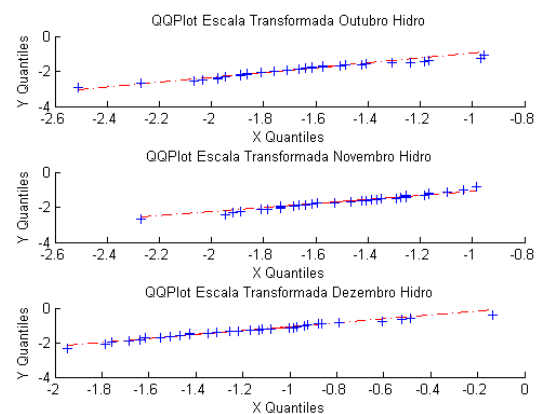


Fig. 156 – Vz: QQplot (outubro, novembro e dezembro) – Variáveis transformadas

ANEXO 4: RESULTADOS DO MODELO V&V PARA OS ESTUDOS DE CASO 2 E 3**A. Estudo de caso 2**

COEFICIENTE	VALOR
Intercepto	-0.068
ϕ_1^{vt}	0.431
ϕ_2^{vt}	0.035
ϕ_3^{vt}	0.035
ϕ_4^{vt}	-0.049
ϕ_5^{vt}	0.069
ϕ_6^{vt}	-0.038
ϕ_7^{vt}	0.032
ϕ_8^{vt}	0.007
ϕ_9^{vt}	0.006
ϕ_{10}^{vt}	0.012
ϕ_{11}^{vt}	0.112
ϕ_{12}^{vt}	-0.050
β^{jan}	-0.358
β^{fev}	-0.602
β^{mar}	-0.855
β^{abr}	-0.565
β^{mai}	-0.104
β^{jun}	0.131
β^{jul}	0.099
β^{ago}	0.269
β^{set}	0.250
β^{out}	0.201
β^{nov}	0.163

Tabela 33 – Coeficientes estimados para Estudo de caso 2.

B. Estudo de caso 3

COEFICIENTE	VALOR
Intercepto	1.16
ϕ_1^{vt}	0.44
ϕ_2^{vt}	0.00
ϕ_3^{vt}	0.04
ϕ_4^{vt}	-0.04
ϕ_5^{vt}	0.06
ϕ_6^{vt}	-0.01
ϕ_7^{vt}	0.01
ϕ_8^{vt}	-0.02
ϕ_9^{vt}	-0.01
ϕ_{10}^{vt}	-0.01
ϕ_{11}^{vt}	0.20
ϕ_{12}^{vt}	0.10
ϕ_1^{ENA-SE}	-0.11
ϕ_2^{ENA-SE}	0.08
ϕ_1^{ENA-S}	-0.01
ϕ_2^{ENA-S}	0.01
ϕ_1^{ENA-NE}	0.13
ϕ_2^{ENA-NE}	-0.09
ϕ_1^{ENA-N}	-0.30
ϕ_2^{ENA-N}	0.16

Tabela 34 – Coeficientes estimados para Estudo de caso 3.