

**P&D UTE Norte Fluminense\ PUC-Rio**

---

**Relatório 5: Aumento da competitividade na  
comercialização de contratos de energia  
proveniente de fontes renováveis no ACL**

Prof. Alexandre Street, *Coordenador*; Prof. Delberis A. Lima, *Gerente*; Prof. Álvaro Veiga;  
Alexandre Moreira da Silva; Bruno Fânzeres; e Lucas Freire

Relatório quadrimestral realizado para UTE NORTE FLUMINENSE S.A.

Projeto P&D ANEEL PD-0678-0310/2010



## SUMÁRIO

<b>I. Resumo</b>	4
<b>II. Introdução</b>	4
<b>III. Modelo estatístico da ferramenta de Vento &amp; Vazão</b>	7
A. Formulação do modelo VARX para V&V	8
B. Estimação dos parâmetros por máxima verossimilhança condicional	9
C. Estimação heurística rápida por máxima verossimilhança condicional	11
D. Simulação de cenários de vento e vazão coerentes com o PLD	11
E. Estudos de caso	13
<b>IV. Modelo matemático da ferramenta de contratação</b>	21
A. Tipos de contrato de comercialização de energia	22
B. Critérios de risco	25
C. O modelo de otimização	28
<b>V. Estudos de caso de contratação ótima</b>	28
A. Motivação	28
B. Estudos de caso	30
<b>VI. Conclusão</b>	36
<b>Referências Bibliográficas</b>	37
<b>ANEXO 1: Transformações das variáveis dependentes Vz e FC</b>	38
<b>ANEXO 2: Produto de Kronecker</b>	39
<b>ANEXO 3: Resultados do modelo V&amp;V para o estudo de caso 1</b>	40
<b>ANEXO 4: Resultados do modelo V&amp;V para os estudos de caso 2, 3 e 4</b>	69

## I. RESUMO

O presente projeto tem como objetivo desenvolver uma plataforma de comercialização de energia elétrica capaz de aumentar a competitividade das fontes de energia no ambiente de contratação livre (ACL). A plataforma de comercialização está sendo desenvolvida a partir de duas ferramentas complementares, para uma análise integral da comercialização de energia com fontes renováveis e/ou convencionais. São elas: a ferramenta estatística de simulação de cenários de recursos renováveis, chamada V&V (Vento & Vazão), e a ferramenta de contratação de energia.

A ferramenta V&V simula cenários de fator de capacidade de parques eólicos (FC) e a vazão de pequenas centrais hidrelétricas (Vz), devidamente ajustados aos cenários de preço de liquidação das diferenças (PLD). Essa ferramenta é a principal inovação do projeto, visto que a correlação entre essas variáveis (vento, vazão e PLD) normalmente é ignorada nos modelos tradicionais de comercialização de energia.

Quanto à ferramenta de comercialização de energia, ela permite a simulação e/ou otimização da contratação de energia com diferentes fontes. Essa ferramenta pode lançar mão dos cenários simulados da ferramenta V&V, estabelecendo assim um fluxo de informações completo para a utilização da plataforma.

Devido à complexidade dos modelos envolvidos no projeto, a plataforma está sendo desenvolvida com uma interface amigável para diferentes tipos de análises. Dentre as principais análises que poderão ser executadas, é possível destacar:

- (i) simulação de cenários de recursos renováveis ajustados aos cenários futuros de preço de liquidação das diferenças (PLD);
- (ii) simulação e/ou otimização de contratação de energia com fontes de energia renováveis e/ou convencionais; e
- (iii) simulação e/ou otimização de comercialização de energia considerando diferentes modalidades de contrato, diferentes perfis de risco e diferentes tipos de fonte.

Neste relatório, detalhamos as ferramentas desenvolvidas no projeto com seus respectivos modelos de estimativa e simulação de recursos renováveis, bem como os modelos usados para comercialização de energia. Alguns resultados que ilustram a importância das ferramentas desenvolvidas também estão presentes neste documento.

**Palavras-chave** — Comercialização de energia elétrica; simulação de cenários de recursos renováveis correlacionados com o PLD; otimização de contratação de energia; análise de risco.

## II. INTRODUÇÃO

Em 2004, o governo brasileiro estabeleceu modificações importantes no modelo institucional do setor elétrico buscando aumentar a segurança no suprimento de energia, fomentar a modicidade tarifária e promover a universalização do atendimento aos consumidores. As bases do novo modelo consistem no planejamento de longo prazo, na coexistência dos ambientes de contratação regulada (ACR) e livre (ACL) e na premissa de que os consumidores devem ter 100% da energia demandada lastreada por capacidade assegurada de suprimento [1]. Para implementar as novas medidas, buscou-se incentivar investimentos em geração com a antecedência necessária para que o crescimento da carga fosse lastreado com nova capacidade de geração. Esse processo foi implementado através de leilões que licitam contratos de longo prazo (15 anos para termelétricas, 20 para eólicas e 30 para hidros) com 3 e 5 anos de antecedência – A-3 e A-5, respectivamente. Tais leilões proporcionam uma remuneração mínima de longo prazo a preços definidos através de um processo licitatório. Nesse contexto, cria-se a segurança necessária para que órgãos financiadores aportem recursos a taxas de juros mais baixas, atraiendo investidores privados para participar na expansão do parque gerador [2].

No ACR, os leilões de energia, promovidos a partir de 2004, resultaram em um grande impulso no setor elétrico como um todo. Paralelamente, para incentivar o uso de fontes alternativas de energia, foi instituído, também em 2004, o Programa de Incentivos a Fontes Alternativas (PROINFA) [3], em que as principais fontes alternativas de energia no Brasil (eólica, pequenas centrais hidrelétricas e biomassa) competiram em leilões exclusivos. Inicialmente, o preço médio da energia foi de 298,00 R\$/MWh. Nos leilões seguintes, observou-se uma queda significativa nos preços, chegando a 99,6 R\$/MW no leilão de reserva de 2011.

As vantagens da comercialização de fontes alternativas no ACR estão relacionadas principalmente aos contratos de longo prazo, que permitem viabilizar novos investimentos em geração com a segurança de fluxos de caixa previsíveis no médio e longo prazo. Entretanto, as sucessivas quedas no preço da energia nos últimos leilões têm obrigado investidores a buscar novas alternativas de contratação.

Comparado ao ACR, o ACL sempre foi visto como um ambiente de contratação de alto risco em função da baixa previsibilidade dos recursos renováveis, dos prazos de vigência dos contratos de energia<sup>1</sup> e da incerteza no PLD (Preço de Liquidação das Diferenças), presente na maioria dos contratos para liquidação da diferença entre a energia gerada e a contratada. Com as sucessivas quedas de preços dos últimos leilões, o ACL vem ganhando importância. Entretanto, os desafios associados à baixa previsibilidade dos recursos renováveis e do PLD ainda são os principais obstáculos para a expansão das fontes de energia.

O objetivo central deste projeto é desenvolver um modelo de simulação da geração de usinas renováveis capaz de produzir cenários consistentes (correlacionados) com os cenários de PLD de um modelo de despacho hidrotérmico, no caso brasileiro, o NEWAVE. O nosso modelo será implementado em uma ferramenta computacional, que de agora em diante chamaremos de ferramenta de vento e vazão ou, simplesmente, ferramenta V&V. Com essa ferramenta, podemos criar diversas aplicações para aumentar a competitividade das fontes de energia renováveis no ACL. Neste projeto, apresentamos algumas ideias de como tirar proveito dessa inovação através dos estudos de caso. Para evidenciar o potencial e valor da inovação criada a partir da ferramenta V&V, recorremos a uma plataforma de comercialização de energia também desenvolvida ao longo deste projeto. Essa plataforma permite extrair valor dos cenários de geração das centrais de energia renovável casados com o PLD através de inúmeras aplicações de comercialização que podem ser modeladas. Para isso, foi desenvolvido um modelo de otimização estocástico a fim de encontrar o *mix* de contratos que melhor se beneficia do efeito portfólio, permitindo maximizar o retorno e mitigar o risco associado à comercialização das fontes. Os fatores de risco no modelo proposto são: (i) a produção das fontes renováveis durante o período de vigência dos contratos e (ii) os PLDs futuros para os respectivos submercados.

Com o intuito de alcançar o principal objetivo deste projeto, criamos uma metodologia para a geração de cenários da produção de fontes renováveis baseada em um modelo do tipo VARX (*Vector AutoRegression with eXternal variables*, isto é, autoregressivo vetorial com variáveis externas) para eólicas e PCHs, utilizadas no projeto. Neste caso, a energia produzida pelas fontes renováveis é explicada em parte pela ENA (Energia Natural Afluente) de cada submercado, obtidas pelo NEWAVE. O desenvolvimento da metodologia de geração de cenários se dá em duas etapas: (i) estimação dos coeficientes do modelo e (ii) simulação de cenários de geração. Na etapa de estimação dos coeficientes, o modelo é ajustado utilizando as ENAs históricas produzidas pelo NEWAVE. Na etapa de simulação de cenários de geração, a metodologia lança mão dos cenários coerentes de ENAs e PLDs produzidos pelo NEWAVE a fim de gerar cenários futuros de fator de capacidade, para geração eólica, e vazão, para pequenas centrais hidrelétricas.

A produção de diferentes fontes renováveis pode apresentar um efeito de complementariedade anual, o que pode ser aproveitado a fim de gerar um benefício para o conjunto de fontes e, consequentemente, para cada uma delas. Para ilustrar esse efeito, na Fig. 1 apresentamos os perfis típicos de geração (nos quantis de 5% e 95% para eólicas e PCHs, e o perfil determinístico da Biomassa) das principais fontes renováveis no Brasil. Neste caso, é possível observar a alternância dos picos de geração da PCH e da usina eólica. No âmbito do projeto proposto, o modelo detectou uma correlação negativa nos desvios com relação à média da produção de uma PCH no Sudeste e uma eólica no Nordeste.

---

1. Os contratos de energia no ACL em geral são de poucos anos (5 anos no máximo), enquanto no ACR esses contratos podem chegar a 30 anos.

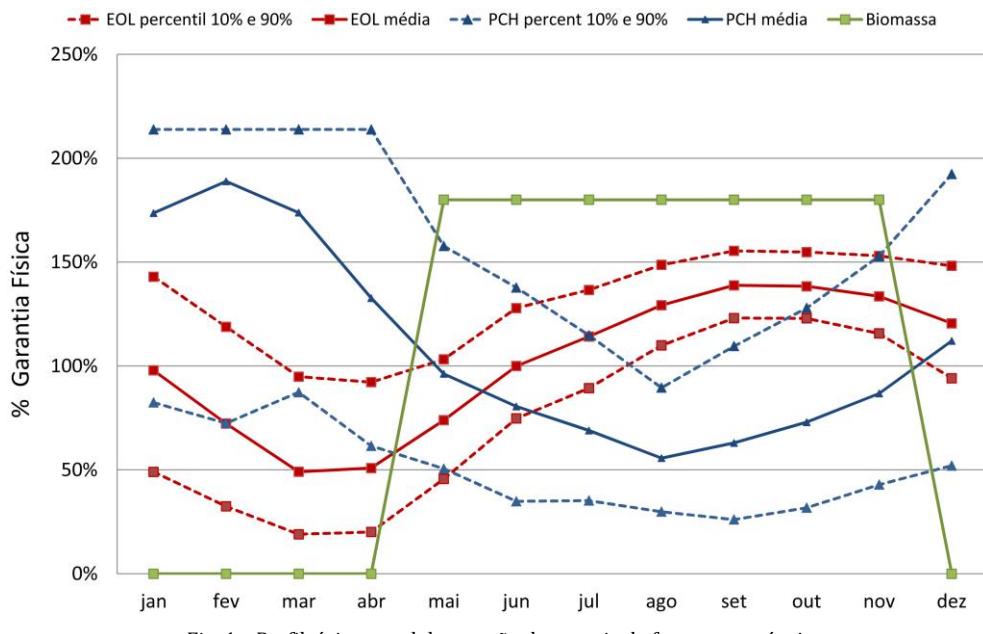


Fig. 1 – Perfil típico anual de geração de energia de fontes renováveis

A Fig. 2 é uma representação esquemática da estrutura da metodologia de geração de cenários. O modelo VARX produz cenários de vento e de vazão a partir dos cenários de ENAs gerados pelo NEWAVE. O mesmo NEWAVE produz uma série de PLDs, oriundos do processo de despacho hidrotérmico, para cada série de ENAs.

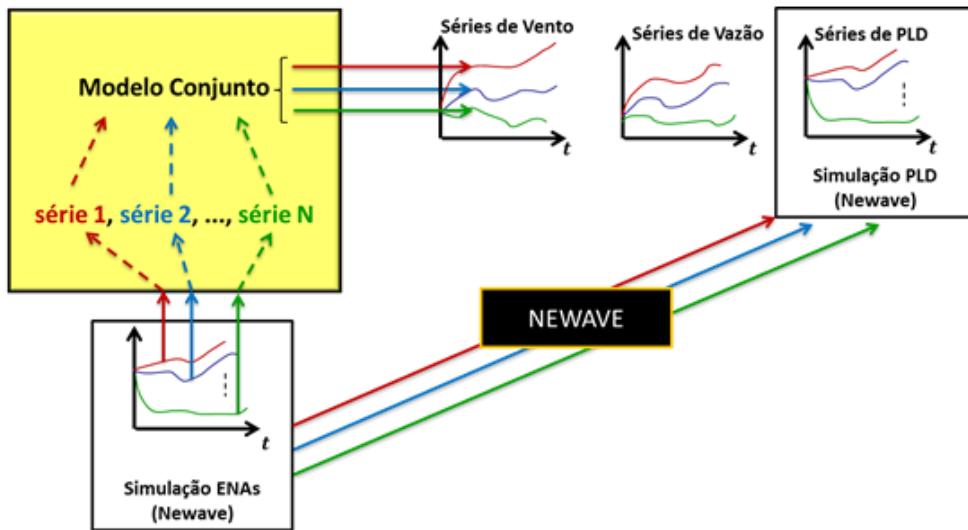


Fig. 2 – Geração de cenários com o modelo V&amp;V

Os modelos desenvolvidos podem ser utilizados em sequência como uma plataforma de apoio à decisão: ferramenta V&V e ferramenta de comercialização de energia. Na figura abaixo, apresentamos os principais elementos que compõe a plataforma de comercialização.

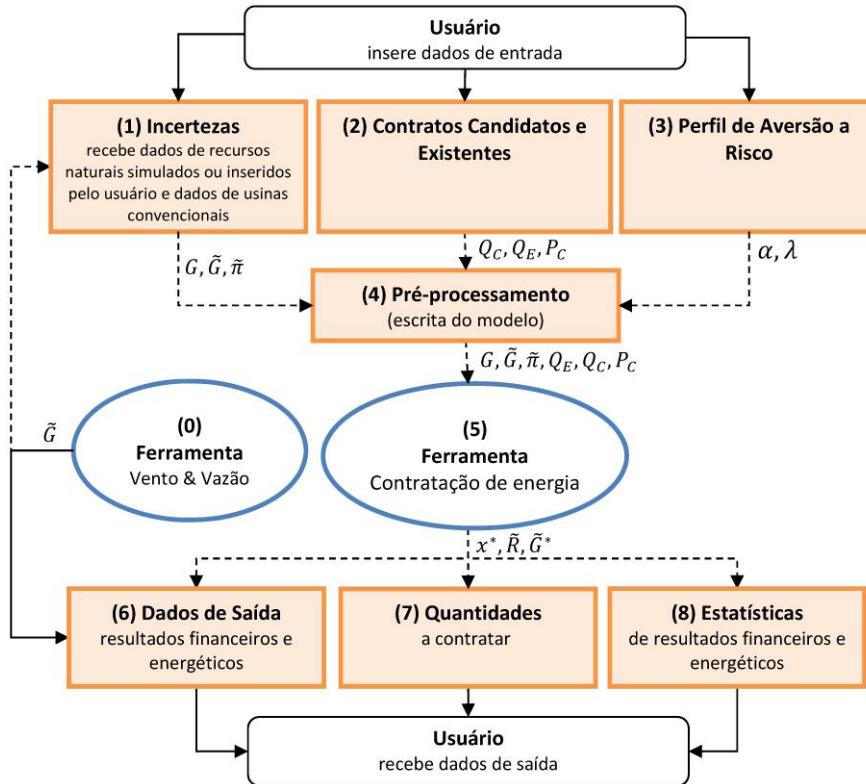


Fig. 3 – Fluxograma da plataforma de comercialização de energia

O bloco 0 (zero) representa a ferramenta V&V, usada para geração de cenários de recursos renováveis correlacionados com o PLD. Nesse ponto, o usuário pode cadastrar séries de dados referentes ao histórico dos recursos de diferentes usinas, bem como o histórico das variáveis operativas (ENAs e PLDs). A ferramenta, então, gera cenários futuros ( $\tilde{G}$ ) de disponibilidade de vento e vazão correlacionados com as ENAs e, consequentemente, com os PLDs.

Considerando um fluxo de informações completo da plataforma de comercialização, o bloco 1 organiza os cenários simulados de vento e vazão correlacionados com o PLD para alimentar a ferramenta de contratação de energia. Os parâmetros que definem a contratação de energia são provenientes dos blocos 2 e 3. O bloco 2 fornece os contratos candidatos ( $Q_C$ ) e existentes ( $Q_E$ ) e seus respectivos preços ( $P_C$ ). Já o bloco 3 provê as informações para definir o perfil de aversão a risco ( $\alpha, \lambda$ ) da comercializadora.

As setas pontilhadas representam o fluxo de informação que ocorre automaticamente dentro da plataforma e não se destinam ao usuário nem se originam dele. As demais setas representam saídas ou entradas de dados cuja interferência do usuário é necessária.

No bloco 4, as informações são organizadas para entrada na ferramenta de contratação e, no bloco 5, as informações são otimizadas com o objetivo de gerar o maior valor possível para a contratação de energia. Os resultados da otimização são transmitidos aos blocos 6, 7 e 8, definindo o percentual de energia a contratar de cada fonte ( $x^*$ ) e o valor financeiro estocástico associado à contratação ( $\tilde{R}$ ), bem como os cenários de vento e vazão ( $\tilde{G}^*$ ) para a devida apresentação através de gráficos e tabelas.

Nas próximas seções deste documento, apresentaremos o modelo estatístico usado para a ferramenta V&V e o modelo matemático da ferramenta de contratação de energia (seções III e IV respectivamente). Já na seção V, desenvolvemos dois estudos de caso que se valem da plataforma completa. Por fim, na seção VI, relatamos as conclusões do estudo. Em seguida, estão as referências bibliográficas e os anexos, que trazem informações mais detalhadas dos modelos utilizados.

### III. MODELO ESTATÍSTICO DA FERRAMENTA DE VENTO & VAZÃO

A ferramenta V&V foi construída em torno de um modelo de séries temporais multivariado do tipo VARX (Vector AutoRegression with eXternal variables, isto é, autoregressivo vetorial com variáveis externas)

descrevendo a dinâmica de evolução das energias produzidas por um conjunto de usinas eólicas e PCHs em base mensal<sup>2</sup>.

Para uma análise representativa do período, o conjunto de vento e vazão de um mês é escrito como uma função dos valores de vento e vazão dos últimos 12 meses e das ENAs dos quatro submercados do próprio mês e do mês anterior. A modelagem vetorial, ou multivariada, permite captar não apenas a dinâmica de cada série em separado, mas principalmente o comportamento conjunto.

O modelo descreve a produção mensal de usinas eólicas e de PCHs como uma função dos mesmos valores dos últimos 12 meses e as ENAs, variáveis exógenas, obtidas pelo programa NEWAVE. A ferramenta V&V é, portanto, concebida para ser utilizada em conjunto com o NEWAVE, servindo-se de diversos elementos por ele produzidos.

Na fase de ajuste dos parâmetros, são utilizados os dados históricos da produção das usinas eólicas e das PCHs, bem como as ENAS históricas calculadas pelo NEWAVE. É importante notar que as ENAs históricas serão recalculadas sempre que houver a entrada de novas usinas, alterando a configuração do sistema hídrico. Isso acarretará um novo ajuste do modelo VARX para cada nova série de ENAs históricas, correspondendo a uma nova configuração.

Posteriormente, o modelo VARX é utilizado para gerar cenários de produção das usinas eólicas e das PCHs, recorrendo aos cenários de ENAs produzidos pelo NEWAVE como entrada do modelo. Como, para cada trajetória criada para as ENAs, o NEWAVE produz também, após a otimização da operação, uma trajetória para os PLDs, podemos associar os cenários de PLD aos cenários de produção eólica e de PCHs.

Dessa forma, para cada trajetória de ENAs e PLDs que o NEWAVE projeta, a ferramenta pode gerar uma ou mais trajetórias para a produção de eólicas e PCHs. Essas trajetórias serão então fornecidas à ferramenta de comercialização para o cálculo do mix ótimo de contratos.

#### A. Formulação do modelo VARX para V&V

Considere  $Y_t$  um vetor de dimensão  $K^3$ , onde os primeiros  $m$  componentes do vetor representam as vazões (Vz) de PCHs e os  $(K - m)$  elementos finais representam o fator de capacidade (FC) de parques eólicos no período  $t^4$ , com  $t = 1, 2, \dots, n$ .

Considere também  $x_t$  um vetor de dimensão 4 contendo as ENAs dos quatro submercados observadas no período  $t$ . No modelo, utilizamos valores transformados dessas variáveis, segundo descrito no ANEXO 1. Essa transformação é necessária para que os cenários gerados posteriormente estejam no intervalo correto.

Uma vez definidos  $Y_t$  e  $x_t$ , podemos modelar  $Y_t$  como um processo vetorial autoregressivo com variáveis externas, VARX. O modelo considera 12 defasagens de  $Y_t$ , além de  $x_t$  e  $x_{t-1}$ . O modelo pode ser expresso por:

$$Y_t = c + \sum_{i=1}^{12} \phi_i Y_{t-i} + \sum_{j=1}^2 \theta_j x_{t-j-1} + A_{m(t)} \epsilon_t, \quad (1)$$

$$\epsilon_t \sim N(\mathbf{0}, \mathbf{I}). \quad (2)$$

Contrariamente ao esperado, o modelo não requer uma componente sazonal. Esse efeito é transmitido à variável  $Y_t$  através das ENAs, representadas pela variável  $x_t$ . Além disso, note que o modelo admite uma matriz de covariâncias da componente aleatória  $A_{m(t)} \epsilon_t$ , dada por  $A_{m(t)} A_{m(t)}^T$ , diferente para cada mês do ano. Essa característica foi observada nos dados históricos dessas variáveis.

Os parâmetros a serem estimados na equação (1) estão descritos a seguir:

$c$  é o intercepto do modelo representado por um vetor de dimensão  $K$ ;

$\phi_i$ ,  $i = 1, \dots, 12$ , são as matrizes/coeficientes de dimensão  $K \times K$ ;

2. A base mensal foi escolhida, pois a simulação da contratação de energia é feita em base mensal. Ressaltamos, porém, que o modelo é genérico e pode ser utilizado em qualquer base, desde que as variáveis dependentes e explicativas sejam dadas na mesma base.

3. A dimensão do vetor  $e$ , portanto, o número de usinas incluídas no modelo seria, a princípio, ilimitado. Contudo, como verificaremos mais adiante, o número de parâmetros do modelo cresce com o quadrado de  $K$ , enquanto a quantidade de dados cresce linearmente com  $K$ . Portanto, o número de parâmetros cresce mais rápido do que o número de dados. A diferença entre os dois determina os chamados graus de liberdade do modelo, que, por sua vez, determinam a precisão da estimativa. Quanto mais graus de liberdade, melhor. Em geral, espera-se que o número de dados seja pelo menos 5 vezes maior do que o número de parâmetros.

4. Lembrando que o modelo é de base mensal e que  $t=1$  corresponde ao primeiro mês do período de análise e, não necessariamente, ao primeiro mês do ano.

$\theta_j, j = 1, 2$ , são as matrizes/coeficientes de dimensão  $K \times 4$ ; e

$A_{m(t)}$  são matrizes  $K \times K$  associadas aos meses do ano, onde  $m(t)$  é o índice do mês referente ao período  $t$  de estudo.

Vale ressaltar, ainda, que as matrizes  $A_{m(t)}$  têm a função de atribuir uma matriz de covariância diferente para cada mês do ano, gerando diferentes resultados de variância observados ao longo do histórico considerado.

Nas próximas subseções, apresentaremos um método exato de estimação baseado no critério da máxima verossimilhança condicional. Este, porém, sofre de instabilidade numérica quando  $K > 8$ . A Tabela 1 mostra o número de coeficientes a estimar em função de  $K$ , calculado por  $K + 12 \cdot K^2 + 2 \cdot K \cdot 4$ . A parte da variância, descrita pelas matrizes  $A_k, k = 1, \dots, 12$ , contém  $6 \cdot K \cdot (K + 1)$  elementos a serem estimados.

<b>K</b>	<b>NÚMERO DE COEFICIENTES</b>
1	21
2	66
3	135
4	228
5	345
6	486
7	651
8	840
9	1053
10	1290

Tabela 1 – Relação entre o número de usinas e o de coeficientes

Para tornar a estimativa estável, propomos um método heurístico que pode ser utilizado, em princípio, para um número arbitrariamente grande de usinas no que se refere à estimativa dos coeficientes. Todavia, para obter estimativas das matrizes de covariâncias que sejam definidas positivas, o número de anos e dados deve crescer junto com o número de usinas.

### B. Estimação dos parâmetros por máxima verossimilhança condicional

Para o projeto, foi inicialmente proposta uma estimativa de parâmetros baseada no critério dos mínimos quadrados ponderados (MQP). O MQP tem a vantagem de não exigir a adoção de uma distribuição específica para a componente aleatória  $\varepsilon_t$ . Por outro lado, a estimativa da variância é feita sem uma justificativa teórica. Retomando o que foi feito no relatório anterior, apresentaremos a estimativa por máxima verossimilhança (MV) proposta para suprir essa deficiência. Para isso, todavia, foi necessário atribuir uma distribuição Normal à componente aleatória  $\varepsilon_t$ . Na prática, quando a distribuição escolhida é a Normal, os valores estimados pelos métodos de MQP e MV resultarão os mesmos. Se a distribuição não for Normal, o método é frequentemente chamado de máxima quasi-verossimilhança (MQV). É possível provar a consistência dos estimadores MQV para casos bastante gerais, incluindo o modelo apresentado neste texto.

É conveniente reescrever o modelo a fim de lidarmos com um único vetor contendo todos os coeficientes desse modelo. Primeiramente, definimos uma matriz  $B$  com dimensão  $K \cdot (1 + 12K + 2K)$ , contendo todos os coeficientes:

$$B = [\mathbf{c} \ \boldsymbol{\phi}_1 \dots \boldsymbol{\phi}_{12} \ \boldsymbol{\theta}_1 \boldsymbol{\theta}_2]. \quad (3)$$

Definimos também um vetor com todas as variáveis do lado direito da equação (1).

$$w_{t-1} = \begin{bmatrix} \mathbf{1} \\ Y_{t-1} \\ \vdots \\ Y_{t-12} \\ x_t \\ x_{t-1} \end{bmatrix}. \quad (4)$$

Com isso, o modelo pode ser escrito de forma mais concisa:

$$\mathbf{Y}_t = B w_{t-1} + \mathbf{A}_{m(t)} \boldsymbol{\epsilon}_t. \quad (5)$$

Avançando um pouco mais, chegamos à forma desejada, em que os coeficientes estão todos colocados em um vetor. Assim, definimos  $\beta = \text{vec}(B)$  e  $W_{t-1} = (w_{t-1}^T \otimes I)$ , onde o operador  $\text{vec}$  representa uma transformação linear que converte uma matriz em vetor coluna e  $\otimes$ , um produto de Kronecker. Ambos os operadores citados estão descritos em [4], e detalhes sobre a técnica podem ser vistos no ANEXO 2. Com isso, o modelo pode ser expresso por:

$$\mathbf{Y}_t = W_{t-1} \beta + \mathbf{A}_{m(t)} \boldsymbol{\epsilon}_t, \quad (6)$$

O desenvolvimento proposto é necessário para que seja possível calcular a derivada da função de verossimilhança, apresentada a seguir, com relação ao vetor de coeficientes.

Considere observações históricas de  $t = 1, \dots, T$ . Assim, a função de log-verossimilhança condicional às 12 primeiras observações pode ser expressa por:

$$l(\beta, \mathbf{A}_1, \dots, \mathbf{A}_{12}) = \mathbf{c} + \frac{1}{2} \sum_{t=13}^T \ln |\Sigma_{m(t)}|^{-1} - \frac{1}{2} \sum_{t=13}^T (\mathbf{Y}_t - W_{t-1} \beta)^T (\Sigma_{m(t)})^{-1} (\mathbf{Y}_t - W_{t-1} \beta), \quad (7)$$

onde  $\Sigma_{m(t)} = \mathbf{A}_{m(t)} \mathbf{A}_{m(t)}^T$ . É importante notar que, para estimar  $\mathbf{A}_{m(t)}$ , o método da máxima verossimilhança vai estimar primeiramente  $\Sigma_{m(t)}$ . A matriz  $\mathbf{A}_{m(t)}$  será a chamada decomposição de Cholesky [6] da matriz  $\Sigma_{m(t)}$ . Outro detalhe operacional se refere ao número de anos de dados necessários para que a matriz  $\Sigma_{m(t)}$  seja invertível, um pressuposto para a existência da função de verossimilhança. A fim de que tal matriz seja invertível, nenhum de seus autovalores pode ser nulo, isto é, ela deve ser de posto cheio. Para tanto, é necessário que o número de dados, neste caso o número de anos de dados, seja maior do que  $K$ , como demonstrado em [7]. Assim,  $T$  tem que ser maior do que  $12xK$ .

A maximização da função da log-verossimilhança expressa no formato acima é um cálculo clássico, presente em livros-texto [4]. Para estimar, devemos resolver o sistema:

$$\hat{\beta} = \arg \max(l(\beta, \mathbf{A}_1, \dots, \mathbf{A}_{12})) = \left[ \sum_{t=13}^T (W_{t-1}^T \hat{\Sigma}_{m(t)}^{-1} W_{t-1}) \right]^{-1} \left[ \sum_{t=13}^T (W_{t-1}^T \hat{\Sigma}_{m(t)}^{-1} Y_{t-1}) \right], \quad (8)$$

$$\hat{\Sigma}_k = \arg \max(l(\beta, \mathbf{A}_1, \dots, \mathbf{A}_{12})) = \frac{\sum_{t=13, m(t)=k}^T (\mathbf{Y}_t - W_{t-1} \hat{\beta})(\mathbf{Y}_t - W_{t-1} \hat{\beta})^T}{\text{numero de meses } k \text{ na amostra}}, \quad (9)$$

$$k = 1, \dots, 12.$$

Podemos empregar o método do ponto fixo para resolver o sistema acima, o que consiste em aplicar o procedimento descrito a seguir.

1. Iniciar contador  $C = 0$ .
2. Atribuir um valor inicial para  $\hat{\beta}$ , por exemplo  $\hat{\beta}^C = 0$ .
3. Fazer  $C = C + 1$ .
4. Calcular  $\hat{\Sigma}_k^C$  (9).
5. Recalcular  $\hat{\beta}^C$ .
6. Avaliar se  $|\hat{\beta}^C - \hat{\beta}^{C-1}| < tol$ .

7. Caso a condição em 6 se verifique verdadeira, o processo convergiu ( $\hat{\beta} = \hat{\beta}^C$ ;  $\hat{\Sigma}_k = \hat{\Sigma}_k^C$ ), caso contrário, retornar ao passo 3.

Após a convergência, é possível obter o estimador das matrizes  $A_k$ , para  $k = 1, \dots, 12$ , pela decomposição de Cholesky da matriz  $\hat{\Sigma}_k$ , também para  $k = 1, \dots, 12$ . A decomposição de Cholesky é aquela que expressa uma matriz simétrica como o produto  $\hat{\Sigma}_k = A_k A_k^T$ , onde  $A_k$  é uma matriz triangular inferior. Essa decomposição só será possível se  $\hat{\Sigma}_k$  for invertível, reforçando a exigência colocada anteriormente sobre o valor mínimo de  $T$ .

### C. Estimação heurística rápida por máxima verossimilhança condicional

Na subseção B, apresentamos o método não-heurístico para calcular a função de máxima verossimilhança. No entanto, o procedimento exige a inversão de uma matriz com dimensão igual ao número total de coeficientes do modelo, o que pode induzir problemas numéricos. Uma forma de minorar esse problema é estimar o modelo separadamente para cada usina. Com isso, podemos estimar os coeficientes e a variância da componente aleatória de cada série. Todavia, sob este enfoque, as covariâncias entre as séries não podem ser estimadas. Propomos, então, que essas covariâncias sejam estimadas diretamente dos resíduos após a convergência da estimação dos modelos individuais. Segundo nossos experimentos, esse procedimento leva a uma aproximação da metodologia não-heurística apresentada anteriormente. Há ainda a vantagem de ser numericamente estável.

O modelo individual para uma usina  $k$  pode ser escrito como:

$$Y_{k,t} = w'_{t-1} \beta_k + \mathbf{h}_{k,m(t)} \boldsymbol{\epsilon}_{k,t}, \quad k = 1, \dots, K, \quad (10)$$

com  $\beta_k$  sendo a  $k$ -ésima linha da matriz  $B$ .

Com isso, o algoritmo de estimação pode ser dividido em duas etapas, conforme descrito a seguir.

#### ETAPA 1

Use o método de estimação descrito na seção anterior para resolver o sistema para  $K$  usinas. Assim,

$$\hat{\beta}_k = [\sum_{t=13}^T (w_{t-1} \hat{\mathbf{h}}_{k,m(t)}^{-1} w_{t-1}^T)]^{-1} [\sum_{t=13}^T (w_{t-1} \hat{\mathbf{h}}_{k,m(t)}^{-1} Y_{k,t-1})], \quad (11)$$

$$\hat{\mathbf{h}}_{k,i} = \frac{\sum_{t \geq 13, m(t)=i}^T (Y_{k,t} - w'_{t-1} \hat{\beta}_k)^2}{\text{número de meses } (i) \text{ na amostra}} \quad i = 1, \dots, 12. \quad (12)$$

#### ETAPA 2

Após a convergência da primeira etapa, a covariância entre as séries  $k$  e  $r$  são estimadas por:

$$\hat{\sigma}_{k,r,i} = \frac{\sum_{t \geq 13, m(t)=i}^T (Y_{k,t} - w'_{t-1} \hat{\beta}_k)(Y_{r,t} - w'_{t-1} \hat{\beta}_r)}{\text{número de meses } i \text{ na amostra}} \quad i = 1, \dots, 12. \quad (13)$$

Uma vez montada a matriz de covariância, as matrizes  $A_{m(t)}$  podem ser obtidas pela decomposição de Cholesky.

### D. Simulação de cenários de vento e vazão coerentes com o PLD

Nesta seção, descreveremos o método de geração de cenários para as energias produzidas pelas usinas eólicas e pelas PCHs, representadas no vetor  $Y_t$ .

Nosso objetivo é criar cenários condicionais aos cenários de ENAs gerados pelo NEWAVE. Para cada cenário de ENA, há um cenário de PLD produzido internamente pelo modelo de otimização do NEWAVE. Esse conjunto de cenários, correspondentes à produção de energia e ao PLD, por sua vez permitirá que o módulo de comercialização determine cenários de receita para cada tipo contrato. O modelo de otimização estocástica vai determinar a carteira ótima considerando então esses cenários de receita.

Nossa estratégia será percorrer cada trajetória de ENA produzida pelo NEWAVE e, lançando mão do modelo (1), gerar uma ou mais trajetórias para o vetor  $Y_t$  de produção de energia através da geração aleatória de valores para o ruído  $\varepsilon_t$ . A geração aleatória pode ser feita por método Monte Carlo usando a distribuição Normal padrão ou através do sorteio dos resíduos padronizados obtidos na etapa de estimação dos parâmetros do modelo (1).

Outro elemento que deve ser levado em conta para que seja possível gerar cenários coerentes é o fato de que a configuração do sistema evolui ao longo do período de estudo. Com isso, as ENAs históricas reconstruídas tendem a aumentar como consequência do aumento da capacidade do sistema. O NEWAVE leva isso em conta, recalcula as ENAs históricas a cada nova configuração e reajusta o modelo de geração de cenários de ENAs. O nosso método de geração de cenários usa o mesmo princípio e, cada vez que o NEWAVE reconstrói o histórico de ENAs, o modelo (1) é reestimado.

Mais uma vez, vale ressaltar que o modelo de geração de cenários deverá ser utilizado em sincronia com um *deck* específico do NEWAVE<sup>5</sup>, onde constam as datas de mudança de configuração, os históricos de ENAs para cada configuração e os cenários de ENAs e PLDs.

Outra característica do modelo de geração de cenários proposto neste projeto é que, contrariamente aos modelos utilizados para gerar cenários de ENAs no NEWAVE, não há preocupação em gerar cenários com valores fora do intervalo permitido como vazões negativas ou fatores de capacidade maiores que 100%. Isso se deve ao tipo de transformação aplicada às variáveis do modelo, que garante essa propriedade, segundo descrito no ANEXO 1.

### a) Algoritmo de simulação

Considere um *deck* do NEWAVE contendo uma análise para períodos mensais  $t = 1, \dots, H$ . Considere que o NEWAVE produziu  $S$  séries hidrológicas para as ENAs (os PLDs serão utilizados apenas pelo módulo de comercialização). Denote por  $x_t^s$  a ENA do instante  $t$  da  $s$ -ésima trajetória, sendo  $s = 1, \dots, S$ . Denote por  $d(t)$  a configuração vigente no período  $t$  do horizonte de estudo. Finalmente, considere que se deseja produzir  $R$  cenários de vento e vazão para cada série hidrológica  $s$  de ENA, totalizando  $R \times S$  cenários.

O algoritmo é composto de 3 etapas, conforme descrevemos a seguir.

#### 1. Condições iniciais.

Para iniciar o processo, são necessários os 12 últimos valores do vetor  $Y$  de vento e vazão, além dos valores atual e defasado de um período das ENAs. Tudo está reunido no vetor  $w_0$ , conforme demonstramos abaixo:

$$w_0 = \begin{bmatrix} 1 \\ Y_0 \\ \vdots \\ Y_{11} \\ x_0 \\ x_{-1} \end{bmatrix}.$$

2. Geração das sequências de ruídos:  $\{\boldsymbol{\varepsilon}_t^{(r,s)}\}_{t=1,\dots,H}^{r=1,\dots,R}$ , com  $\boldsymbol{\varepsilon}_t^{(r,s)} \sim N_K(\mathbf{0}, \mathbf{I})$ .

A seguir, é preciso produzir  $R \times S$  amostras Monte Carlo de  $H$  vetores  $N_K(\mathbf{0}, \mathbf{I})$  de dimensão  $K$ . Formalmente,  $\boldsymbol{\varepsilon}_t^{(r,s)}$  denota o vetor de ruídos que vai formar o cenário do instante  $t$  referente ao  $r$ -ésimo cenário de  $Y$  calculado com as ENAs da  $s$ -ésima série hidrológica produzida pelo NEWAVE.

Outra opção é usar os resíduos da estimativa do modelo para construir amostras *bootstrap*, isto é, através de sorteio com reposição. Isso foi experimentado durante o desenvolvimento do projeto e está disponível na ferramenta. No que diz respeito aos exercícios ilustrativos que serão apresentados neste documento, não houve diferença em relação à geração Monte Carlo, pois os resíduos apresentaram uma distribuição Normal.

---

5. O *deck* do NEWAVE é um conjunto com todas as entradas e saídas referentes a uma execução do programa. Ele contém informações como custos, configurações do sistema, cenários, modelos, dados históricos etc.

3. Construir as trajetórias para o vetor de vento e vazão:  $\{\mathbf{Y}_t^{(r,s)}\}_{t=1,\dots,H}^{r=1,\dots,R, s=1,\dots,S}$ .

Por fim, aplicar recursivamente a equação (1) usando os ruídos da segunda etapa e as condições iniciais da primeira.

É importante lembrar que a configuração do sistema se altera à medida que  $t$  avança. Por isso, o valor dos parâmetros do modelo,  $\mathbf{c}$ ,  $\boldsymbol{\phi}_i$ ,  $\boldsymbol{\theta}_j$  e  $\mathbf{A}_{m(t)}$ , deve se alterar da mesma forma. Considerando que podemos estimar os valores dos parâmetros do modelo sob toda configuração  $d \in D$ ,  $\hat{\mathbf{c}}^{(d)}$ ,  $\hat{\boldsymbol{\phi}}_i^{(d)}$ ,  $\hat{\boldsymbol{\theta}}_j^{(d)}$  e  $\hat{\mathbf{A}}_{m(t)}^{(d)}$ , o procedimento de simulação se resume no seguinte *loop*:

Para todo  $t = 1, \dots, H, s = 1, \dots, S$  e  $r = 1, \dots, R$  calcule:

$$\mathbf{Y}_t^{(r,s)} = \hat{\mathbf{c}}^{(d(t))} + \sum_{i=1}^{12} \hat{\boldsymbol{\phi}}_i^{(d(t))} \mathbf{Y}_{t-1}^{(r,s)} + \sum_{j=1}^2 \hat{\boldsymbol{\theta}}_j^{(d(t))} \mathbf{x}_{t-j-1}^s + \hat{\mathbf{A}}_{m(t)}^{(d(t))} \boldsymbol{\varepsilon}_t^{(r,s)}.$$

## E. Estudos de caso

A título de ilustração, apresentaremos neste trecho uma aplicação do modelo V&V para duas usinas, uma eólica e outra PCH, com o objetivo de comparar o desempenho das diferentes metodologias de estimação apresentadas, utilizando como critério de avaliação as propriedades estatísticas dos modelos estimados, bem como a qualidade das simulações produzidas por eles. Em seguida, apresentamos outros estudos de caso em que utilizamos apenas o método de máxima verossimilhança heurístico para produzir os resultados.

### a) Estudo de caso 1: Avaliação das metodologias de estimação

Neste exemplo em particular, a complementariedade entre as produções eólica e hídrica é bastante nítida. É preciso ressaltar, porém, que isso não necessariamente se reproduz com outros conjuntos de usinas. Assim, o modelo bivariado será apresentado em três versões.

- (i) Na primeira, utilizamos o método de máxima verossimilhança (subseção III.B) considerando a correlação entre as produções eólica e hídrica constantes ao longo do ano.
- (ii) Em seguida, recorremos mais uma vez ao método de máxima verossimilhança, mas deixamos a correlação entre as produções eólica e hídrica variar ao longo do ano.
- (iii) Finalmente, utilizamos o método de máxima verossimilhança heurístico (subseção III.C) deixando, como no item (ii), que as correlações variem ao longo do ano.

Os resultados completos referentes à estimação dos modelos (medidas de ajuste, análise de resíduos, previsão fora da amostra) e sua utilização para a geração de cenários, são apresentados no ANEXO 3. Nesta seção, vamos nos ater a comparar os principais resultados.

Essencialmente, concluiremos que, especificamente para os dados utilizados, o modelo com correlações variantes no tempo revela uma correlação significante entre FC e Vz em alguns meses e não-significante em outros. Além disso, ela não tem o mesmo sinal para todos os meses do ano. Essa é uma característica importante, dado que poderá ser utilizada para construir estratégias de contratação mais eficientes. Observamos também que o modelo estimado pelo método da máxima verossimilhança heurística revela uma estrutura de correlações mês a mês bastante próxima às obtidas pelo método não-heurístico.

#### Comparação do ajuste dos modelos dentro da amostra

As três formulações apresentaram desempenho bastante semelhante em termos da qualidade de ajuste. A Fig. 38 à Fig. 45, a Fig. 74 à Fig. 81 e a Fig. 110 à Fig. 117, no Anexo 3, mostram a análise de resíduos e resíduos ao quadrado, ambas de vento e vazão para cada caso. É possível verificar que em nenhum dos casos os resíduos apresentam correlação serial. Há uma ligeira vantagem nos métodos que deixam a correlação variar ao longo do ano. No que diz respeito à plataforma de comercialização, o conhecimento dessa variação aperfeiçoa a otimização dos contratos.

O mesmo pode ser dito em relação às medidas de ajuste ( $R^2$ ,  $R^2$  ajustado) apresentadas na Tabela 7, na Tabela 14 e na Tabela 21. O teste de Jarque-Bera indica que os resíduos referentes à variável  $Vz$  são significantes no nível de 5%, mas não no de 1%. Consideramos o resultado aceitável e atribuímos o desvio moderado da normalidade a uma observação aberrante à esquerda da amostra, conforme é possível observar, por exemplo, no histograma dos resíduos padronizados na Fig. 42 e na Fig. 43.

#### Comparação da estrutura de correlações entre FC e Vz

A Fig. 4 apresenta as correlações estimadas pelo modelo de correlações constantes ao longo dos meses (linha pontilhada) e pelo modelo de correlações variantes mês a mês, ajustadas pelos métodos heurístico e não-heurístico.

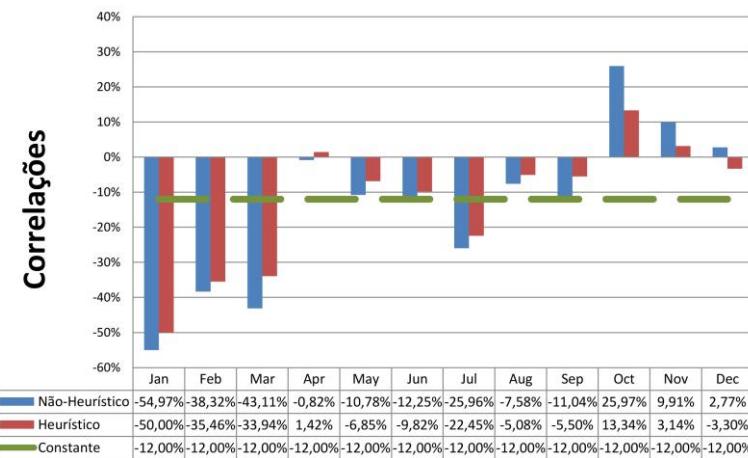


Fig. 4 – Resultado da correlação entre FC e Vz mês a mês, com os modelos heurístico e não-heurístico

Conforme adiantamos, as correlações estimadas mês a mês variam bastante. O valor médio anual é próximo ao valor obtido pelo modelo com correlação constante para os dois métodos. É interessante notar que os meses de outubro e novembro têm correlações positivas entre FC e Vz. Há alguma discrepância entre os métodos para o mês de outubro, mas a estrutura geral foi mantida.

Os valores das variâncias mês a mês, estimados pelos dois métodos, foram muito semelhantes para a variável FC, conforme podemos verificar na Fig. 5. Já no caso da das variâncias mês a mês da variável Vz, ambos os métodos encontraram o mesmo resultado. Assim, concluímos que, para efeitos da estimação da variância mensal, o método heurístico apresentou um resultado satisfatório para os dados utilizados.

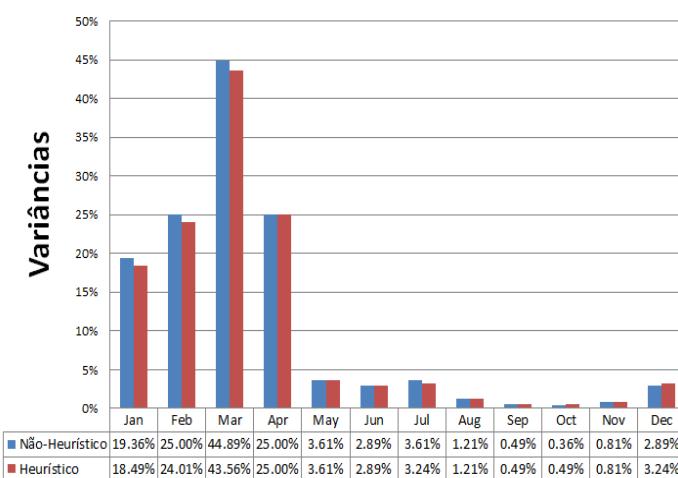


Fig. 5 – Resultado da variância de FC mês a mês, com os modelos heurístico e não-heurístico

### Comparação da capacidade de previsão fora da amostra

As três versões do modelo tiveram desempenho praticamente idêntico fora da amostra. Isso era esperado na medida em que a estimativa dos coeficientes do modelo VARX são pouco influenciados pela estrutura de covariâncias do modelo. Isso fica demonstrado na Tabela 8, na Tabela 22 e na Tabela 15.

### Geração de cenários

Na Fig. 56, na Fig. 57, na Fig. 92, na Fig. 93, na Fig. 128, na Fig. 129, na Fig. 148 e na Fig. 149, os históricos estão representados por pontos; os intervalos de confiança para 2000 cenários produzidos para FC e Vz, por linhas azuis; as médias dos cenários, por linhas pretas; e os mínimos e máximos também dos cenários, por linhas vermelhas. Tais cenários foram gerados segundo a metodologia descrita na subseção III.D com base nas três formulações e podem ser vistos na Fig. 54, na Fig. 55, na Fig. 90, na Fig. 91, na Fig. 126, na Fig. 127, na Fig. 146 e na Fig. 147.

A semelhança entre as distribuições históricas e simuladas também pode ser evidenciada pelos gráficos de probabilidade mês a mês apresentados na Fig. 58 à Fig. 73, na Fig. 94 à Fig. 109, na Fig. 130 à Fig. 145 e na Fig. 150 à Fig. 165, onde é possível observar um excelente ajuste, caracterizado pela relação quase perfeitamente linear entre os quantis observados e os simulados.

### **b) Estudo de caso 2: Uma usina eólica com sazonalidade via variáveis dummies**

Neste estudo, pretendemos estimar um modelo para FC lançando mão do próprio FC defasado no tempo, além de *dummies* (variáveis indicadoras binárias) para os meses do ano como variáveis explicativas de maneira a caracterizar a sazonalidade. Em seguida, simularemos 2000 cenários de FC utilizando o modelo estimado.

As séries históricas de vento utilizadas nesse estudo podem ser vistas a seguir, na Fig. 6.

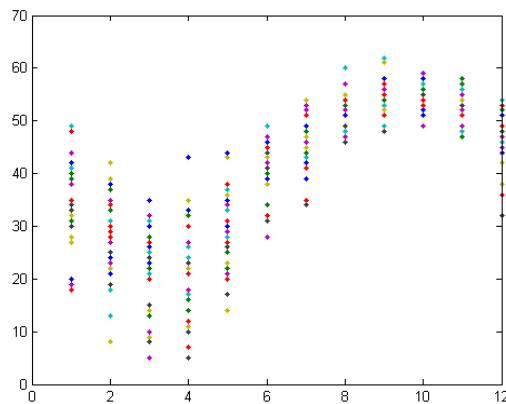
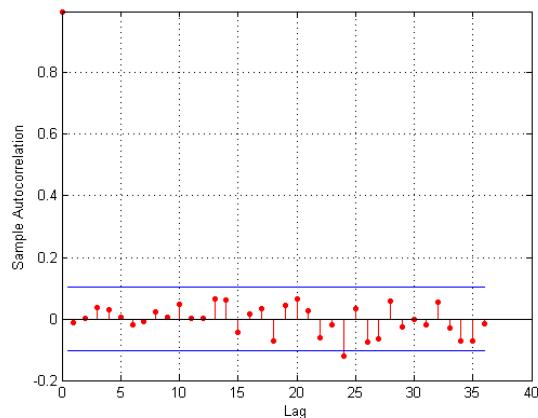
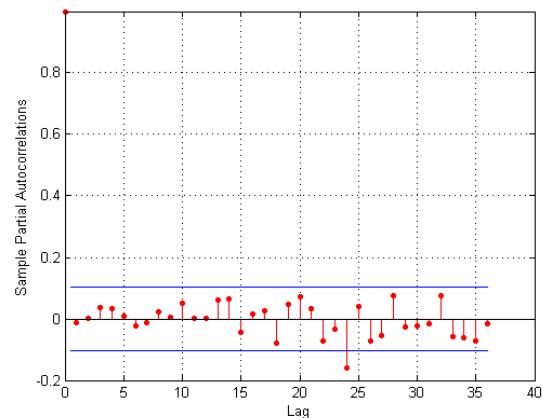
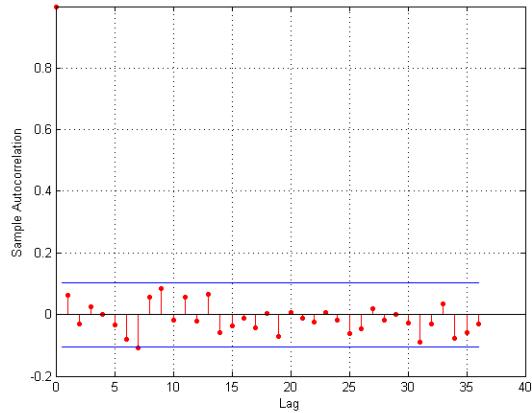
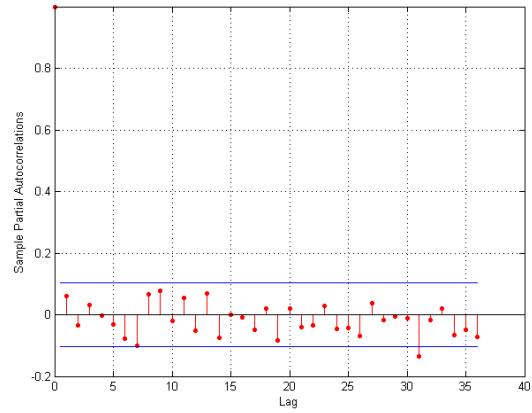
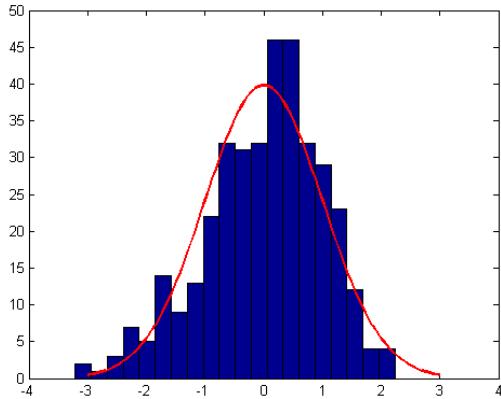
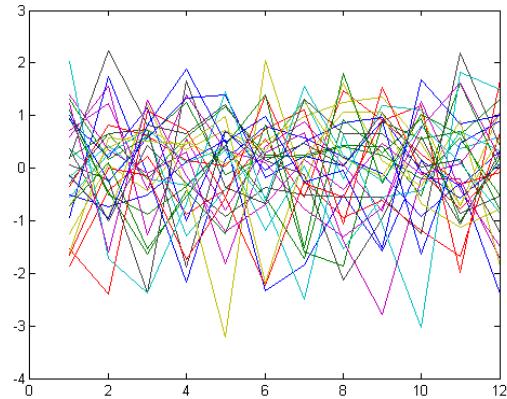


Fig. 6 – FC': Séries históricas de janeiro a dezembro empilhadas

Estimamos então o modelo, cujos coeficientes podem ser vistos na Tabela 33, no ANEXO 4. Abaixo, podemos verificar a análise básica dos resíduos na Fig. 7 à Fig. 12.

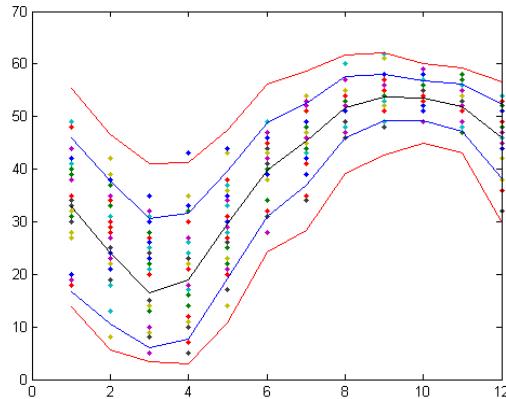
Fig. 7 – Fac dos resíduos  $FC'$ Fig. 8 – FACP dos resíduos  $FC'$ Fig. 9 – Fac dos resíduos quadrados  $FC'$ Fig. 10 – FACP dos resíduos quadrados  $FC'$ Fig. 11 –  $FC'$ : Histograma dos resíduosFig. 12 –  $FC'$ : Comparativo anual dos resíduos

As figuras acima confirmam uma boa qualidade na estimativa, o que também é corroborado pelos resultados das medidas de aderência presentes na Tabela 2.

<b><i>FC</i></b>	
<b><i>R</i><sup>2</sup></b>	0.8170
<b><i>R</i><sup>2</sup> ajustado</b>	0.8064
<b>P-valor JB dos Resíduos</b>	0.0053

Tabela 2 – Medidas de Aderência – Dentro da Amostra

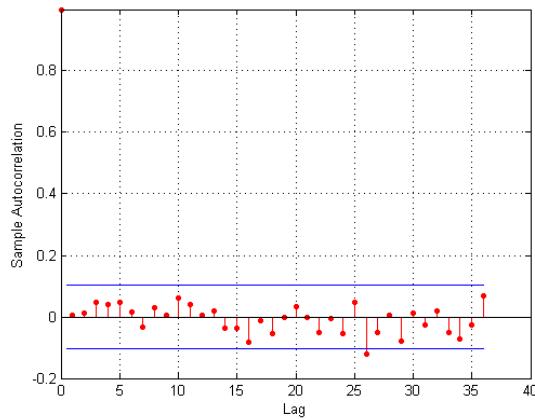
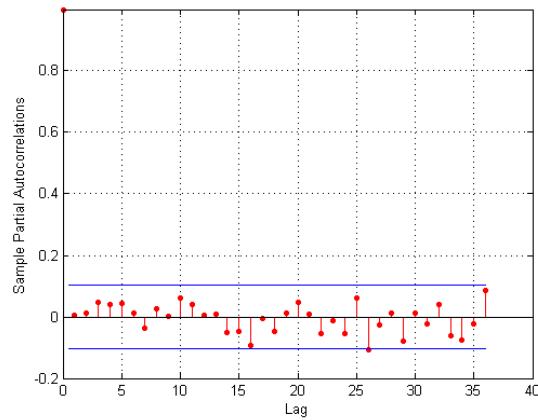
Por fim, apresentamos um gráfico em que pontos representam as realizações dos anos do nosso histórico; linhas azuis, o intervalo de confiança dos cenários simulados; uma linha preta, a média dos cenários; e linhas vermelhas, o mínimo e o máximo também dos cenários.

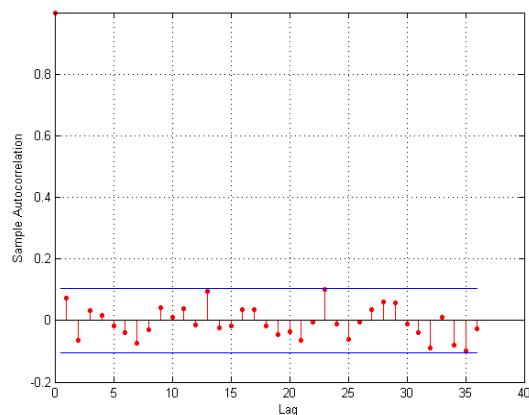
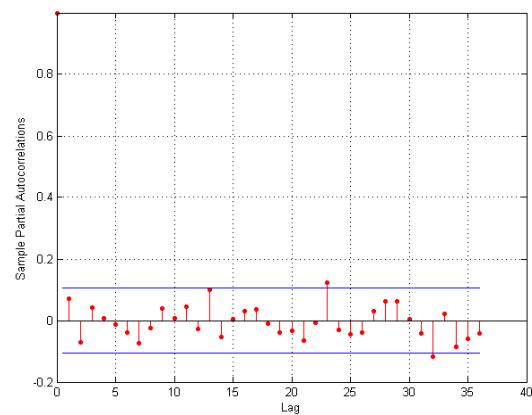
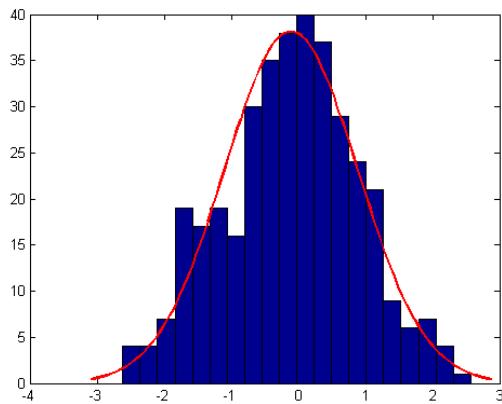
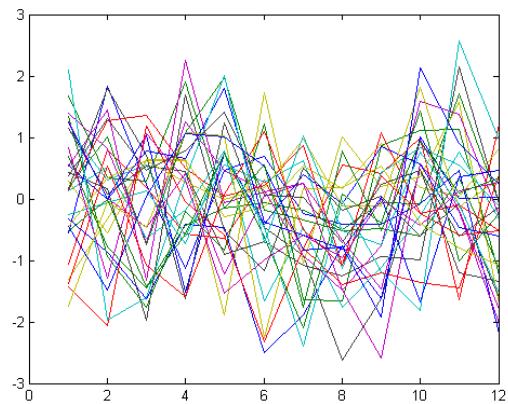
Fig. 13 –  $FC'$ : Histórico com Intervalo de Confiança de 95%

### c) Estudo de caso 3: Uma usina eólica com sazonalidade via ENAs

Neste estudo de caso, repetiremos a análise anterior, mas buscaremos caracterizar a sazonalidade não mais através de variáveis *dummies*. Isso agora será feito através das ENAs dos 4 submercados considerados no estudo operativo. O histórico utilizado é o mesmo da Fig. 6.

Novamente, estimamos o modelo utilizando o método de máxima verossimilhança heurístico, e os coeficientes obtidos constam da Tabela 34, no ANEXO 4. A seguir, apresentamos os gráficos referentes à análise básica dos resíduos (Fig. 14 a Fig. 19).

Fig. 14 – Fac dos resíduos  $FC'$ Fig. 15 – Facf dos resíduos  $FC'$

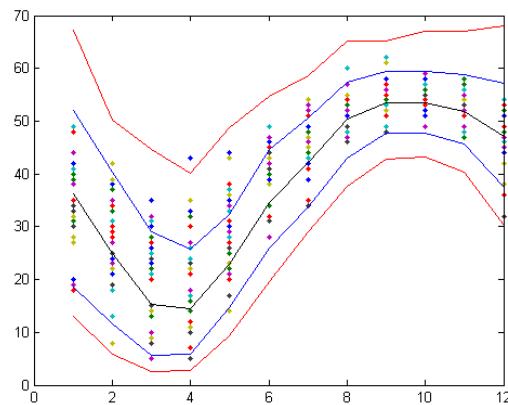
Fig. 16 – Fac dos resíduos quadrados  $FC'$ Fig. 17 – Fcapc dos resíduos quadrados  $FC'$ Fig. 18 –  $FC'$ : Histograma dos resíduosFig. 19 –  $FC'$ : Comparativo anual dos resíduos

Os gráficos acima nos mostram que o modelo foi bem estimado e confirmam os resultados da Tabela 3.

<b><i>FC</i></b>	
<b><i>R</i><sup>2</sup></b>	0.7596
<b><i>R</i><sup>2</sup> ajustado</b>	0.7457
<b>P-valor JB dos Resíduos</b>	0.3418

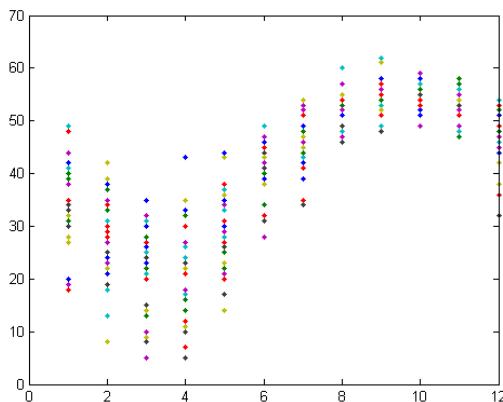
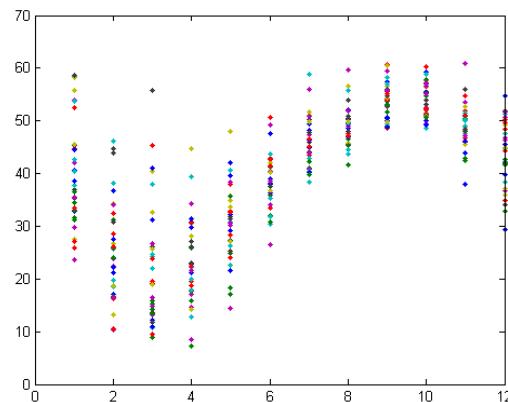
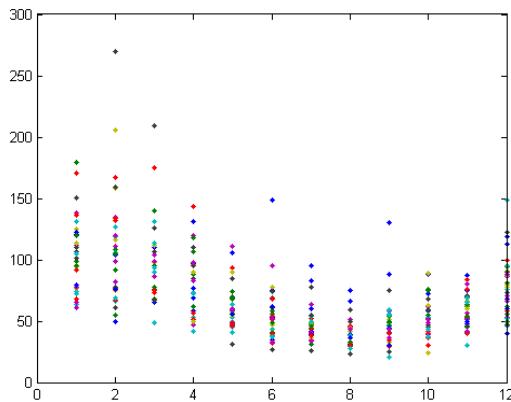
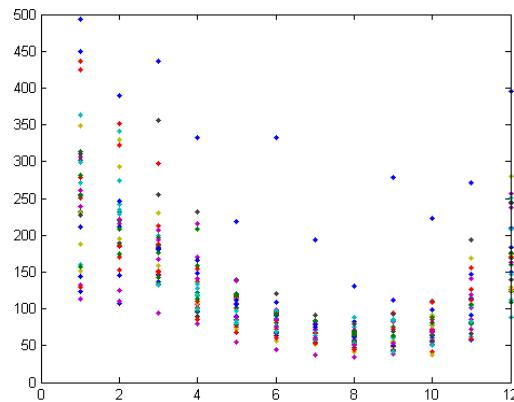
Tabela 3 – Medidas de Aderência – Dentro da Amostra

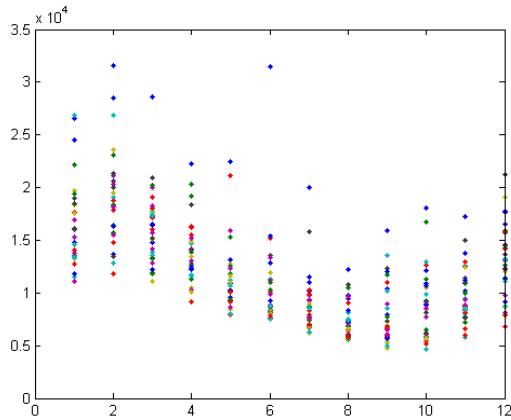
A seguir, a Fig. 20 apresenta o histórico com o intervalo de confiança dos cenários gerados em linhas azuis, a média dos cenários em uma linha preta e o mínimo e máximo dos cenários em linhas vermelhas. Esse gráfico indica que a simulação está coerente com os dados observados.

Fig. 20 –  $FC'$ : Histórico com intervalo de confiança de 95% das simulações

#### d) Estudo de caso 4: Duas usinas eólicas e três PCHs com ENAs

O último estudo de caso do modelo V&V envolve duas séries de FC e três de Vz, além de ENAs dos quatro submercados, consideradas como variáveis explicativas. Os históricos que foram utilizados constam da Fig. 21 à Fig. 25.

Fig. 21 –  $FC'_1$ : Séries históricas de janeiro a dezembro empilhadasFig. 22 –  $FC'_2$ : Séries históricas de janeiro a dezembro empilhadasFig. 23 –  $Vz'_1$ : Séries históricas de janeiro a dezembro empilhadasFig. 24 –  $Vz'_2$ : Séries históricas de janeiro a dezembro empilhadas

Fig. 25 –  $Vz'_3$ : Séries históricas de janeiro a dezembro empilhadas

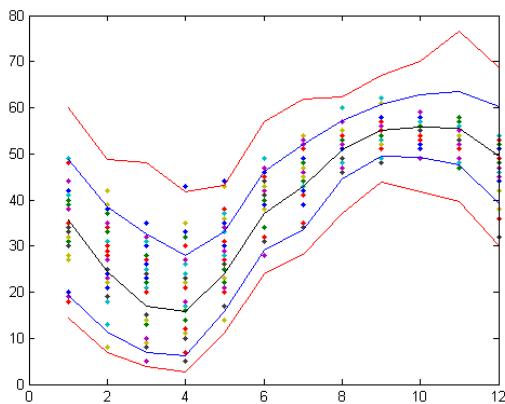
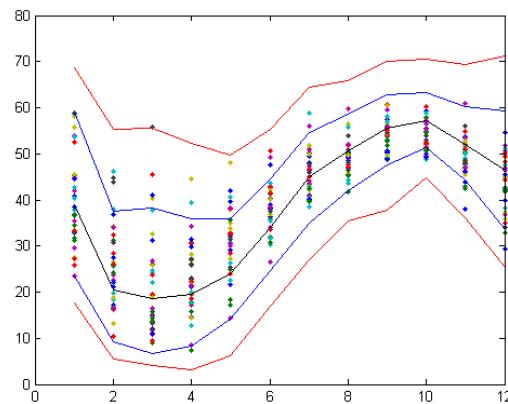
Ao estimarmos o modelo pelo método heurístico, obtivemos os coeficientes da Tabela 35 para FC e da Tabela 36 para Vz. Os gráficos referentes aos resíduos estão no ANEXO 4, na Fig. 166 à Fig. 195. Tais gráficos sugerem uma boa estimativa do modelo. A seguir, a Tabela 4 apresenta as medidas de aderência pertinentes ao estudo.

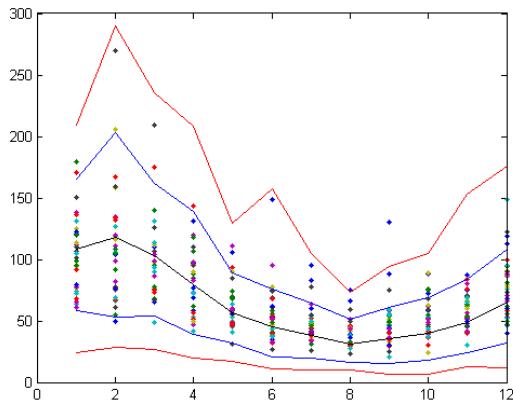
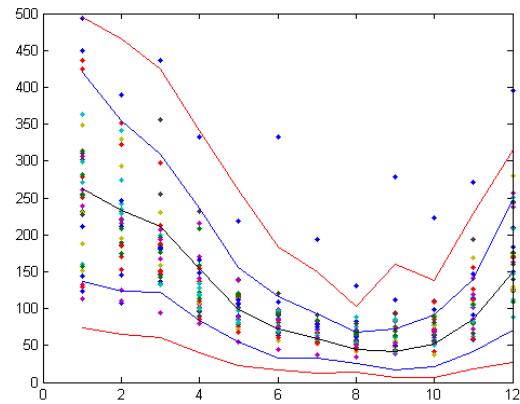
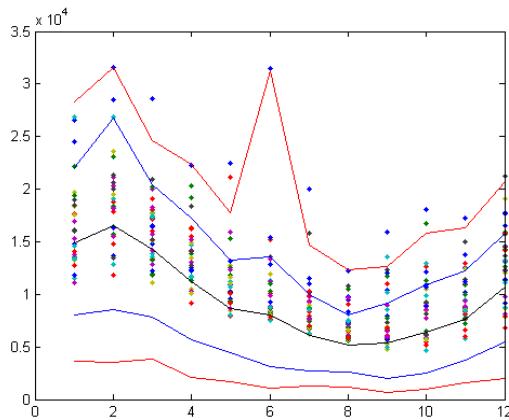
	$FC_1$	$FC_2$	$Vz_1$	$Vz_2$	$Vz_3$
$R^2$	0.8070	0.6998	0.7734	0.8818	0.7566
$R^2$ ajustado	0.7630	0.6313	0.7217	0.8549	0.7010
P-valor JB dos Resíduos	0.1148	0.3188	0.3723	0.001	0.001

Tabela 4 – Medidas de Aderência – Dentro da Amostra

Como podemos perceber, apenas duas das séries de vazão apresentam resultado de teste de normalidade (JB) para os resíduos não satisfatórios, fato ocasionado por observações aberrantes. De maneira geral, os resultados da Tabela 4 estão de acordo com o esperado.

Por fim, apresentamos abaixo os históricos das cinco séries acompanhados de intervalos de confiança gerados pelos cenários simulados seguindo o mesmo padrão dos demais estudos de caso.

Fig. 26 –  $FC'_1$ : Histórico com Intervalo de Confiança de 95% das simulaçõesFig. 27 –  $FC'_2$ : Histórico com Intervalo de Confiança de 95% das simulações

Fig. 28 –  $Vz'_1$ : Histórico com Intervalo de Confiança de 95% das simulaçõesFig. 29 –  $Vz'_2$ : Histórico com Intervalo de Confiança de 95% das simulaçõesFig. 30 –  $Vz'_3$ : Histórico com Intervalo de Confiança de 95% das simulações

Mais uma vez, podemos perceber que os cenários gerados são bastante coerentes com os históricos de fato observados. E dessa maneira, concluímos que a metodologia proposta consegue capturar a dinâmica real e simular cenários adequados.

#### IV. MODELO MATEMÁTICO DA FERRAMENTA DE CONTRATAÇÃO

Após a reforma do setor elétrico, os contratos de energia se tornaram um importante mecanismo de incentivo à expansão da geração elétrica e um importante instrumento para mitigar a exposição dos geradores/comercializadores ao preço de liquidação de diferenças (PLD). Contudo, o nível de contratação do comercializador é algo preocupante e deve ser tratado adequadamente por conta do risco de preço e quantidade [10][11]. No ambiente de contratação livre (ACL), os contratos são negociados livremente entre a entidade vendedora do contrato e a compradora. Assim, sob o ponto de vista do comercializador, é um desafio montar uma carteira de contratos diversificados entre diferentes vendedores e, além disso, maximizar uma medida de valor para si. Torna-se necessário, então, modelar adequadamente cada tipo de contrato e o perfil de risco do agente, além de utilizar técnicas de otimização para obter a quantidade contratada ótima das oportunidades contratuais.

Nesta seção, descreveremos a modelagem matemática dos contratos mais comuns na comercialização do mercado livre, bem como as diferentes maneiras de tratar o risco consideradas na plataforma de comercialização de energia em desenvolvimento neste projeto. Por fim, apresentaremos um esquema do modelo de otimização implementado.

## A. Tipos de contrato de comercialização de energia

A plataforma de comercialização contempla quatro formas distintas de contrato: Contratos de Quantidade Padrão, Contratos de Quantidade *Flex*, Contratos de Quantidade Baseados no PLD com Piso e Teto e Contratos de Disponibilidade. Além desses, acrescentamos uma quinta modalidade, denominada Contratos Generalizados.

### a) Contratos de Quantidade Padrão

O Contrato de Quantidade Padrão é a forma mais simples de negociar um contrato. O vendedor se compromete a entregar ao comprador, para cada período de vigência do contrato, uma determinada quantidade de energia. A expressão da receita devida à venda desse contrato é definida como:

$$R_{i,t}^Q = P_{i,t} \cdot h_t \cdot Q_{i,t}. \quad (14)$$

Sendo:

$Q_{i,t}$  a quantidade de energia do contrato  $i$  sazonalizada no período  $t$  (em MWméd);

$P_{i,t}$  o preço da energia contratada através do contrato  $i$  no período  $t$  (em R\$/MWh); e

$h_t$  o número de horas do período  $t$ .

De maneira análoga, o custo devido à compra de um contrato  $i$  de quantidade no período  $t$  é definido como:

$$C_{i,t}^Q = P_{i,t} \cdot h_t \cdot Q_{i,t}. \quad (15)$$

### b) Contratos de Quantidade Flex

Os contratos de quantidade com cláusulas de *Take or Pay (ToP)* apresentados em relatórios anteriores foram ligeiramente alterados para melhor se adaptarem à realidade da comercialização e passaram a se chamar Contratos de Quantidade *Flex*. A lógica dessa modalidade de contrato continua a mesma, permitindo flexibilizar a quantidade de energia contratada para uma quantidade mínima ( $Q_i^{min}$ ) ou uma quantidade máxima ( $Q_i^{max}$ ). Contudo, na prática de negociação do setor, os parâmetros mais comuns definidos em contrato desse tipo são:  $Q_{i,t}^{nom}$ , que representa uma quantidade nominal que pode ser sazonalizada para cada período  $t$  do contrato (MWméd), e  $\gamma(\%)$ , que representa a flexibilidade de variação da quantidade do contrato em relação à quantidade nominal de cada período.

Assim, a expressão de receita de venda associada aos Contratos de Quantidade *Flex* assume uma forma similar a de (14). Contudo, a quantidade de energia contratada passa a ser função do preço da energia do contrato  $i$  com relação ao preço *spot* ( $\pi_{t,s}^{sub,i}$ ) no submercado do contrato  $i$ , no período  $t$  e no cenário  $s$ . Dessa forma:

$$Q_{i,t}(\pi_{t,s}^{sub,i}) = \begin{cases} Q_{i,t}^{nom}(1 + \gamma), & \pi_{t,s}^{sub,i} \geq P_{i,t}^{flex}; \\ Q_{i,t}^{nom}(1 - \gamma), & \pi_{t,s}^{sub,i} < P_{i,t}^{flex}. \end{cases} \quad (16)$$

Sendo:

$\pi_{t,s}^{sub,i}$  o preço *spot* (em R\$/MWh) do submercado onde está localizado o contrato  $i$  no período  $t$  e

$P_{i,t}^{flex}$  o preço da energia contratada (R\$/MWh) por meio do contrato  $i$ , no contrato de venda de quantidade *Flex* no período  $t$ .

Nesse tipo de contrato, a prerrogativa de escolha é do comprador. A decisão de consumo passa a ser função do PLD, uma vez que o comprador pode comprar e vender energia no curto prazo. Assim, toda vez que o PLD ( $\pi_{t,s}^{sub,i}$ ) estiver acima do preço de contrato ( $P_{i,t}^{flex}$ ), ele tem o direito de consumir o máximo da sua capacidade e, eventualmente, revender o excesso de energia no curto prazo a um preço superior ao de compra. Caso contrário, ele consome o mínimo, comprando a energia que falta no curto prazo a um preço inferior ao do contrato.

### c) Contratos de Quantidade Baseados no PLD com Piso e Teto

Assim como na modalidade *Flex*, os contratos baseados no PLD com piso e teto também podem flexibilizar os parâmetros do contrato. No entanto, o ajuste é realizado no preço do contrato em função dos cenários de PLD. As expressões de renda e custo dessa modalidade permanecem as mesmas dos Contratos de Quantidade Padrão ((14) e (15) respectivamente), contudo o preço a ser pago pela energia a entregar é função também do PLD.

$$P_{i,t}(\pi_{t,s}^{sub_i}) = \begin{cases} \pi_{i,t}^{max}, & \pi_{t,s}^{sub_i}(1 + a_i) \geq \pi_{i,t}^{max}; \\ \pi_{i,t}^{min}, & \pi_{t,s}^{sub_i}(1 + a_i) \leq \pi_{i,t}^{min}; \\ \pi_{t,s}^{sub_i}(1 + a_i), & \pi_{i,t}^{min} \leq \pi_{t,s}^{sub_i}(1 + a_i) \leq \pi_{i,t}^{max}. \end{cases} \quad (17)$$

Sendo:

$a_i$  o valor do ágio aplicado sobre o preço *spot* (em %) do submercado onde foi firmado o contrato  $i$ ;

$\pi_{i,t}^{max}$  o preço *spot* teto (R\$/MWh) do contrato  $i$  no período  $t$ ; e

$\pi_{i,t}^{min}$  o preço *spot* piso (R\$/MWh) do contrato  $i$  no período  $t$ .

### d) Contratos de Disponibilidade

Podemos definir os Contratos de Disponibilidade como contratos de “aluguel” ou “arrendamento” de usinas em que o comprador paga um valor mensal a um gerador pelo direito de comercializar todo ou parte do seu lastro e produção. No caso de usinas térmicas, nas ocasiões em que o PLD supera o valor do custo variável unitário (CVU), estabelecido em contrato, o comprador deve reembolsar o gerador pelo custo variável associado à geração acima de um valor mínimo  $G_i^{min}$ . Já para contratos com renováveis, o CVU pode ser considerado zero e o custo do contrato para o comprador passa a ser apenas o custo fixo mensal. Além disso, no caso das renováveis, como a produção não está associada a um despacho centralizado e sim à natureza do recurso renovável em questão, existe a possibilidade de limitar a entrega de energia por meio de um piso e um teto. Assim, o gerador assume o risco de ir ao mercado de curto prazo caso a sua geração seja inferior ao piso. Em contrapartida, nos casos em que a geração é superior ao teto, o gerador fica com a renda referente à liquidação no *spot* da geração excedente.

Na plataforma de comercialização, duas modalidades de Contrato de Disponibilidade foram consideradas: um para térmicas e outro para renováveis. No primeiro caso, os parâmetros da usina  $i$  considerados no contrato são: garantia física ( $GF_i$ ), em  $MWméd$ ; potência, em  $MW$ ; geração mínima, em  $MWméd$ ; e CVU, em R\$/MWh. A partir desses parâmetros e do PLD, a plataforma monta os cenários de geração associados a essa usina para que sejam considerados na comercialização.

Já nos Contratos de Disponibilidade para renováveis, os parâmetros considerados para a usina  $i$  são: piso e teto de geração, em  $MWméd$ , e o CVU da usina, em R\$/MWh, ainda que este último seja considerado zero na maioria dos casos. Contudo, em algumas situações, o CVU diferente de zero para usinas renováveis pode ser interessante, como no caso de usinas a biomassa, que podem produzir comprando cavaco de cana, palha ou outros insumos. Ainda assim, os cenários de geração devem ser providos externamente pelo usuário e devem ser inseridos no cadastro do contrato para que sejam considerados na comercialização.

Na plataforma de comercialização, consideramos que os Contratos de Disponibilidade estão disponíveis apenas para compra. Nesse caso, a compra de um contrato  $i$  de disponibilidade proporciona um custo no período  $t$  e cenário  $s$  de:

$$C_{i,t,s}^D = Q_{i,t}^D \cdot h_t \cdot P_{i,t}^D + (G_{i,t,s} - G_i^{min}) \cdot Q_{i,t}^D \cdot CVU_i \cdot h_t. \quad (18)$$

Sendo:

$Q_{i,t}^D$  a quantidade de energia do contrato  $i$  no período  $t$  na modalidade disponibilidade (em  $MWméd$ );

$P_{i,t}^D$  o preço do contrato  $i$  no período  $t$  na modalidade disponibilidade (em R\$/MWh);

$G_{i,t,s}$  a geração da usina no período  $t$  e cenário  $s$ , associada ao contrato  $i$ ;

$G_i^{min}$  a geração mínima da usina associada ao contrato  $i$ ;

$CVU_i$  o custo variável unitário de geração associado ao contrato  $i$  (em R\$/MWh); e

$h_t$  o número de horas do período  $t$ .

## e) Contratos Generalizados

Visando tornar a plataforma de comercialização mais completa, incluímos ainda um tipo genérico de contrato, denominado Generalizado, a fim de atender os contratos não especificados na plataforma. Essa modalidade permite ao usuário incluir na plataforma qualquer outro tipo de contrato.

Nesses casos, o agente simplesmente cadastra o perfil de preço e quantidade do contrato. As expressões de receita e custo permanecem as mesmas dos Contratos Padrão (14) e (15).

## f) Expressão de Renda Líquida na CCEE

De acordo com o modelo vigente do setor elétrico brasileiro, todas as compras e vendas no ACL devem ser registradas na *Câmara de Comercialização de Energia Elétrica* (CCEE). Na prática, toda energia comprada e vendida por uma comercializadora é contabilizada na CCEE ao PLD. Os direitos e deveres dessa liquidação na CCEE para a comercializadora têm as seguintes expressões de receita e despesa respectivamente:

$$\begin{aligned} R_{t,s}^{CCEE} = & \sum_{\substack{i \in CC_Q \cup CC_{Gen} \\ \cup CC_{PLD}}} x_i \cdot Q_{i,t} \cdot \pi_{t,s}^{sub_i} + \sum_{i \in DC} x_i \cdot G_{i,t,s} \cdot \pi_{t,s}^{sub_i} \\ & + \sum_{i \in CC_{Flx}} x_i \cdot Q_{i,t}(\pi_{t,s}^{sub_i}) \cdot \pi_{t,s}^{sub_i} + \sum_{\substack{i \in CE_Q \cup CE_{Gen} \\ \cup CE_{PLD}}} Q_{i,t} \cdot \pi_{t,s}^{sub_i} \\ & + \sum_{i \in DE} (G_{i,t,s}^{D,F}(CVU_i, \pi_{t,s}^{sub_i}) + G_i^{min}) \cdot \pi_{t,s}^{sub_i} + \sum_{i \in CE_{Flx}} Q_{i,t}(\pi_{t,s}^{sub_i}) \cdot \pi_{t,s}^{sub_i}; \end{aligned} \quad (19)$$

$$\begin{aligned} C_{t,s}^{CCEE} = & \sum_{\substack{i \in VC_Q \cup VC_{Gen} \\ \cup VC_{PLD}}} x_i \cdot Q_{i,t} \cdot \pi_{t,s}^{sub_i} + \sum_{\substack{i \in VE_Q \cup VE_{Gen} \\ \cup VE_{PLD}}} Q_{i,t} \cdot \pi_{t,s}^{sub_i} \\ & + \sum_{i \in VC_{Flx}} x_i \cdot Q_{i,t}(\pi_{t,s}^{sub_i}) \cdot \pi_{t,s}^{sub_i} + \sum_{i \in VE_{Flx}} Q_{i,t}(\pi_{t,s}^{sub_i}) \cdot \pi_{t,s}^{sub_i}. \end{aligned} \quad (20)$$

Sendo:

$\boldsymbol{x}$  o vetor de variáveis de decisão (o elemento  $i$  do vetor  $\boldsymbol{x}$  representa o percentual da quantidade  $Q_{i,t}$  a ser contratada, sendo  $x_i \in [0,1]$ );

$CC_j$  o conjunto de contratos candidatos de compra pertencentes à modalidade  $j$ ;

$CE_j$  o conjunto de contratos existentes de compra pertencentes à modalidade  $j$ ;

$VC_j$  o conjunto de contratos candidatos de venda pertencentes à modalidade  $j$ ;

$VE_j$  o conjunto de contratos existentes de venda pertencentes à modalidade  $j$ ;

$DC$  o conjunto de contratos candidatos pertencentes à modalidade *Disponibilidade*; e

$DE$  o conjunto de contratos existentes pertencentes à modalidade *Disponibilidade*;

onde a modalidade  $j$  tal que  $j \in \{Q, Flx, PLD, Gen\}$ ;

$Q$  os contratos de *quantidade*;

$Flx$  os contratos de *quantidade* com cláusula de *flexibilidade*;

$PLD$  os contratos de *quantidade* com preços *baseados no PLD com piso e teto*;

$Gen$  os contratos generalizados.

$R_{t,s}^{CCEE}$  a receita proveniente da contabilização dos direitos da comercializadora na CCEE (R\$); e

$C_{t,s}^{CCEE}$  o custo proveniente da contabilização dos deveres da comercializadora na CCEE (R\$).

É importante ressaltar que toda quantidade de contrato comprada passa a ser um direito da comercializadora, assim como toda quantidade vendida passa a ser uma obrigação. A CCEE é o ambiente em que todos esses direitos e obrigações são liquidados ao PLD. Dessa forma, os contratos de compra geram uma liquidação positiva e os de venda uma liquidação negativa, ambos na proporção da quantidade contratada. A exceção são os Contratos de Disponibilidade, cujo direito se dá sobre o despacho de uma usina. Portanto, o saldo final da contabilização dos direitos e deveres da comercializadora na CCEE possui a expressão a seguir.

$$S_{t,s}^{CCCEE} = R_{t,s}^{CCCEE} - C_{t,s}^{CCCEE}. \quad (21)$$

### g) Expressão Final de Renda da Comercializadora

Por fim, a expressão de renda final da comercializadora para um período  $t$  e um cenário  $s$ , considerando os contratos existentes e candidatos, pode ser obtida por:

$$\begin{aligned} R_{t,s} = & S_{t,s}^{CCCEE} - \sum_{\substack{i \in DC \\ \cup VC_{Flx} \\ \cup VC_{PLD} \\ \cup VC_{Gen}}} x_i \cdot C_{i,t}^D + \sum_{\substack{i \in VC_Q \\ \cup VC_{Flx} \\ \cup VC_{PLD} \\ \cup VC_{Gen}}} x_i \cdot R_{i,t,s}^Q + \sum_{\substack{i \in VE_Q \\ \cup VE_{Flx} \\ \cup VE_{PLD} \\ \cup VE_{Gen}}} R_{i,t,s}^Q - \\ & \sum_{\substack{i \in CC_Q \\ \cup CC_{Flx} \\ \cup CC_{PLD} \\ \cup CC_{Gen}}} x_i \cdot C_{i,t,s}^Q - \sum_{\substack{i \in CE_Q \\ \cup CE_{Flx} \\ \cup CE_{PLD} \\ \cup CE_{Gen}}} C_{i,t,s}^Q. \end{aligned} \quad (22)$$

A relação entre contratos de compra e venda no período  $t$  deve satisfazer a restrição de balanço de energia, garantindo que a comercializadora não sofrerá penalidade<sup>6</sup>. Assim:

$$\begin{aligned} & \sum_{\substack{i \in VC_Q \\ \cup VC_{PLD}}} x_i \cdot Q_{i,t} + \sum_{\substack{i \in VE_Q \\ \cup VE_{PLD}}} Q_{i,t} + \sum_{VC_{Flx}} x_i \cdot Q_{i,t}^{nom} + \sum_{VE_{Flx}} Q_{i,t}^{nom} \\ & \leq \sum_{\substack{i \in CC_Q \\ \cup CC_{PLD}}} x_i \cdot Q_{i,t} + \sum_{CC_{Flx}} x_i \cdot Q_{i,t}^{nom} + \sum_{\substack{i \in CE_Q \\ \cup CE_{PLD}}} Q_{i,t} \\ & \quad + \sum_{CE_{Flx}} Q_{i,t}^{nom} + \sum_{i \in DC} x_i \cdot Q_{i,t}^C + \sum_{i \in DE} Q_{i,t}^C. \end{aligned} \quad (23)$$

### B. Critérios de risco

O problema de seleção da carteira ótima de contratos de energia consiste na escolha de ativos que desencadearão receitas futuras estocásticas. Essa natureza aleatória acarreta um problema nada trivial, pois cada possibilidade de carteira proporciona um conjunto de cenários de fluxos de caixa para cada período do horizonte de estudo. Tais cenários caracterizam sequências de distribuições de probabilidade no tempo, que, em geral, são dependentes entre si. Dessa forma, a utilização da otimização a fim de encontrar a melhor carteira de ativos exige que seja possível expressar a preferência entre diferentes fluxos de caixa estocásticos de forma analítica.

Tradicionalmente, os economistas abordam esse problema através da axiomatização de propriedades que as preferências devem ter para serem consideradas racionais. Em função desses axiomas, é possível estabelecer formas funcionais que as preferências podem exibir. O caso mais clássico é a Teoria da Utilidade Esperada [8]. Na prática, porém, essa teoria pouco contribui para a tomada de decisão de agentes financeiros, pois é difícil para empresas especificarem uma função utilidade. Destacamos [9] para uma discussão relevante em torno da aplicabilidade da Teoria de Utilidade Esperada e medidas de risco em decisões financeiras. Algumas maneiras práticas de resolver esse problema são apresentadas em [10] e [11].

Em busca de uma solução pragmática e consistente, a análise de risco ganhou espaço entre os agentes financeiros, que passaram a defini-lo em termos de perdas financeiras ou da distância em relação a uma determinada meta. Nesse sentido, o uso de medidas de risco passou a caracterizar a abordagem preferencial desses agentes e voltou os holofotes da academia ao estudo das suas propriedades e às escolhas decorrentes do seu uso. Muitas medidas de risco foram utilizadas desde o trabalho inicial de seleção de portfólio de Markowitz [14]. Originalmente, esse trabalho recorria ao desvio padrão da distribuição dos retornos de uma carteira de ativos financeiros para expressar o risco inerente à comercialização. Posteriormente, muitas outras medidas de risco foram propostas com diversos intuições.

6. De fato, a restrição de lastro contratual é verificada através de uma média móvel. Entretanto, adotamos aqui uma restrição mais conservadora.

A semivariância [15], por exemplo, foi a primeira tentativa de considerar a assimetria das distribuições e caracterizar como risco apenas os desvios negativos. Logo após, surgiu o VaR (*Value-at-Risk*) [13], que visa quantificar o valor da perda financeira que não é excedida por um determinado nível de significância. Mais recentemente, foi criado o CVaR (*Conditional Value-at-Risk*) [16] [17], que expressa o valor esperado das perdas condicional aos eventos de perdas que superaram o VaR.

Em especial, o CVaR tem recebido bastante atenção na última década, tanto pelos acadêmicos quanto pela indústria. Os principais motivos para o súbito interesse são: (i) a sua interpretação econômica intuitiva, o que permite, com uma ligeira redefinição, que ele possa ser entendido como medida de valor [17]; (ii) o seu enquadramento como medida coerente de risco, caracterizada por quatro propriedades desejáveis [12]; e, por fim, (iii) a sua forma funcional escrita como um problema de programação matemática convexo, o que proporciona uma grande vantagem algorítmica, pois não interfere na convexidade de problemas convexos ao considerarmos tal medida como métrica de otimização [16].

O CVaR, por ser uma medida de risco, é tradicionalmente definido como a média dos  $(1 - \alpha) \cdot 100\%$ <sup>7</sup> piores (maiores) cenários de perdas financeiras [16]. Entretanto, assim como em [17], vamos considerá-lo um funcional de valor para distribuições de renda ou lucro, já que o lucro da comercialização de energia é o foco do nosso estudo neste projeto. Nesse sentido, podemos definir o CVaR como a média dos  $(1 - \alpha) \cdot 100\%$  piores (menores) cenários de renda ou lucro. Na figura a seguir, ilustramos o CVaR para uma distribuição contínua de renda líquida.

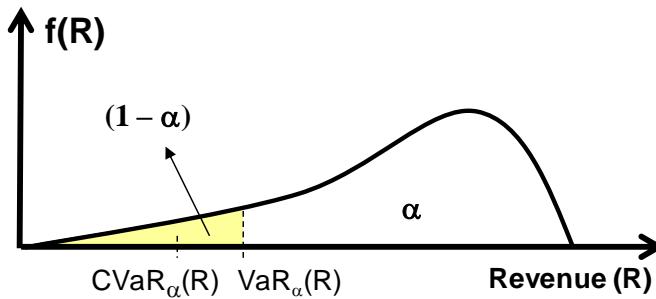


Fig. 31 – CVaR e VaR redefinidos para uma densidade de probabilidade de receita

Assim, para uma distribuição de renda líquida genérica  $\tilde{R}$ , caracterizada pelos respectivos pares de cenários e probabilidades  $\{R_s, p_s\}_{s=1}^S$ , o CVaR de  $\alpha \cdot 100\%$  pode ser obtido através do seguinte problema de programação linear:

$$CVaR_\alpha(\tilde{R}) = \max_{z, \delta} z - \frac{1}{(1 - \alpha)} \sum_{s=1}^S p_s \delta_s \quad (24)$$

sujeto a:

$$\delta_s \geq z - R_s, \quad \forall s = 1, \dots, S \quad (25)$$

$$\delta_s \geq 0, \quad \forall s = 1, \dots, S. \quad (26)$$

Como leitura complementar, destacamos a referência [17]. Nesse artigo, o Remark 3 apresenta uma interpretação bastante pragmática e objetiva para a preferência de um agente que busca otimizar o CVaR. O principal conceito a ser extraído desse trecho, que justifica o uso do CVaR como medida de risco pode ser descrito da seguinte forma: quando uma das variáveis aleatórias a analisar representa o valor do projeto, o CVaR é a medida do pior valor que esse projeto pode ter. Assim, um investidor avesso a risco que aposte em tal projeto cria um valor pessimista de referência para o seu resultado – VaR ou quantil de 5%, por exemplo – e só se arrepende do investimento caso o futuro que se realize proporcione um valor pior do que a referência com a qual contava. Nesse caso, para cada unidade abaixo da referência, tal investidor exibe um decréscimo marginal de satisfação de  $(1 - \alpha)^{-1}$ . Entretanto, para os casos em que o futuro se realize de maneira satisfatória, ou seja, acima do resultado de referência, o investidor utiliza o mesmo valor de referência para fins de tomada de decisão.

Em vista das mencionadas virtudes do CVaR, julgamos que esse funcional, definido conforme (24)-(26), é a melhor opção disponível hoje na literatura para medir o valor pessimista de segurança de um

7. Tendo como valor típico algo entre 1% e 5%.

determinado projeto. Assim, ao limitarmos o CVaR da receita a um recebimento mínimo, é possível garantir uma alta probabilidade (definida pelo usuário através do parâmetro  $\alpha$ , tipicamente entre 0.95 e 0.99) de que esse limite não seja ultrapassado.

No caso multiperíodo, foco deste relatório, o controle do risco deve ser realizado não somente em relação ao total acumulado do resultado financeiro, mas também sobre cada período. Isso decorre da possibilidade de endividamento para cobrir resultados negativos das empresas. Nesse sentido, diversas abordagens podem ser utilizadas a fim de controlar o risco financeiro quando as decisões apresentam consequências em mais de um período. Essas abordagens serão listadas a seguir supondo um horizonte de tempo de  $T$  períodos em que uma função de renda líquida estocástica genérica, dada por  $\{\tilde{R}_t(\mathbf{x})\}_{t=1}^T$ , é decorrente das decisões de comercialização representadas pelo vetor de decisões  $\mathbf{x}$ . Em todos os exemplos a seguir, assumiremos que o processo estocástico (sequência temporal de variáveis aleatórias) realiza um conjunto de cenários discreto e finito com probabilidades conhecidas:  $\{R_{ts}(\mathbf{x}), p_s\}_{t,s=1}^{T,S}$ .

### a) Restrição de CVaR mínimo por período

Esse caso se justifica toda vez que a política de risco da empresa não desejar contar com os lucros acumulados de períodos anteriores para garantir o resultado mínimo por período exigido. Assim, aplicamos uma restrição de CVaR para cada período da seguinte forma:

$$CVaR_\alpha(\tilde{R}_t(\mathbf{x})) \geq R_t^{min}, \quad \forall t = 1, \dots, T. \quad (27)$$

### b) Restrição de CVaR acumulado mínimo por período

Esse caso se aplica toda vez que a política de risco da empresa desejar contar com os lucros acumulados para garantir o resultado mínimo exigido por período. Essa política deve ser empregada ao caixa da empresa ou da área de comercialização. Assim, utilizamos uma restrição de CVaR sobre o caixa ( $\tilde{C}_t$ ) para cada período da seguinte forma:

$$\tilde{C}_t = \tilde{C}_{t-1} + \tilde{R}_t(\mathbf{x}), \quad \forall t = 1, \dots, T \quad (28)$$

$$CVaR_\alpha(\tilde{C}_t) \geq R_t^{min}, \quad \forall t = 1, \dots, T. \quad (29)$$

### c) Risco máximo por período

Essa política impõe que o Valor Esperado da renda líquida menos o CVaR seja superior a um valor mínimo por período.

$$\mathbb{E}[\tilde{R}_t(\mathbf{x})] - CVaR_\alpha(\tilde{R}_t(\mathbf{x})) \geq R_t^{min}, \quad \forall t = 1, \dots, T. \quad (30)$$

Outro meio de considerar a aversão a risco na tomada de decisão é incluir o CVaR na função objetivo. Nesse caso, a relevância do CVaR na função objetivo pode ser conjugada com a do valor esperado incondicional por meio de uma combinação convexa entre ambos. De acordo com [17], se um agente toma suas decisões de modo a maximizar o CVaR da decisão resultante, este pode ser entendido como o Equivalente Certo (EC) do agente. O EC de uma distribuição de renda pode ser definido como o menor valor financeiro (determinístico) que um agente estaria disposto a trocar por essa distribuição, ou seja, o valor determinístico de indiferença com o fluxo incerto. Como o CVaR de um montante determinístico assume o valor do próprio montante, então, o Equivalente Certo ( $EC(\tilde{R})$  em R\$) de uma distribuição de renda genérica  $\tilde{R}$  pode ser encontrado através da seguinte relação:  $CVaR_\alpha(EC(\tilde{R})) = CVaR_\alpha(\tilde{R})$ , que resulta em  $EC(\tilde{R}) = CVaR_\alpha(\tilde{R})$ . Como a combinação convexa entre o CVaR e o valor esperado da renda líquida possui unidade monetária, a métrica descrita no próximo tópico pode ser utilizada como função objetivo.

**d) Métrica de otimização baseada no valor presente das combinações entre CVaR e valor esperado de cada período**

$$EC(\{\tilde{R}_t(\mathbf{x})\}_{t=1}^T) = \sum_{t=1}^T \left[ \frac{\lambda \cdot CVaR_\alpha(\tilde{R}_t(\mathbf{x})) + (1 - \lambda) \cdot \mathbb{E}(\tilde{R}_t(\mathbf{x}))}{(1 + K)^t} \right]. \quad (31)$$

Essa medida, valor presente do fluxo de equivalentes certos ao longo do horizonte, envolve o custo de capital livre de risco  $K$  (em % equivalente por período) e o parâmetro de aversão a risco  $\lambda \in [0,1]$ . Esse parâmetro define a proporção da função objetivo que será destinada ao CVaR e ao valor esperado de cada período, onde  $\lambda = 1$  significa 100% avesso a risco e  $\lambda = 0$ , totalmente neutro a risco. Essa métrica pode ser entendida como o Equivalente Certo do fluxo financeiro e, assim, a expressão (31) pode ser otimizada e conjugada com os critérios de restrição de risco anteriormente descritos.

**e) Métrica de otimização baseada na combinação entre o VPL e o CVaR do VPL de cada período**

$$EC(\{\tilde{R}_t(\mathbf{x})\}_{t=1}^T) = \lambda \cdot CVaR_\alpha(VPL(\tilde{R}_t(\mathbf{x}))) + (1 - \lambda) \cdot \mathbb{E}[VPL(\tilde{R}_t(\mathbf{x}))], \quad (32)$$

$$\text{onde, } VPL(\tilde{R}_t(\mathbf{x})) = \sum_{t \in T} \frac{\tilde{R}_t(\mathbf{x})}{(1 + K)^t}.$$

Essa medida também envolve o custo de capital livre de risco  $K$  (em % equivalente por período) do agente e o parâmetro de aversão a risco  $\lambda \in [0,1]$ , além de se assemelhar a (31).

### C. O modelo de otimização

Uma vez apresentada a modelagem matemática dos contratos e as medidas de risco adotadas na comercialização, o modelo de otimização utilizado na plataforma está formado e pode ser descrito como:

$$EC^* = \max_{\mathbf{x}} \{ (31) \text{ ou } (32) \}$$

sujeito a:

(22) → Expressão da Renda da Comercialização

(23) → Balanço de Energia

(27)-(29)-(30) → Restrições de Risco, caso o agente queira adotá-las.

Sendo que  $\mathbf{x}$  é o vetor de quantidades dos contratos candidatos.

## V. ESTUDOS DE CASO DE CONTRATAÇÃO ÓTIMA

### A. Motivação

A fim de evidenciar a importância das ferramentas desenvolvidas durante o projeto para a precificação dos riscos na comercialização de energia renovável no ACL, esta seção começa apresentando um breve estudo de caso. Nele, buscamos evidenciar a importância de um modelo de geração de cenários que capture a correlação entre a geração renovável (intermitente) e o PLD para precificar um contrato de venda lastreado em uma usina eólica.

O estudo supõe um parque eólico no Nordeste (fictício, mas com dinâmica histórica baseada em um caso real) com 1 MWmédio de lastro 100% contratado por quantidade a 100 R\$/MWh no mesmo submercado. Nesse contexto, analisaremos as consequências das diferentes maneiras de tratar os fatores de risco (geração eólica e PLD) na distribuição de renda do gerador. Três métodos foram escolhidos para simular esses cenários de geração.

- I. **Cenários independentes do PLD via Bootstrap:** aplicar a técnica de *bootstrap* (geração de cenários a partir da seleção aleatória dos anos do histórico) no histórico de geração da usina, que proporciona resultados estatisticamente independentes do PLD.
- II. **Cenários independentes do PLD via Modelo Estatístico:** utilizar o modelo estatístico apresentado neste relatório sem levar em consideração as variáveis operativas do sistema e, consequentemente, obter cenários simulados também independentes do PLD.
- III. **Cenários casados com o PLD via modelo estatístico:** recorrer ao modelo estatístico desenvolvido no projeto, utilizando sua capacidade de gerar séries de FC correlacionadas aos cenários de PLD provenientes de um caso de simulação operativa.

Em II e III, a mesma estrutura temporal de modelo é utilizada, entretanto, no caso II, a sazonalidade é tratada através de variáveis *dummies* e no caso III, através das ENAs. Nos três casos, a análise é feita sob a mesma ótica: calcula-se a renda mensal durante um ano de contrato para cada um dos cenários de geração das três modalidades. A partir da renda mensal, obtém-se a renda anual de cada cenário apenas somando, para cada série, os valores mensais. Com as séries de renda anuais, analisamos o risco da comercialização a partir da sua curva de pertinência, que mede a probabilidade de ocorrência de determinado valor de renda. Essa curva pode ser entendida como a curva de probabilidade acumulada transposta, em que a probabilidade acumulada encontra-se no eixo horizontal e os quantis de renda (ou cenários de renda anual) associados a cada probabilidade acumulada se encontram no eixo vertical. Apresentamos o gráfico comparativo com as curvas de pertinência de cada modalidade a seguir.

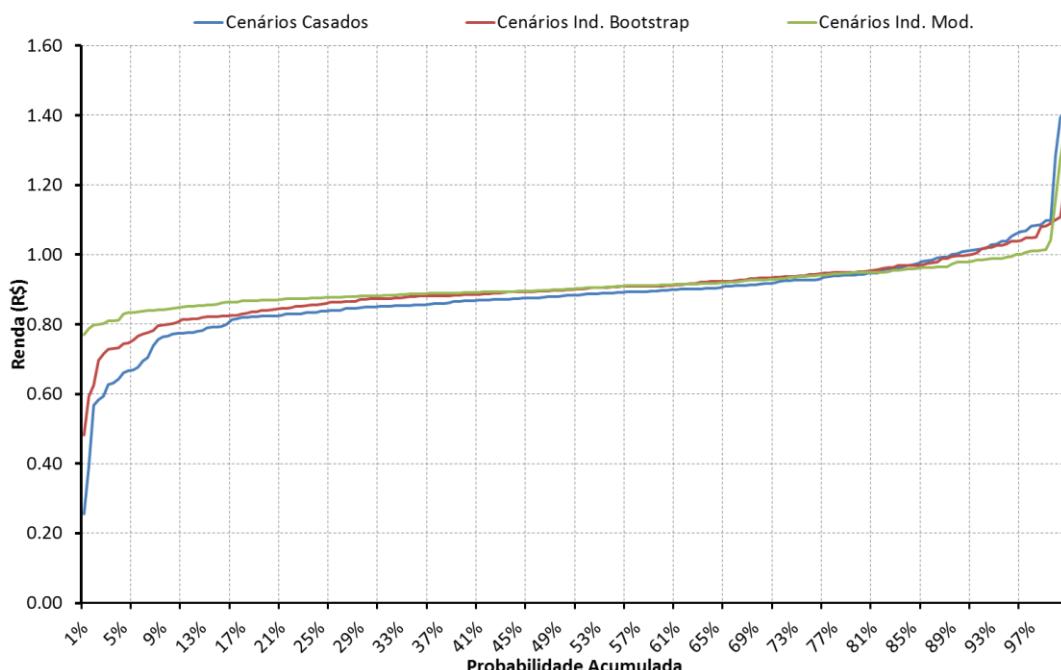


Fig. 32 – Comparação do risco na comercialização utilizando-se três maneiras diferentes de obter os cenários de geração

A informação mais importante a extrair Fig. 32 está na calda esquerda das curvas. É possível perceber que os piores cenários de renda ocorreram quando as séries utilizadas foram extraídas do modelo V&V (caso III). Isso significa que esse método de geração de cenários captura um risco não apreendido pelos demais modelos, que pressupõem independência do PLD. Já o método por *bootstrap* (I), bastante utilizado por agentes do setor, captura levemente o risco da contratação, mas não de maneira eficaz. Essencialmente, vemos que os três modelos quase “concordam” nos cenários medianos. O ponto de discordância está justamente nos cenários mais arriscados, onde os dois modelos que não capturam a correlação da geração eólica com o PLD subestimam o risco na contratação. Consequentemente, podemos concluir que o modelo de geração de cenários desenvolvido no projeto proporciona uma informação mais acurada sobre o risco na comercialização de energia renovável no ACL.

## B. Estudos de caso

### a) Estudo de Caso 1: Eólica e PCH

Neste estudo de caso, analisaremos, sob a ótica de um comercializador, a formação de um portfólio de compra de energia proveniente de duas usinas renováveis, uma eólica e uma PCH. Esse portfólio será constituído via contratos por disponibilidade, com entrega nos respectivos submercados dos geradores renováveis – PCH no Sudeste e Eólica no Nordeste –, para lastrear a venda de um contrato de quantidade com um consumidor livre no submercado Sudeste. O estudo terá duração de um ano, com todos os contratos iniciando em janeiro de 2014, em etapas mensais. Um dos nossos objetivos é determinar a partir de qual preço de venda esse negócio é vantajoso para o comercializador. Além disso, apresentaremos uma maneira alternativa de caracterizar o perfil de aversão ao risco do agente comercializador através de “restrições de risco”.

Como decisão do modelo, teremos as quantidades de compra e venda dos contratos candidatos do comercializador: contratos de disponibilidade com as renováveis e de venda por quantidade com um consumidor. Esse portfólio será otimizado de forma a maximizar o valor da comercialização para o agente. A fim de atender toda a oportunidade de venda, o comercializador pode se contratar apenas com uma das duas fontes ou com uma combinação das duas, desde que o montante “comprado” (MWmédio) garanta uma quantidade de lastro suficiente para cobrir o contrato de venda. Antes de apresentar os resultados do estudo, explicaremos as etapas para a sua realização com o auxílio da plataforma de comercialização em desenvolvimento no projeto.

Na ferramenta de comercialização, adicionaremos dois contratos candidatos de compra do tipo disponibilidade: um deles firmado com uma PCH situada no Sudeste e outro, com uma eólica no Nordeste, ambas com potência instalada de 30 MW. Para cada um deles é necessário associar os arquivos de cenários simulados de geração por unidade de garantia física para todo período de vigência do contrato. Tais cenários podem ser provenientes da ferramenta V&V, em desenvolvimento no projeto, ou de um arquivo de entrada independente, fornecido pelo usuário.

As garantias físicas da usina eólica e da PCH são, respectivamente, 11.5 MWméd e 18.4 MWméd. Para o contrato de venda, cadastramos um contrato candidato de quantidade com 10 MWméd. Nossa ideia é emular uma situação em que o agente tenha a opção de atender toda a oportunidade de venda com apenas uma das fontes, caso isso corresponda à solução ótima. Como ponto de partida, adotaremos o preço de 100 R\$/MWh para o contrato de venda.

Em relação aos critérios de risco, utilizaremos um perfil de neutralidade a risco, o que equivale a um agente que maximiza o valor esperado da renda. Na plataforma, isso se traduz como  $\lambda = 0$ . Por fim, devemos cadastrar também os dados de PLD dos dois subsistemas presentes na análise – SE e NE. Cadastrados os preços, podemos otimizar a carteira do comercializador.

Veja a seguir o resultado deste primeiro estudo:

Preço Venda (R\$/MWh)	Contratação PCH	Contratação Eólica	Contratação Venda
100	0%	0%	0%

Tabela 5 – Estratégia otimizada de comercialização

O procedimento descrito até aqui nos permitiu analisar um caso base, em que a preferência do agente não considera o tradeoff entre risco e retorno. Assim sendo, esse caso não corresponde a um estudo aprofundado de comercialização e ainda é pobre no que diz respeito à disposição a contratar do agente comercializador. Como podemos realizar uma análise de sensibilidade mais profunda? Como variam as contratações em relação à medida de risco adotada e, principalmente, em relação ao preço do contrato de venda? Para responder a essas perguntas é necessário simular o caso diversas vezes, para diferentes preços e diferentes medidas de risco. Assim, foram realizados três conjuntos de estudos variando o preço do contrato de venda entre 100 e 200 R\$/MWh. A diferença entre cada um desses conjuntos está apenas nos critérios de risco adotados.

1. Função objetivo igual ao valor esperado ( $\lambda = 0$ ).
2. Função objetivo igual à combinação linear entre  $CVaR_{95\%}$  e valor esperado ( $\lambda = 0.5$  e  $\alpha = 95\%$ ).
3. Função objetivo igual ao  $CVaR_{95\%}$  ( $\lambda = 1$  e  $\alpha = 95\%$ ).

Para todos os casos, o otimizador sugere não contratar nenhuma das oportunidades de compra e venda até que o preço do contrato de venda seja significativamente maior do que a média do PLD do subsistema desse contrato. Isso cria uma curva de disposição a contratar na forma de degrau. Isso significa que até determinado preço não se contrata nenhuma das oportunidades de compra ou de venda; em contrapartida, a partir desse preço, a indicação é contratar totalmente a oportunidade de venda. Veja o resultado dos três estudos na tabela abaixo.

	$CVaR_{95\%}$	$0.5 \cdot CVaR_{95\%} + 0.5 \cdot E[ ]$	$E[ ]$
<b>Preço de Gatilho (R\$/MWh)</b>	185	155	115
<b>Contratação PCH (MWmédio)</b>	7.65	5.13	0.00
<b>Contratação Eólica (MWmédio)</b>	9.52	11.40	10.00
<b>Contratação Venda (MWmédio)</b>	10.00	10.00	10.00

Tabela 6 – Resultados da comercialização otimizada para diferentes funções objetivo

Por fim, apresentaremos uma outra maneira de considerar o perfil de aversão a risco do agente comercializador, inserindo uma “restrição de risco” ao estudo. Vamos considerar como medida de valor da comercialização (função objetivo) o valor esperado dos cenários de renda ( $\lambda = 0$ ) e acrescentar uma restrição determinando que o  $CVaR_{95\%}$  da renda em cada mês do estudo seja superior -1 MMR\$. Essa restrição é equivalente a limitar o CVaR da perda a 1 MMR\$.

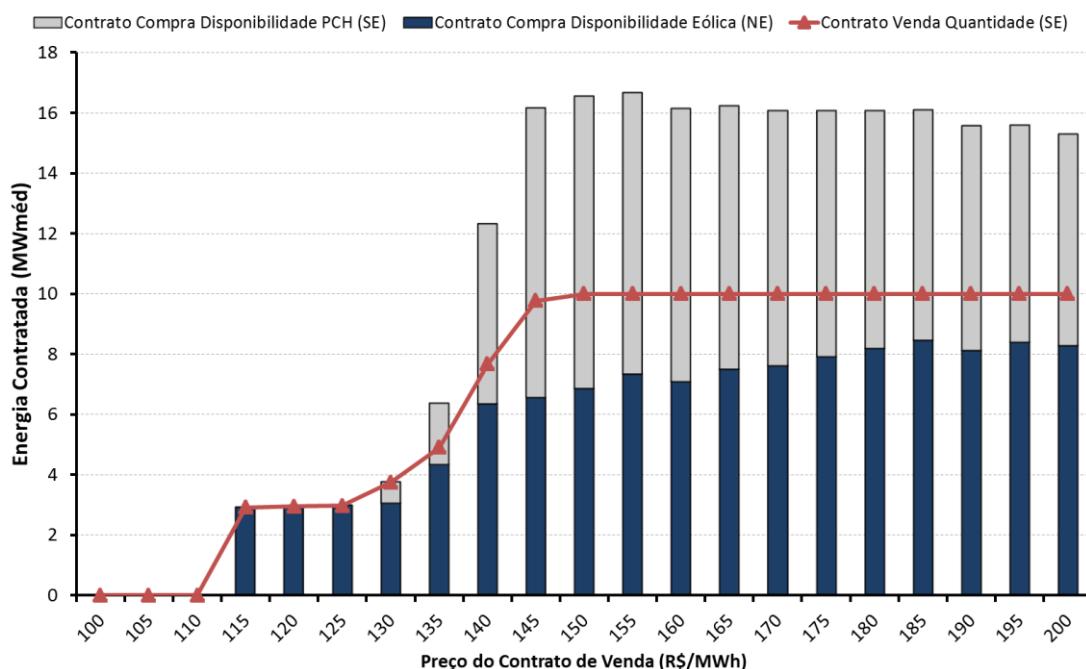


Fig. 33 – Análise de contratação de portfólio renovável

No gráfico acima são exibidos os montantes ótimos de compra e venda dos contratos candidatos para cada possível preço do contrato de venda. Ao observá-lo, é possível perceber que, a partir de 150 R\$/MWh, passa a ser ótimo contratar 100% da oportunidade de venda (10 MWméd). Outro fato interessante de notar é a maneira como se dá a formação do portfólio de renováveis. Conforme era de se esperar, é vantajoso para o agente diversificar o portfólio de compra, tirando proveito dos benefícios do efeito portfólio. Com isso, é possível reduzir a sazonalidade e intermitência inerentes à geração das renováveis, principal fator de risco da comercialização desse tipo de fonte. E mais, a solução ótima indica a contratação de um montante além da quantidade do contrato de venda. Essa é uma forma de se proteger do risco de preço e quantidade, resultante da absorção de todo o risco da geração das renováveis, decorrente das compras por disponibilidade, para vender um contrato por quantidade. O risco de preço e

quantidade se materializa em cenários de baixa geração e alto valor de PLD. Nesses cenários, o comercializador deve comprar no mercado *spot* para cobrir a quantidade contratada a um PLD que pode valer seis vezes o preço do contrato, podendo onerar substancialmente o fluxo de caixa do empreendedor.

Esse mesmo estudo pode ser realizado para uma situação ligeiramente diferente, em que o contrato de venda é firmado com um consumidor no Nordeste. Neste caso, podemos proceder com a mesma análise do caso anterior.

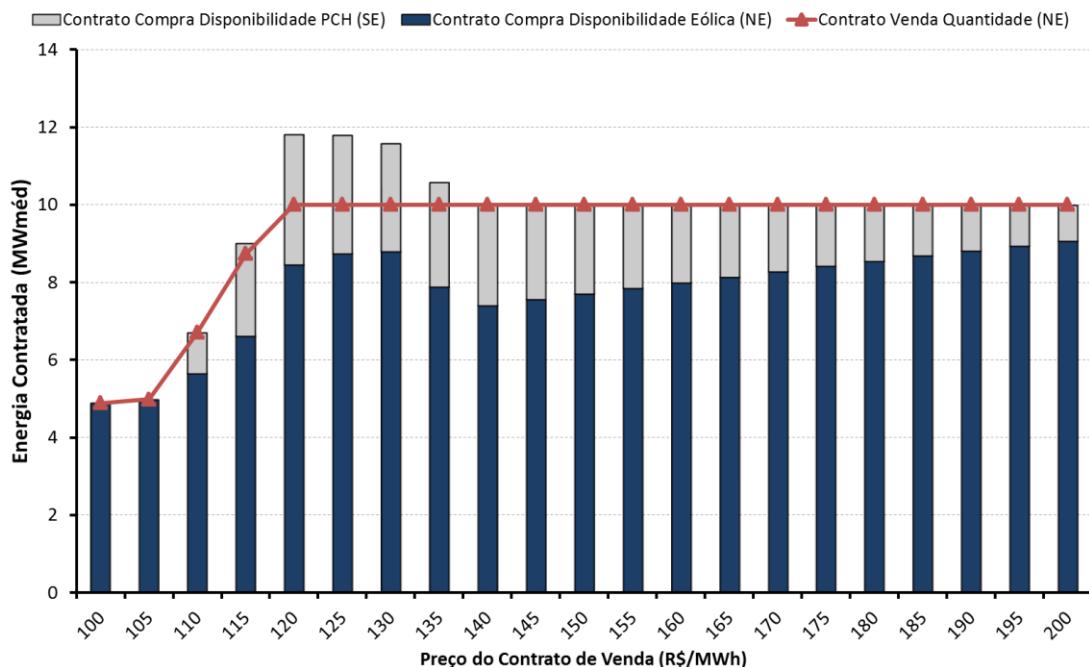


Fig. 34 – Análise de contratação de portfólio renovável por disponibilidade lastreado um contrato de venda no Nordeste por quantidade

É possível constatar que o preço de venda a partir do qual o comercializador decide entrar 100% no negócio é bastante inferior ao caso em que a venda é realizada no submercado Sudeste, passando de 150.00 para 120.00 R\$/MWh. Isso indica que o sobrepreço necessário para compensar o risco de comprar por disponibilidade das renováveis nos seus submercados e revender por quantidade no Nordeste gera um negócio menos arriscado do que vender no Sudeste. Essa conclusão está embasada no fato de que os PLDs do Nordeste são levemente mais baixos que os do Sudeste. Assim, a liquidação na CCEE da parcela da PCH, que está no Sudeste, implica uma receita superior ao custo referente à liquidação na CCEE relativa à parcela do contrato de venda, quando este está no Nordeste.

### b) Estudo de Caso 2: Eólica e Térmica a gás

O objetivo deste estudo é determinar o valor que 1 MWhméd de contrato de disponibilidade com uma unidade termelétrica tem para um gerador eólico que comercializa, no ACL, sua energia no seu submercado, Nordeste. Vamos assumir que a eólica vende um contrato de quantidade padrão *flat* para um consumidor livre do Nordeste. Para criar um *hedge* contra o risco de preço e quantidade, ela decide adquirir 1 MWhméd de contrato de disponibilidade com uma termelétrica também no Nordeste, o que equivale à aquisição de uma opção de compra de energia com preço de exercício igual ao CVU (custo variável unitário, em R\$/MWh) da térmica. Em todos os cenários em que o PLD assume um valor superior a CVU, o contrato pagará ao seu comprador (gerador eólico), a diferença entre PLD e o CVU. Assim, esse contrato protege o gerador eólico em momentos de baixa produção e alto PLD. **Para efeitos práticos, ao longo deste estudo de caso, denominaremos o contrato de compra de disponibilidade térmico como contrato de hedge ou opção de compra.**

O valor (ou prêmio) da opção de compra para o gerador eólico depende implicitamente do risco que este está exposto, logo, do contrato de venda que esse gerador comercializa com o consumidor livre. Para

um gerador 100% contratado, o risco de preço e quantidade é maior que para um gerador que otimiza o montante de venda de maneira a considerar esse risco. Assim sendo, vamos calcular o valor da opção de compra para ambos os casos e, então, encontrar limites para o valor do *hedge* que essa opção pode proporcionar. Por fim, entendendo que a decisão de compra do contrato de *hedge* e a decisão de venda do contrato de quantidade são dependentes, vamos abordar um terceiro caso em que o gerador eólico traça sua estratégia ótima de venda levando em conta o efeito de *hedge* da opção de compra. Assim, vamos traçar a oferta ótima de contrato de venda de energia de maneira conjunta à demanda ótima pela opção de compra para cada possível preço (ou prêmio) dessa opção.

Para os três casos, vamos assumir um gerador eólico no Nordeste do Brasil com 30 MW de potência disponível e garantia física igual a 11.5 MWméd, bem como um contrato de venda de quantidade padrão de um ano a 100 R\$/MWh com montante igual à garantia física da usina, 11.5 MWméd. Se otimizássemos a comercialização desse contrato a esse preço, sem a opção de compra, obteríamos como contratação ótima um montante 9.54 MWméd (aproximadamente 83% da garantia física) e um CVaR de MMR\$ 7.59.

A opção de compra terá um valor de exercício (CVU) de 90 R\$/MWh. Assim sendo, toda vez que o PLD assumir um valor acima desse patamar, o contrato de *hedge* dará o direito ao gerador eólico de comprar 1 MWméd de energia a 90R\$/MWh. Conforme mencionado anteriormente, vamos abordar os seguintes casos:

- (i) gerador eólico com 100% da garantia física contratada no ACL,
- (ii) gerador eólico com quantidade de contrato de venda otimizado e
- (iii) gerador eólico com contrato de venda e opção de compra otimizados em conjunto.

Os casos (i) e (ii) seguirão uma metodologia de busca pela indiferença, onde o valor do portfólio do gerador eólico considerando a opção de compra, além do contrato de venda, será contrastado com o valor do portfólio somente com o contrato de venda. Para isso, o preço do contrato de *hedge* (preço fixo pago pelo contrato de disponibilidade com a termelétrica) será variado até que o CVaR da renda anual do portfólio considerando o contrato de *hedge* se iguale ao CVaR do portfólio da eólica somente com o contrato de venda. Esperamos identificar um valor muito mais alto para o preço de indiferença no caso (i) do que para o caso (ii). Isso se deve ao fato de que o valor do *hedge* para um contrato não otimizado deve ser maior do que para um contrato que foi otimizado justamente para minimizar o risco para o qual o contrato de *hedge* oferece proteção. Já no caso (iii), como analisamos a possibilidade do gerador eólico realizar a venda da energia de maneira conjunta com a compra do contrato de *hedge*, o que desejamos identificar é o surplus na quantidade ótima de contrato de venda de energia, acima da quantidade ótima que o gerador venderia sem o *hedge*, que o contrato de *hedge* permite o gerador eólico realizar.

Como estamos realizando o estudo sob o ponto de vista do gerador eólico e a ferramenta de comercialização contempla o caso geral de um agente comercializador, podemos pensar que a comercializadora “compra” por disponibilidade a produção da eólica a preço nulo, simulando uma situação em que o comercializador é o dono do parque gerador. Uma vez que o preço do contrato é 0, ao inserirmos um contrato candidato de compra por disponibilidade com 100% da garantia física do gerador eólico, a estratégia ótima será sempre comprar todo o montante deste contrato, resultando no aluguel de 100%, a custo zero, desse gerador.

#### Caso (i): Gerador eólico com 100% da garantia física contratada no ACL

Para realizar este estudo, devemos adicionar três contratos na ferramenta de contratação. A oportunidade de venda segue o mesmo padrão apresentado no estudo de caso anterior (venda de um contrato por quantidade). Contudo, como o montante contrato é fixo, ele deve ser tratado como um contrato existente.

O mesmo procedimento deve ser seguido para a opção de compra de um contrato de disponibilidade com a termelétrica. O cadastro do contrato deve ser feito em Contratos Existentes, adicionando um contrato por disponibilidade “Térmica”. Além do CVU de 90 R\$/MWh, os parâmetros da opção são potência e garantia física de 1 MW e geração mínima de 0 MW. Os cenários de geração desse contrato são formados automaticamente pela plataforma em função dos cenários de PLD associados à opção. Como mencionado anteriormente, um contrato de compra de disponibilidade com o gerador eólico, a preço zero e quantidade igual a 100% da garantia física, deve ser inserido como contrato existente.

Uma vez cadastrados os contratos, a figura abaixo apresenta o CVaR da renda anual do portfólio com e sem o contrato de *hedge*, para distintos valores do preço do contrato de *hedge*.

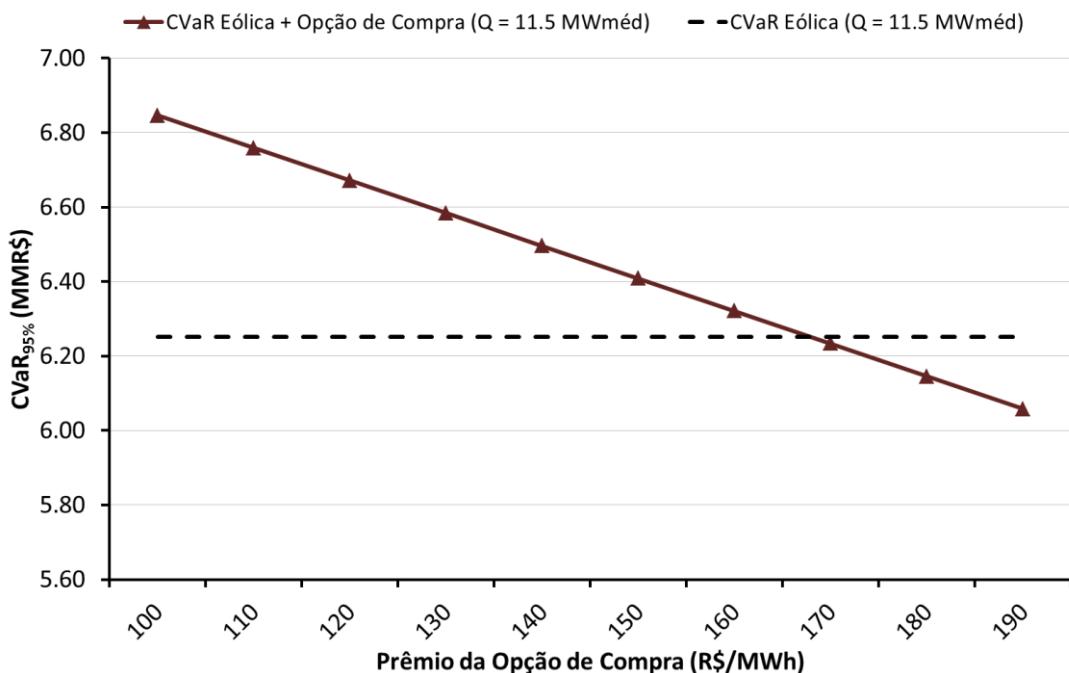


Fig. 35 – Evolução do CVaR<sub>95%</sub> da eólica com e sem a opção de compra ao longo do valor do prêmio da opção para o caso de 100% contratado (11.5 MWméd)

Neste estudo percebemos que o valor de indiferença entre ter e não ter a opção de compra, em termos de CVaR, é de 170 R\$/MWh. O que se conclui é: este gerador eólico estaria disposto a pagar um prêmio de até 170 R\$/MWh pela opção de compra de 1 MWmédio a 90 R\$/MWh para se proteger do risco de preço e quantidade produzido pela venda, por quantidade, de 100% de sua GF a 100R\$/MWh no ACL (Nordeste).

#### Gerador eólico com quantidade de contrato de venda otimizado

Este segundo estudo tem características muito semelhantes ao estudo anterior. A única diferença está no montante contratado da oportunidade de venda pela eólica, que assumiremos ser de 9.54 MWméd (como mencionado anteriormente, 83% da GF do gerador eólico). Na plataforma, basta substituirmos o valor de 11.5 atribuído ao contrato de quantidade padrão de venda existente por 9.54 e proceder como no estudo anterior. Essa quantidade pode ser encontrada ao se considerar o contrato de venda de quantidade como candidato, sem o contrato de hedge, e otimizando o CVaR do VPL da renda, considerando uma taxa de desconto de 0% a.a. O gráfico a seguir mostra o novo ponto de indiferença.

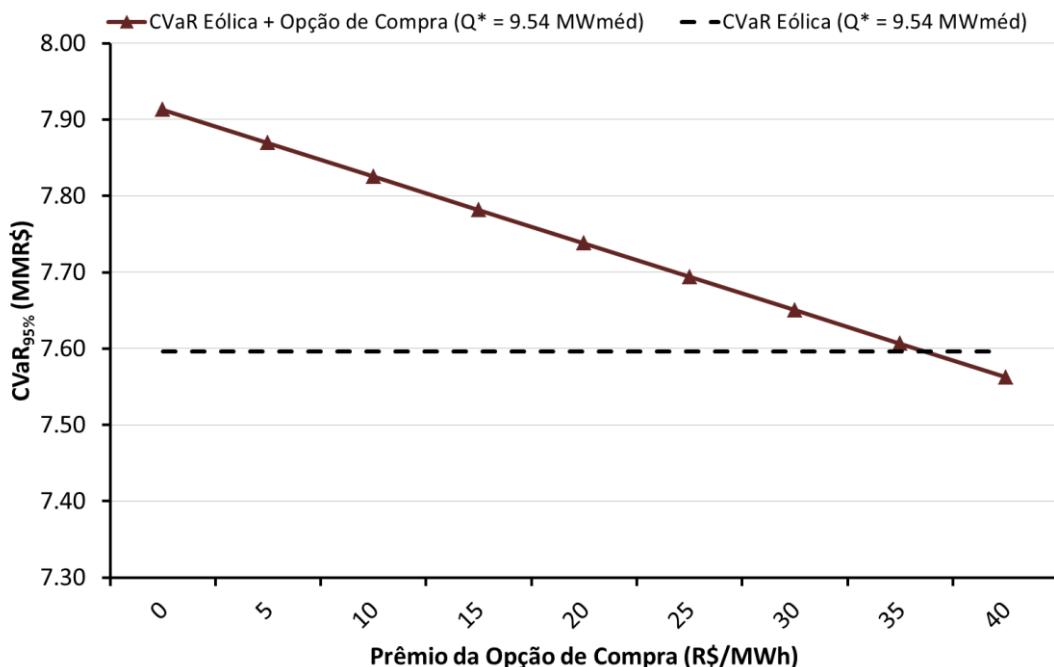


Fig. 36 – Evolução do CVaR<sub>95%</sub> da eólica com e sem a opção de compra ao longo do valor do prêmio da opção para o caso de otimamente contratado (9.54 MWméd)

O principal efeito que percebemos é a drástica queda no valor de indiferença, que passa a valer 35 R\$/MWh. Esse resultado era esperado e coerente, pois, na medida em que a contratação da eólica é otimizada para maximizar o CVaR da renda anual, o valor base de comparação, CVaR da renda somente com o contrato de venda, sobe bastante: de 6.25 para 7.59 MMR\$. Além disso, diminui a necessidade de proteção que o contrato de hedge pode proporcionar em cenários de PLD alto, pois a quantidade ótima de venda é inferior a 100% da GF da eólica justamente para mitigar casos de geração inferior ao montante de contrato em períodos de PLD alto. Consequentemente, diminui também o prêmio pago pelo hedge.

#### Gerador eólico com contrato de venda e opção de compra otimizados em conjunto

Por fim, vamos analisar o comportamento da comercialização em um caso em que ambas as quantidades – montante de venda e opção de compra – são otimizadas conjuntamente. Na plataforma, são poucas as alterações a serem feitas. Basta que os dois contratos cadastrados como existentes nos estudos anteriores (disponibilidade com a termelétrica e quantidade padrão de venda) sejam cadastrados como candidatos. Assim, para distintos valores de prêmio para a opção de compra, encontramos os montantes ótimos de contrato de venda no ACL e de compra dessa opção. O gráfico a seguir ilustra os valores de quantidade ótima de ambos os contratos otimizados conjuntamente. Neste mesmo gráfico, o CVaR da renda anual do portfólio otimizado (venda + contrato de hedge) e do portfólio somente com o contrato de venda otimizado é contrastado.

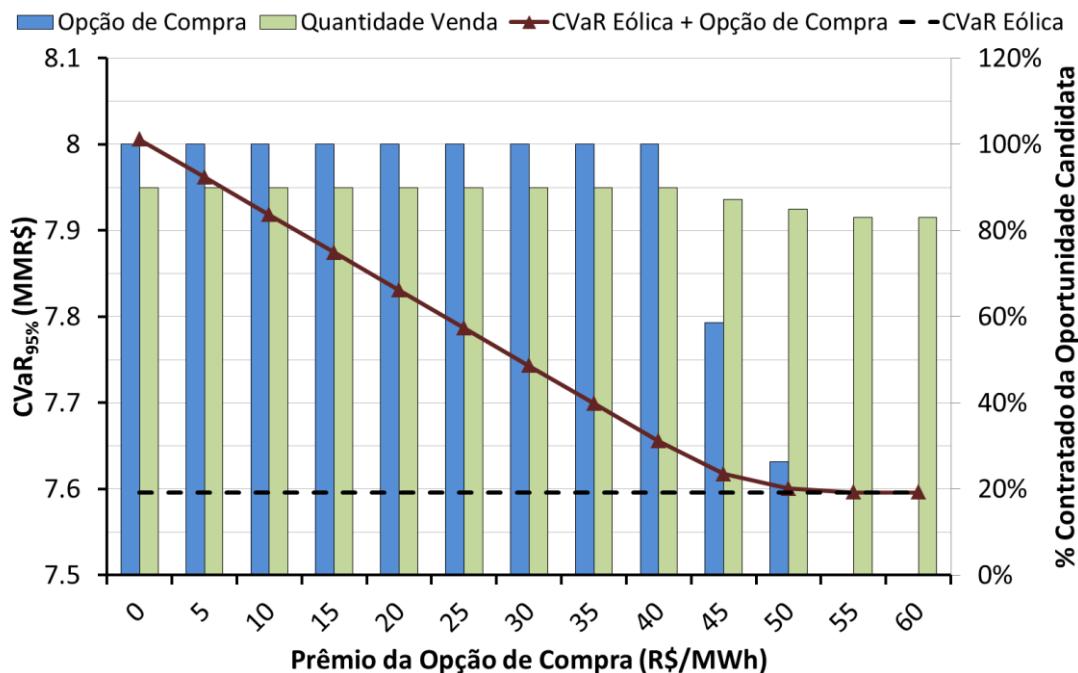


Fig. 37 – Evolução do CVaR<sub>95%</sub> da eólica com e sem a opção de compra e do % contratado da oportunidade candidata com relação ao prêmio da opção de compra

Pela figura acima, podemos perceber que, até 40 R\$/MWh, a decisão ótima seleciona 100% da opção de compra (1 MWmédio) e o montante de venda por quantidade ótimo sobe de 83% para 90% da GF da eólica (9.54 para 10.35 MWmédio).

## VI. CONCLUSÃO

Neste relatório, foram apresentadas as partes que constituem a plataforma de comercialização de energia. Ela pode ser dividida em dois componentes: a ferramenta V&V, que simula cenários de fator de capacidade (FC) e vazão (Vz) com variáveis operativas do sistema elétrico, e a ferramenta de contratação de energia, que determina a contratação ótima de uma comercializadora no ACL considerando diferentes modalidades de contratos de energia.

A versão final da ferramenta V&V foi desenvolvida a partir de um modelo VARX (*Vector AutoRegression with eXternal variables*) que utiliza como variáveis explicativas o histórico de vento e vazão dessas fontes e as ENAs de cada submercado brasileiro. Estudos desenvolvidos com a ferramenta V&V indicaram um R2 de 76.86% para o FC de uma eólica no Nordeste e de 75.49% para a Vz de uma PCH no Sudeste. O modelo é genérico e pode ser utilizado para qualquer usina com padrão de produção sazonal e intermitente.

Já a versão final da ferramenta de contratação de energia considera, além de diferentes modalidades de contratos de energia, vários critérios de risco que um usuário pode adotar. O objetivo desta segunda ferramenta é proporcionar uma primeira aplicação rentável da principal inovação deste projeto: o modelo V&V. Estudos desenvolvidos com essa ferramenta indicam que os cenários produzidos pela ferramenta V&V são capazes de capturar o risco potencializado pela dependência entre a incerteza da geração renovável e do PLD. Essa informação é bastante solicitada por comercializadoras e investidores, dado que indica com maior precisão os piores resultados possíveis associados às possíveis estratégias de contratação no ACL. O modelo de contratação de energia desenvolvido no projeto também é bastante abrangente, podendo simular contratos de energia no ACL e ACR com diferentes fontes de energia (renováveis e convencionais).

No último quadrimestre desse projeto vamos finalizar a interface da ferramenta V&V e demonstrar estudos adicionais que podem ser realizados com esta ferramenta. Nesses estudos vamos abordar uma contribuição para o sistema como um todo, modelando as bacias eólicas do Brasil e produzindo cenários que podem capturar os benefícios para a operação e expansão do sistema.

## Referências Bibliográficas

- [1] ANEEL – Agência Nacional de Energia Elétrica. **Resolução Normativa ANEEL Nº 5163**, de 30 de julho de 2004.
- [2] MME – Ministério das Minas e Energia. **Modelo institucional do setor elétrico**, Brasília, dezembro de 2003.
- [3] PROINFA – Programa de Incentivo às Fontes Alternativas de Energia Elétrica. [Online]. Disponível em: <http://www.mme.gov.br/programas/proinfa/>.
- [4] LÜTKEPOHL, H. **Introduction to Multiple Time Series Analysis**. Berlin: Springer-Verlag, 1993.
- [5] KENNEDY, P. **A guide to econometrics**. 3. ed. Massachusetts: The MIT Press, 1992.
- [6] HAMILTON, J.D. **Time Series Analysis**. New Jersey: Princeton University Press, 1994.
- [7] JOHNSON, R. e WICHERN, D. **Applied Multivariate Statistical Analysis**. Prentice Hall, 1992.
- [8] LUENBERGER, D. **Investment Science**. New York: Oxford University Press, 1997.
- [9] STREET, A. **Equivalente Certo e Medidas de Risco em decisões de Comercialização de Energia Elétrica**. Rio de Janeiro. 2008. 174p. Tese de Doutorado – Departamento de Engenharia Elétrica, Pontifícia Universidade Católica do Rio de Janeiro (PUC-Rio).
- [10] STREET, A. **Estratégia de Oferta de Geradoras em Leilões de Contratação de Energia Elétrica**. Rio de Janeiro, 2004. 103p. Dissertação de Mestrado – Departamento de Engenharia Elétrica, Pontifícia Universidade Católica do Rio de Janeiro (PUC-Rio).
- [11] STREET, A.; BARROSO, L. A.; GRANVILLE, S.; e PEREIRA, M. V. "Bidding Strategy under Uncertainty for Risk-Averse Generator Companies in a Long-Term Forward Contract Auction". **Power & Energy Society General Meeting**, 2009. PES'09. IEEE , p. 1-8, jun. 2009.
- [12] ARTZNER, P.; DELBAEN, F.; EBER, J. M.; e HEATH, D. "Coherent measures of risk". **Mathematical Finance**, v. 9, n. 3, p. 203-228, 1999.
- [13] JORION, P. **Value-at-Risk: The New Benchmark for Managing Financial Risk**. 3 ed. McGraw-Hill, 2006.
- [14] MARKOWITZ, H.M. "Portfolio Selection". **The Journal of Finance**, v. 7, n. 1, p. 77–91, 1952.
- [15] MARKOWITZ, H.; TODD, P., XU, G.; e YAMANE, Y. "Computation of mean-semivariance efficient sets by the Critical Line Algorithm". **Annals of Operations Research**, v. 45, n. 1, p 307-317, 1993.
- [16] ROCKAFELLAR, R. T. e URYASEV, S. P. "Optimization of conditional Value-at-Risk". **Journal of Risk**, v. 2, p. 21-41, 2000.
- [17] STREET, A. On the Conditional Value-at-Risk Probability Dependent Utility Function. **Theory and Decision**, v. 68, p. 49-68, 2010.

## ANEXO 1: TRANSFORMAÇÕES DAS VARIÁVEIS DEPENDENTES VZ E FC

Uma das nossas variáveis de interesse, o fator de capacidade (FC), está representada em valores percentuais e, portanto, é restrita ao intervalo [0,1]. Assim, a transformação deve respeitar essa restrição e gerar um modelo capaz de simular valores consistentes.

A transformação selecionada, para o nosso caso, é conhecida como Logaritmo da Razão de Chance [5]. No seu uso original, a Razão é de Chance é a probabilidade de um evento ocorrer dividida pela probabilidade de não ocorrer. Observa-se que a Razão de Chance é um número no intervalo  $[0, \infty)$ . Usa-se então um logaritmo para obter uma medida no intervalo  $(-\infty, +\infty)$ .

Neste trabalho, adaptamos essa ideia para o caso de variáveis com valor no intervalo (Min, Max), já que os mínimos e máximos das vazões das PCHs e do FC das eólicas estão dentro de limites bem definidos. Assim, seja  $X_t$  uma variável e seja  $X'_t$  a sua transformada, então,

$$FC'_t = X'_t = \ln \left( \frac{X_t - Min}{Max - X_t} \right). \quad (1A)$$

Como o fator de capacidade é um percentual da potência nominal, FC deverá ficar entre Min=0 e Max=100. Logo, a variável  $FC'_t$  (FC transformada para cada período de tempo), será expressa da seguinte forma:

$$FC'_t = \ln \left( \frac{FC_t}{100 - FC_t} \right) ; \quad \forall t \in T. \quad (1B)$$

A transformação da variável Vazão (Vz) seguirá o mesmo conceito, porém com um limite diferente. A vazão é uma variável que mede a quantidade de água escoada em  $m^3/s$ . Teoricamente não há limite máximo para essa variável; contudo, há algumas considerações físicas que devemos respeitar. Observando os dados históricos, percebemos que a vazão máxima registrada para o rio considerado no estudo foi igual a 270 [ $m^3/s$ ]. Dessa forma, atribuímos uma vazão máxima de 300 [ $m^3/s$ ]. Assim, a variável  $Vz'_t$  ( Vz transformada para cada período de tempo) será expressa da seguinte forma:

$$Vz'_t = \ln \left( \frac{Vz_t}{300 - Vz_t} \right) ; \quad \forall t \in T. \quad (1C)$$

Como o uso da Razão de Chance nas variáveis dependentes foi motivado pela constatação de valores não realistas na simulação de cenários de vento e vazão, e como as ENAs são variáveis exógenas ao modelo, sendo a simulação apenas condicional a elas, essas variáveis sofrerão apenas uma simples transformação logarítmica. Assim:

$$SE'_t = \ln(SE_t) ; \quad S'_t = \ln(S_t) ; \quad NE'_t = \ln(NE_t) ; \quad N'_t = \ln(N_t) ; \quad \forall t \in T. \quad (1D)$$

## ANEXO 2: PRODUTO DE KRONECKER

Considere as matrizes A de dimensão (mxn) e a matriz B de dimensão (uxv), conforme descrito abaixo:

$$A = \begin{bmatrix} a_{11} & \cdots & a_{1m} \\ \vdots & \ddots & \vdots \\ a_{n1} & \cdots & a_{mn} \end{bmatrix}, \quad (2A)$$

$$B = \begin{bmatrix} b_{11} & \cdots & b_{1u} \\ \vdots & \ddots & \vdots \\ b_{v1} & \cdots & b_{uv} \end{bmatrix}. \quad (2B)$$

O operador *vec* representa uma transformação linear que converte uma matriz em vetor coluna. Assim:

$$\text{vec}(A) = \begin{bmatrix} a_{11} \\ a_{21} \\ \vdots \\ a_{mn} \end{bmatrix}. \quad (2C)$$

O produto de Kronecker, representado pelo operador  $\otimes$ , é uma operação em duas matrizes de tamanho arbitrário, resultando em uma matriz de bloco. Logo:

$$A \otimes B = \begin{bmatrix} a_{11} \cdot B & \cdots & a_{1m} \cdot B \\ \vdots & \ddots & \vdots \\ a_{n1} \cdot B & \cdots & a_{mn} \cdot B \end{bmatrix}. \quad (2D)$$

### ANEXO 3: RESULTADOS DO MODELO V&V PARA O ESTUDO DE CASO 1

#### A. Método não-heurístico

##### a) Correlações constantes

###### a.1) Especificação - Fator de Capacidade Eólico (FC')

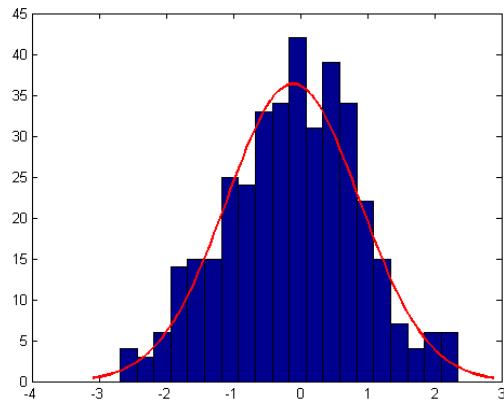


Fig. 38 – FC': Histograma dos resíduos

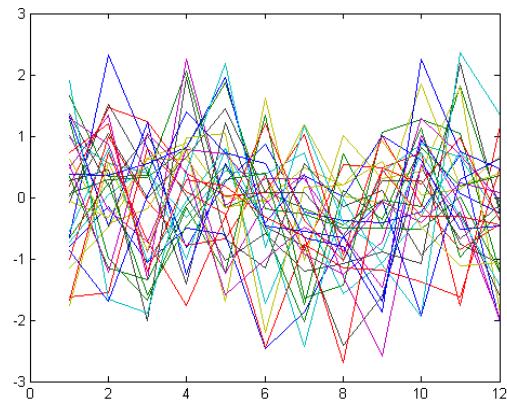


Fig. 39 – FC': Comparativo anual dos resíduos

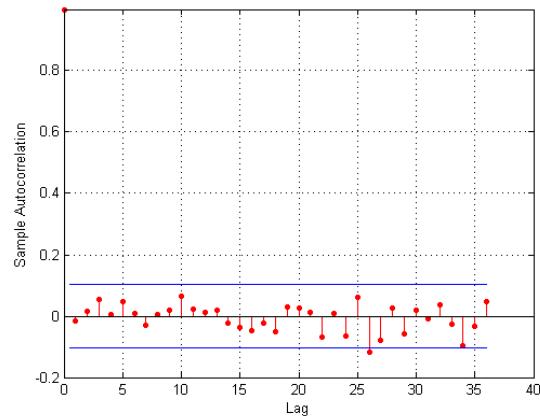


Fig. 40 – FC': Correlograma para os resíduos

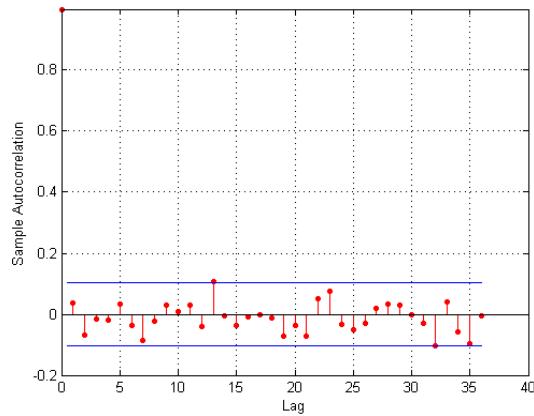


Fig. 41 – FC': Correlograma para os quadrados dos resíduos

### a.2) Especificação - Vazao(Vz')

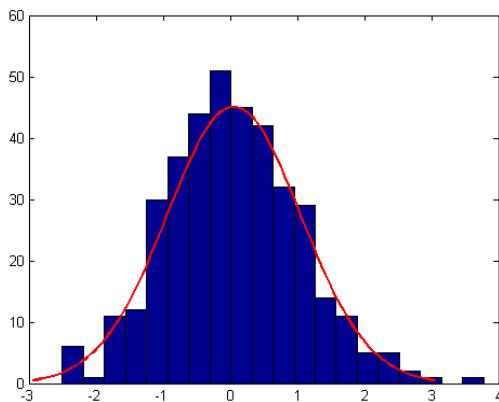


Fig. 42 – Vz': Histograma dos resíduos

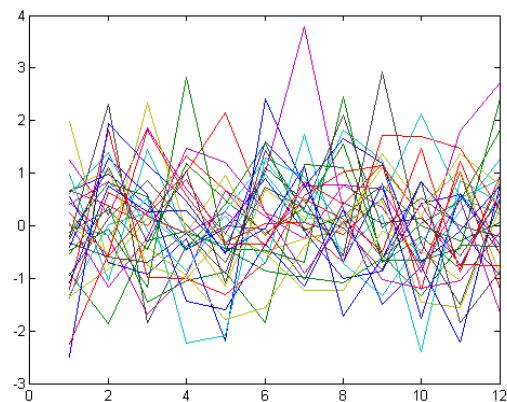


Fig. 43 – Vz': Comparativo anual dos resíduos

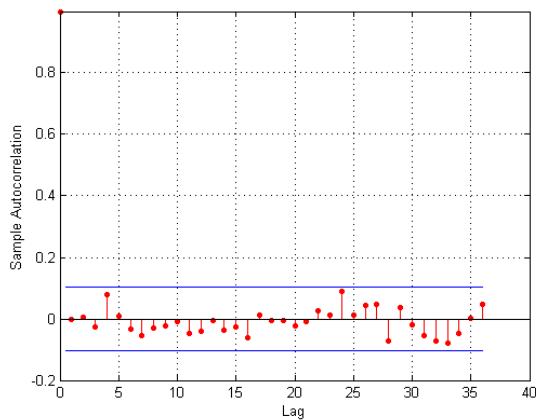


Fig. 44 – Vz': Correlograma para os resíduos

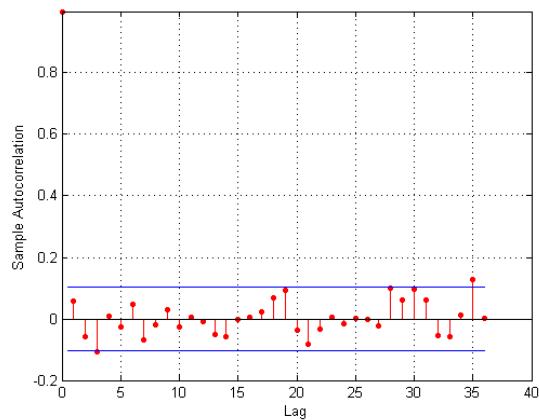


Fig. 45 – Vz': Correlograma para os quadrados dos resíduos

### a.3) Análise do modelo

#### ANÁLISE DENTRO DA AMOSTRA

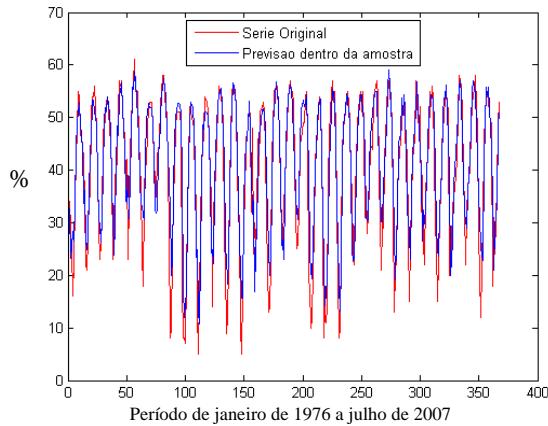


Fig. 46 – FC: Previsão dentro da amostra

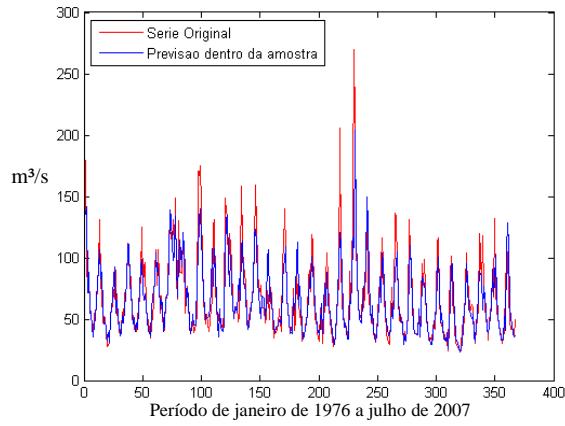
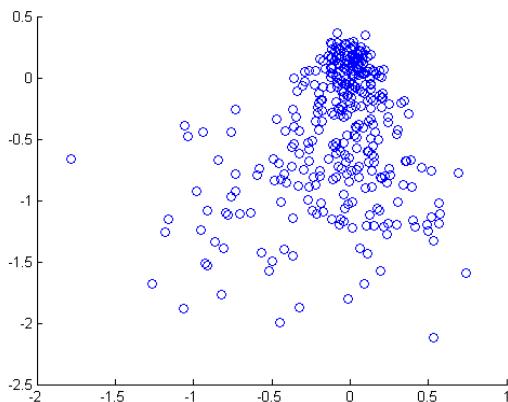
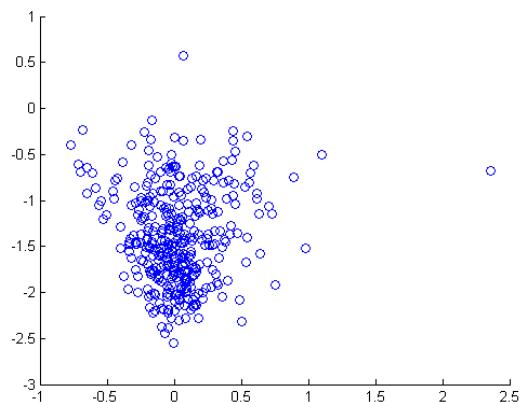
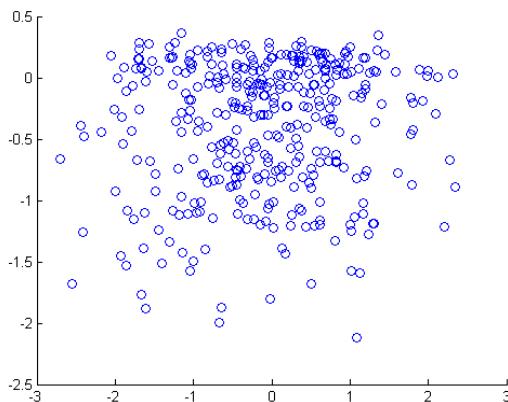
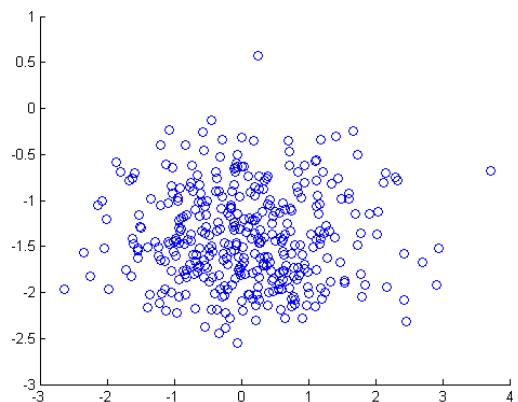


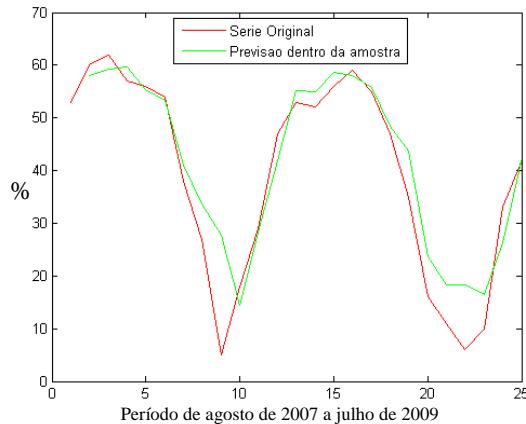
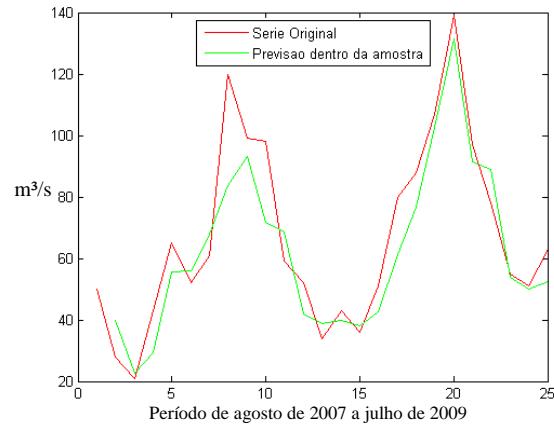
Fig. 47 – Vz: Previsão dentro da amostra

	<i>FC</i>	<i>Vz</i>
<i>R</i> <sup>2</sup>	0.7594	0.7578
<i>R</i> <sup>2</sup> <b>ajustado</b>	0.7371	0.7354
<b>P-valor JB dos Resíduos</b>	0.4330	0.0488

Tabela 7 – Medidas de aderência – Dentro da amostra

Fig. 48 – Resíduos X valor predito para *FC*Fig. 49 – Resíduos X valor predito para *Vz*Fig. 50 – Resíduos padronizados X valor predito para *FC*Fig. 51 – Resíduos padronizados X valor predito para *Vz*

## ANÁLISE FORA DA AMOSTRA

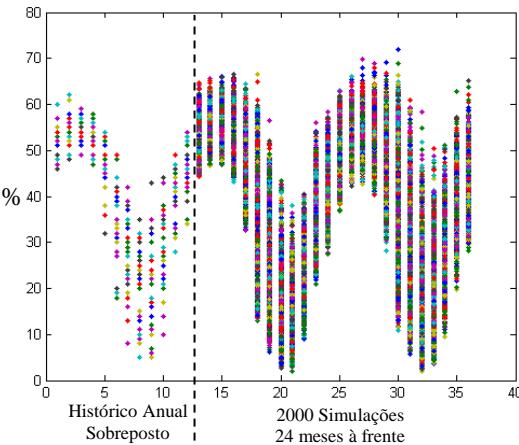
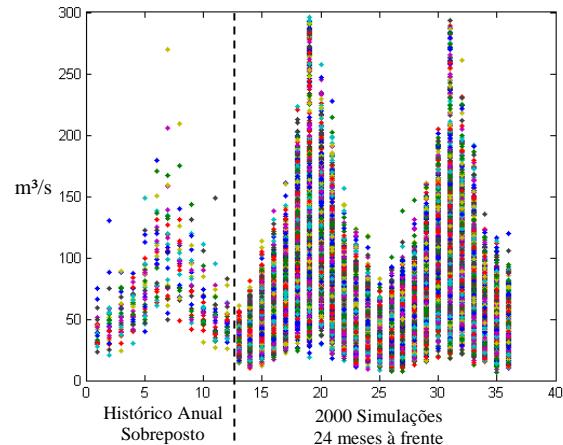
Fig. 52 – Desempenho do modelo fora da amostra para  $FC$ Fig. 53 – Desempenho do modelo fora da amostra para  $Vz$ 

	$FC$	$Vz$
<b>MAPE</b>	41.17	14.30
<b>MAE</b>	4.63	9.37
<b>RMS</b>	6.71	12.30
<b>MPE</b>	0.36	-0.04
<b>SDPE</b>	0.98	0.17
<b>U</b>	0.08	0.09

Tabela 8 – Medidas de Aderência – Fora da Amostra

**a.4) Correlações**CORRELAÇÃO ENTRE AS SÉRIES DE VAZÃO ( $Vz$ ) E FATOR DE CAPACIDADE ( $FC$ )

	Resíduos $FC'$	Resíduos $Vz'$
Resíduos $FC'$	$r_{1,1}^2 = 1,0000$	$r_{1,2}^2 = -0,1393$
Resíduos $Vz'$	$r_{2,1}^2 = -0,1393$	$r_{2,2}^2 = 1,0000$

Tabela 9 – Matriz de correlação residual  $\varepsilon_t$ **a.5) Simulação**Fig. 54 –  $FC$ : 2000 simulaçõesFig. 55 –  $Vz$ : 2000 simulações

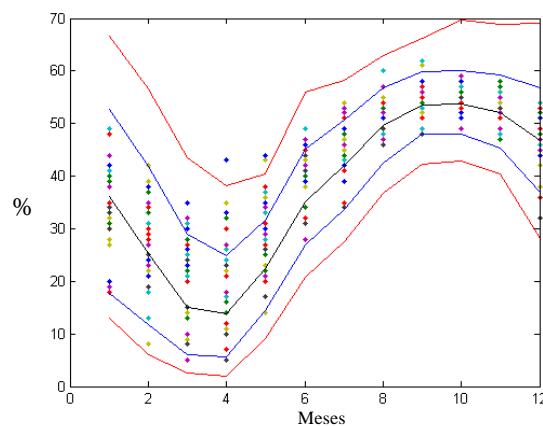


Fig. 56 – FC: Histórico com Intervalo de Confiança de 95% das simulações

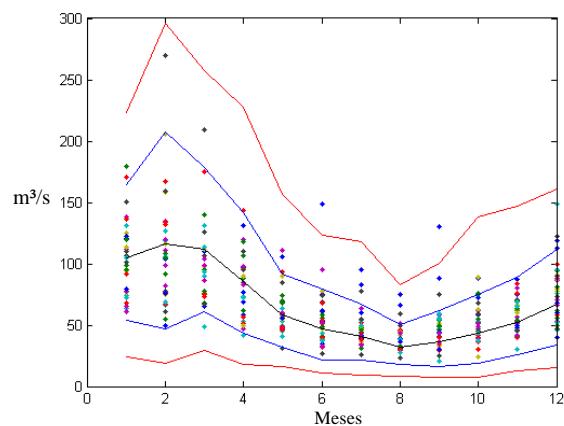


Fig. 57 – Vz: Histórico com Intervalo de Confiança de 95% das simulações

Estatísticas Descritivas FC	Período Observado							Simulações						
	Média	Desvio	Mínimo	Máximo	Q.5%	Mediana	Q.95%	Média	Desvio	Mínimo	Máximo	Q.5%	Mediana	Q.95%
Janeiro	35.73	7.65	18.00	49.00	19.15	38.00	48.00	36.54	10.22	10.97	71.93	17.77	36.88	53.98
Fevereiro	26.30	8.93	8.00	42.00	8.75	28.00	38.85	26.23	9.85	5.68	60.97	11.59	25.37	43.31
Marco	19.06	8.49	5.00	35.00	5.45	21.00	31.85	16.44	8.00	2.06	58.39	6.13	15.01	31.66
Abril	21.64	9.85	5.00	43.00	6.15	22.00	35.00	16.41	7.49	2.01	50.30	6.21	15.21	30.34
Maio	30.30	8.35	10.00	44.00	14.45	31.00	43.85	25.05	6.58	9.09	51.03	15.43	24.46	36.70
Junho	40.85	5.18	28.00	49.00	31.15	42.00	48.70	36.43	6.05	19.68	62.83	27.58	36.01	47.08
Julho	45.97	5.08	34.00	54.00	35.60	46.00	53.00	42.75	5.50	27.54	65.09	33.86	42.79	52.02
Agosto	52.21	3.50	46.00	60.00	47.15	52.00	57.00	51.52	4.35	36.75	64.79	44.09	51.77	58.32
Setembro	54.52	3.02	48.00	62.00	49.30	55.00	60.55	54.29	3.35	42.32	66.16	48.67	54.28	59.84
Outubro	54.15	2.28	49.00	59.00	49.30	54.00	57.85	54.46	3.42	42.78	69.77	48.93	54.38	60.23
Novembro	52.58	2.77	47.00	58.00	48.00	53.00	56.85	52.76	4.03	40.45	68.83	46.30	52.68	59.43
Dezembro	46.73	4.93	32.00	54.00	36.30	47.00	53.85	46.86	5.89	28.13	69.06	37.59	46.55	56.72

Tabela 10 – Análise de cenários simulados – FC – Escala original

Estatísticas Descritivas FC	Período Observado							Simulações						
	Média	Desvio	Mínimo	Máximo	Q.5%	Mediana	Q.95%	Média	Desvio	Mínimo	Máximo	Q.5%	Mediana	Q.95%
Janeiro	105.64	30.58	61.00	179.00	64.15	105.00	167.85	100.68	34.42	19.20	223.32	49.87	97.61	161.70
Fevereiro	112.09	45.45	50.00	270.00	55.90	108.00	200.15	110.16	50.61	17.62	295.70	44.07	103.85	200.75
Marco	95.70	32.66	49.00	209.00	65.00	93.00	169.75	104.15	35.70	21.27	260.65	53.08	100.09	168.01
Abril	79.12	26.11	42.00	143.00	42.75	77.00	129.35	79.08	30.62	13.16	227.72	37.47	75.00	137.21
Maio	60.70	18.27	31.00	111.00	41.60	56.00	104.05	55.71	18.08	15.06	156.92	30.19	53.73	88.39
Junho	53.79	22.46	27.00	149.00	32.15	51.00	92.45	45.82	17.88	6.59	122.82	20.07	43.53	78.44
Julho	46.73	12.36	26.00	83.00	31.45	43.00	75.90	39.64	14.14	9.09	119.75	20.14	37.75	65.90
Agosto	40.30	11.55	23.00	75.00	28.00	38.00	64.95	31.59	8.73	8.59	82.99	19.12	30.74	47.28
Setembro	48.45	20.16	21.00	130.00	25.60	46.00	86.05	35.72	12.99	7.12	100.31	16.73	34.17	59.57
Outubro	52.30	15.32	24.00	89.00	30.90	49.00	86.20	44.81	16.02	7.85	138.40	21.45	43.07	73.61
Novembro	59.85	13.98	30.00	87.00	40.15	60.00	83.40	54.04	18.37	12.95	147.13	28.21	51.64	89.25
Dezembro	77.70	24.64	40.00	149.00	46.15	76.00	121.55	68.83	22.86	15.35	161.38	35.73	66.22	110.43

Tabela 11 – Análise de cenários simulados – Vz – Escala original

Estatísticas Descritivas FC	Período Observado							Simulações						
	Média	Desvio	Mínimo	Máximo	Q.5%	Mediana	Q.95%	Média	Desvio	Mínimo	Máximo	Q.5%	Mediana	Q.95%
Janeiro	-0.61	0.36	-1.52	-0.04	-1.44	-0.49	0.10	-0.58	0.47	-2.09	0.94	-1.53	-0.54	0.16
Fevereiro	-1.10	0.53	-2.44	-0.32	-2.36	-0.94	0.52	-1.10	0.54	-2.81	0.45	-2.03	-1.08	-0.27
Marco	-1.56	0.64	-2.94	-0.62	-2.87	-1.32	0.12	-1.74	0.60	-3.86	0.34	-2.73	-1.73	-0.77
Abril	-1.41	0.67	-2.94	-0.28	-2.73	-1.27	-0.39	-1.73	0.57	-3.89	0.01	-2.72	-1.72	-0.83
Maio	-0.87	0.45	-2.20	-0.24	-1.78	-0.80	-0.73	-1.13	0.36	-2.30	0.04	-1.70	-1.13	-0.55
Junho	-0.38	0.22	-0.94	-0.04	-0.79	-0.32	-0.90	-0.57	0.26	-1.41	0.52	-0.97	-0.57	-0.12
Julho	-0.16	0.21	-0.66	0.16	-0.59	-0.16	-1.17	-0.30	0.23	-0.97	0.62	-0.67	-0.29	0.08
Agosto	0.09	0.14	-0.16	0.41	-0.11	0.08	-1.37	0.06	0.18	-0.54	0.61	-0.24	0.07	0.34
Setembro	0.18	0.12	-0.08	0.49	-0.03	0.20	-1.00	0.17	0.14	-0.31	0.67	-0.05	0.17	0.40
Outubro	0.17	0.09	-0.04	0.36	-0.03	0.16	-1.00	0.18	0.14	-0.29	0.84	-0.04	0.18	0.41
Novembro	0.10	0.11	-0.12	0.32	-0.08	0.12	-1.04	0.11	0.16	-0.39	0.79	-0.15	0.11	0.38
Dezembro	-0.13	0.20	-0.75	0.16	-0.56	-0.12	-0.49	-0.13	0.24	-0.94	0.80	-0.51	-0.14	0.27

Tabela 12 – Análise de cenários simulados – FC – Escala transformada

Estatísticas Descritivas FC	Período Observado							Simulações						
	Média	Desvio	Mínimo	Máximo	Q.5%	Mediana	Q.95%	Média	Desvio	Mínimo	Máximo	Q.5%	Mediana	Q.95%
Janeiro	-0.74	0.44	-1.45	0.24	-1.38	-0.72	0.10	-0.83	0.53	-2.75	0.84	-1.69	-0.82	0.02
Fevereiro	-0.65	0.66	-1.69	1.69	-1.55	-0.67	0.52	-0.71	0.77	-2.84	2.50	-1.83	-0.73	0.52
Março	-0.89	0.47	-1.71	0.63	-1.37	-0.89	0.12	-0.77	0.53	-2.64	1.48	-1.62	-0.79	0.10
Abril	-1.16	0.44	-1.89	-0.21	-1.87	-1.15	-0.39	-1.18	0.53	-3.15	0.90	-2.02	-1.18	-0.29
Maio	-1.49	0.35	-2.23	-0.63	-1.90	-1.55	-0.73	-1.61	0.40	-3.01	-0.04	-2.26	-1.60	-0.96
Junho	-1.66	0.43	-2.38	-0.14	-2.19	-1.66	-0.90	-1.87	0.47	-3.86	-0.47	-2.70	-1.85	-1.12
Julho	-1.80	0.29	-2.43	-1.05	-2.22	-1.86	-1.17	-2.02	0.41	-3.53	-0.51	-2.70	-2.01	-1.35
Agosto	-1.97	0.31	-2.56	-1.18	-2.34	-2.00	-1.37	-2.25	0.31	-3.59	-1.05	-2.76	-2.24	-1.75
Setembro	-1.79	0.44	-2.66	-0.38	-2.44	-1.78	-1.00	-2.14	0.42	-3.78	-0.78	-2.90	-2.12	-1.48
Outubro	-1.67	0.35	-2.51	-0.95	-2.24	-1.71	-1.00	-1.88	0.43	-3.68	-0.27	-2.63	-1.86	-1.21
Novembro	-1.50	0.30	-2.27	-0.99	-1.94	-1.47	-1.04	-1.65	0.41	-3.17	-0.16	-2.34	-1.65	-0.95
Dezembro	-1.18	0.41	-1.95	-0.14	-1.78	-1.17	-0.49	-1.35	0.44	-2.99	0.02	-2.07	-1.34	-0.64

Tabela 13 – Análise de cenários simulados – Vz – Escala transformada

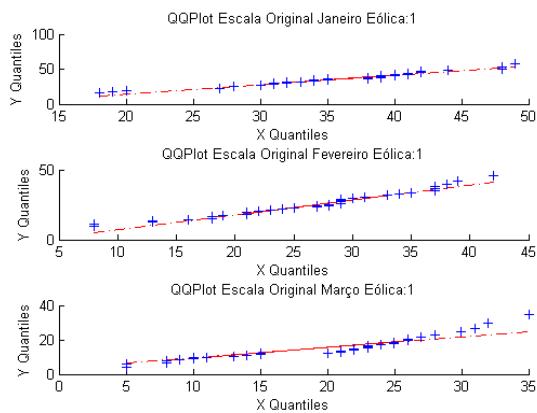


Fig. 58 – FC: QQplot (janeiro, fevereiro e março) – Variáveis originais

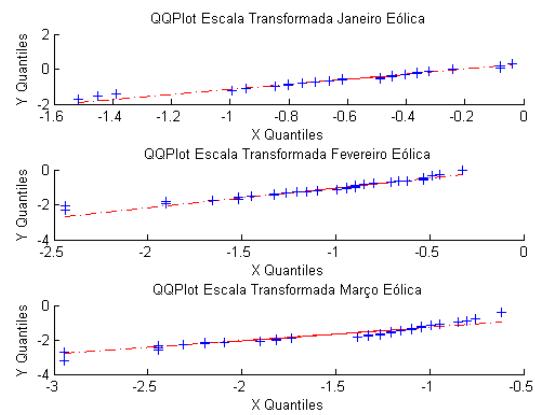


Fig. 59 – FC: QQplot (janeiro, fevereiro e março) – Variáveis transformadas

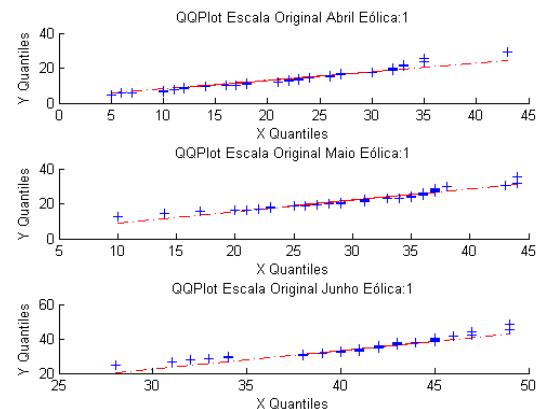


Fig. 60 – FC: QQplot (abril, maio e junho) – Variáveis originais

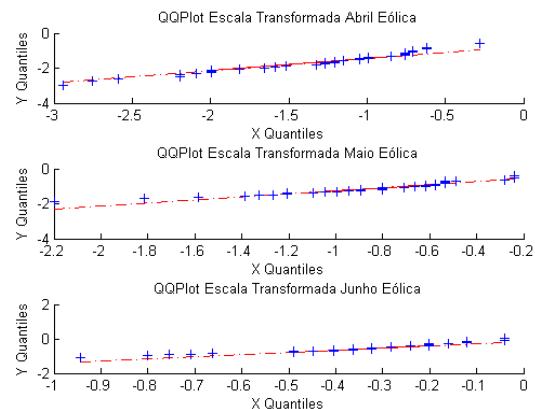


Fig. 61 – FC: QQplot (abril, maio e junho) – Variáveis transformadas

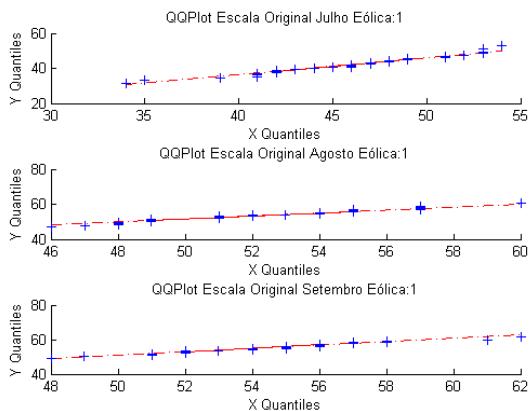


Fig. 62 – FC: QQplot (julho, agosto e setembro) – Variáveis originais

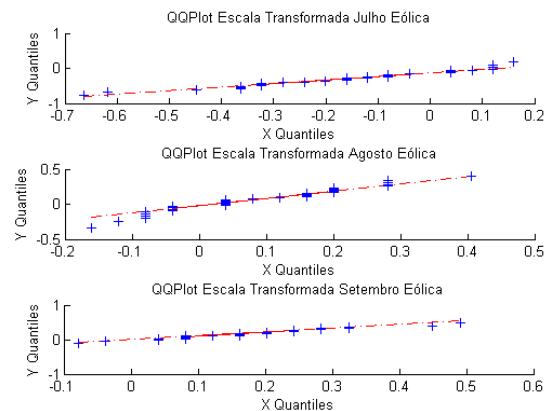


Fig. 63 – FC: QQplot (julho, agosto e setembro) – Variáveis transformadas

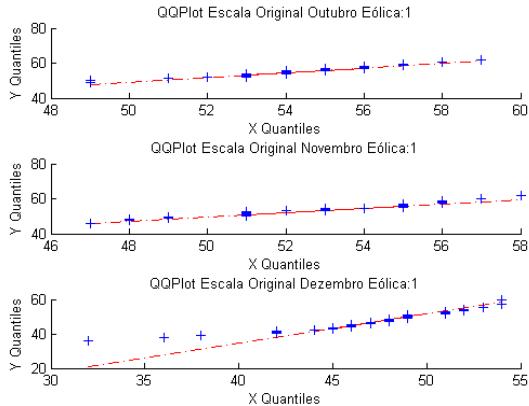


Fig. 64 – FC: QQplot (outubro, novembro e dezembro) – Variáveis originais

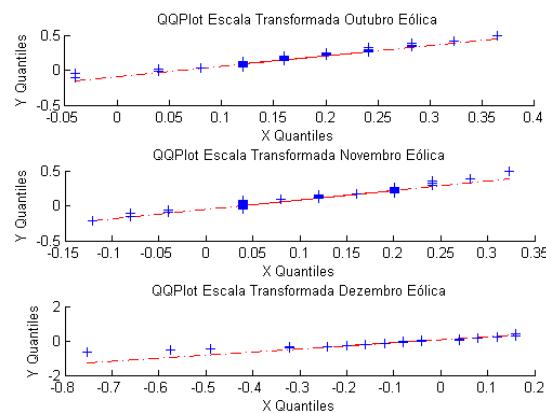


Fig. 65 – FC: QQplot (outubro, novembro e dezembro) – Variáveis transformadas

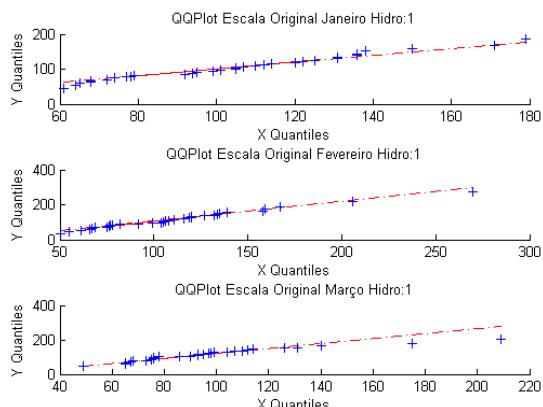


Fig. 66 – Vz: QQplot (janeiro, fevereiro e março) – Variáveis originais

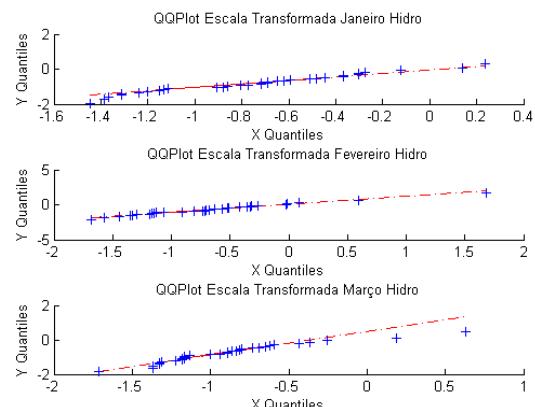


Fig. 67 – Vz: QQplot (janeiro, fevereiro e março) – Variáveis transformadas

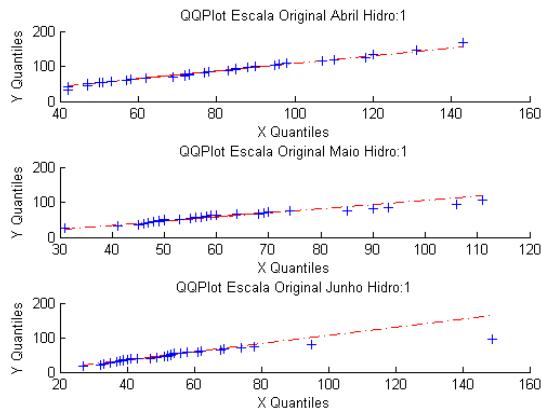


Fig. 68 – Vz: QQplot (abril, maio e junho) – Variáveis originais

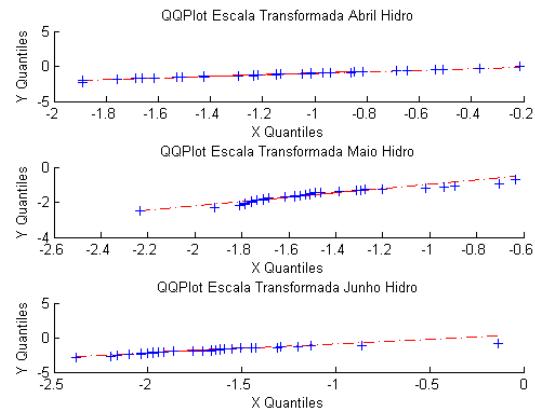


Fig. 69 – Vz: QQplot (abril, maio e junho) – Variáveis transformadas

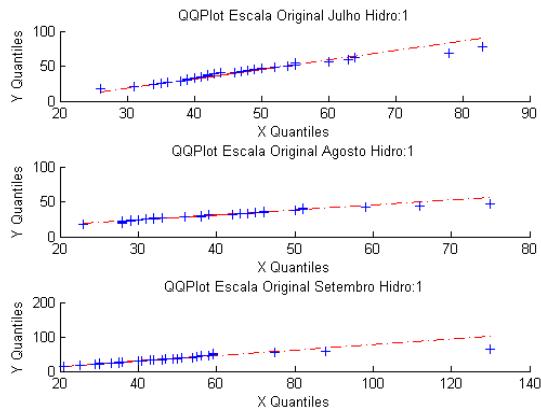


Fig. 70 – Vz: QQplot (julho, agosto e setembro) – Variáveis originais

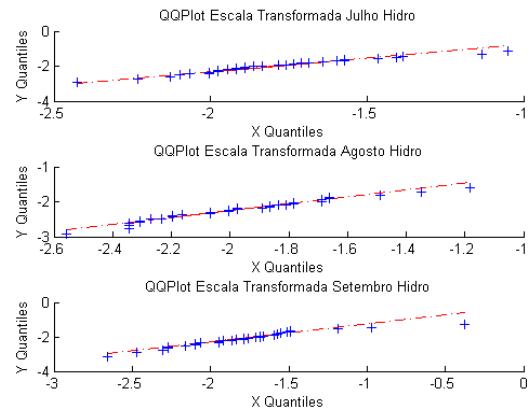


Fig. 71 – Vz: QQplot (julho, agosto e setembro) – Variáveis transformadas

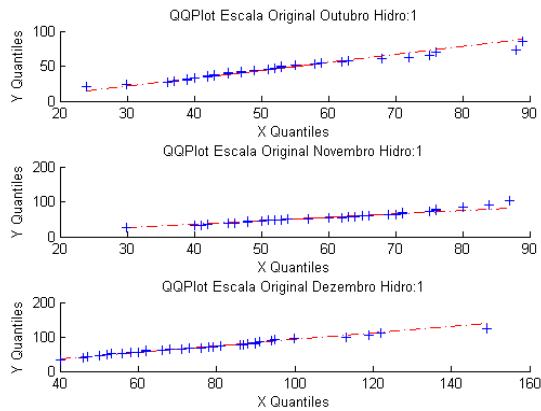


Fig. 72 – Vz: QQplot (outubro, novembro e dezembro) – Variáveis originais

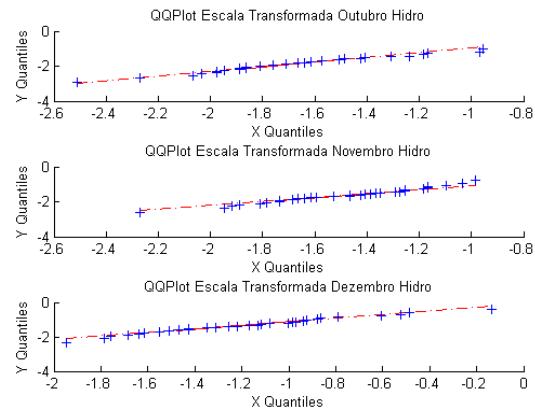


Fig. 73 – Vz: QQplot (outubro, novembro e dezembro) – Variáveis transformadas

## b) Correlações mês a mês

### b.1) Especificação - Fator de Capacidade Eólico (FC')

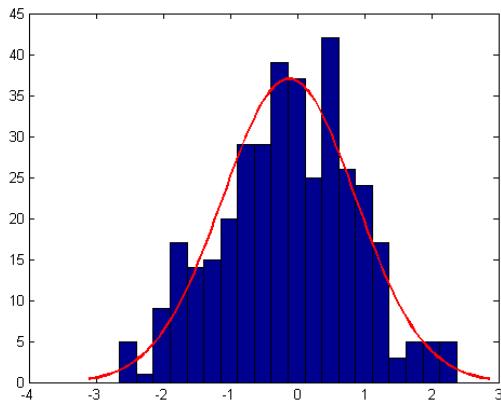


Fig. 74 – FC': Histograma dos resíduos

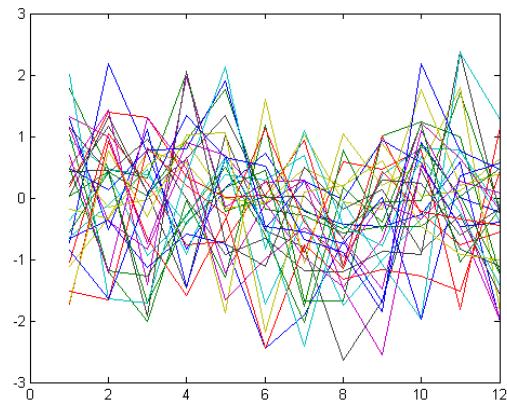


Fig. 75 – FC': Comparativo anual dos resíduos

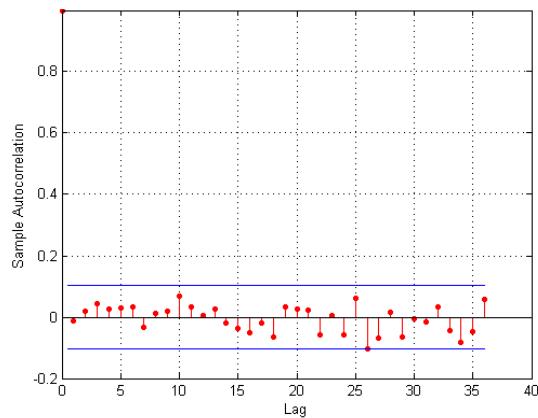


Fig. 76 – FC': Correlograma para os resíduos

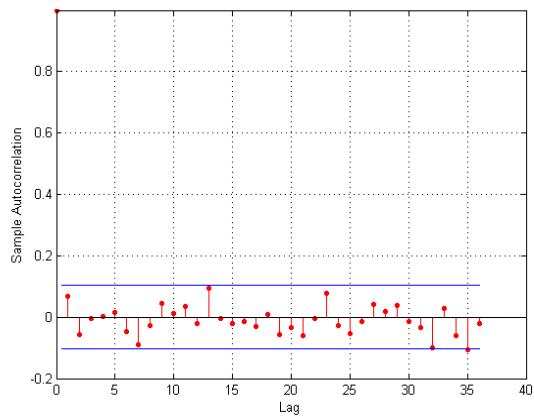


Fig. 77 – FC': Correlograma para os quadrados dos resíduos

### b.2) Especificação - Vazão (Vz')

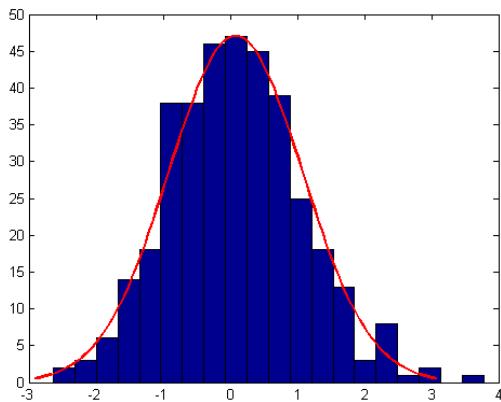


Fig. 78 – Vz': Histograma dos resíduos

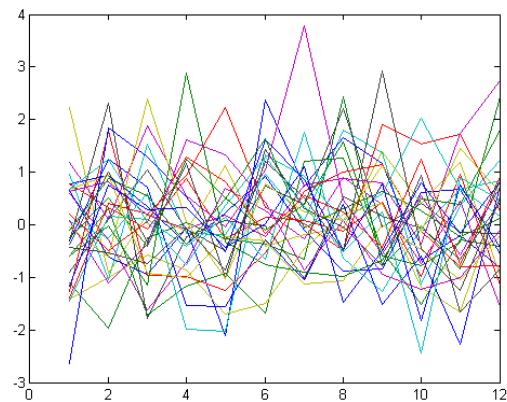


Fig. 79 – Vz': Comparativo anual dos resíduos

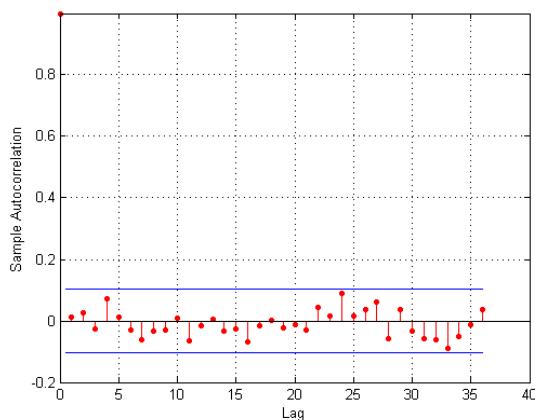


Fig. 80 – Vz': Correlograma para os resíduos

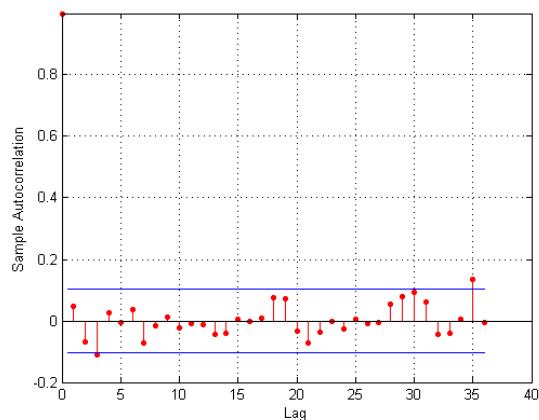


Fig. 81 – Vz': Correlograma para os quadrados dos resíduos

### b.3) Análise do modelo

#### ANÁLISE DENTRO DA AMOSTRA

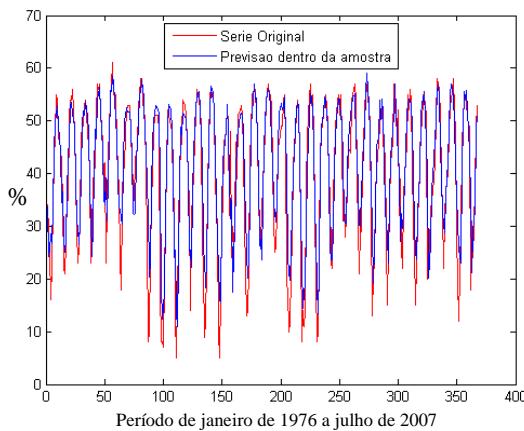


Fig. 82 – FC: Previsão dentro da amostra

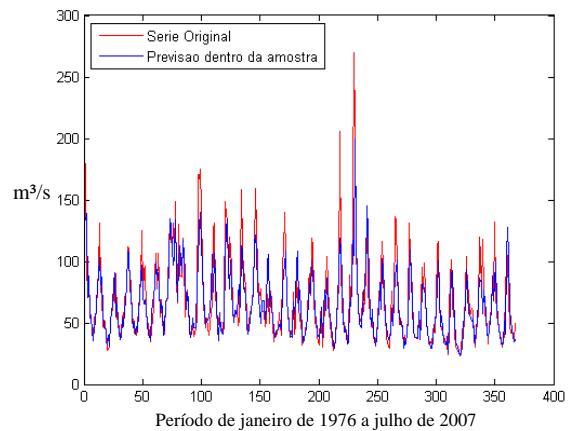
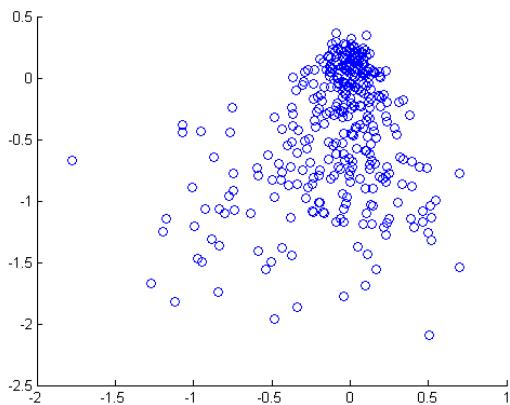
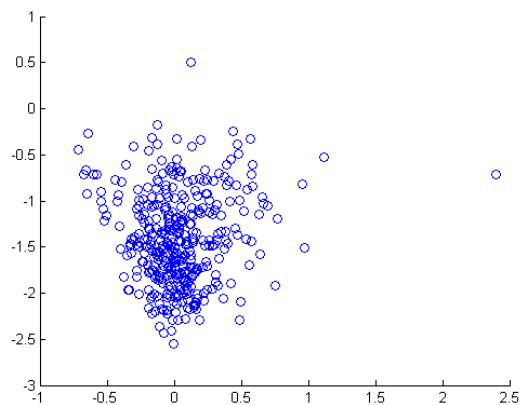
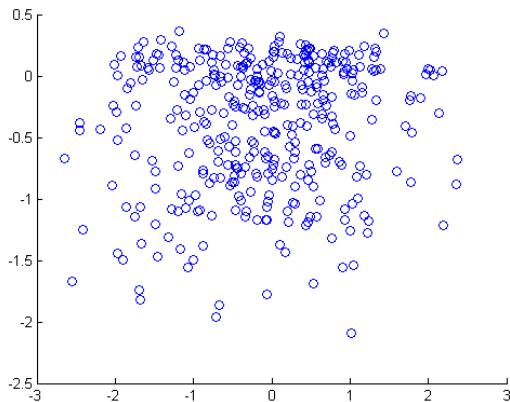
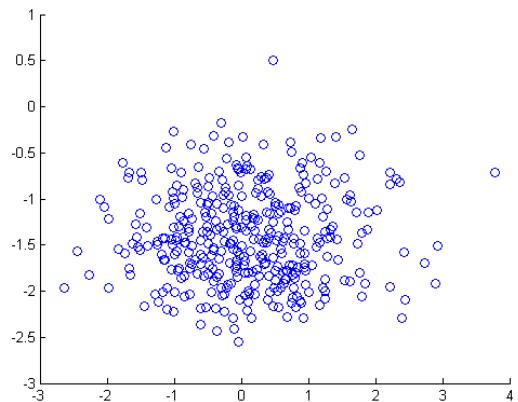


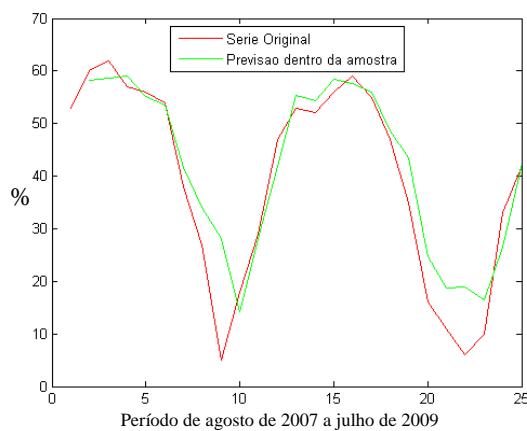
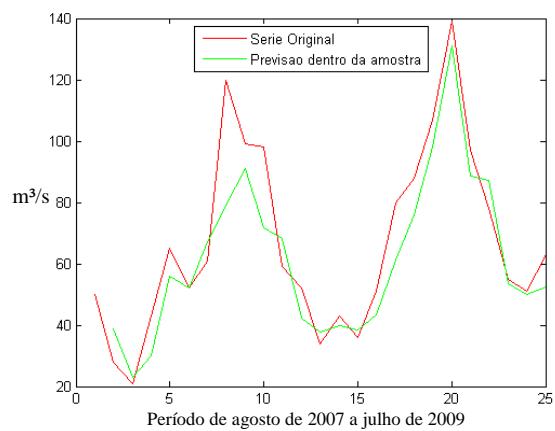
Fig. 83 – Vz: Previsão dentro da amostra

	<b>FC</b>	<b>Vz</b>
<b>R<sup>2</sup></b>	0.7634	0.7502
<b>R<sup>2</sup> ajustado</b>	0.7408	0.7262
<b>P-valor JB dos Resíduos</b>	0.3756	0.0452

Tabela 14 – Medidas de Aderência – Dentro da Amostra

Fig. 84 – Resíduos  $X$  valor predito para  $FC$ Fig. 85 – Resíduos  $X$  valor predito para  $Vz$ Fig. 86 – Resíduos padronizados  $X$  valor predito para  $FC$ Fig. 87 – Resíduos padronizados  $X$  valor predito para  $Vz$ 

#### ANÁLISE FORA DA AMOSTRA

Fig. 88 – Desempenho do modelo fora da amostra para  $FC$ Fig. 89 – Desempenho do modelo fora da amostra para  $Vz$

	<i>FC</i>	<i>Vz</i>
<b>MAPE</b>	41.17	14.30
<b>MAE</b>	4.63	9.37
<b>RMS</b>	6.71	12.30
<b>MPE</b>	0.35	-0.04
<b>SDPE</b>	0.98	0.17
<b>U</b>	0.08	0.09

Tabela 15 – Medidas de Aderência – Fora da Amostra

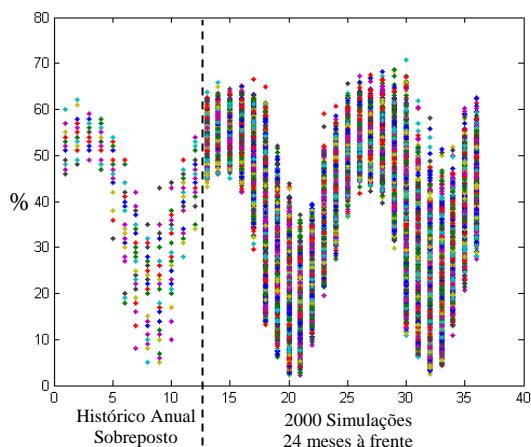
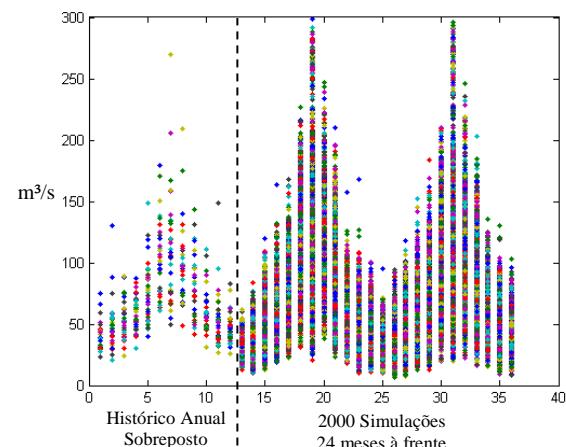
#### b.4) Correlações

##### CORRELAÇÃO ENTRE AS SÉRIES DE VAZÃO (*Vz*) E FATOR DE CAPACIDADE (*FC*)

MÊS	$\sigma_1$	$\sigma_2$	CORRELAÇÃO
1	0.44	0.40	<b>-54.97%</b>
2	0.50	0.63	<b>-38.32%</b>
3	0.67	0.26	<b>-43.11%</b>
4	0.50	0.33	-0.82%
5	0.19	0.09	-10.78%
6	0.17	0.17	-12.25%
7	0.19	0.20	<b>-25.96%</b>
8	0.11	0.13	-7.58%
9	0.07	0.17	-11.04%
10	0.06	0.20	25.97%
11	0.09	0.26	9.91%
12	0.17	0.26	2.77%

Tabela 16 – Desvio padrão e correlação mensal das séries

#### b.5) Simulação

Fig. 90 – *FC*: 2000 simulaçõesFig. 91 – *Vz*: 2000 simulações

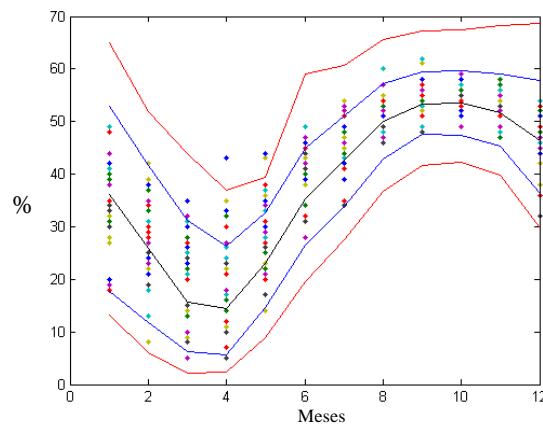


Fig. 92 – FC: Histórico com Intervalo de Confiança de 95% das simulações

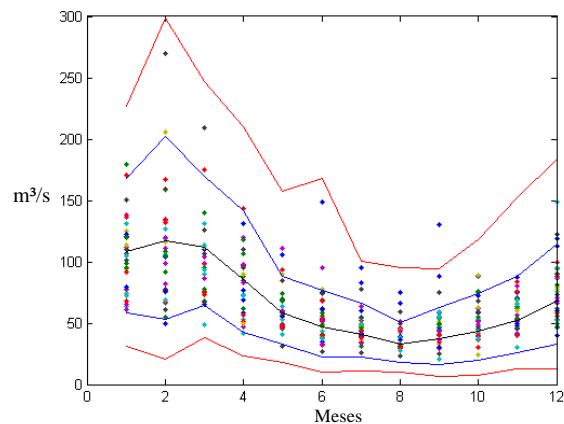


Fig. 93 – Vz: Histórico com Intervalo de Confiança de 95% das simulações

Estatísticas Descritivas FC	Período Observado							Simulações						
	Média	Desvio	Mínimo	Máximo	Q.5%	Mediana	Q.95%	Média	Desvio	Mínimo	Máximo	Q.5%	Mediana	Q.95%
Janeiro	35.73	7.65	18.00	49.00	19.15	38.00	48.00	36.45	10.10	10.97	70.73	17.91	36.64	53.17
Fevereiro	26.30	8.93	8.00	42.00	8.75	28.00	38.85	26.38	9.46	6.11	61.98	11.96	25.80	42.82
Março	19.06	8.49	5.00	35.00	5.45	21.00	31.85	17.25	8.38	2.12	58.24	6.52	15.64	33.92
Abril	21.64	9.85	5.00	43.00	6.15	22.00	35.00	17.09	7.95	2.29	51.45	6.57	15.78	31.67
Maio	30.30	8.35	10.00	44.00	14.45	31.00	43.85	25.54	6.66	8.81	51.70	15.53	25.08	37.39
Junho	40.85	5.18	28.00	49.00	31.15	42.00	48.70	36.71	6.05	19.64	60.18	27.27	36.29	47.22
Julho	45.97	5.08	34.00	54.00	35.60	46.00	53.00	43.16	5.52	27.49	62.57	34.16	43.12	52.02
Agosto	52.21	3.50	46.00	60.00	47.15	52.00	57.00	51.57	4.21	36.66	65.55	44.40	51.71	58.19
Setembro	54.52	3.02	48.00	62.00	49.30	55.00	60.55	53.96	3.38	41.66	67.20	48.40	53.94	59.52
Outubro	54.15	2.28	49.00	59.00	49.30	54.00	57.85	53.95	3.40	42.26	67.46	48.44	53.87	59.71
Novembro	52.58	2.77	47.00	58.00	48.00	53.00	56.85	52.51	4.01	39.76	68.30	46.19	52.39	59.13
Dezembro	46.73	4.93	32.00	54.00	36.30	47.00	53.85	46.68	6.02	29.68	68.72	37.15	46.55	57.18

Tabela 17 – Análise de cenários simulados – FC – Escala original

Estatísticas Descritivas FC	Período Observado							Simulações						
	Média	Desvio	Mínimo	Máximo	Q.5%	Mediana	Q.95%	Média	Desvio	Mínimo	Máximo	Q.5%	Mediana	Q.95%
Janeiro	105.64	30.58	61.00	179.00	64.15	105.00	167.85	103.00	34.96	20.09	226.36	50.59	99.77	165.12
Fevereiro	112.09	45.45	50.00	270.00	55.90	108.00	200.15	111.23	49.61	19.74	298.28	45.69	104.35	199.76
Março	95.70	32.66	49.00	209.00	65.00	93.00	169.75	103.65	34.71	22.21	247.25	53.57	99.33	166.30
Abril	79.12	26.11	42.00	143.00	42.75	77.00	129.35	79.36	30.12	15.86	210.51	37.73	74.86	136.09
Maio	60.70	18.27	31.00	111.00	41.60	56.00	104.05	55.47	17.55	15.18	157.74	30.14	53.54	87.16
Junho	53.79	22.46	27.00	149.00	32.15	51.00	92.45	45.48	17.41	9.16	168.03	20.86	43.57	77.19
Julho	46.73	12.36	26.00	83.00	31.45	43.00	75.90	39.58	13.99	8.22	103.36	20.21	37.59	65.99
Agosto	40.30	11.55	23.00	75.00	28.00	38.00	64.95	32.10	8.79	9.82	94.88	19.35	31.37	47.55
Setembro	48.45	20.16	21.00	130.00	25.60	46.00	86.05	36.51	12.98	6.31	94.39	16.98	35.47	59.72
Outubro	52.30	15.32	24.00	89.00	30.90	49.00	86.20	45.57	16.27	7.09	119.61	22.01	43.98	74.85
Novembro	59.85	13.98	30.00	87.00	40.15	60.00	83.40	55.47	18.46	12.84	163.69	29.26	53.04	88.85
Dezembro	77.70	24.64	40.00	149.00	46.15	76.00	121.55	70.74	23.50	12.32	183.37	35.88	68.61	112.82

Tabela 18 – Análise de cenários simulados – Vz – Escala original

Estatísticas Descritivas FC	Período Observado							Simulações						
	Média	Desvio	Mínimo	Máximo	Q.5%	Mediana	Q.95%	Média	Desvio	Mínimo	Máximo	Q.5%	Mediana	Q.95%
Janeiro	-0.61	0.36	-1.52	-0.04	-1.44	-0.49	-0.08	-0.46	0.15	-0.84	0.20	-0.68	-0.48	-0.18
Fevereiro	-1.10	0.53	-2.44	-0.32	-2.36	-0.94	-0.45	-0.77	0.16	-1.19	-0.13	-1.02	-0.78	-0.49
Março	-1.56	0.64	-2.94	-0.62	-2.87	-1.32	-0.76	-1.07	0.21	-1.53	-0.41	-1.37	-1.07	-0.74
Abril	-1.41	0.67	-2.94	-0.28	-2.73	-1.27	-0.62	-1.17	0.27	-1.65	-0.40	-1.53	-1.12	-0.78
Maio	-0.87	0.45	-2.20	-0.24	-1.78	-0.80	-0.25	-0.89	0.20	-1.30	-0.23	-1.17	-0.88	-0.58
Junho	-0.38	0.22	-0.94	-0.04	-0.79	-0.32	-0.05	-0.45	0.14	-0.78	0.16	-0.66	-0.46	-0.21
Julho	-0.16	0.21	-0.66	0.16	-0.59	-0.16	0.12	-0.13	0.10	-0.40	0.24	-0.28	-0.14	0.04
Agosto	0.09	0.14	-0.16	0.41	-0.11	0.08	0.28	0.09	0.09	-0.16	0.44	-0.05	0.08	0.24
Setembro	0.18	0.12	-0.08	0.49	-0.03	0.20	0.43	0.17	0.09	-0.07	0.61	0.04	0.16	0.34
Outubro	0.17	0.09	-0.04	0.36	-0.03	0.16	0.32	0.18	0.11	-0.11	0.69	0.02	0.16	0.38
Novembro	0.10	0.11	-0.12	0.32	-0.08	0.12	0.28	0.08	0.12	-0.26	0.66	-0.10	0.07	0.30
Dezembro	-0.13	0.20	-0.75	0.16	-0.56	-0.12	0.15	-0.16	0.14	-0.57	0.48	-0.37	-0.18	0.10

Tabela 19 – Análise de cenários simulados – FC – Escala transformada

Estatísticas Descritivas FC	Período Observado							Simulações						
	Média	Desvio	Mínimo	Máximo	Q.5%	Median a	Q.95%	Média	Desvio	Mínimo	Máxi mo	Q.5%	Median a	Q.95%
Janeiro	-0.74	0.44	-1.45	0.24	-1.38	-0.72	0.10	-0.98	0.35	-2.44	0.16	-1.59	-0.96	-0.44
Fevereiro	-0.65	0.66	-1.69	1.69	-1.55	-0.67	0.52	-0.97	0.37	-2.41	0.04	-1.61	-0.95	-0.40
Março	-0.89	0.47	-1.71	0.63	-1.37	-0.89	0.12	-1.04	0.35	-2.48	-0.09	-1.62	-1.03	-0.50
Abril	-1.16	0.44	-1.89	-0.21	-1.87	-1.15	-0.39	-1.43	0.35	-2.78	-0.54	-2.04	-1.41	-0.90
Maio	-1.49	0.35	-2.23	-0.63	-1.90	-1.55	-0.73	-1.80	0.30	-2.97	-0.97	-2.32	-1.78	-1.35
Junho	-1.66	0.43	-2.38	-0.14	-2.19	-1.66	-0.90	-1.99	0.39	-3.38	-0.91	-2.70	-1.95	-1.41
Julho	-1.80	0.29	-2.43	-1.05	-2.22	-1.86	-1.17	-2.17	0.31	-3.42	-1.30	-2.72	-2.15	-1.70
Agosto	-1.97	0.31	-2.56	-1.18	-2.34	-2.00	-1.37	-2.25	0.24	-3.39	-1.51	-2.69	-2.23	-1.88
Setembro	-1.79	0.44	-2.66	-0.38	-2.44	-1.78	-1.00	-2.20	0.37	-3.72	-1.26	-2.89	-2.15	-1.67
Outubro	-1.67	0.35	-2.51	-0.95	-2.24	-1.71	-1.00	-1.91	0.37	-3.37	-0.93	-2.57	-1.86	-1.37
Novembro	-1.50	0.30	-2.27	-0.99	-1.94	-1.47	-1.04	-1.67	0.30	-2.86	-0.83	-2.20	-1.64	-1.21
Dezembro	-1.18	0.41	-1.95	-0.14	-1.78	-1.17	-0.49	-1.32	0.33	-2.72	-0.44	-1.93	-1.29	-0.84

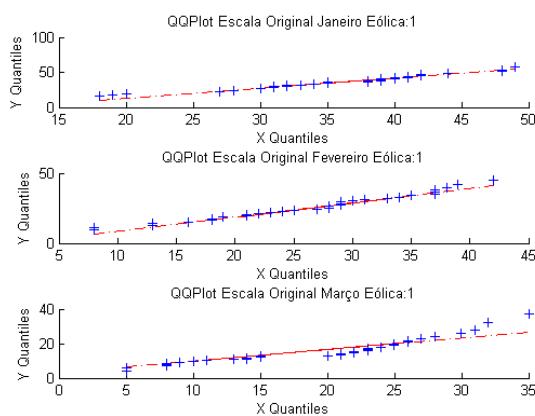
Tabela 20 – Análise de cenários simulados –  $V_z$  – Escala transformada

Fig. 94 – FC: QQplot (janeiro, fevereiro e março) – Variáveis originais

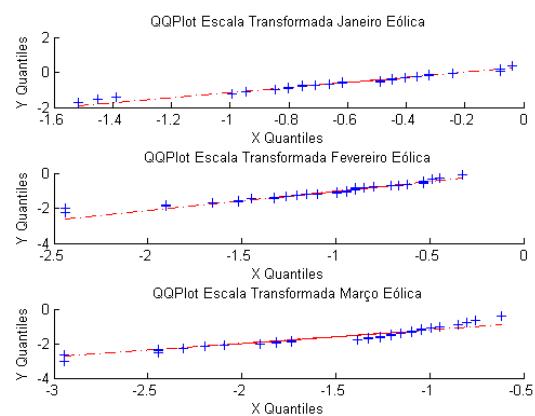


Fig. 95 – FC: QQplot (janeiro, fevereiro e março) – Variáveis transformadas

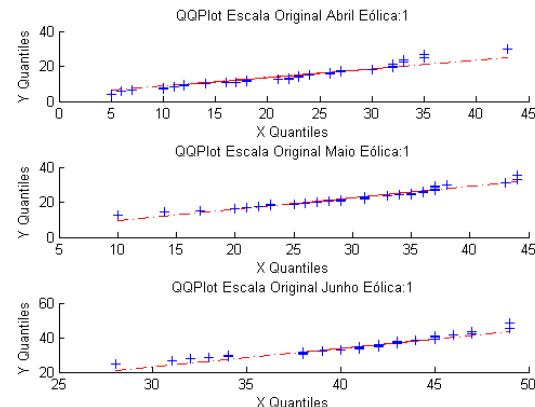


Fig. 96 – FC: QQplot (abril, maio e junho) – Variáveis originais

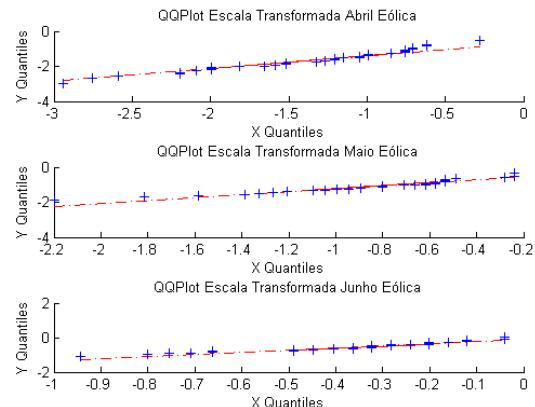


Fig. 97 – FC: QQplot (abril, maio e junho) – Variáveis transformadas

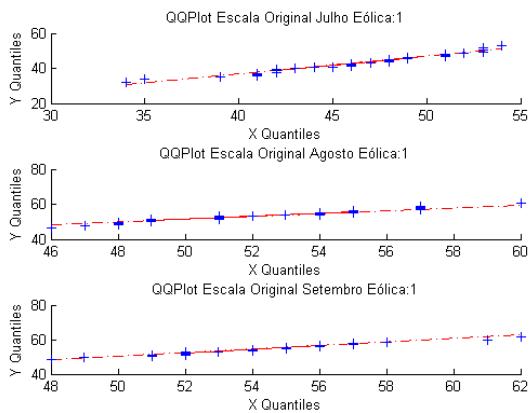


Fig. 98 – FC: QQplot (julho, agosto e setembro) – Variáveis originais

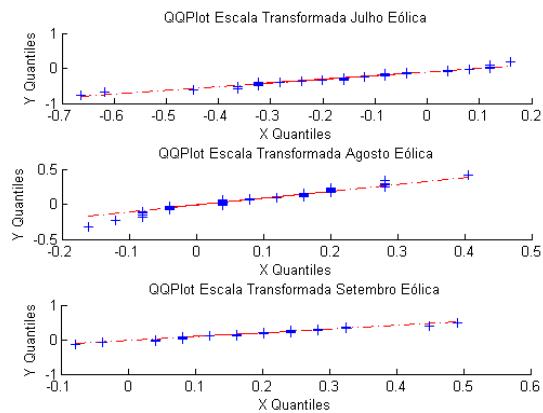


Fig. 99 – FC: QQplot (julho, agosto e setembro) – Variáveis transformadas

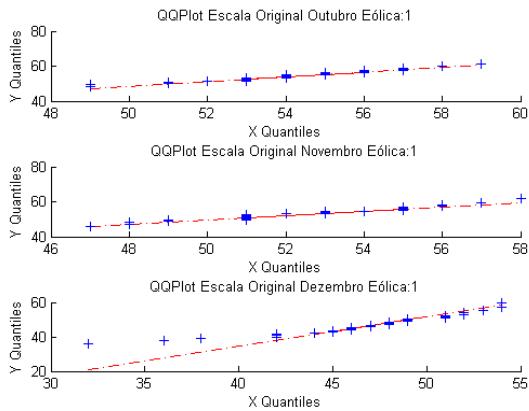


Fig. 100 – FC: QQplot (outubro, novembro e dezembro) – Variáveis originais

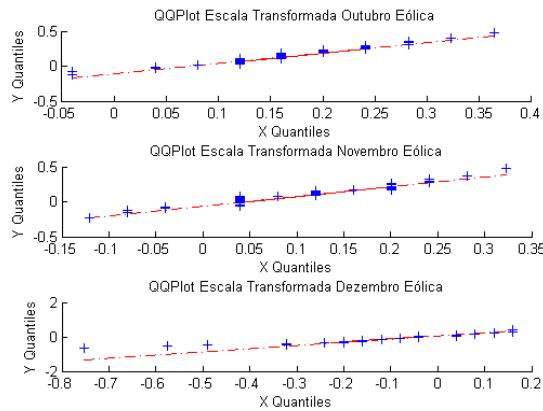


Fig. 101 – FC: QQplot (outubro, novembro e dezembro) – Variáveis transformadas

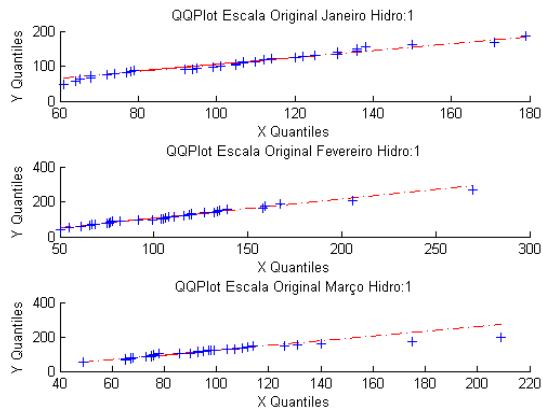


Fig. 102 – Vz: QQplot (janeiro, fevereiro e março) – Variáveis originais

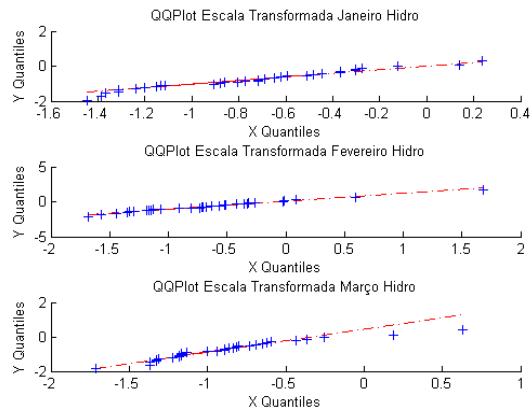


Fig. 103 – Vz: QQplot (janeiro, fevereiro e março) – Variáveis transformadas

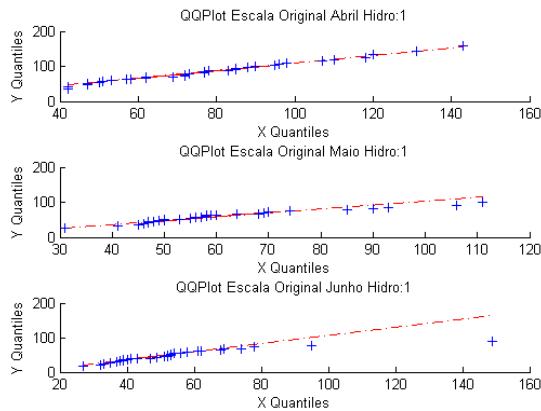


Fig. 104 – Vz: QQplot (abril, maio e junho) – Variáveis originais

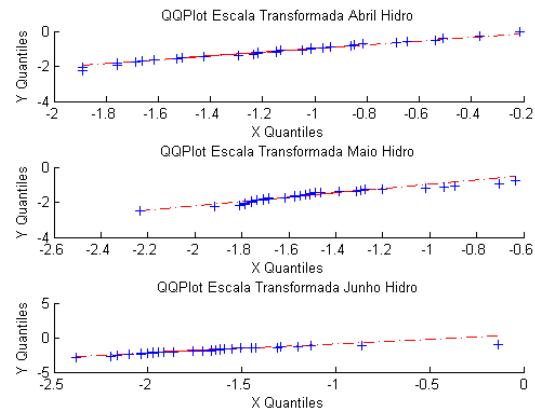


Fig. 105 – Vz: QQplot (abril, maio e junho) – Variáveis transformadas

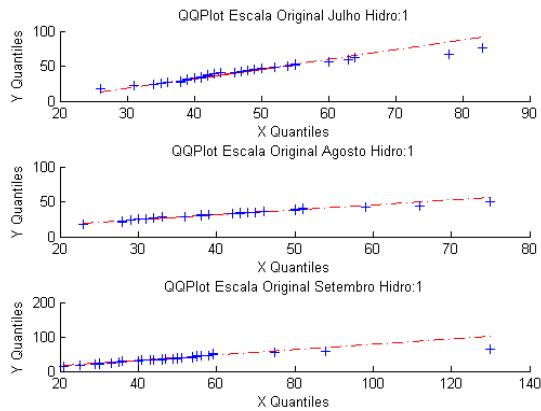


Fig. 106 – Vz: QQplot (julho, agosto e setembro) – Variáveis originais

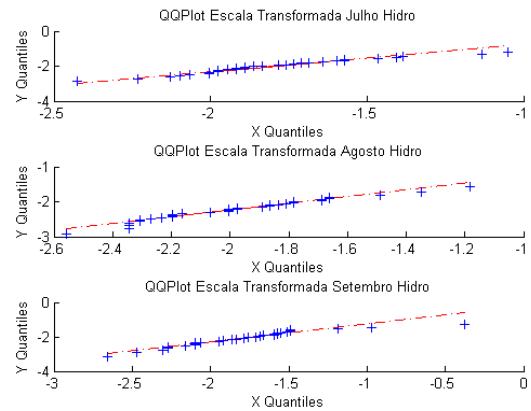


Fig. 107 – Vz: QQplot (julho, agosto e setembro) – Variáveis transformadas

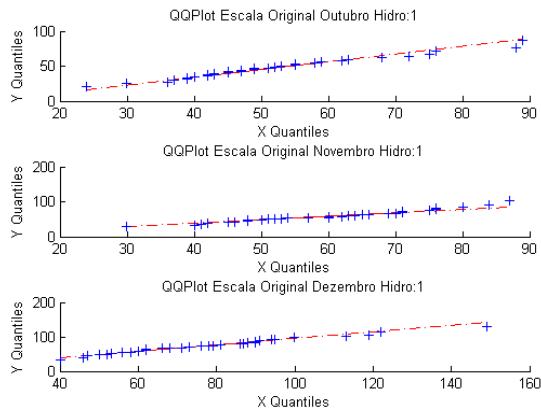


Fig. 108 – Vz: QQplot (outubro, novembro e dezembro) – Variáveis originais

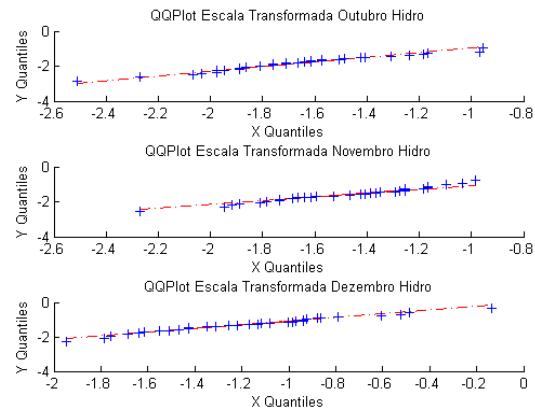


Fig. 109 – Vz: QQplot (outubro, novembro e dezembro) – Variáveis transformadas

## B. Método heurístico

### a) Inventar subtítulo

#### a.1) Especificação - Fator de Capacidade Eólico (FC')

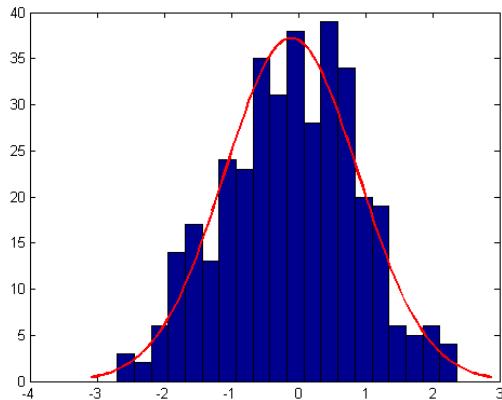


Fig. 110 – FC': Histograma dos resíduos

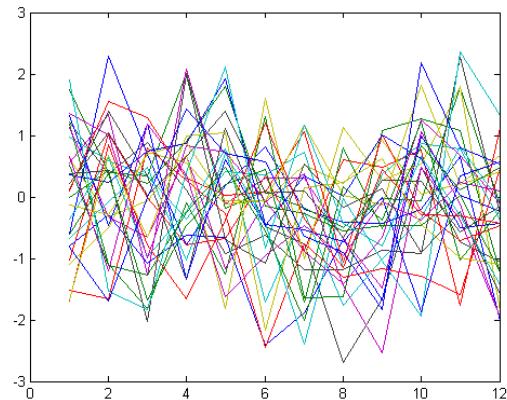


Fig. 111 – FC': Comparativo anual dos resíduos

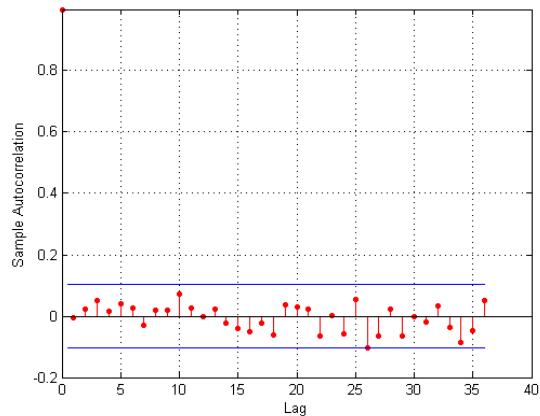


Fig. 112 – FC': Correlograma para os resíduos

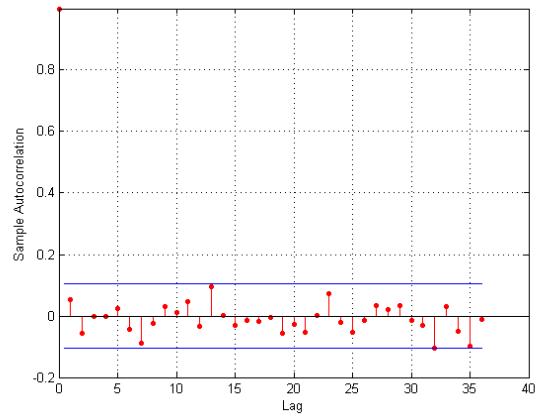
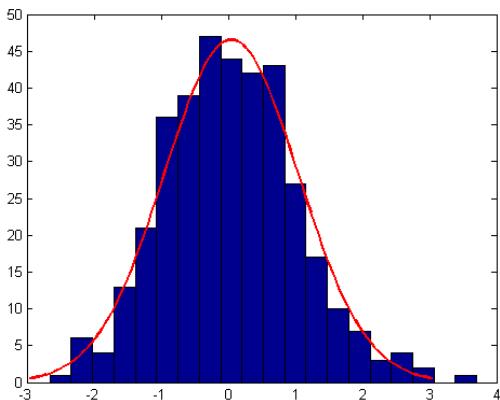
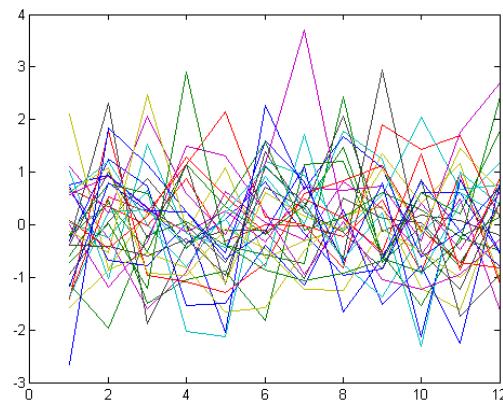
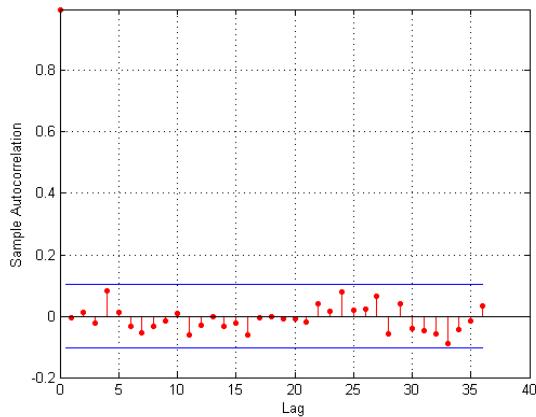
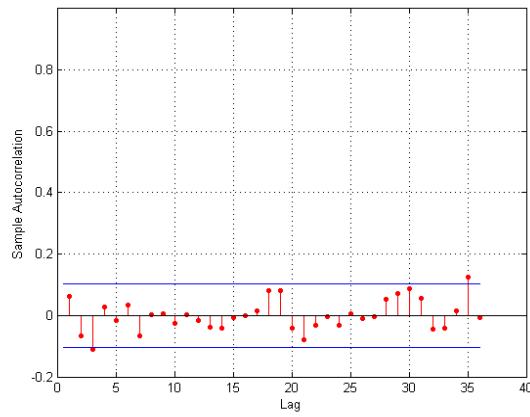


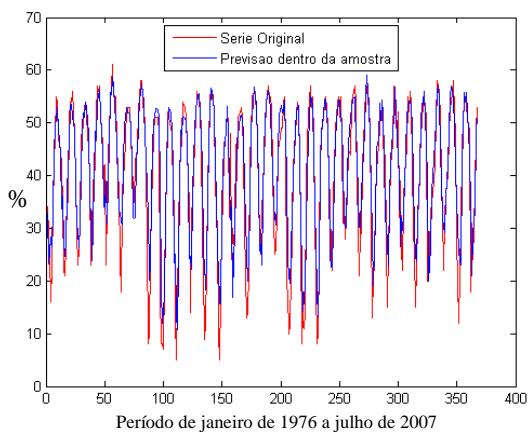
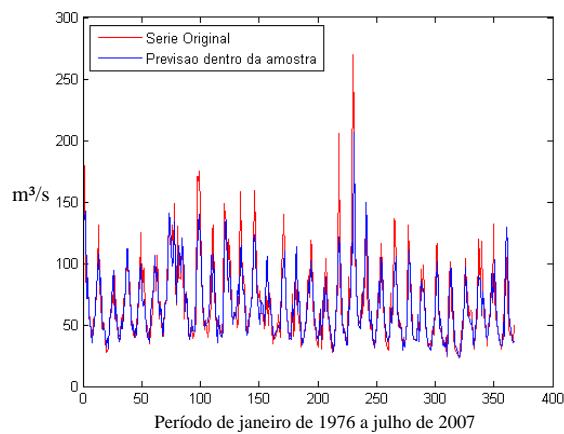
Fig. 113 – FC': Correlograma para os quadrados dos resíduos

### a.2) Especificação - Vazão( $Vz'$ )

Fig. 114 –  $Vz'$ : Histograma dos resíduosFig. 115 –  $Vz'$ : Comparativo anual dos resíduosFig. 116 –  $Vz'$ : Correlograma para os resíduosFig. 117 –  $Vz'$ : Correlograma para os quadrados dos resíduos

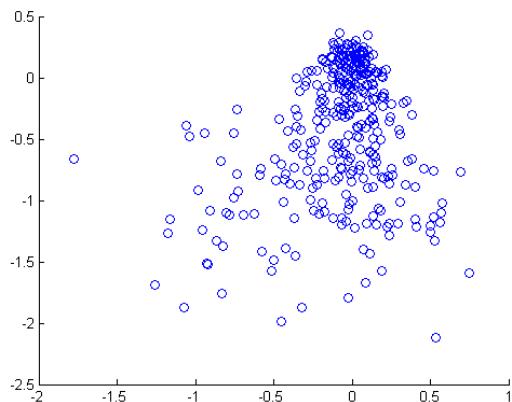
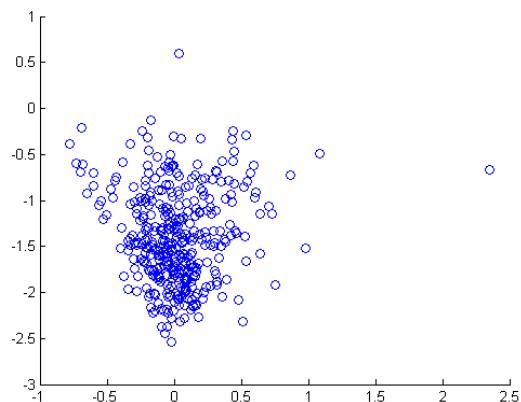
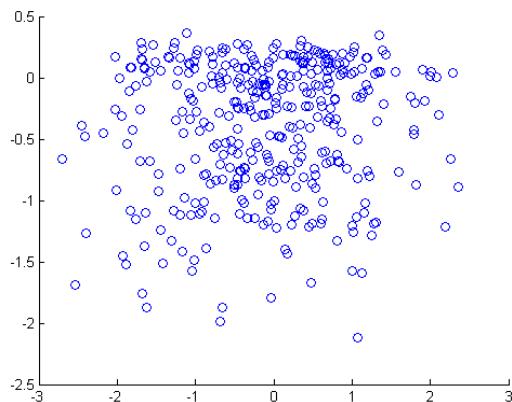
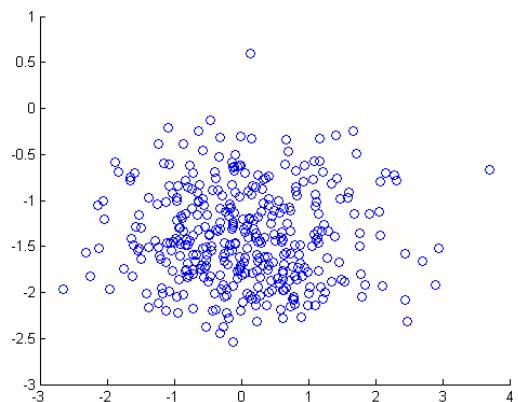
### a.3) Análise do modelo

#### ANÁLISE DENTRO DA AMOSTRA

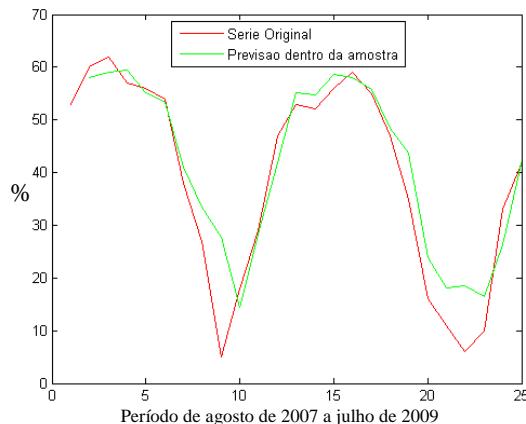
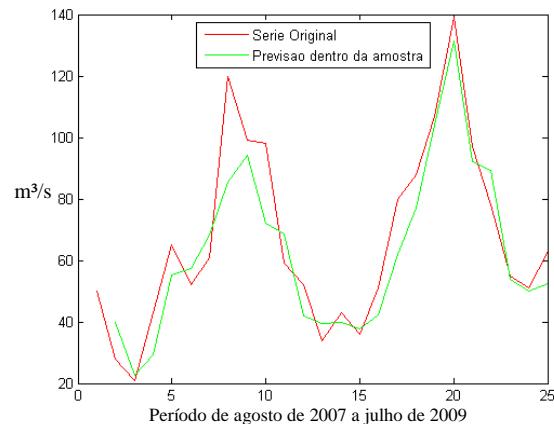
Fig. 118 –  $FC$ : Previsão dentro da amostraFig. 119 –  $Vz$ : Previsão dentro da amostra

	<i>FC</i>	<i>Vz</i>
<i>R</i> <sup>2</sup>	0.7686	0.7549
<i>R</i> <sup>2</sup> <i>ajustado</i>	0.7464	0.7314
P-valor JB dos Resíduos	0.3263	0.0344

Tabela 21 – Medidas de Aderência – Dentro da Amostra

Fig. 120 – Resíduos X valor predito para *FC*Fig. 121 – Resíduos X valor predito para *Vz*Fig. 122 – Resíduos padronizados X valor predito para *FC*Fig. 123 – Resíduos padronizados X valor predito para *Vz*

## ANÁLISE FORA DA AMOSTRA

Fig. 124 – Desempenho do modelo fora da amostra para *FC*Fig. 125 – Desempenho do modelo fora da amostra para *Vz*

	<i>FC</i>	<i>Vz</i>
<b>MAPE</b>	41.21	14.36
<b>MAE</b>	4.63	9.27
<b>RMS</b>	6.71	12.05
<b>MPE</b>	0.36	-0.04
<b>SDPE</b>	0.98	0.17
<b>U</b>	0.08	0.09

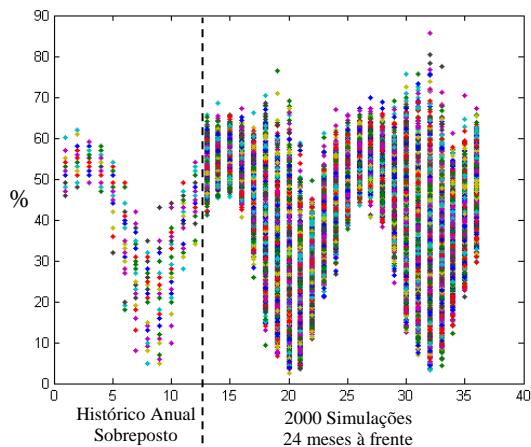
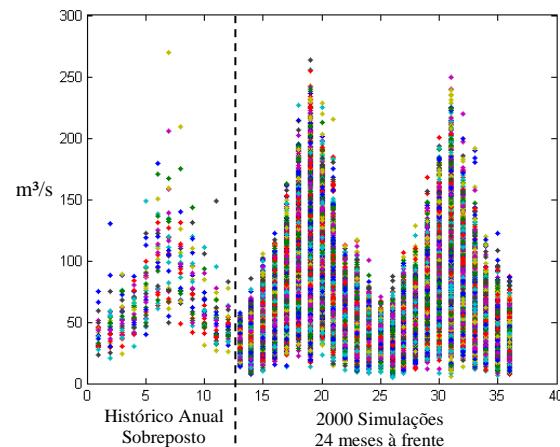
Tabela 22 – Medidas de Aderência – Fora da Amostra

**a.4) Correlações constantes**CORRELAÇÃO ENTRE AS SÉRIES DE VAZÃO (*Vz*) E FATOR DE CAPACIDADE (*FC*)

	Resíduos <i>FC'</i>	Resíduos <i>Vz'</i>
Resíduos <i>FC'</i>	$r_{1,1}^2 = 1,0000$	$r_{1,2}^2 = -0,1306$
Resíduos <i>Vz'</i>	$r_{2,1}^2 = -0,1306$	$r_{2,2}^2 = 1,0000$

Tabela 23 – Matriz de correlação residual  $\epsilon_t$ 

## SIMULAÇÃO

Fig. 126 – *FC*: 2000 simulaçõesFig. 127 – *Vz*: 2000 simulações

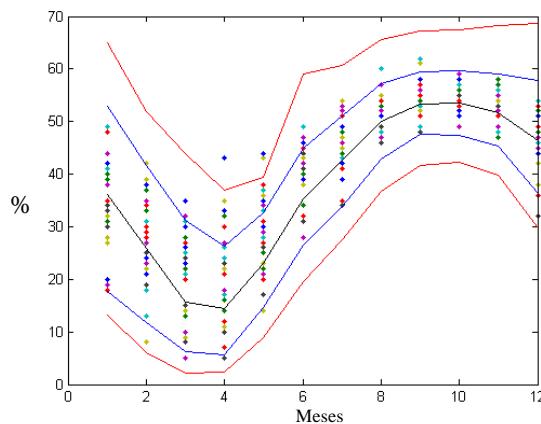


Fig. 128 – FC: Histórico com Intervalo de Confiança de 95% das simulações

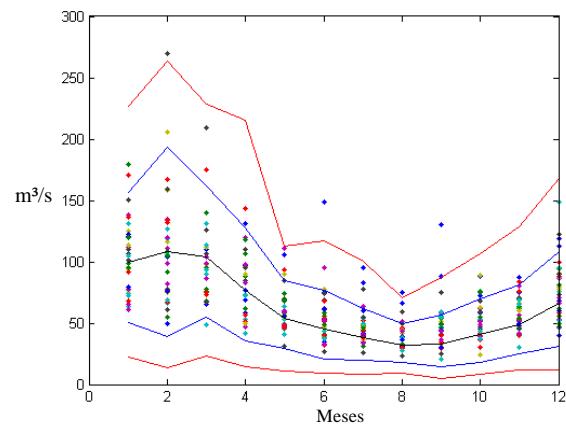


Fig. 129 – Vz: Histórico com Intervalo de Confiança de 95% das simulações

Estatísticas Descritivas FC	Período Observado							Simulações						
	Média	Desvio	Mínimo	Máximo	Q.5%	Mediana	Q.95%	Média	Desvio	Mínimo	Máximo	Q.5%	Mediana	Q.95%
Janeiro	35.73	7.65	18.00	49.00	19.15	38.00	48.00	38.95	10.55	9.25	75.56	22.53	38.41	57.54
Fevereiro	26.30	8.93	8.00	42.00	8.75	28.00	38.85	31.97	11.62	6.70	76.42	14.98	30.61	53.17
Março	19.06	8.49	5.00	35.00	5.45	21.00	31.85	26.68	13.60	2.53	85.71	8.86	24.17	52.87
Abril	21.64	9.85	5.00	43.00	6.15	22.00	35.00	24.24	11.61	3.68	77.51	9.26	22.03	47.17
Maio	30.30	8.35	10.00	44.00	14.45	31.00	43.85	28.84	7.95	10.90	61.10	17.44	27.91	43.33
Junho	40.85	5.18	28.00	49.00	31.15	42.00	48.70	38.61	6.44	21.08	70.48	28.65	38.25	49.68
Julho	45.97	5.08	34.00	54.00	35.60	46.00	53.00	46.01	5.90	26.62	67.27	36.50	45.90	56.01
Agosto	52.21	3.50	46.00	60.00	47.15	52.00	57.00	51.93	4.10	37.83	65.70	45.01	51.98	58.65
Setembro	54.52	3.02	48.00	62.00	49.30	55.00	60.55	54.39	3.31	43.42	68.60	49.04	54.26	60.06
Outubro	54.15	2.28	49.00	59.00	49.30	54.00	57.85	54.72	3.44	40.60	69.81	49.27	54.57	60.55
Novembro	52.58	2.77	47.00	58.00	48.00	53.00	56.85	52.18	4.10	38.37	68.76	45.47	52.12	58.96
Dezembro	46.73	4.93	32.00	54.00	36.30	47.00	53.85	46.01	5.99	24.57	69.20	36.33	45.90	55.71

Tabela 24 – Análise de cenários simulados – FC – Escala original

Estatísticas Descritivas FC	Período Observado							Simulações						
	Média	Desvio	Mínimo	Máximo	Q.5%	Mediana	Q.95%	Média	Desvio	Mínimo	Máximo	Q.5%	Mediana	Q.95%
Janeiro	105.64	30.58	61.00	179.00	64.15	105.00	167.85	91.97	33.31	8.65	226.99	43.66	89.23	151.52
Fevereiro	112.09	45.45	50.00	270.00	55.90	108.00	200.15	98.75	46.83	5.94	263.47	31.65	92.64	186.50
Marco	95.70	32.66	49.00	209.00	65.00	93.00	169.75	92.28	33.98	13.19	228.63	42.30	89.14	153.62
Abri	79.12	26.11	42.00	143.00	42.75	77.00	129.35	69.06	27.93	11.57	215.51	30.35	65.34	120.89
Maio	60.70	18.27	31.00	111.00	41.60	56.00	104.05	49.76	16.63	10.13	119.52	25.32	48.00	80.24
Junho	53.79	22.46	27.00	149.00	32.15	51.00	92.45	42.61	16.80	6.98	121.97	18.78	40.74	72.86
Julho	46.73	12.36	26.00	83.00	31.45	43.00	75.90	35.93	12.86	7.27	100.69	18.07	34.25	59.50
Agosto	40.30	11.55	23.00	75.00	28.00	38.00	64.95	31.59	8.60	9.10	70.21	18.67	30.95	46.90
Setembro	48.45	20.16	21.00	130.00	25.60	46.00	86.05	33.32	12.03	4.44	87.59	15.30	32.20	54.87
Outubro	52.30	15.32	24.00	89.00	30.90	49.00	86.20	42.85	15.40	8.06	106.42	20.30	41.28	71.09
Novembro	59.85	13.98	30.00	87.00	40.15	60.00	83.40	52.13	17.76	11.50	128.85	26.51	50.35	84.82
Dezembro	77.70	24.64	40.00	149.00	46.15	76.00	121.55	70.67	24.02	11.76	168.29	35.52	68.21	113.72

Tabela 25 – Análise de cenários simulados – Vz – Escala original

Estatísticas Descritivas FC	Período Observado							Simulações						
	Média	Desvio	Mínimo	Máximo	Q.5%	Mediana	Q.95%	Média	Desvio	Mínimo	Máximo	Q.5%	Mediana	Q.95%
Janeiro	-0.61	0.36	-1.52	-0.04	-1.44	-0.49	-0.08	-0.47	0.46	-2.28	1.13	-1.24	-0.47	0.30
Fevereiro	-1.10	0.53	-2.44	-0.32	-2.36	-0.94	-0.45	-0.81	0.56	-2.63	1.18	-1.74	-0.82	0.13
Marco	-1.56	0.64	-2.94	-0.62	-2.87	-1.32	-0.76	-1.13	0.75	-3.65	1.79	-2.33	-1.14	0.11
Abri	-1.41	0.67	-2.94	-0.28	-2.73	-1.27	-0.62	-1.24	0.65	-3.26	1.24	-2.28	-1.26	-0.11
Maio	-0.87	0.45	-2.20	-0.24	-1.78	-0.80	-0.25	-0.93	0.39	-2.10	0.45	-1.55	-0.95	-0.27
Junho	-0.38	0.22	-0.94	-0.04	-0.79	-0.32	-0.05	-0.47	0.27	-1.32	0.87	-0.91	-0.48	-0.01
Julho	-0.16	0.21	-0.66	0.16	-0.59	-0.16	0.12	-0.16	0.24	-1.01	0.72	-0.55	-0.16	0.24
Agosto	0.09	0.14	-0.16	0.41	-0.11	0.08	0.28	0.08	0.17	-0.50	0.65	-0.20	0.08	0.35
Setembro	0.18	0.12	-0.08	0.49	-0.03	0.20	0.43	0.18	0.13	-0.26	0.78	-0.04	0.17	0.41
Outubro	0.17	0.09	-0.04	0.36	-0.03	0.16	0.32	0.19	0.14	-0.38	0.84	-0.03	0.18	0.43
Novembro	0.10	0.11	-0.12	0.32	-0.08	0.12	0.28	0.09	0.17	-0.47	0.79	-0.18	0.08	0.36
Dezembro	-0.13	0.20	-0.75	0.16	-0.56	-0.12	0.15	-0.16	0.24	-1.12	0.81	-0.56	-0.16	0.23

Tabela 26 – Análise de cenários simulados – FC – Escala transformada

Estatísticas Descritivas FC	Período Observado							Simulações						
	Média	Desvio	Mínimo	Máximo	Q.5%	Mediana	Q.95%	Média	Desvio	Mínimo	Máximo	Q.5%	Mediana	Q.95%
Janeiro	-0.74	0.44	-1.45	0.24	-1.38	-0.72	0.10	-0.97	0.54	-3.58	0.89	-1.85	-0.95	-0.11
Fevereiro	-0.65	0.66	-1.69	1.69	-1.55	-0.67	0.52	-0.91	0.76	-3.97	1.54	-2.21	-0.90	0.33
Março	-0.89	0.47	-1.71	0.63	-1.37	-0.89	0.12	-0.96	0.55	-3.15	0.92	-1.88	-0.95	-0.08
Abril	-1.16	0.44	-1.89	-0.21	-1.87	-1.15	-0.39	-1.37	0.54	-3.28	0.72	-2.26	-1.36	-0.50
Maio	-1.49	0.35	-2.23	-0.63	-1.90	-1.55	-0.73	-1.75	0.41	-3.42	-0.52	-2.45	-1.73	-1.09
Junho	-1.66	0.43	-2.38	-0.14	-2.19	-1.66	-0.90	-1.95	0.48	-3.80	-0.48	-2.77	-1.92	-1.22
Julho	-1.80	0.29	-2.43	-1.05	-2.22	-1.86	-1.17	-2.13	0.41	-3.76	-0.78	-2.82	-2.12	-1.48
Agosto	-1.97	0.31	-2.56	-1.18	-2.34	-2.00	-1.37	-2.25	0.31	-3.53	-1.27	-2.78	-2.23	-1.76
Setembro	-1.79	0.44	-2.66	-0.38	-2.44	-1.78	-1.00	-2.22	0.43	-4.26	-0.98	-2.99	-2.19	-1.58
Outubro	-1.67	0.35	-2.51	-0.95	-2.24	-1.71	-1.00	-1.93	0.44	-3.66	-0.70	-2.69	-1.91	-1.25
Novembro	-1.50	0.30	-2.27	-0.99	-1.94	-1.47	-1.04	-1.69	0.42	-3.29	-0.39	-2.40	-1.68	-1.02
Dezembro	-1.18	0.41	-1.95	-0.14	-1.78	-1.17	-0.49	-1.32	0.46	-3.27	0.10	-2.08	-1.31	-0.60

Tabela 27 – Análise de cenários simulados – Vz – Escala transformada

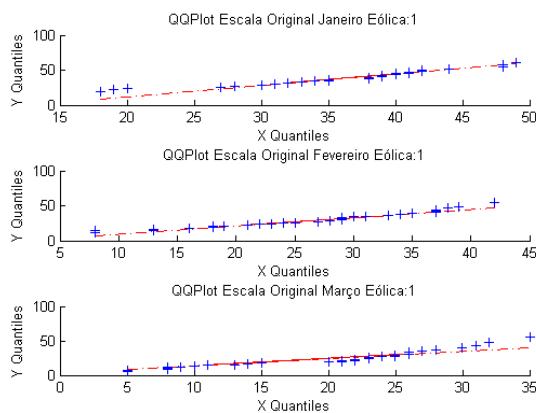


Fig. 130 – FC: QQplot (janeiro, fevereiro e março) – Variáveis originais

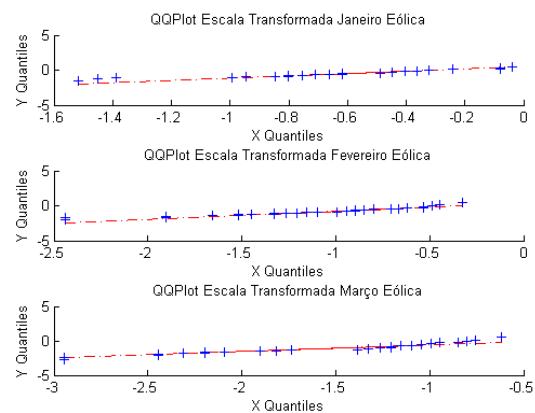


Fig. 131 – FC: QQplot (janeiro, fevereiro e março) – Variáveis transformadas

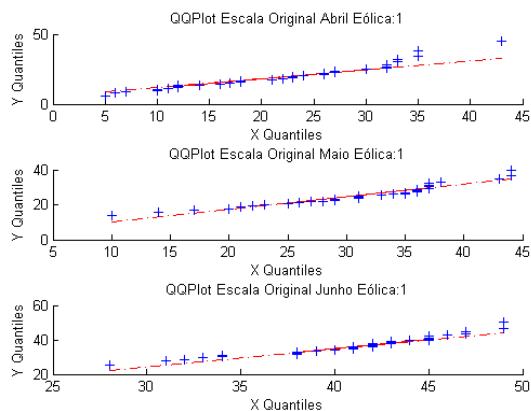


Fig. 132 – FC: QQplot (abril, maio e junho) – Variáveis originais

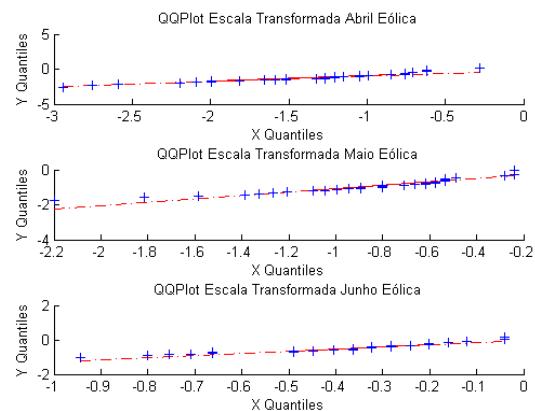


Fig. 133 – FC: QQplot (abril, maio e junho) – Variáveis transformadas

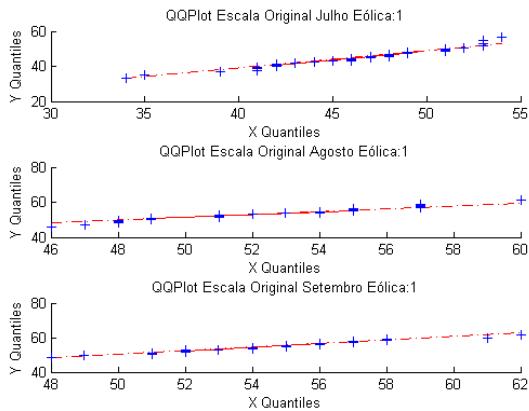


Fig. 134 – FC: QQplot (julho, agosto e setembro) – Variáveis originais

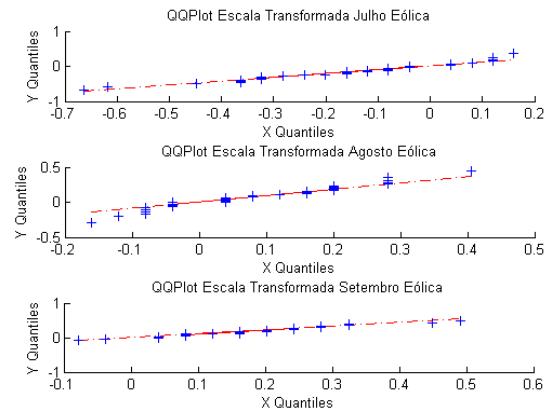


Fig. 135 – FC: QQplot (julho, agosto e setembro) – Variáveis transformadas

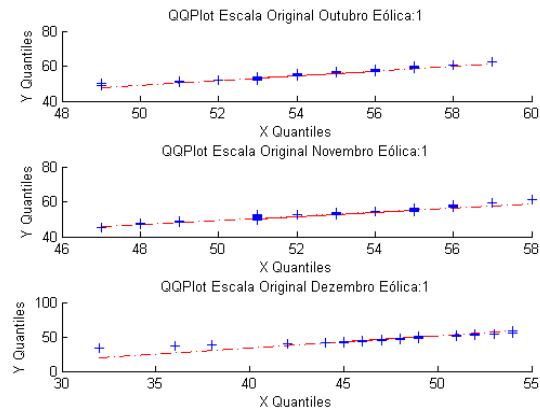


Fig. 136 – FC: QQplot (outubro, novembro e dezembro) – Variáveis originais

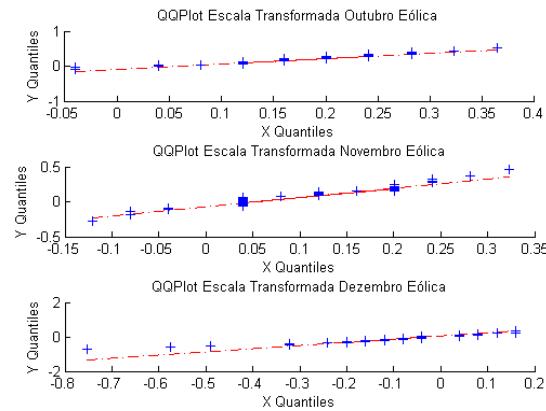


Fig. 137 – FC: QQplot (outubro, novembro e dezembro) – Variáveis transformadas

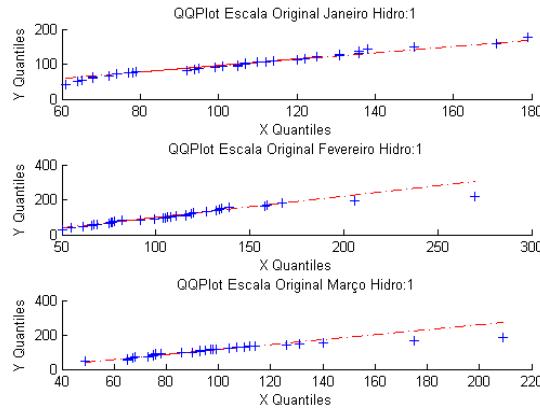


Fig. 138 – Vz: QQplot (janeiro, fevereiro e março) – Variáveis originais

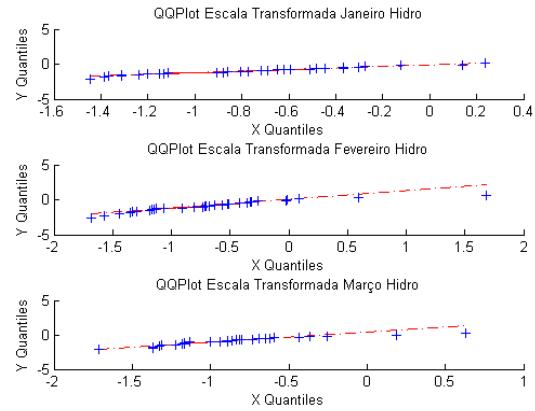


Fig. 139 – Vz: QQplot (janeiro, fevereiro e março) – Variáveis transformadas

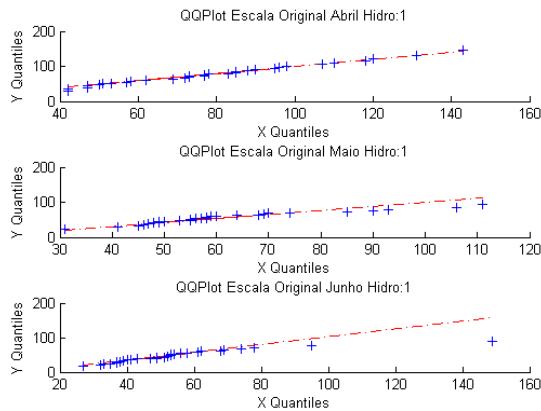


Fig. 140 – Vz: QQplot (abril, maio e junho) – Variáveis originais

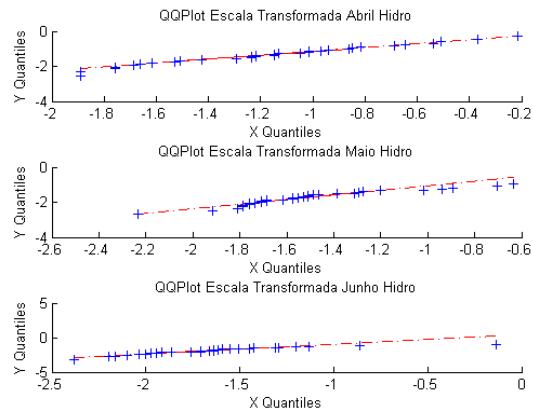


Fig. 141 – Vz: QQplot (abril, maio e junho) – Variáveis transformadas

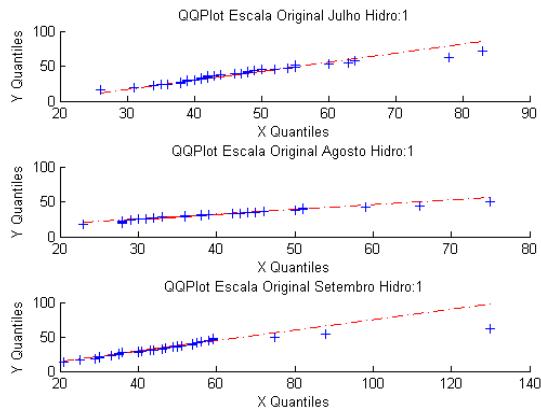


Fig. 142 – Vz: QQplot (julho, agosto e setembro) – Variáveis originais

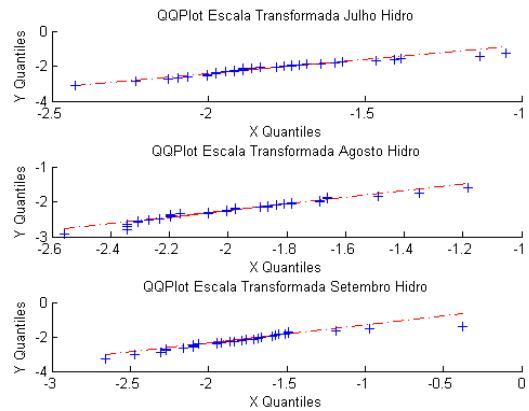


Fig. 143 – Vz: QQplot (julho, agosto e setembro) – Variáveis transformadas

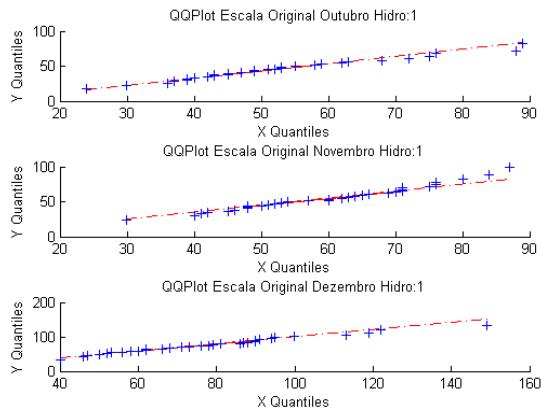


Fig. 144 – Vz: QQplot (outubro, novembro e dezembro) – Variáveis originais

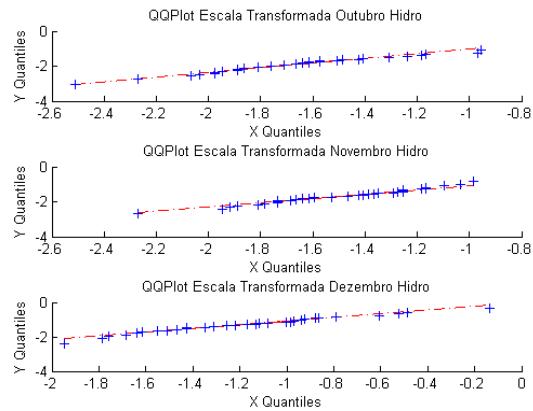


Fig. 145 – Vz: QQplot (outubro, novembro e dezembro) – Variáveis transformadas

### b) Correlações mês a mês

CORRELAÇÃO ENTRE AS SÉRIES DE VAZÃO (VZ) E FATOR DE CAPACIDADE (FC)

MÊS	$\sigma_1$	$\sigma_2$	CORRELAÇÃO
1	0.43	0.38	<b>-50.00%</b>
2	0.49	0.64	<b>-35.46%</b>
3	0.66	0.26	<b>-33.94%</b>
4	0.50	0.33	1.42%
5	0.19	0.09	-6.85%
6	0.17	0.17	-9.82%
7	0.18	0.20	<b>-22.45%</b>
8	0.11	0.13	-5.08%
9	0.07	0.18	-5.50%
10	0.07	0.21	13.34%
11	0.09	0.26	3.14%
12	0.18	0.26	-3.30%

Tabela 28 – Desvio padrão e correlação mensal das séries

SIMULAÇÃO

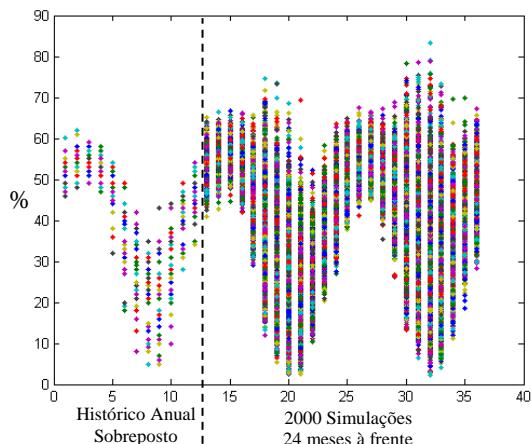


Fig. 146 – FC: 2000 simulações

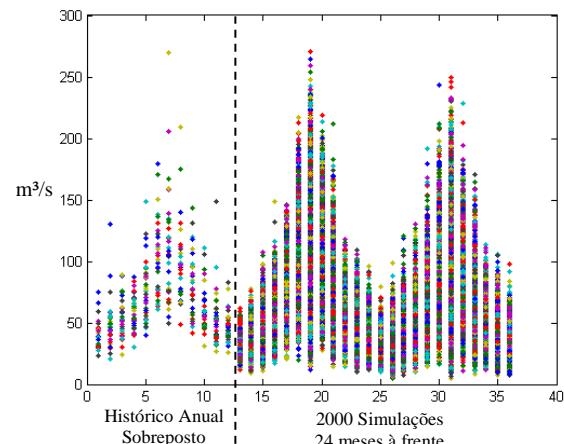


Fig. 147 – Vz: 2000 simulações

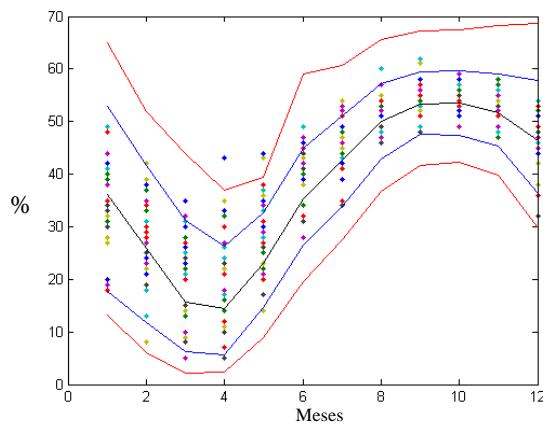


Fig. 148 – FC: Histórico com Intervalo de Confiança de 95% das simulações

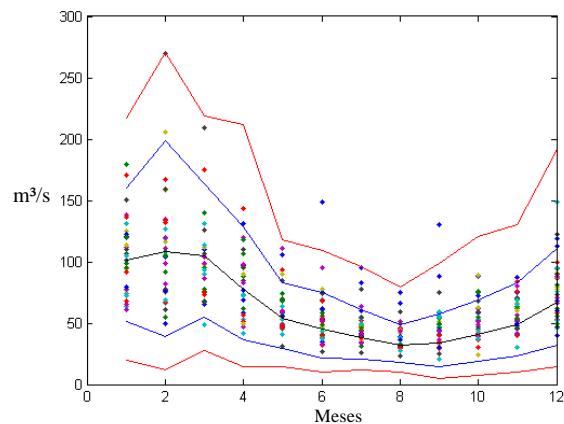


Fig. 149 – Vz: Histórico com Intervalo de Confiança de 95% das simulações

Estatísticas Descritivas FC	Período Observado							Simulações						
	Média	Desvio	Mínimo	Máximo	Q.5%	Mediana	Q.95%	Média	Desvio	Mínimo	Máximo	Q.5%	Mediana	Q.95%
Janeiro	35.73	7.65	18.00	49.00	19.15	38.00	48.00	38.66	10.91	12.00	78.37	22.03	37.81	58.12
Fevereiro	26.30	8.93	8.00	42.00	8.75	28.00	38.85	31.94	11.88	5.48	78.67	14.89	30.66	53.49
Marco	19.06	8.49	5.00	35.00	5.45	21.00	31.85	26.77	13.73	2.23	83.26	8.47	24.65	52.28
Abril	21.64	9.85	5.00	43.00	6.15	22.00	35.00	24.61	12.07	2.37	73.16	8.90	22.37	47.84
Maio	30.30	8.35	10.00	44.00	14.45	31.00	43.85	29.04	8.34	10.41	69.71	16.96	28.21	44.20
Junho	40.85	5.18	28.00	49.00	31.15	42.00	48.70	38.61	6.62	18.47	69.81	28.31	38.34	49.97
Julho	45.97	5.08	34.00	54.00	35.60	46.00	53.00	46.21	6.05	26.93	67.33	36.38	46.15	56.39
Agosto	52.21	3.50	46.00	60.00	47.15	52.00	57.00	51.89	4.10	37.79	65.07	44.78	52.00	58.42
Setembro	54.52	3.02	48.00	62.00	49.30	55.00	60.55	54.38	3.34	41.12	67.48	48.97	54.32	60.05
Outubro	54.15	2.28	49.00	59.00	49.30	54.00	57.85	54.71	3.40	44.62	66.62	49.24	54.60	60.45
Novembro	52.58	2.77	47.00	58.00	48.00	53.00	56.85	52.22	3.97	35.32	67.31	45.78	52.13	59.01
Dezembro	46.73	4.93	32.00	54.00	36.30	47.00	53.85	46.10	5.97	26.10	68.74	36.71	45.98	56.47

Tabela 29 – Análise de cenários simulados – FC – Escala original

Estatísticas Descritivas FC	Período Observado							Simulações						
	Média	Desvio	Mínimo	Máximo	Q.5%	Mediana	Q.95%	Média	Desvio	Mínimo	Máximo	Q.5%	Mediana	Q.95%
Janeiro	105.64	30.58	61.00	179.00	64.15	105.00	167.85	93.13	33.91	16.31	243.48	43.81	89.70	154.20
Fevereiro	112.09	45.45	50.00	270.00	55.90	108.00	200.15	98.86	47.23	4.57	270.40	32.91	93.22	188.36
Marco	95.70	32.66	49.00	209.00	65.00	93.00	169.75	92.79	34.09	11.21	228.68	42.09	89.00	155.40
Abril	79.12	26.11	42.00	143.00	42.75	77.00	129.35	70.10	28.33	8.06	211.82	30.20	67.09	122.69
Maio	60.70	18.27	31.00	111.00	41.60	56.00	104.05	50.15	16.56	11.92	117.73	26.15	48.47	79.38
Junho	53.79	22.46	27.00	149.00	32.15	51.00	92.45	42.60	16.39	7.76	109.42	18.85	40.68	72.26
Julho	46.73	12.36	26.00	83.00	31.45	43.00	75.90	36.14	12.77	7.16	97.74	18.14	34.66	59.37
Agosto	40.30	11.55	23.00	75.00	28.00	38.00	64.95	31.45	8.52	10.50	79.45	18.97	30.53	46.51
Setembro	48.45	20.16	21.00	130.00	25.60	46.00	86.05	33.51	12.19	4.58	98.88	15.45	32.27	55.45
Outubro	52.30	15.32	24.00	89.00	30.90	49.00	86.20	42.72	15.26	7.78	120.24	20.81	41.35	69.78
Novembro	59.85	13.98	30.00	87.00	40.15	60.00	83.40	52.00	17.68	9.72	149.03	26.89	50.03	84.30
Dezembro	77.70	24.64	40.00	149.00	46.15	76.00	121.55	70.64	23.90	14.55	191.54	35.01	68.12	113.48

Tabela 30 – Análise de cenários simulados – Vz – Escala original

Estatísticas Descritivas FC	Período Observado							Simulações						
	Média	Desvio	Mínimo	Máximo	Q.5%	Mediana	Q.95%	Média	Desvio	Mínimo	Máximo	Q.5%	Mediana	Q.95%
Janeiro	-0.61	0.36	-1.52	-0.04	-1.44	-0.49	-0.08	-0.49	0.48	-1.99	1.29	-1.26	-0.50	0.33
Fevereiro	-1.10	0.53	-2.44	-0.32	-2.36	-0.94	-0.45	-0.81	0.58	-2.85	1.31	-1.74	-0.82	0.14
Marco	-1.56	0.64	-2.94	-0.62	-2.87	-1.32	-0.76	-1.13	0.76	-3.78	1.60	-2.38	-1.12	0.09
Abril	-1.41	0.67	-2.94	-0.28	-2.73	-1.27	-0.62	-1.23	0.68	-3.72	1.00	-2.33	-1.24	-0.09
Maio	-0.87	0.45	-2.20	-0.24	-1.78	-0.80	-0.25	-0.93	0.41	-2.15	0.83	-1.59	-0.93	-0.23
Junho	-0.38	0.22	-0.94	-0.04	-0.79	-0.32	-0.05	-0.47	0.28	-1.49	0.84	-0.93	-0.48	0.00
Julho	-0.16	0.21	-0.66	0.16	-0.59	-0.16	0.12	-0.15	0.25	-1.00	0.72	-0.56	-0.15	0.26
Agosto	0.09	0.14	-0.16	0.41	-0.11	0.08	0.28	0.08	0.17	-0.50	0.62	-0.21	0.08	0.34
Setembro	0.18	0.12	-0.08	0.49	-0.03	0.20	0.43	0.18	0.14	-0.36	0.73	-0.04	0.17	0.41
Outubro	0.17	0.09	-0.04	0.36	-0.03	0.16	0.32	0.19	0.14	-0.22	0.69	-0.03	0.18	0.42
Novembro	0.10	0.11	-0.12	0.32	-0.08	0.12	0.28	0.09	0.16	-0.60	0.72	-0.17	0.09	0.36
Dezembro	-0.13	0.20	-0.75	0.16	-0.56	-0.12	0.15	-0.16	0.24	-1.04	0.79	-0.54	-0.16	0.26

Tabela 31 – Análise de cenários simulados – FC – Escala transformada

Estatísticas Descritivas FC	Período Observado							Simulações						
	Média	Desvio	Mínimo	Máximo	Q.5%	Mediana	Q.95%	Média	Desvio	Mínimo	Máximo	Q.5%	Mediana	Q.95%
Janeiro	-0.74	0.44	-1.45	0.24	-1.38	-0.72	0.10	-0.95	0.54	-2.92	1.16	-1.84	-0.94	-0.07
Fevereiro	-0.65	0.66	-1.69	1.69	-1.55	-0.67	0.52	-0.91	0.77	-4.24	1.70	-2.17	-0.89	0.36
Março	-0.89	0.47	-1.71	0.63	-1.37	-0.89	0.12	-0.96	0.55	-3.32	0.92	-1.89	-0.95	-0.06
Abril	-1.16	0.44	-1.89	-0.21	-1.87	-1.15	-0.39	-1.35	0.54	-3.66	0.67	-2.26	-1.33	-0.48
Maio	-1.49	0.35	-2.23	-0.63	-1.90	-1.55	-0.73	-1.74	0.40	-3.25	-0.54	-2.42	-1.72	-1.11
Junho	-1.66	0.43	-2.38	-0.14	-2.19	-1.66	-0.90	-1.95	0.47	-3.69	-0.65	-2.77	-1.93	-1.23
Julho	-1.80	0.29	-2.43	-1.05	-2.22	-1.86	-1.17	-2.12	0.41	-3.78	-0.82	-2.81	-2.11	-1.48
Agosto	-1.97	0.31	-2.56	-1.18	-2.34	-2.00	-1.37	-2.25	0.30	-3.38	-1.11	-2.76	-2.25	-1.77
Setembro	-1.79	0.44	-2.66	-0.38	-2.44	-1.78	-1.00	-2.22	0.43	-4.23	-0.80	-2.98	-2.19	-1.56
Outubro	-1.67	0.35	-2.51	-0.95	-2.24	-1.71	-1.00	-1.94	0.43	-3.69	-0.51	-2.67	-1.91	-1.28
Novembro	-1.50	0.30	-2.27	-0.99	-1.94	-1.47	-1.04	-1.70	0.42	-3.46	-0.14	-2.39	-1.69	-1.03
Dezembro	-1.18	0.41	-1.95	-0.14	-1.78	-1.17	-0.49	-1.32	0.45	-3.04	0.40	-2.10	-1.31	-0.60

Tabela 32 – Análise de cenários simulados – Vz – Escala transformada

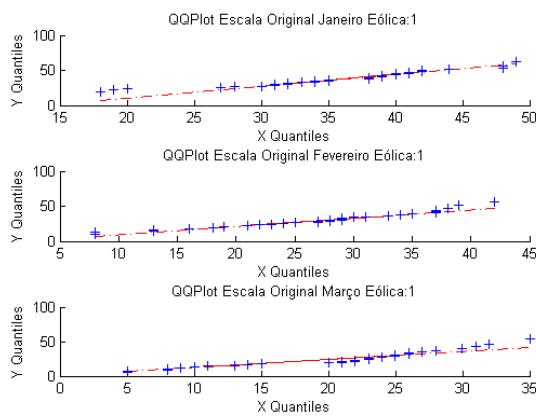


Fig. 150 – FC: QQplot (janeiro, fevereiro e março) – Variáveis originais

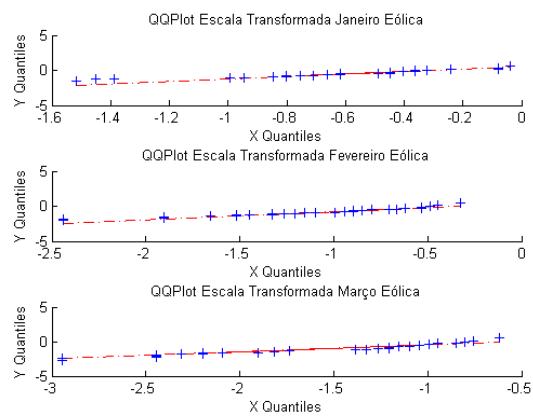


Fig. 151 – FC: QQplot (janeiro, fevereiro e março) – Variáveis transformadas

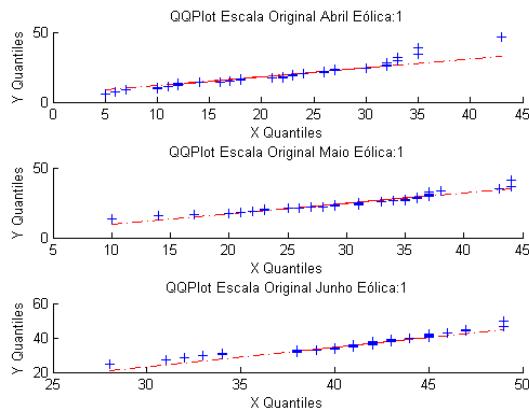


Fig. 152 – FC: QQplot (abril, maio e junho) – Variáveis originais

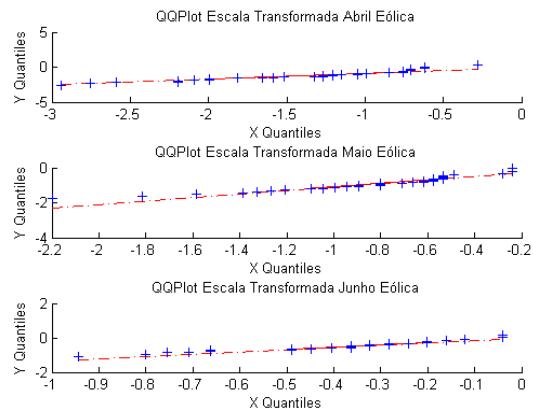


Fig. 153 – FC: QQplot (abril, maio e junho) – Variáveis transformadas

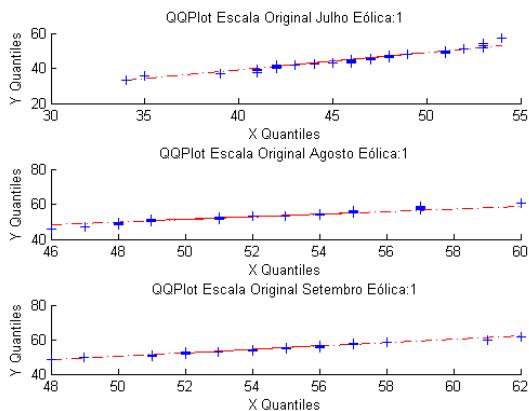


Fig. 154 – FC: QQplot (julho, agosto e setembro) – Variáveis originais

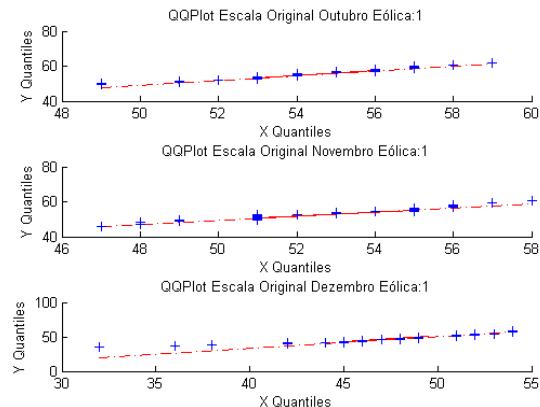


Fig. 156 – FC: QQplot (outubro, novembro e dezembro) – Variáveis originais

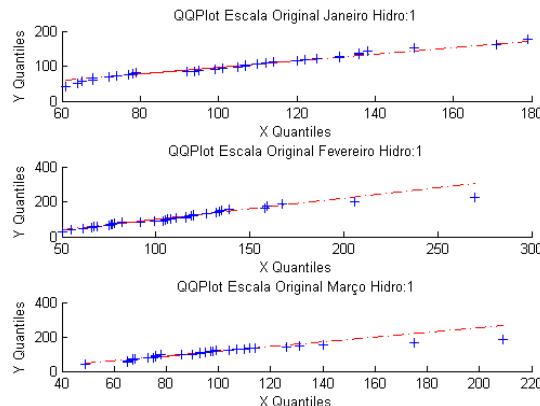


Fig. 158 – Vz: QQplot (janeiro, fevereiro e março) – Variáveis originais

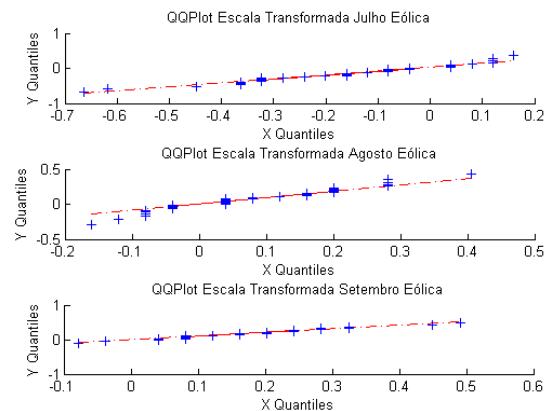


Fig. 155 – FC: QQplot (julho, agosto e setembro) – Variáveis transformadas

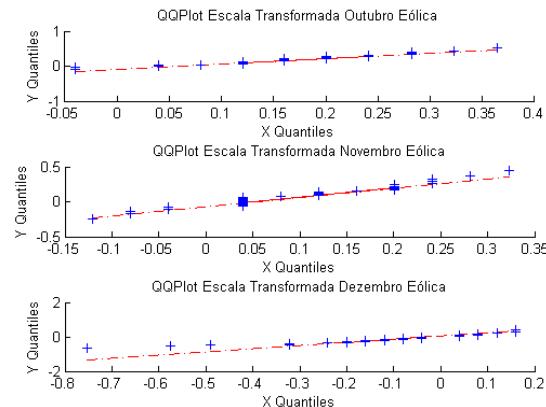


Fig. 157 – FC: QQplot (outubro, novembro e dezembro) – Variáveis transformadas

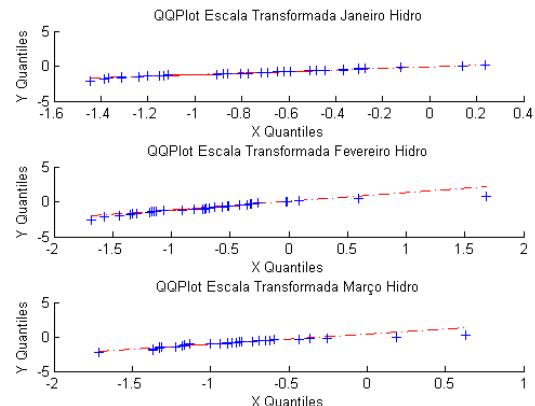


Fig. 159 – Vz: QQplot (janeiro, fevereiro e março) – Variáveis transformadas

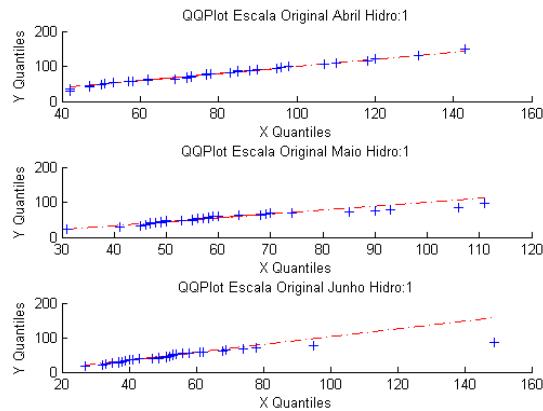


Fig. 160 – Vz: QQplot (abril, maio e junho) – Variáveis originais

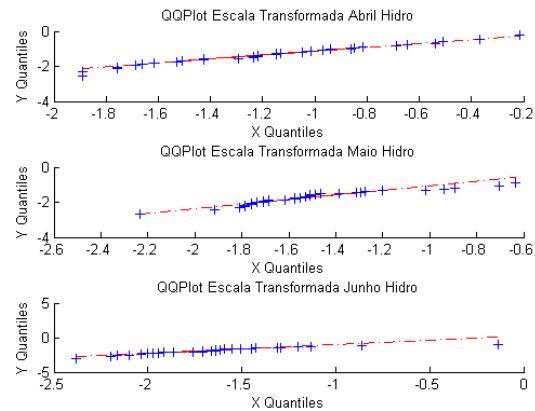


Fig. 161 – Vz: QQplot (abril, maio e junho) – Variáveis transformadas

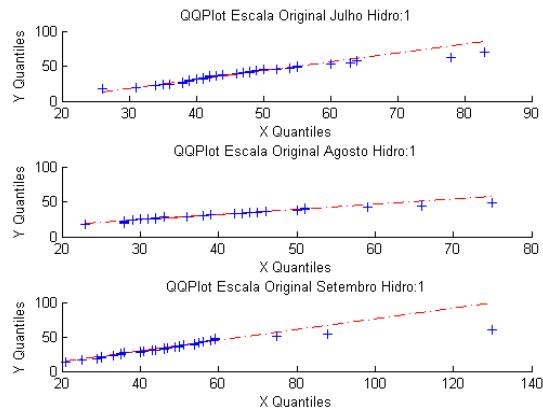


Fig. 162 – Vz: QQplot (julho, agosto e setembro) – Variáveis originais

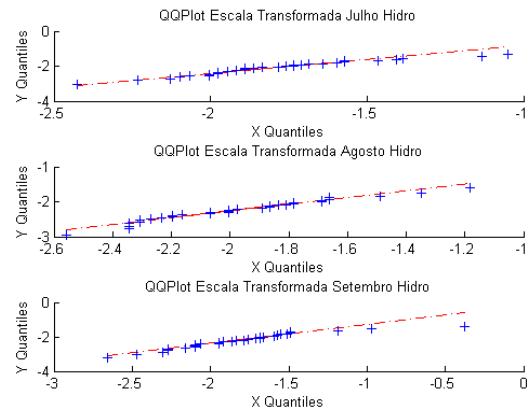


Fig. 163 – Vz: QQplot (julho, agosto e setembro) – Variáveis transformadas

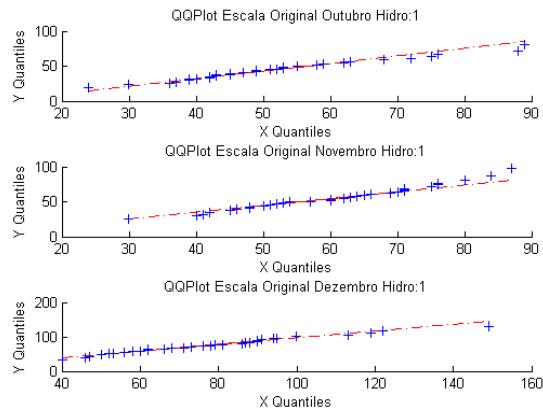


Fig. 164 – Vz: QQplot (outubro, novembro e dezembro) – Variáveis originais

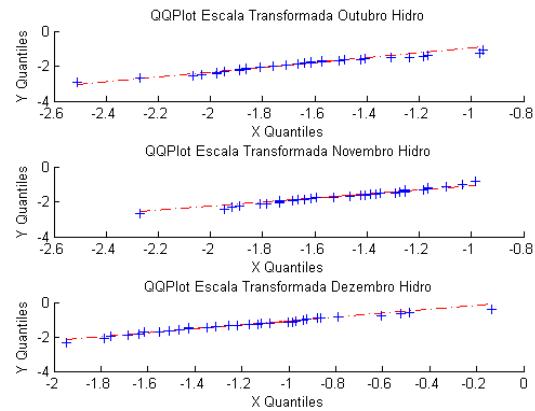


Fig. 165 – Vz: QQplot (outubro, novembro e dezembro) – Variáveis transformadas

#### ANEXO 4: RESULTADOS DO MODELO V&V PARA O ESTUDOS DE CASO 2,3 E 4

##### A. Estudo de caso 2

COEFICIENTE	VALOR
Intercepto	-0.068
$\phi_1^{vt}$	0.431
$\phi_2^{vt}$	0.035
$\phi_3^{vt}$	0.035
$\phi_4^{vt}$	-0.049
$\phi_5^{vt}$	0.069
$\phi_6^{vt}$	-0.038
$\phi_7^{vt}$	0.032
$\phi_8^{vt}$	0.007
$\phi_9^{vt}$	0.006
$\phi_{10}^{vt}$	0.012
$\phi_{11}^{vt}$	0.112
$\phi_{12}^{vt}$	-0.050
$\beta^{jan}$	-0.358
$\beta^{fev}$	-0.602
$\beta^{mar}$	-0.855
$\beta^{abr}$	-0.565
$\beta^{mai}$	-0.104
$\beta^{jun}$	0.131
$\beta^{jul}$	0.099
$\beta^{ago}$	0.269
$\beta^{set}$	0.250
$\beta^{out}$	0.201
$\beta^{nov}$	0.163

Tabela 33 – Coeficientes estimados para estudo de caso 2

##### B. Estudo de caso 3

COEFICIENTE	VALOR
Intercepto	1.16
$\phi_1^{vt}$	0.44
$\phi_2^{vt}$	0.00
$\phi_3^{vt}$	0.04
$\phi_4^{vt}$	-0.04
$\phi_5^{vt}$	0.06
$\phi_6^{vt}$	-0.01
$\phi_7^{vt}$	0.01
$\phi_8^{vt}$	-0.02
$\phi_9^{vt}$	-0.01
$\phi_{10}^{vt}$	-0.01
$\phi_{11}^{vt}$	0.20
$\phi_{12}^{vt}$	0.10
$\phi_1^{ENA-SE}$	-0.11
$\phi_2^{ENA-SE}$	0.08
$\phi_1^{ENA-S}$	-0.01
$\phi_2^{ENA-S}$	0.01
$\phi_1^{ENA-NE}$	0.13
$\phi_2^{ENA-NE}$	-0.09
$\phi_1^{ENA-N}$	-0.30
$\phi_2^{ENA-N}$	0.16

Tabela 34 – Coeficientes estimados para estudo de caso 3

### C. Estudo de caso 4

EÓLICA 1		EÓLICA 2	
COEFICIENTE	VALOR	COEFICIENTE	VALOR
Intercepto	0.425	Intercepto	1.226
$\phi_1^{vt\_1}$	0.426	$\phi_1^{vt\_1}$	0.049
$\phi_2^{vt\_1}$	0.039	$\phi_2^{vt\_1}$	0.458
$\phi_3^{vt\_1}$	0.019	$\phi_3^{vt\_1}$	-0.014
$\phi_4^{vt\_1}$	0.041	$\phi_4^{vt\_1}$	0.011
$\phi_5^{vt\_1}$	0.013	$\phi_5^{vt\_1}$	-0.043
$\phi_6^{vt\_1}$	0.008	$\phi_6^{vt\_1}$	0.038
$\phi_7^{vt\_1}$	0.013	$\phi_7^{vt\_1}$	0.029
$\phi_8^{vt\_1}$	-0.034	$\phi_8^{vt\_1}$	-0.038
$\phi_9^{vt\_1}$	0.063	$\phi_9^{vt\_1}$	-0.041
$\phi_{10}^{vt\_1}$	0.000	$\phi_{10}^{vt\_1}$	0.012
$\phi_{11}^{vt\_1}$	-0.010	$\phi_{11}^{vt\_1}$	0.025
$\phi_{12}^{vt\_1}$	-0.031	$\phi_{12}^{vt\_1}$	0.000
$\phi_1^{vt\_2}$	-0.006	$\phi_1^{vt\_2}$	-0.023
$\phi_2^{vt\_2}$	-0.017	$\phi_2^{vt\_2}$	0.014
$\phi_3^{vt\_2}$	-0.006	$\phi_3^{vt\_2}$	0.017
$\phi_4^{vt\_2}$	0.057	$\phi_4^{vt\_2}$	0.046
$\phi_5^{vt\_2}$	-0.019	$\phi_5^{vt\_2}$	0.031
$\phi_6^{vt\_2}$	-0.083	$\phi_6^{vt\_2}$	-0.043
$\phi_7^{vt\_2}$	-0.034	$\phi_7^{vt\_2}$	0.111
$\phi_8^{vt\_2}$	0.015	$\phi_8^{vt\_2}$	0.014
$\phi_9^{vt\_2}$	0.178	$\phi_9^{vt\_2}$	-0.069
$\phi_{10}^{vt\_2}$	0.115	$\phi_{10}^{vt\_2}$	0.047
$\phi_{11}^{vt\_2}$	0.070	$\phi_{11}^{vt\_2}$	0.122
$\phi_{12}^{vt\_2}$	0.028	$\phi_{12}^{vt\_2}$	0.000
$\phi_1^{vz\_1}$	0.061	$\phi_1^{vz\_1}$	-0.075
$\phi_2^{vz\_1}$	-0.056	$\phi_2^{vz\_1}$	0.040
$\phi_3^{vz\_1}$	-0.029	$\phi_3^{vz\_1}$	0.030
$\phi_4^{vz\_1}$	-0.012	$\phi_4^{vz\_1}$	0.038
$\phi_5^{vz\_1}$	-0.058	$\phi_5^{vz\_1}$	-0.166
$\phi_6^{vz\_1}$	0.030	$\phi_6^{vz\_1}$	-0.009
$\phi_7^{vz\_1}$	0.065	$\phi_7^{vz\_1}$	-0.028
$\phi_8^{vz\_1}$	-0.058	$\phi_8^{vz\_1}$	-0.006
$\phi_9^{vz\_1}$	0.006	$\phi_9^{vz\_1}$	0.049
$\phi_{10}^{vz\_1}$	0.023	$\phi_{10}^{vz\_1}$	-0.011
$\phi_{11}^{vz\_1}$	0.066	$\phi_{11}^{vz\_1}$	0.093
$\phi_{12}^{vz\_1}$	-0.017	$\phi_{12}^{vz\_1}$	-0.037
$\phi_1^{vz\_2}$	-0.064	$\phi_1^{vz\_2}$	0.012
$\phi_2^{vz\_2}$	0.029	$\phi_2^{vz\_2}$	0.001
$\phi_3^{vz\_2}$	0.055	$\phi_3^{vz\_2}$	-0.019
$\phi_4^{vz\_2}$	0.029	$\phi_4^{vz\_2}$	0.017
$\phi_5^{vz\_2}$	-0.012	$\phi_5^{vz\_2}$	-0.003
$\phi_6^{vz\_2}$	-0.048	$\phi_6^{vz\_2}$	0.022
$\phi_7^{vz\_2}$	-0.039	$\phi_7^{vz\_2}$	0.028
$\phi_8^{vz\_2}$	0.017	$\phi_8^{vz\_2}$	0.020
$\phi_9^{vz\_2}$	0.024	$\phi_9^{vz\_2}$	-0.061
$\phi_{10}^{vz\_2}$	0.003	$\phi_{10}^{vz\_2}$	-0.032
$\phi_{11}^{vz\_2}$	-0.013	$\phi_{11}^{vz\_2}$	-0.002
$\phi_{12}^{vz\_2}$	0.004	$\phi_{12}^{vz\_2}$	0.021
$\phi_1^{vz\_3}$	-0.007	$\phi_1^{vz\_3}$	0.035
$\phi_2^{vz\_3}$	-0.001	$\phi_2^{vz\_3}$	0.019
$\phi_3^{vz\_3}$	-0.036	$\phi_3^{vz\_3}$	0.055
$\phi_4^{vz\_3}$	-0.029	$\phi_4^{vz\_3}$	-0.016
$\phi_5^{vz\_3}$	-0.004	$\phi_5^{vz\_3}$	-0.036
$\phi_6^{vz\_3}$	0.024	$\phi_6^{vz\_3}$	-0.024
$\phi_7^{vz\_3}$	0.044	$\phi_7^{vz\_3}$	-0.059
$\phi_8^{vz\_3}$	0.044	$\phi_8^{vz\_3}$	-0.009
$\phi_9^{vz\_3}$	-0.006	$\phi_9^{vz\_3}$	0.047

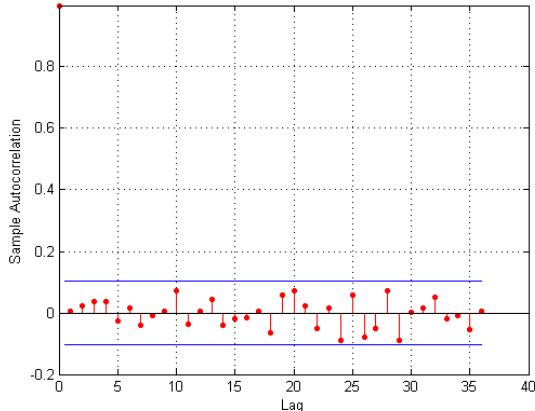
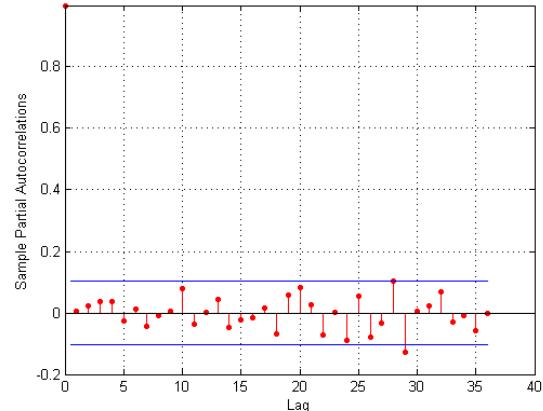
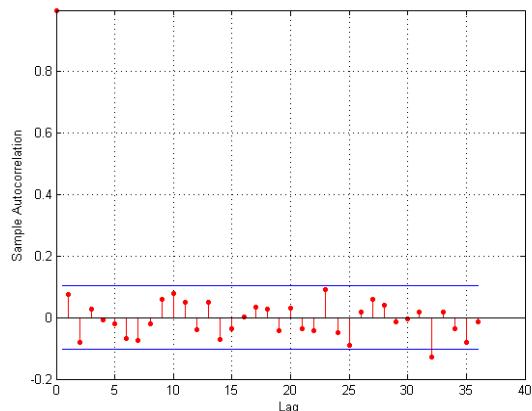
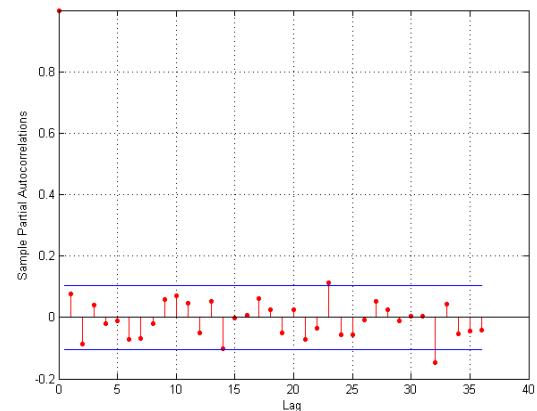
$\phi_{10}^{vz\_3}$	0.052	$\phi_{10}^{vz\_3}$	0.130
$\phi_{11}^{vz\_3}$	-0.055	$\phi_{11}^{vz\_3}$	-0.047
$\phi_{12}^{vz\_3}$	-0.046	$\phi_{12}^{vz\_3}$	-0.023
$\phi_1^{ENA-SE}$	-0.153	$\phi_1^{ENA-SE}$	-0.002
$\phi_2^{ENA-SE}$	0.129	$\phi_2^{ENA-SE}$	-0.158
$\phi_1^{ENA-S}$	0.010	$\phi_1^{ENA-S}$	0.041
$\phi_2^{ENA-S}$	-0.019	$\phi_2^{ENA-S}$	-0.010
$\phi_1^{ENA-NE}$	0.146	$\phi_1^{ENA-NE}$	-0.110
$\phi_2^{ENA-NE}$	-0.072	$\phi_2^{ENA-NE}$	0.171
$\phi_1^{ENA-N}$	-0.299	$\phi_1^{ENA-N}$	0.057
$\phi_2^{ENA-N}$	0.210	$\phi_2^{ENA-N}$	-0.115

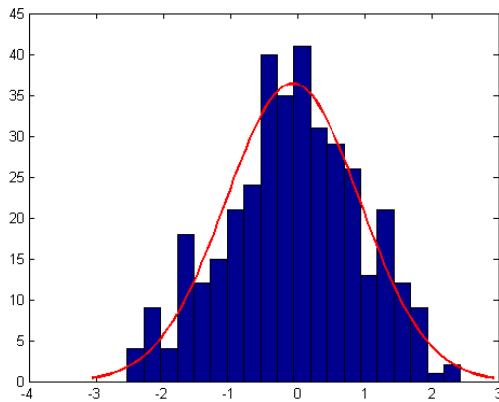
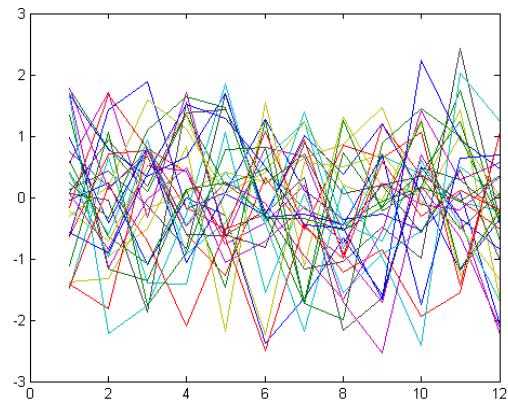
Tabela 35 – Coeficientes estimados para FC no estudo de caso 4

PCH 1		PCH 2		PCH 3	
COEFICIENTE	VALOR	COEFICIENTE	VALOR	COEFICIENTE	VALOR
Intercepto	-3.876	Intercepto	-4.279	Intercepto	-16.542
$\phi_1^{vt\_1}$	-0.063	$\phi_1^{vt\_1}$	0.029	$\phi_1^{vt\_1}$	-0.059
$\phi_2^{vt\_1}$	-0.005	$\phi_2^{vt\_1}$	-0.025	$\phi_2^{vt\_1}$	0.016
$\phi_3^{vt\_1}$	-0.064	$\phi_3^{vt\_1}$	0.025	$\phi_3^{vt\_1}$	0.021
$\phi_4^{vt\_1}$	0.042	$\phi_4^{vt\_1}$	0.034	$\phi_4^{vt\_1}$	0.006
$\phi_5^{vt\_1}$	0.043	$\phi_5^{vt\_1}$	0.025	$\phi_5^{vt\_1}$	0.000
$\phi_6^{vt\_1}$	0.017	$\phi_6^{vt\_1}$	-0.024	$\phi_6^{vt\_1}$	0.012
$\phi_7^{vt\_1}$	0.012	$\phi_7^{vt\_1}$	-0.025	$\phi_7^{vt\_1}$	-0.006
$\phi_8^{vt\_1}$	0.010	$\phi_8^{vt\_1}$	0.072	$\phi_8^{vt\_1}$	0.062
$\phi_9^{vt\_1}$	0.027	$\phi_9^{vt\_1}$	0.021	$\phi_9^{vt\_1}$	-0.016
$\phi_{10}^{vt\_1}$	0.032	$\phi_{10}^{vt\_1}$	-0.033	$\phi_{10}^{vt\_1}$	-0.051
$\phi_{11}^{vt\_1}$	-0.087	$\phi_{11}^{vt\_1}$	-0.003	$\phi_{11}^{vt\_1}$	0.023
$\phi_{12}^{vt\_1}$	0.013	$\phi_{12}^{vt\_1}$	0.012	$\phi_{12}^{vt\_1}$	-0.003
$\phi_1^{vt\_2}$	0.083	$\phi_1^{vt\_2}$	-0.002	$\phi_1^{vt\_2}$	-0.015
$\phi_2^{vt\_2}$	-0.017	$\phi_2^{vt\_2}$	0.066	$\phi_2^{vt\_2}$	-0.020
$\phi_3^{vt\_2}$	-0.030	$\phi_3^{vt\_2}$	0.034	$\phi_3^{vt\_2}$	0.023
$\phi_4^{vt\_2}$	-0.006	$\phi_4^{vt\_2}$	-0.038	$\phi_4^{vt\_2}$	-0.002
$\phi_5^{vt\_2}$	-0.031	$\phi_5^{vt\_2}$	-0.157	$\phi_5^{vt\_2}$	-0.028
$\phi_6^{vt\_2}$	0.079	$\phi_6^{vt\_2}$	-0.025	$\phi_6^{vt\_2}$	0.026
$\phi_7^{vt\_2}$	-0.063	$\phi_7^{vt\_2}$	0.030	$\phi_7^{vt\_2}$	-0.008
$\phi_8^{vt\_2}$	-0.091	$\phi_8^{vt\_2}$	-0.083	$\phi_8^{vt\_2}$	-0.007
$\phi_9^{vt\_2}$	-0.023	$\phi_9^{vt\_2}$	-0.127	$\phi_9^{vt\_2}$	0.048
$\phi_{10}^{vt\_2}$	-0.056	$\phi_{10}^{vt\_2}$	0.048	$\phi_{10}^{vt\_2}$	0.004
$\phi_{11}^{vt\_2}$	-0.006	$\phi_{11}^{vt\_2}$	0.011	$\phi_{11}^{vt\_2}$	-0.019
$\phi_{12}^{vt\_2}$	-0.087	$\phi_{12}^{vt\_2}$	0.064	$\phi_{12}^{vt\_2}$	0.061
$\phi_1^{vz\_1}$	0.411	$\phi_1^{vz\_1}$	-0.060	$\phi_1^{vz\_1}$	0.023
$\phi_2^{vz\_1}$	0.028	$\phi_2^{vz\_1}$	0.426	$\phi_2^{vz\_1}$	-0.040
$\phi_3^{vz\_1}$	0.008	$\phi_3^{vz\_1}$	0.065	$\phi_3^{vz\_1}$	0.101
$\phi_4^{vz\_1}$	0.085	$\phi_4^{vz\_1}$	0.108	$\phi_4^{vz\_1}$	-0.082
$\phi_5^{vz\_1}$	-0.057	$\phi_5^{vz\_1}$	0.042	$\phi_5^{vz\_1}$	0.077
$\phi_6^{vz\_1}$	-0.027	$\phi_6^{vz\_1}$	-0.044	$\phi_6^{vz\_1}$	-0.012
$\phi_7^{vz\_1}$	0.087	$\phi_7^{vz\_1}$	0.005	$\phi_7^{vz\_1}$	-0.007
$\phi_8^{vz\_1}$	-0.016	$\phi_8^{vz\_1}$	0.063	$\phi_8^{vz\_1}$	0.002
$\phi_9^{vz\_1}$	0.045	$\phi_9^{vz\_1}$	0.012	$\phi_9^{vz\_1}$	0.016
$\phi_{10}^{vz\_1}$	0.109	$\phi_{10}^{vz\_1}$	0.070	$\phi_{10}^{vz\_1}$	-0.003
$\phi_{11}^{vz\_1}$	-0.052	$\phi_{11}^{vz\_1}$	-0.021	$\phi_{11}^{vz\_1}$	0.007
$\phi_{12}^{vz\_1}$	-0.026	$\phi_{12}^{vz\_1}$	0.042	$\phi_{12}^{vz\_1}$	-0.004
$\phi_1^{vz\_2}$	0.047	$\phi_1^{vz\_2}$	-0.039	$\phi_1^{vz\_2}$	0.009
$\phi_2^{vz\_2}$	0.006	$\phi_2^{vz\_2}$	0.043	$\phi_2^{vz\_2}$	-0.054
$\phi_3^{vz\_2}$	-0.001	$\phi_3^{vz\_2}$	-0.036	$\phi_3^{vz\_2}$	-0.043
$\phi_4^{vz\_2}$	0.005	$\phi_4^{vz\_2}$	-0.012	$\phi_4^{vz\_2}$	0.043
$\phi_5^{vz\_2}$	-0.028	$\phi_5^{vz\_2}$	0.021	$\phi_5^{vz\_2}$	-0.014
$\phi_6^{vz\_2}$	0.080	$\phi_6^{vz\_2}$	-0.004	$\phi_6^{vz\_2}$	0.001
$\phi_7^{vz\_2}$	0.070	$\phi_7^{vz\_2}$	0.009	$\phi_7^{vz\_2}$	-0.021
$\phi_8^{vz\_2}$	-0.074	$\phi_8^{vz\_2}$	-0.006	$\phi_8^{vz\_2}$	0.014
$\phi_9^{vz\_2}$	-0.019	$\phi_9^{vz\_2}$	0.042	$\phi_9^{vz\_2}$	-0.015
$\phi_{10}^{vz\_2}$	-0.049	$\phi_{10}^{vz\_2}$	0.035	$\phi_{10}^{vz\_2}$	0.010

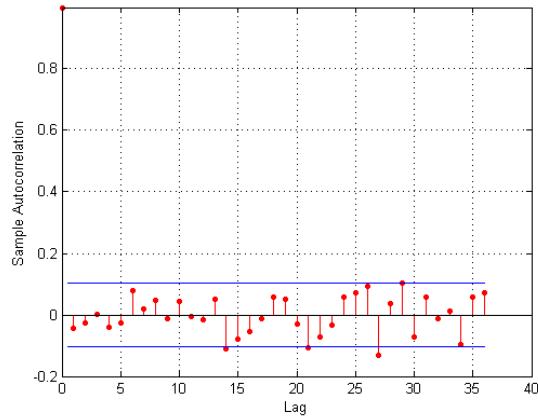
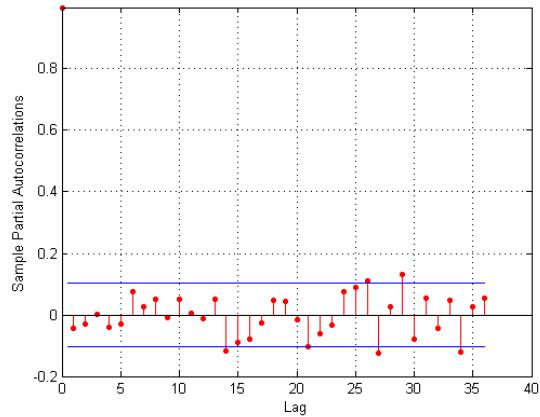
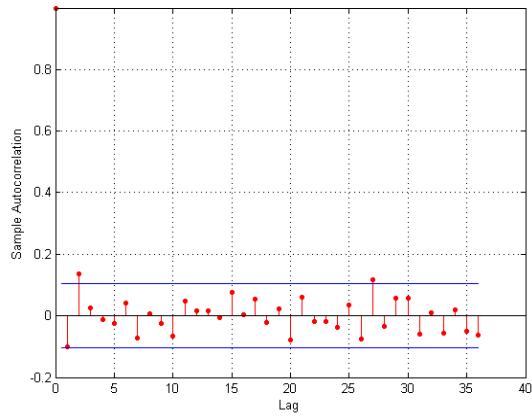
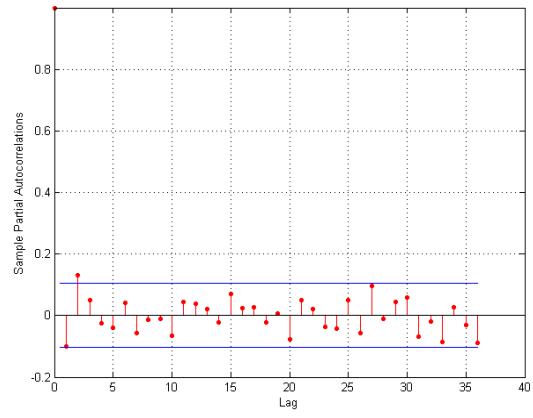
$\phi_{11}^{vz\_2}$	0.110	$\phi_{11}^{vz\_2}$	0.039	$\phi_{11}^{vz\_2}$	0.016
$\phi_{12}^{vz\_2}$	-0.040	$\phi_{12}^{vz\_2}$	-0.082	$\phi_{12}^{vz\_2}$	0.002
$\phi_1^{vz\_3}$	0.026	$\phi_1^{vz\_3}$	0.020	$\phi_1^{vz\_3}$	-0.062
$\phi_2^{vz\_3}$	-0.002	$\phi_2^{vz\_3}$	-0.006	$\phi_2^{vz\_3}$	0.009
$\phi_3^{vz\_3}$	-0.009	$\phi_3^{vz\_3}$	0.014	$\phi_3^{vz\_3}$	0.028
$\phi_4^{vz\_3}$	0.033	$\phi_4^{vz\_3}$	0.092	$\phi_4^{vz\_3}$	-0.032
$\phi_5^{vz\_3}$	0.026	$\phi_5^{vz\_3}$	-0.032	$\phi_5^{vz\_3}$	-0.024
$\phi_6^{vz\_3}$	-0.030	$\phi_6^{vz\_3}$	-0.006	$\phi_6^{vz\_3}$	0.013
$\phi_7^{vz\_3}$	-0.014	$\phi_7^{vz\_3}$	-0.077	$\phi_7^{vz\_3}$	0.029
$\phi_8^{vz\_3}$	-0.039	$\phi_8^{vz\_3}$	0.015	$\phi_8^{vz\_3}$	-0.037
$\phi_9^{vz\_3}$	0.008	$\phi_9^{vz\_3}$	0.056	$\phi_9^{vz\_3}$	0.012
$\phi_{10}^{vz\_3}$	-0.018	$\phi_{10}^{vz\_3}$	0.001	$\phi_{10}^{vz\_3}$	-0.035
$\phi_{11}^{vz\_3}$	0.086	$\phi_{11}^{vz\_3}$	0.013	$\phi_{11}^{vz\_3}$	0.050
$\phi_{12}^{vz\_3}$	-0.045	$\phi_{12}^{vz\_3}$	0.023	$\phi_{12}^{vz\_3}$	-0.035
$\phi_{ENA-SE}$	1.047	$\phi_{ENA-SE}$	1.114	$\phi_{ENA-SE}$	1.525
$\phi_1^{ENA-SE}$	-0.641	$\phi_2^{ENA-SE}$	-0.651	$\phi_2^{ENA-SE}$	0.142
$\phi_2^{ENA-S}$	0.038	$\phi_1^{ENA-S}$	-0.091	$\phi_1^{ENA-S}$	0.120
$\phi_1^{ENA-S}$	-0.010	$\phi_2^{ENA-S}$	0.023	$\phi_2^{ENA-S}$	-0.009
$\phi_1^{ENA-NE}$	-0.122	$\phi_1^{ENA-NE}$	0.086	$\phi_1^{ENA-NE}$	-0.160
$\phi_2^{ENA-NE}$	0.209	$\phi_2^{ENA-NE}$	-0.015	$\phi_2^{ENA-NE}$	-0.088
$\phi_1^{ENA-N}$	-0.154	$\phi_1^{ENA-N}$	-0.174	$\phi_1^{ENA-N}$	-0.146
$\phi_2^{ENA-N}$	-0.067	$\phi_2^{ENA-N}$	0.069	$\phi_2^{ENA-N}$	0.112

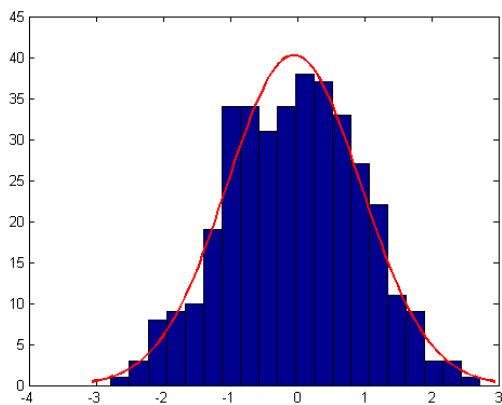
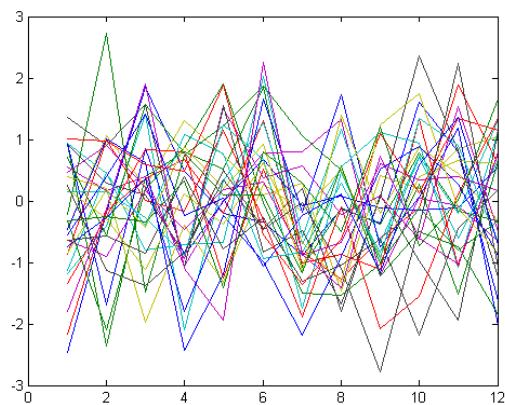
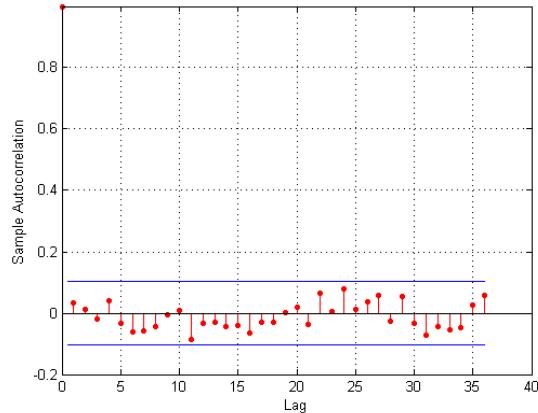
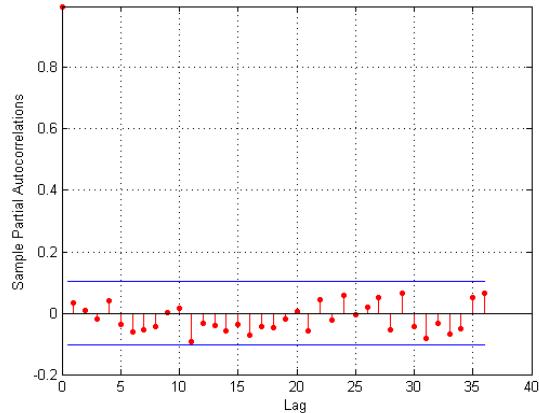
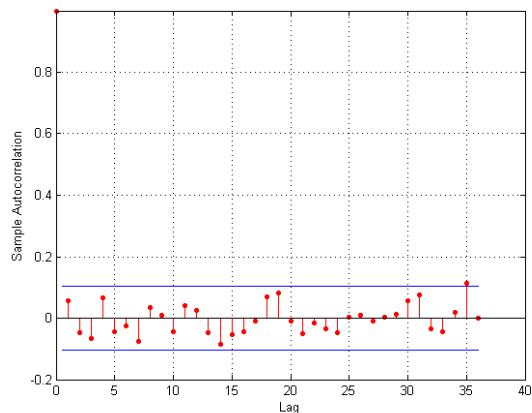
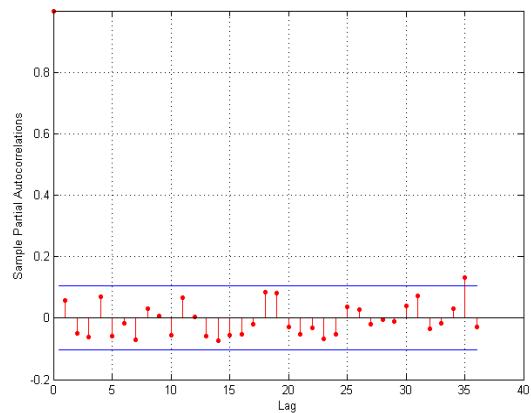
Tabela 36 – Coeficientes estimados para Vz no estudo de caso 4

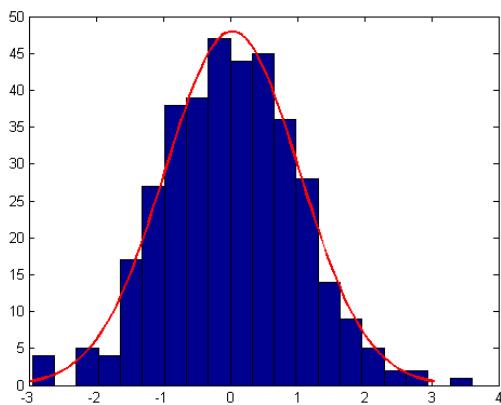
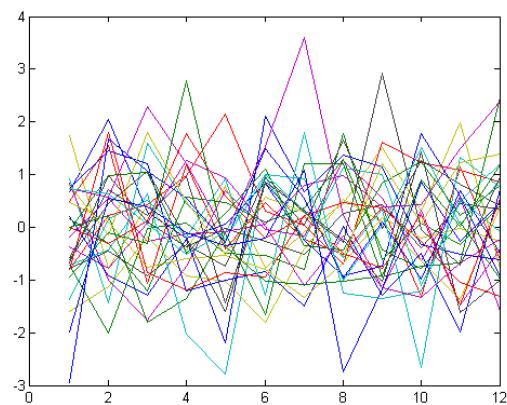
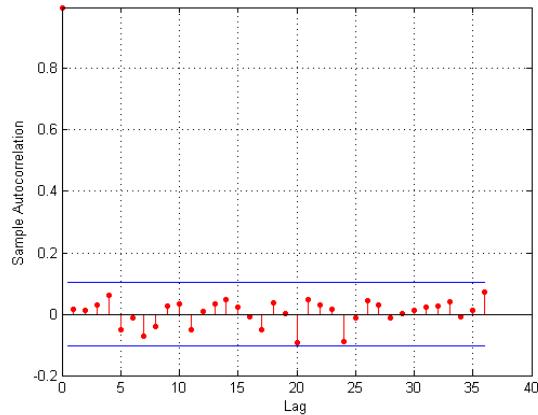
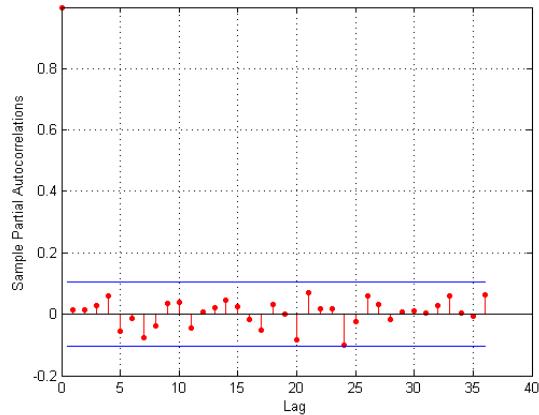
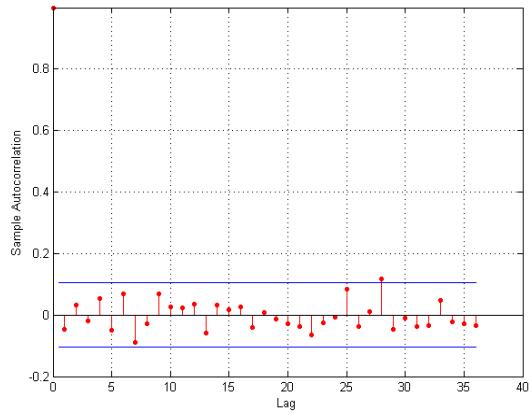
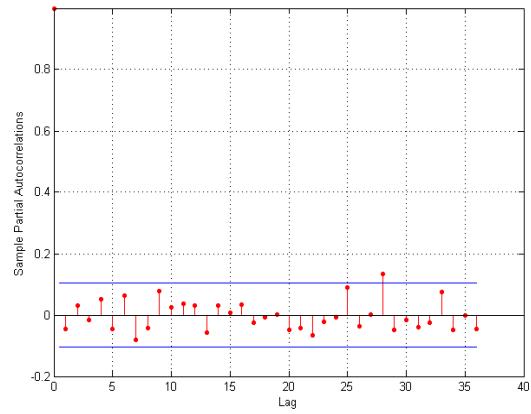
Eólica 1Fig. 166 – Fac dos resíduos  $FC'_1$ Fig. 167 – Fcapc dos resíduos  $FC'_1$ Fig. 168 – Fac dos resíduos quadrados  $FC'_1$ Fig. 169 – Fcapc dos resíduos quadrados  $FC'_1$

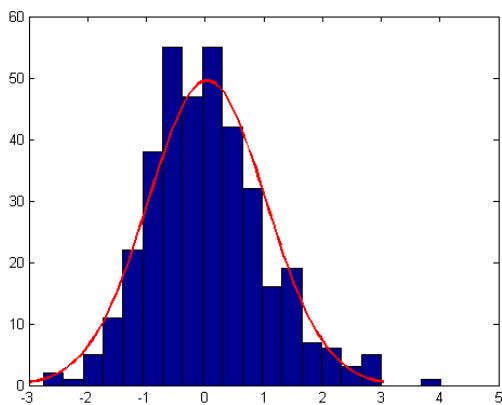
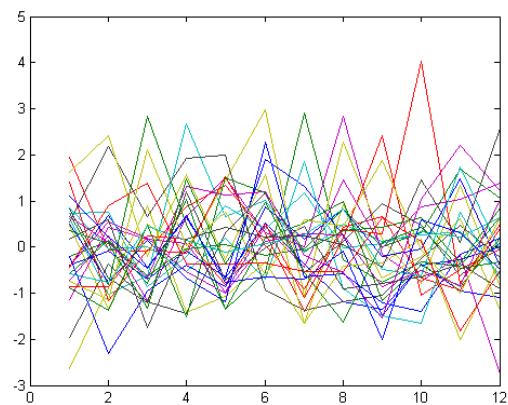
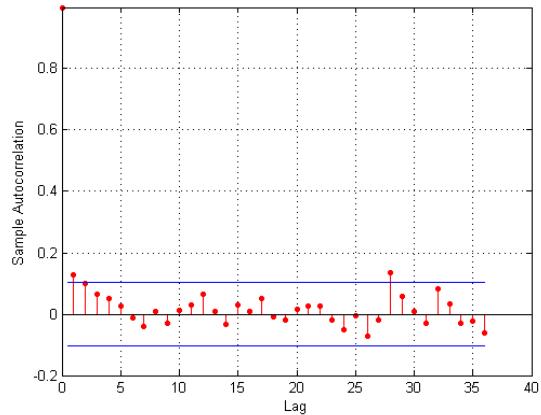
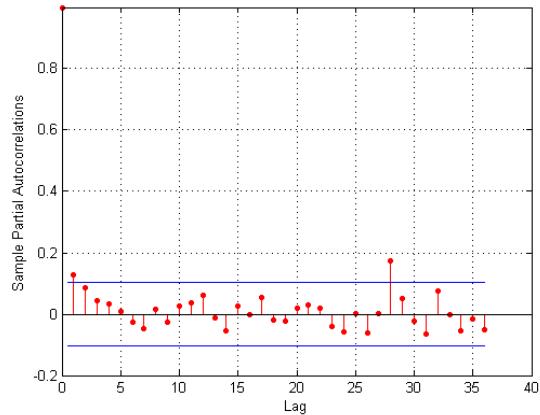
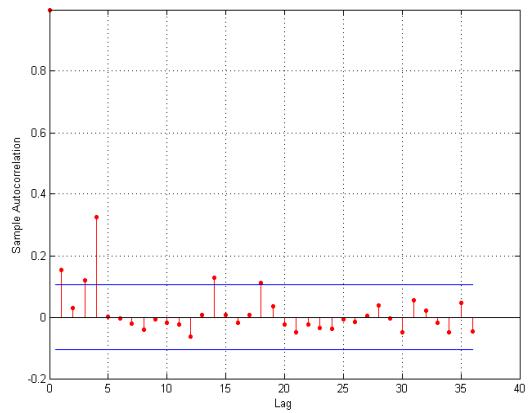
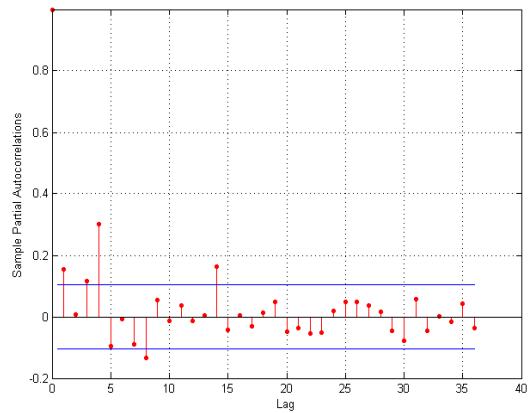
Fig. 170 –  $FC'_1$ : Histograma dos resíduosFig. 171 –  $FC'_1$ : Comparativo anual dos resíduos

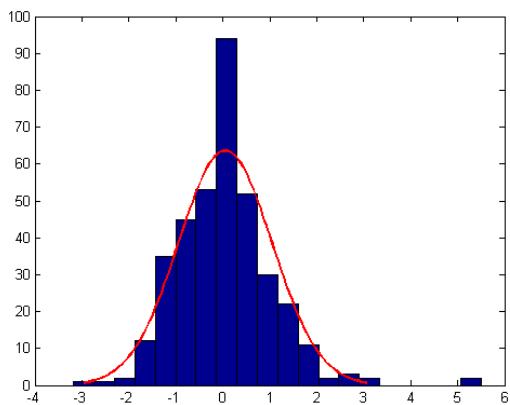
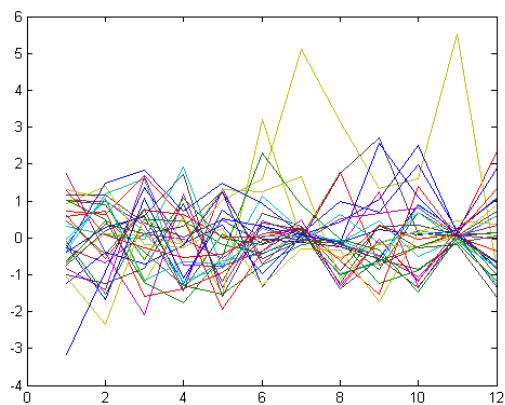
## Eólica 2

Fig. 172 – Fac dos resíduos  $FC'_2$ Fig. 173 – Facp dos resíduos  $FC'_2$ Fig. 174 – Fac dos resíduos quadrados  $FC'_2$ Fig. 175 – Facp dos resíduos quadrados  $FC'_2$

Fig. 176 –  $FC'_2$ : Histograma dos resíduosFig. 177 –  $FC'_2$ : Comparativo anual dos resíduosPCH 1Fig. 178 – Fac dos resíduos  $Vz'_1$ Fig. 179 – Facp dos resíduos  $Vz'_1$ Fig. 180 – Fac dos resíduos quadrados  $Vz'_1$ Fig. 181 – Facp dos resíduos quadrados  $Vz'_1$

Fig. 182 –  $Vz'_1$ : Histograma dos resíduosFig. 183 –  $Vz'_1$ : Comparativo anual dos resíduos**PCH 2**Fig. 184 – Fac dos resíduos  $Vz'_2$ Fig. 185 – Facp dos resíduos  $Vz'_2$ Fig. 186 – Fac dos resíduos quadrados  $Vz'_2$ Fig. 187 – Facp dos resíduos quadrados  $Vz'_2$

Fig. 188 –  $Vz'_2$ : Histograma dos resíduosFig. 189 –  $Vz'_2$ : Comparativo anual dos resíduos**PCH 3**Fig. 190 – Fac dos resíduos  $Vz'_3$ Fig. 191 – Facp dos resíduos  $Vz'_3$ Fig. 192 – Fac dos resíduos quadrados  $Vz'_3$ Fig. 193 – Facp dos resíduos quadrados  $Vz'_3$

Fig. 194 –  $Vz'_2$ : Histograma dos resíduosFig. 195 –  $Vz'_2$ : Comparativo anual dos resíduos